Lecture 4 : Écouter la machine

TinyML, traitement du signal audio et qualité des données, projet EcoTri 4.0

Le moteur du tapis va-t-il tomber en panne ?

Pr. Aissam BERRAHOU

Département Ingénierie des systèmes embarqués et mobiles, Smart Systems Lab
IA en Edge Computing, projet fédérateur EcoTri 4.0, version 2027
ENSIAS, Université Mohammed V de Rabat

aissam.berrahou@ensias.um5.ac.ma

Feuille de route

- **Pourquoi écouter ?** : *Que dit le son d'un moteur sur son état, et pourquoi le traiter sur place ?*
- **TinyML : cycle et outils** : *Quelles étapes et quels outils pour mettre un modèle dans 1 Mo de RAM ?*
- **Du son aux caractéristiques** : *Comment passer de 16 000 nombres par seconde à une « image » de 40 bandes ?*
- **Classes ou anomalies** : *Faut-il apprendre chaque panne, ou seulement le fonctionnement normal ?*
- **Qualité des données** : *Pourquoi un modèle à 100 % en test peut-il échouer le lendemain ?*

Objectifs

Ce que vous saurez faire en sortant de la salle

À la fin de cette lecture, vous serez capables de :

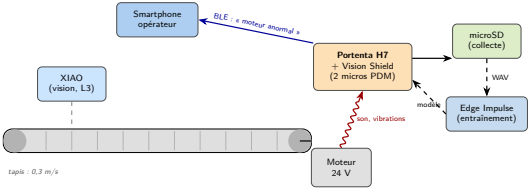
- **Décrire** le cycle de vie d'un projet TinyML et situer TFLite Micro, CMSIS-NN, CMSIS-DSP et Edge Impulse dans l'écosystème.
- **Dimensionner** une chaîne d'acquisition audio : fréquence d'échantillonnage, trames, résolution, mémoire.
- **Calculer et interpréter** une FFT, un spectrogramme, des MFE et des MFCC ; **choisir** leurs paramètres.
- **Choisir** entre classification supervisée et détection d'anomalies, et **fixer** un seuil.
- **Construire** un dataset de qualité : équilibre, biais, fuites, découpage par session ; le **documenter** par une fiche.

Le fil rouge et le livrable

- La station **voit** (lecture 2) et **parle** (lecture 3) ; elle doit maintenant **écouter** son propre moteur.
- Jalon **J4** : la **fiche du dataset** « EcoTri-Moteur » et un **premier modèle audio** (classes + anomalies) évalué honnêtement.

Le problème déclencheur

Le moteur du tapis va-t-il tomber en panne ?



La situation

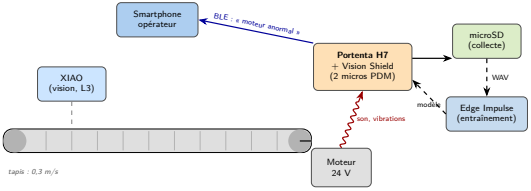
- Un arrêt non planifié du tapis bloque tout le centre de tri : plusieurs heures de production perdues.
- Les techniciens « entendent » un roulement fatigué des semaines avant la casse.
- On dispose de deux micros sur le Vision Shield, d'une microSD et d'aucune panne étiquetée.

À vous (5 min, par équipe)

1. Combien d'octets par seconde produit un micro à 16 kHz en 16 bits ? Par jour ?
2. Pourquoi ne pas envoyer ce flux au cloud en BLE ?
3. Comment apprendre à reconnaître une panne que l'on n'a jamais enregistrée ?

Le problème déclencheur

Le moteur du tapis va-t-il tomber en panne ?



La situation

- Un arrêt non planifié du tapis bloque tout le centre de tri : plusieurs heures de production perdues.
- Les techniciens « entendent » un roulement fatigué des semaines avant la casse.
- On dispose de deux micros sur le Vision Shield, d'une microSD et d'aucune panne étiquetée.

À vous (5 min, par équipe)

1. Combien d'octets par seconde produit un micro à 16 kHz en 16 bits ? Par jour ?
2. Pourquoi ne pas envoyer ce flux au cloud en BLE ?
3. Comment apprendre à reconnaître une panne que l'on n'a jamais enregistrée ?

Réponse

$16\,000 \times 2 = $ **32 Ko/s**, soit **2,8 Go/jour**. C'est plus que le débit BLE utile mesuré au TP3, en continu. On calcule donc **sur place** et l'on n'envoie qu'un état. Pour les pannes inconnues : apprendre le **normal** et signaler l'écart (détection d'anomalies).

Pourquoi écouter ?

Que dit le son d'un moteur sur son état, et pourquoi le traiter sur place ?

Pourquoi écouter ?

De la maintenance corrective à la maintenance prédictive

Stratégie	Principe	Coût
Corrective	réparer après la casse	arrêts subis
Préventive	changer à date fixe	pièces jetées trop tôt
Conditionnelle / prédictive	intervenir quand la **mesure** le dit	capteurs + modèle

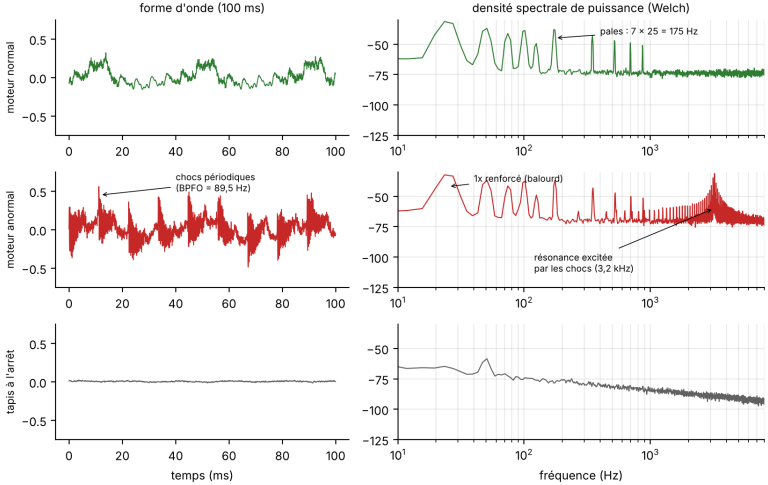
ISO 17359 (surveillance des machines) recommande de choisir le descripteur d'après les **modes de défaillance** attendus.

Ce que l'on entend sur un moteur

- **Balourd** : raie à la fréquence de rotation f_r (« 1x ») renforcée.
- **Désalignement** : harmoniques 2x, 3x.
- **Roulement** : chocs périodiques à des fréquences caractéristiques (BPFO, BPFI...) qui excitent les résonances de la structure.
- **Frottement, courroie** : bruit large bande, sifflements.

Pourquoi écouter ?

Un signal, trois états : ce que montrent l'onde et le spectre



Signaux synthétiques à 16 kHz construits sur un modèle physique : 25 tr/s, ventilateur à 7 pales, défaut de bague extérieure (Randall & Antoni, 2011). Script `gen_images.py`.

Pour N_b billes de diamètre d, un diamètre primitif D et un angle de contact ϕ :

$$\text{BPFO} = \frac{N_b f_r}{2}\left(1 - \frac{d}{D}\cos\phi\right)$$

$$\text{BPFI} = \frac{N_b f_r}{2}\left(1 + \frac{d}{D}\cos\phi\right)$$

- Exemple : $N_b = 8$, $d/D = 0{,}1$, $f_r = 25$ Hz $\Rightarrow$ BPFO = **90 Hz**, BPFI = **110 Hz**.
- Le défaut ne crée pas une raie pure : il crée des **chocs** qui excitent une résonance de quelques kHz, **modulée** par la BPFO.

Conséquence pour l'IA

Les signes d'une panne sont à la fois en **basse fréquence** (1x, harmoniques) et en **haute fréquence** (résonance) : la représentation doit couvrir les deux, d'où une fréquence d'échantillonnage $\geq$ 8 kHz.

Micro ou accéléromètre ?

L'accéléromètre fixé sur le carter est la référence industrielle ; le micro est **sans contact** et déjà sur la carte, mais il entend aussi l'atelier.

Pourquoi écouter ?

Pourquoi sur la Portenta et pas dans le cloud ?

- **Débit** : 32 Ko/s en continu dépasse ce que le lien BLE de la lecture 3 transporte de façon fiable.
- **Énergie** : la radio coûte 10^4 fois plus par bit qu'une opération (lecture 3).
- **Confidentialité** : un micro d'atelier capte les conversations ; traiter localement et ne garder que des caractéristiques résout le problème **par conception**.
- **Disponibilité** : la surveillance doit fonctionner sans réseau.

Donnée transmise	Débit
Audio brut 16 kHz, 16 bits	256 kbit/s
MFE 40 bandes, 8 bits, 100 trames/s	32 kbit/s
Score d'anomalie, 1/s	0,03 kbit/s
Alerte (événement)	≈ 0

! « envoyer la décision, pas le signal » : un facteur 10^4 entre l'audio brut et le score.

Question flash

?

Le moteur tourne à 1500 tr/min avec une poulie à 7 pales de ventilation. À quelles fréquences attendez-vous des raies ? Une fréquence d'échantillonnage de 1 kHz suffirait-elle ?

Question flash

?

Le moteur tourne à 1500 tr/min avec une poulie à 7 pales de ventilation. À quelles fréquences attendez-vous des raies ? Une fréquence d'échantillonnage de 1 kHz suffirait-elle ?

Réponse

$f_r = 1500/60 =$ **25 Hz** (et 50, 75…) ; passage des pales $7 \times 25 =$ **175 Hz** et harmoniques ; 100 Hz électrique (2×50 Hz). 1 kHz suffirait pour ces raies ($f_e/2 = 500$ Hz), mais **pas** pour la résonance des chocs de roulement (2 à 5 kHz) : on choisit 16 kHz, comme pour la parole.

TinyML : cycle et outils

Quelles étapes et quels outils pour mettre un modèle dans 1 Mo de RAM ?

TinyML (Warden & Situnayake, 2019 ; Harvard CS249r)

Apprentissage automatique exécuté sur des **microcontrôleurs** : quelques centaines de Ko de RAM, quelques Mo de Flash, une consommation de l'ordre du **milliwatt**, toujours en marche (*always-on*).

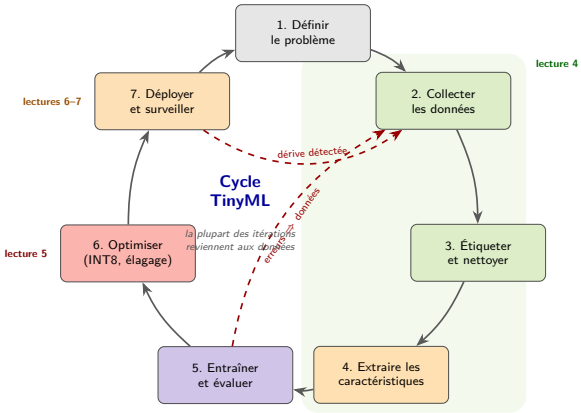
- L'**inférence** se fait sur la cible ; l'**entraînement** reste (pour l'instant) sur PC ou cloud.
- Applications phares : mots-clés (« OK Google »), détection de personnes, maintenance prédictive, gestes.
- Fondation TinyML (2019), puis **EDGE AI Foundation** (2024) ; banc d'essai **MLPerf Tiny** (Banbury et al., 2021).

	Smartphone	**Portenta M7**
RAM	8 Go	1 Mo
Fréquence	3 GHz	480 MHz
Puissance	3–5 W	0,1–0,5 W
OS	Android	aucun / RTOS

! 4 ordres de grandeur en mémoire : on ne « porte » pas un modèle, on le **conçoit** pour la cible.

TinyML : cycle et outils

Le cycle de vie : un processus centré sur les données

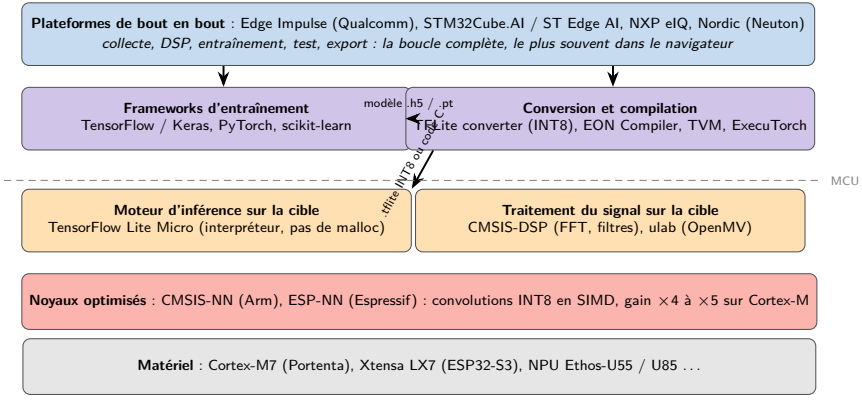


- Chaque étape a ses **critères de sortie** : volume par classe, taux d'accord des annotateurs, budget mémoire…
- Les erreurs du modèle **renvoient aux données** plus souvent qu'à l'architecture (Ng, « data-centric AI », Stanford, 2021).
- En production, la **dérive** (nouveau moteur, saison, bruit) relance la collecte.

> **!** étapes 2 à 4 et premier passage par 5 ; l'optimisation est l'objet de la lecture 5.

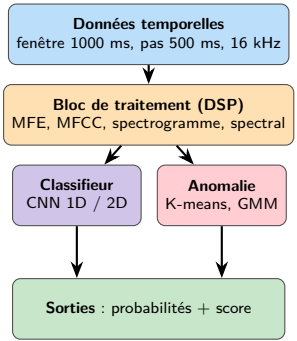
TinyML : cycle et outils

L'écosystème logiciel



PC / cloud : en haut. Microcontrôleur : à partir de « moteur d'inférence ».

- **TFLite Micro** (David et al., MLSys 2021) : interpréteur C++ de quelques dizaines de Ko, mémoire allouée **statiquement** dans une *arena*, opérateurs enregistrés à la demande.
- **CMSIS-NN** (Lai, Suda, Chandra, Arm, 2018) : noyaux INT8 qui exploitent les instructions SIMD du Cortex-M ; **CMSIS-DSP** pour les FFT et filtres.



- Plateforme en ligne (Hymel et al., MLSys 2023), propriété de **Qualcomm** depuis 2025, gratuite pour l'enseignement.
- Un projet = un **impulse** : fenêtrage, DSP, un ou plusieurs blocs d'apprentissage.
- **EON Compiler** : transforme le modèle en code C sans interpréteur (moins de RAM et de Flash).
- Export : bibliothèque Arduino, C++, OpenMV (vision), binaire prêt à flasher.

Esprit critique

Une plateforme accélère, mais ne remplace pas la compréhension du DSP et de l'évaluation : c'est l'objet des deux sections suivantes.

Élément	Taille	Mémoire
Tampon audio 1 s, int16	16 000 × 2	32 Ko
Double tampon (DMA)	× 2	64 Ko
Trame + FFT 512 (float32)	512 × 4 × 2	4 Ko
MFE 99 × 40 (float32)	3960 × 4	15,5 Ko
MFE quantifiée INT8	3960	3,9 Ko
Arena TFLM (petit CNN)	–	30–80 Ko
Total		**≈ 150 Ko**

- La Portenta a 1 Mo de SRAM : **large**. L'ESP32-S3 sans PSRAM (512 Ko) : **possible**. Un Cortex-M0+ à 32 Ko : **impossible** sans streaming.
- **Streaming** : on calcule les MFE trame par trame, au fil de l'eau, sans stocker 1 s d'audio brut.

! faire ce tableau **avant** de choisir la fenêtre et le modèle.

Question flash

?

Vous passez de 16 kHz à 8 kHz et de fenêtres de 1 s à 2 s. Que deviennent la taille du tampon audio, la plus haute fréquence observable et le nombre de trames MFE (pas 10 ms) ?

Question flash

? Vous passez de 16 kHz à 8 kHz et de fenêtres de 1 s à 2 s. Que deviennent la taille du tampon audio, la plus haute fréquence observable et le nombre de trames MFE (pas 10 ms) ?

Réponse

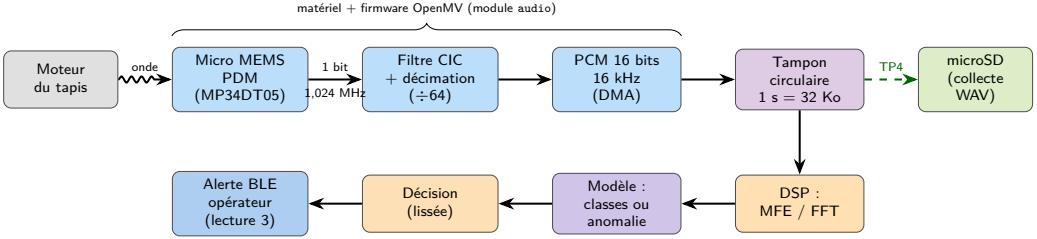
Tampon : $8000 \times 2 \times 2 = \mathbf{32\ Ko}$ (inchangé). Fréquence max : $f_e/2 = \mathbf{4\ kHz}$: la résonance à 3,2 kHz reste visible, de justesse. Trames : **199** au lieu de 99 : l'entrée du modèle double, et donc ses MACs pour un CNN.

Du son aux caractéristiques

Comment passer de 16 000 nombres par seconde à une « image » de 40 bandes ?

Du son aux caractéristiques

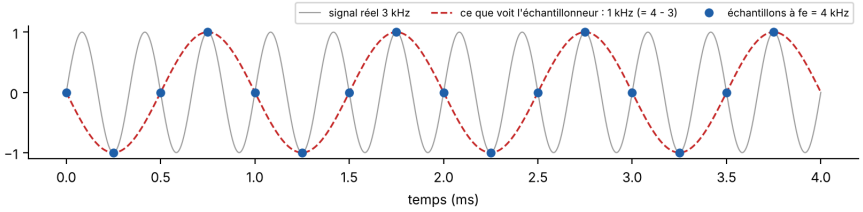
La chaîne d'acquisition



- Micro **PDM** : un flux de 1 bit à haute fréquence (1 à 3 MHz) dont la densité de « 1 » suit la pression (modulation $\Sigma\Delta$).
- Filtre **CIC** + décimation : on obtient du PCM 16 bits à 16 kHz.
- Le **gain** et le **filtre passe-haut** (suppression de la composante continue) sont des paramètres du module `audio` d'OpenMV : à **figer** et **documenter**.
- Saturation = information perdue : vérifier le crête $< 32\,767$.

Du son aux caractéristiques

Échantillonnage : Nyquist-Shannon et repliement



- Un signal à bande limitée à B est reconstructible si $f_e > 2B$.
- Sinon, une composante à f apparaît à $|f - kf_e|$: **repliement** (*aliasing*), irréversible.

! le filtre de décimation du micro fait office d'**anti-repliement** ; si l'on **sous-échantillonne** soi-même (16 → 8 kHz), il faut filtrer **avant** de garder un échantillon sur deux.

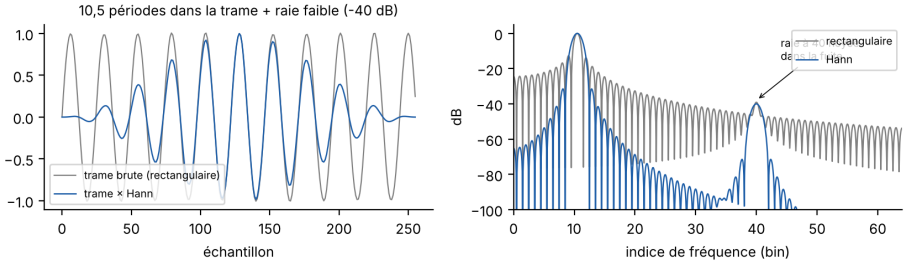
$$X[k] = \sum_{n=0}^{N-1} x[n]\, e^{-j2\pi kn/N}, \quad k = 0, \ldots, N-1$$

- Le bin k correspond à la fréquence $f_k = k\, f_e/N$; résolution $\Delta f = f_e/N$.
- Signal réel : seuls $N/2 + 1$ bins sont utiles (symétrie hermitienne).
- **FFT** (Cooley & Tukey, 1965) : $O(N \log_2 N)$ au lieu de $O(N^2)$. Pour $N = 512$: 4600 opérations au lieu de 262 000.
- Spectre de puissance : $P[k] = |X[k]|^2/N$; en décibels $10 \log_{10} P$.

Exemple

$f_e = 16$ kHz, $N = 512$: $\Delta f =$ **31,25 Hz**, 257 bins de 0 à 8 kHz. La raie 1x à 25 Hz tombe dans le bin 1 : elle n'est **pas résolue** de la composante continue !

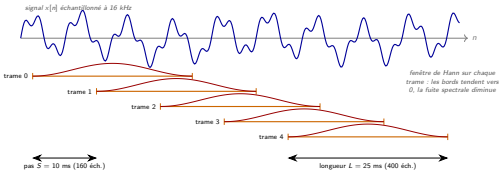
```
from ulab import numpy as np   # OpenMV
X = np.fft.fft(trame)           # (re, im)
```



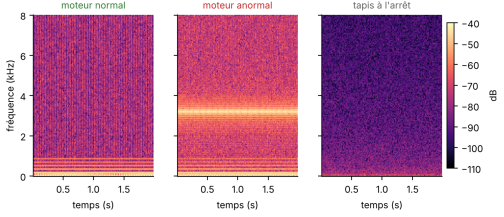
- Couper une trame = multiplier par un rectangle : son spectre en sinus cardinal « bave » sur les bins voisins (lobes secondaires à -13 dB).
- Fenêtre de **Hann** $w[n] = \sin^2(\pi n/N)$: lobes à -31 dB, décroissance rapide ; prix : lobe principal 2 fois plus large (Harris, *Proc. IEEE*, 1978).

Du son aux caractéristiques

Trames recouvrantes et spectrogramme (STFT)



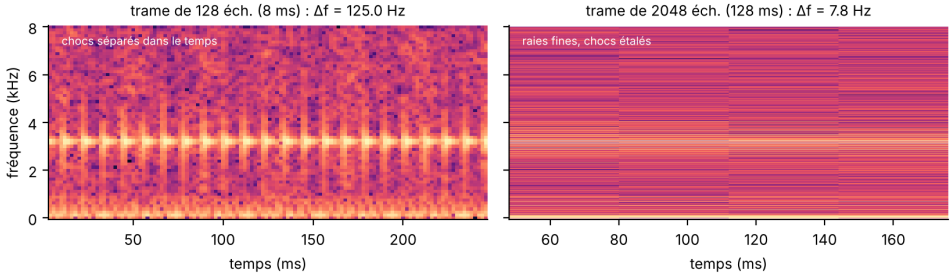
$$S[m,k] = \left| \sum_{n} x[n+mS]\, w[n]\, e^{-j2\pi kn/N} \right|^2$$



- Nombre de trames : $\lfloor (T-L)/S \rfloor + 1 = \mathbf{98}$ **à 99** pour 1 s.
- Normal : raies stables. Anormal : bande à 3,2 kHz. Arrêt : bruit faible.

Du son aux caractéristiques

Le compromis temps-fréquence

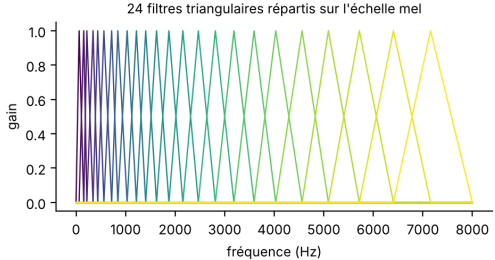


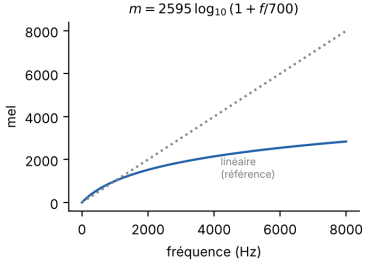
- Principe d'incertitude (Gabor, 1946) : $\Delta t \cdot \Delta f \geq$ constante.
- Trame courte : on **localise les chocs** ; trame longue : on **sépare les raies**.

> **!** 25 ms (parole) est un bon compromis ; pour isoler 1x à 25 Hz, il faudrait $\geq$ 160 ms. Autre solution : deux représentations (une longue, une courte).

Du son aux caractéristiques

L'échelle mel et le banc de filtres

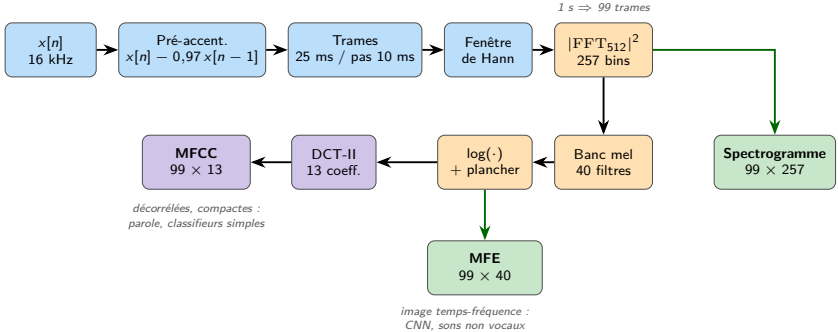




- Échelle psychoacoustique (Stevens, Volkmann & Newman, 1937) : linéaire sous 1 kHz, logarithmique au-dessus.
- Chaque filtre triangulaire somme l'énergie des bins qu'il couvre : 257 bins $\rightarrow$ 40 bandes. Réduction $\times 6$, et robustesse aux petits décalages de fréquence.

Du son aux caractéristiques

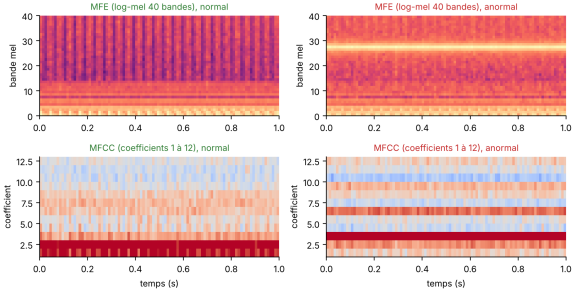
De la FFT aux MFE et aux MFCC



- **MFE** (log-mel) : $E[m, b] = \log \sum_k H_b[k]\, S[m, k]$. Le log imite la sonie et compresse la dynamique.
- **MFCC** (Davis & Mermelstein, 1980) : DCT des MFE, on garde 13 coefficients : décorrèle et compresse l'**enveloppe** spectrale.

Du son aux caractéristiques

MFE ou MFCC pour un moteur ?



- Les MFCC ont été conçus pour la **parole** : la DCT lisse les raies fines, précieuses pour un moteur.
- Les **MFE** gardent la structure en bandes : c'est une image pour un CNN. Edge Impulse les recommande pour les sons **non vocaux**.
- Le **spectrogramme** complet garde tout, mais coûte 6 fois plus.

> **!** parole : MFCC ; machines, environnement : MFE ; doute : comparer en validation.

Du son aux caractéristiques

Des caractéristiques simples, calculables partout

Descripteur	Définition, sens
RMS	$\sqrt{\frac{1}{N}\sum x^2}$: énergie globale
Facteur de crête	$\max \lvert x \rvert / \text{RMS}$: chocs
Kurtosis	$E[(x-\mu)^4]/\sigma^4$: impulsivité (3 si gaussien)
Centroïde spectral	$\sum f_k P_k / \sum P_k$: « brillance »
Énergie par bande	$\sum_{k \in b} P_k$: 4 à 8 bandes

- Le **kurtosis** est le descripteur historique des défauts de roulement (Dyer & Stewart, 1978) : il augmente nettement avec les chocs.
- Ces 10 nombres par fenêtre suffisent à un premier **détecteur d'anomalie embarqué** en MicroPython : c'est le Tutorial 4.

> **!** commencer simple, établir une **référence**, puis justifier la complexité (comme le classifieur à règles de J2).

Question flash

?

Avec $f_e = 16$ kHz, $L = 25$ ms, $S = 10$ ms, FFT de 512 points et 40 filtres mel : combien de nombres en entrée du modèle pour une fenêtre de 1 s ? Quel facteur de réduction par rapport à l'audio brut ?

Question flash

? Avec $f_e = 16$ kHz, $L = 25$ ms, $S = 10$ ms, FFT de 512 points et 40 filtres mel : combien de nombres en entrée du modèle pour une fenêtre de 1 s ? Quel facteur de réduction par rapport à l'audio brut ?

Réponse

Trames : $\lfloor (1000-25)/10 \rfloor + 1 = \mathbf{98}$. Entrée : $98 \times 40 = \mathbf{3920}$ valeurs, contre 16 000 échantillons : réduction $\times$ 4, et surtout une représentation où les classes sont **séparables**. Avec 13 MFCC : 1274 valeurs ($\times$ 12,5).

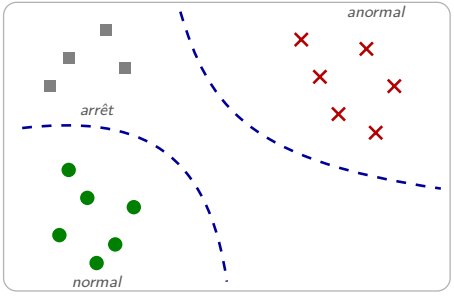
Classes ou anomalies

Faut-il apprendre chaque panne, ou seulement le fonctionnement normal ?

Classes ou anomalies

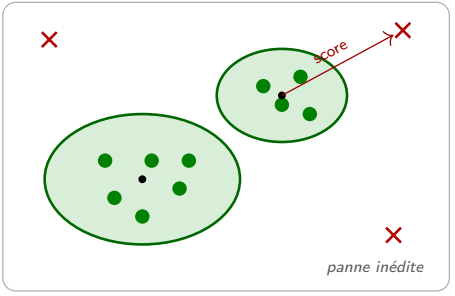
Deux façons de poser le problème

Classification supervisée (3 classes)



*exige des exemples **étiquetés de chaque panne** ;*
ne reconnaît que ce qu'il a vu

Détection d'anomalies (apprise sur le normal)



*n'exige **que du fonctionnement normal** ;*
signale « différent », sans dire quoi

! les pannes sont **rares**, **variées** et coûteuses à provoquer : on a des heures de « normal » et quelques minutes de « anormal ». La détection d'anomalies (Chandola, Banerjee & Kumar, U. Minnesota, 2009) est souvent le seul point de départ possible.

Classes ou anomalies

Classification supervisée : un petit CNN sur les MFE

```
# Entrée : MFE 99 x 40 (une « image » à 1 canal)
m = Sequential([
  Reshape((99, 40, 1), input_shape=(3960,)),
  Conv2D(8, 3, activation="relu", padding="same"),
  MaxPooling2D(2),
  Conv2D(16, 3, activation="relu", padding="same"),
  MaxPooling2D(2),
  Dropout(0.25), Flatten(),
  Dense(3, activation="softmax")])  # normal, anormal, arret
```

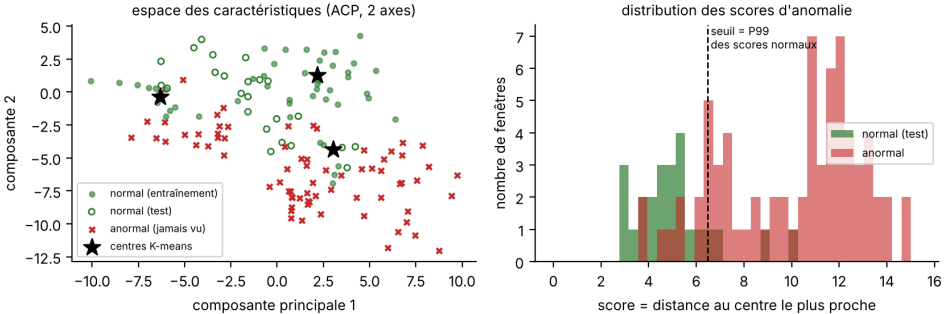
- Paramètres : $\approx$ 1,2 k (convolutions) + 11,5 k (dense) : **12,8 k**, 13 Ko en INT8.
- Variante 1D (convolutions le long du temps, 40 canaux) : moins de MACs, souvent aussi bonne pour des sons stationnaires.
- Sortie : probabilités ; décision par **seuil** et **lissage** sur plusieurs fenêtres (vote majoritaire).

Classe « arrêt »

indispensable : sinon le modèle attribue le silence à « normal » ou « anormal ».

Classes ou anomalies

Détection d'anomalies : K-means et distance



- Apprentissage sur le **normal seul** : K centres c_j ; score $s(x) = \min_j \|x - c_j\|$ (Edge Impulse : K-means ou GMM, sur des caractéristiques choisies).
- Variantes : GMM (vraisemblance), auto-encodeur (erreur de reconstruction, référence du challenge DCASE 2020, tâche 2), Isolation Forest.

Classes ou anomalies

Fixer le seuil : un compromis, pas un réglage

- Seuil τ = percentile élevé (P99) des scores **normaux de validation** : on choisit le taux de fausses alarmes.
- Dans la figure : 12,5 % de fausses alarmes en test, 86 % des anomalies détectées. Le test contient des sessions **jamais vues** : le score normal y est plus élevé qu'à l'entraînement.
- Métriques indépendantes du seuil : **AUC** de la courbe ROC, **pAUC** (zone des faibles taux de fausses alarmes), utilisées par DCASE.

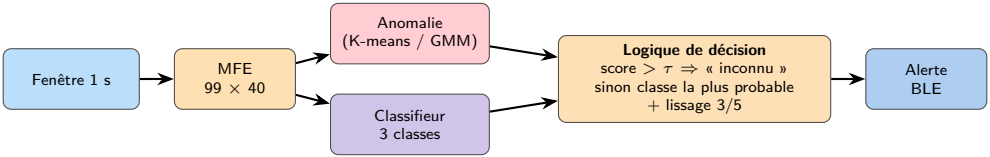
Coût d'une erreur pour EcoTri

Fausse alarme	technicien dérangé (15 min)
Panne manquée	tapis arrêté (4 h)

! filtrer dans le temps : alerte si le score dépasse τ sur **3 fenêtres sur 5**. Les fausses alarmes isolées disparaissent ; la panne, durable, reste.

Classes ou anomalies

Combiner les deux : l'architecture EcoTri



- Le classifieur nomme les états **connus** ; le détecteur protège contre les états **inconnus** : un classifieur softmax est sûr de lui même hors de sa distribution (Hendrycks & Gimpel, ICLR 2017).
- Cette logique sera reprise et fusionnée avec la vision en lecture 6.

Question flash

?

Sur 10 000 fenêtres normales de validation, votre seuil produit 50 fausses alarmes. La station analyse une fenêtre par seconde, 8 h par jour. Combien d'alertes intempestives par jour ? Avec le lissage 3/5, en supposant les fausses alarmes indépendantes ?

Question flash

?

Sur 10 000 fenêtres normales de validation, votre seuil produit 50 fausses alarmes. La station analyse une fenêtre par seconde, 8 h par jour. Combien d'alertes intempestives par jour ? Avec le lissage 3/5, en supposant les fausses alarmes indépendantes ?

Réponse

$p = 0{,}5\ \%$; $28\,800 \times 0{,}005 =$ **144 alertes/jour** : inacceptable. Lissage : $P(\geq 3 \text{ sur } 5) \approx \binom{5}{3} p^3 = 10 \times 1{,}25 \cdot 10^{-7} \approx 1{,}25 \cdot 10^{-6}$; $\approx$ **0,04 alerte/jour**. En pratique, les fausses alarmes sont corrélées (un bruit d'atelier dure) : le gain réel est moindre, il faut le **mesurer**.

Qualité des données

Pourquoi un modèle à 100 % en test peut-il échouer le lendemain ?

Qualité des données

« Garbage in, garbage out » : les cinq défauts classiques

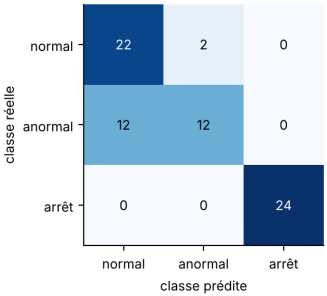
Défaut	Exemple EcoTri	Parade
Déséquilibre	2 h de normal, 5 min d'anormal	pondérer, sur-échantillonner, métriques adaptées
Biais de collecte	tout « anormal » enregistré le soir, atelier vide	varier conditions et moments pour **chaque** classe
Étiquettes bruitées	« normal » enregistré pendant un démarrage	protocole, double annotation, écoute
Fuite de données	fenêtres d'un même fichier en train et en test	découper par **session**
Dérive	nouveau moteur, nouvelle courroie	surveiller, recollecter (lecture 7)

! un modèle apprend la règle la plus facile qui sépare les classes, même si c'est le bruit de fond ou l'heure de l'enregistrement (Geirhos et al., *Nature Machine Intelligence*, 2020).

Qualité des données

Le déséquilibre et les bonnes métriques

- 95 % de normal : un modèle qui répond toujours « normal » a **95 % d'exactitude** et ne sert à rien.
- Précision $= \frac{VP}{VP+FP}$; rappel $= \frac{VP}{VP+FN}$; F_1 leur moyenne harmonique.
- **Exactitude équilibrée** : moyenne des rappels par classe.
- Remèdes : poids de classe $w_c \propto 1/n_c$, augmentation (bruit, décalage temporel, gain), sur-échantillonnage du minoritaire **dans l'entraînement seulement**.

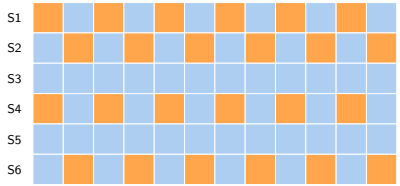


Matrice de confusion (régression logistique, sessions de test jamais vues) : la confusion se fait entre « normal » et « anormal » léger.

Qualité des données

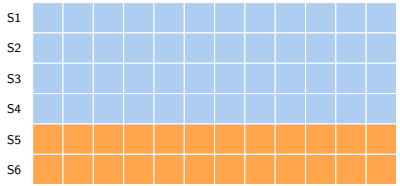
La fuite de données : le piège n°1 de l'audio

(a) Découpage aléatoire des fenêtres : fuite



*des fenêtres voisines d'une **même session** (même micro, même jour, même bruit de fond) se retrouvent en entraînement **et** en test : le modèle reconnaît la session, pas la panne*

(b) Découpage par session (ou par jour, par machine)



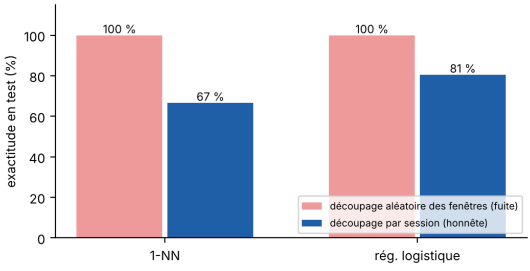
*les sessions de test n'ont **jamais** été vues : on mesure la capacité à généraliser à une nouvelle condition, comme en production*

entraînement test

- Une fenêtre de 1 s avec un pas de 0,5 s **partage la moitié** de ses échantillons avec sa voisine : un découpage aléatoire met des quasi-doublons des deux côtés.
- Kapoor & Narayanan (Princeton, *Patterns*, 2023) recensent la fuite dans des centaines d'articles publiés, dans 17 disciplines.

Qualité des données

La fuite, mesurée



- Même données, mêmes modèles : 18 sessions simulées, chacune avec sa position de micro et une machine voisine.
- Découpage aléatoire : **100 %** ; découpage par session : **67 à 81 %**.
- Le 1-NN, qui « mémorise », profite le plus de la fuite.

> **!** on découpe **d'abord** (par session, jour, machine), **ensuite** on fenêtre, normalise et augmente, en ajustant tout sur l'entraînement seul.

Qualité des données

Entraînement, validation, test

- **Entraînement** : ajuster les poids.
- **Validation** : choisir les hyperparamètres, le seuil, l'arrêt précoce.
- **Test** : mesurer **une seule fois**, à la fin. Le regarder pour régler quoi que ce soit le transforme en validation.
- Peu de sessions ? **Validation croisée par groupes** (`GroupKFold` de scikit-learn, groupe = session).

Plan de collecte EcoTri (TP4)

- 3 classes $\times \geq 4$ sessions $\times$ 2 min.
- Session = un emplacement de carte, un réglage, un moment.
- Sessions 1–2 : entraînement ; 3 : validation ; 4 : test.
- Même gain, même f_e, mêmes réglages pour toutes les classes.

Qualité des données

Documenter : la fiche du dataset (jalon J4)

Fiche du dataset « EcoTri-Moteur v1 » (d'après *Datasheets for Datasets*, Gebru et al., 2021)

1. Motivation pourquoi ce dataset ? quelle tâche (3 classes, anomalie) ? qui l'a financé, construit ?	**2. Composition** nombre de fenêtres par classe, durée, format (WAV 16 kHz 16 bits), sessions, déséquilibre	**3. Collecte** carte, micro, gain, position, vitesse du moteur, dates, opérateur, bruit ambiant
4. Prétraitement découpage en fenêtres, normalisation, fichiers retirés et pourquoi, étiquetage (qui, comment)	**5. Usages** usages prévus, usages à proscrire, découpage recommandé (par session), limites connues	**6. Distribution et maintenance** licence, version, hachés des fichiers, contact, plan de mise à jour

- Inspirée des fiches techniques des composants électroniques (Gebru et al., *Communications of the ACM*, 2021) ; complétée par les *Model Cards* pour le modèle (Mitchell et al., FAT* 2019).
- Elle force à écrire ce que l'on sait, et révèle ce que l'on **ne sait pas**.

Question flash

?

Une équipe obtient 99 % en test sur Edge Impulse. Elle a enregistré « normal » avec le moteur neuf le lundi et « anormal » avec une masse collée sur l'hélice le mardi, la carte posée à un autre endroit. Quels risques ? Que proposez-vous ?

Question flash

?

Une équipe obtient 99 % en test sur Edge Impulse. Elle a enregistré « normal » avec le moteur neuf le lundi et « anormal » avec une masse collée sur l'hélice le mardi, la carte posée à un autre endroit. Quels risques ? Que proposez-vous ?

Réponse

Confusion totale entre classe et **session** (jour, position) : le modèle a pu apprendre la position de la carte. De plus, le découpage automatique d'Edge Impulse mélange les fenêtres d'un même fichier. Remèdes : enregistrer les deux classes dans **chaque** session, alterner, découper par session, tester sur une session nouvelle, écouter les erreurs.

Question flash

?

Proposez la chaîne complète du moteur d'EcoTri : f_e, fenêtre, pas, représentation, modèle(s), seuil, décision, données à collecter, mémoire estimée. Justifiez chaque choix en une phrase.

Question flash

?

Proposez la chaîne complète du moteur d'EcoTri : f_e, fenêtre, pas, représentation, modèle(s), seuil, décision, données à collecter, mémoire estimée. Justifiez chaque choix en une phrase.

Réponse

16 kHz (résonance 3 kHz) ; fenêtre 1 s, pas 0,5 s ; MFE 40 bandes, trame 25 ms / 10 ms (sons non vocaux) ; CNN 2D $\approx$ 13 k paramètres (3 classes) + K-means sur les MFE moyennes (inconnu) ; seuil au P99 de la validation ; alerte si 3 fenêtres sur 5 ; $\geq$ 4 sessions par classe, découpage par session ; mémoire $\approx$ 150 Ko sur 1 Mo. Le tout consigné dans la fiche J4.

À retenir

- **TinyML** : inférence sur MCU (mW, Ko) ; cycle **centré données** ; TFLite Micro, CMSIS-NN/DSP, Edge Impulse.
- **Acquisition** : PDM → PCM 16 kHz ; Nyquist ; gain et filtre figés et documentés.
- **DSP** : trames 25/10 ms, Hann, FFT ($\Delta f = f_e/N$), banc mel, log ⇒ MFE ; DCT ⇒ MFCC. Machines : MFE.
- **Modèles** : classification si les pannes sont connues et étiquetées ; anomalie (apprise sur le normal) sinon ; les deux en cascade dans EcoTri.
- **Seuil** : choisi sur la validation, d'après le coût des erreurs ; lissage temporel.
- **Données** : équilibre, biais, étiquettes, **fuite** ; découper par session **avant** tout ; documenter par une fiche.

Glossaire et références

Terme	Définition courte
PDM	modulation de densité d'impulsions
STFT	FFT sur trames glissantes
MFE	énergies log-mel
MFCC	DCT des MFE
BPFO	fréquence défaut bague ext.
TFLM	TensorFlow Lite Micro
AUC	aire sous la courbe ROC
Fuite	info du test vue à l'entraînement
Session	conditions d'enregistrement

- P. Warden, D. Situnayake, *TinyML*, O'Reilly, 2019.
- V. Janapa Reddi et al. (Harvard), *Machine Learning Systems*, mlsysbook.ai ; cours CS249r.
- R. David et al., « TensorFlow Lite Micro », MLSys 2021 ; L. Lai, N. Suda, V. Chandra, « CMSIS-NN », arXiv 1801.06601, 2018.
- S. Hymel et al., « Edge Impulse : An MLOps Platform for Tiny Machine Learning », MLSys 2023.
- C. Banbury et al. (Harvard), « MLPerf Tiny Benchmark », NeurIPS Datasets & Benchmarks, 2021.
- S. Davis, P. Mermelstein, *IEEE Trans. ASSP*, 28(4), 1980 ; F. J. Harris, *Proc. IEEE*, 66(1), 1978.
- A. V. Oppenheim, R. W. Schafer (MIT), *Discrete-Time Signal Processing*, Pearson, 3e éd.
- R. B. Randall, J. Antoni, « Rolling element bearing diagnostics – A tutorial », *MSSP*, 25(2), 2011.
- V. Chandola, A. Banerjee, V. Kumar (U. Minnesota), « Anomaly Detection : A Survey », *ACM Comput. Surv.*, 2009.
- H. Purohit et al., « MIMII Dataset », DCASE 2019 ; Y. Koizumi et al., DCASE 2020 Task 2.
- T. Gebru et al., « Datasheets for Datasets », *CACM*, 64(12), 2021.
- S. Kapoor, A. Narayanan (Princeton), « Leakage and the reproducibility crisis in ML-based science », *Patterns*, 2023.

Prochaine étape

Tutorial 4 : audio, FFT et détecteur embarqué sur la Portenta. **TP 4** : dataset moteur, Edge Impulse, jalon J4.