Lecture 7 : Industrialiser et défendre l'IA embarquée

MLOps embarqué, sécurité, intégration industrielle et perspectives, projet EcoTri 4.0

D'un démonstrateur qui marche le jour J à une station que l'on peut exploiter dix ans.

Pr. Aissam BERRAHOU

Département Ingénierie des systèmes embarqués et mobiles, Smart Systems Lab
IA en Edge Computing, projet fédérateur EcoTri 4.0, version 2027
ENSIAS, Université Mohammed V de Rabat

aissam.berrahou@ensias.um5.ac.ma

Feuille de route

- **MLOps embarqué** : *Comment mettre à jour, tracer et surveiller un modèle qui tourne sur 50 stations ?*
- **Sécuriser la station** : *Qui peut écouter, falsifier ou tromper EcoTri, et comment l'en empêcher ?*
- **Intégrer l'usine** : *Comment la station parle-t-elle au MES, et quels indicateurs prouvent sa valeur ?*
- **Perspectives** : *NPU, apprentissage sur la cible, apprentissage fédéré : que change la décennie qui vient ?*
- **Évaluer et défendre** : *Comment argumenter une architecture devant un jury (soutenance, épreuve, réflexion) ?*

Objectifs

Bloom : évaluer et justifier

À la fin de cette lecture, vous serez capables de :

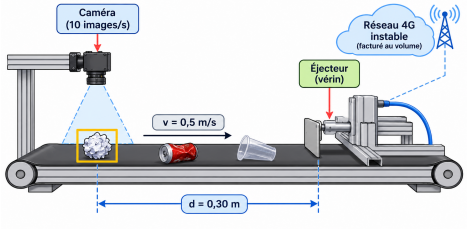
- **Décrire** le cycle TinyMLOps : versionnage, registre, OTA A/B, déploiement canari, retour arrière.
- **Détecter** une dérive des données sur la cible (PSI, test de Kolmogorov-Smirnov, Page-Hinkley) sans étiquettes.
- **Analyser** les menaces de la station (STRIDE) et choisir les parades : BLE LE Secure Connections, démarrage sécurisé, signature des modèles, robustesse adverse.
- **Positionner** la station dans la pyramide ISA-95 et **calculer** l'OEE et ses composantes.
- **Évaluer** les ruptures à venir (NPU, apprentissage sur la cible, fédéré) au regard de vos mesures J1–J6.
- **Défendre** une feuille de route vers la production.

Format de la séance (4 h)

- $\approx$ 1 h de cours (ce support) puis $\approx$ 3 h d'**évaluation** : soutenance d'équipe avec démonstration, épreuve pratique individuelle sur une variante, réflexion écrite.
- Le Tutorial 7 (versionnage, signature, surveillance de dérive) est le socle de l'épreuve pratique : faites-le **avant** la séance.

Le problème déclencheur

Six mois après la mise en service



Trois incidents réels (scénario)

- **Novembre** : la précision tombe de 92 % à 71 %. Rien n'a changé dans le code… mais le fournisseur d'emballages, si.
- **Décembre** : un stagiaire envoie `STOP` depuis son téléphone en salle de pause : le tapis s'arrête.
- **Janvier** : la direction demande « combien la station nous fait-elle gagner ? ». Personne ne sait répondre.

À vous (5 min, par équipe)

Pour chaque incident : quelle **information** vous manquait, quel **mécanisme** l'aurait évité, et lequel de vos jalons J1–J6 aurait dû le prévoir ?

MLOps embarqué

Comment mettre à jour, tracer et surveiller un modèle déployé ?

MLOps embarqué

La dette technique cachée (Sculley et al., Google, NeurIPS 2015)

- Dans un système de ML réel, le code du modèle est une **petite boîte** entourée de collecte, configuration, vérification, surveillance, déploiement.
- Sur MCU, s'ajoutent : firmware, version des noyaux (CMSIS-NN, ESP-NN), quantification, calibration, prétraitement de la caméra.
- **Conséquence** : une prédiction n'est reproductible que si l'on connaît le **quadruplet** (données, code, modèle, firmware).

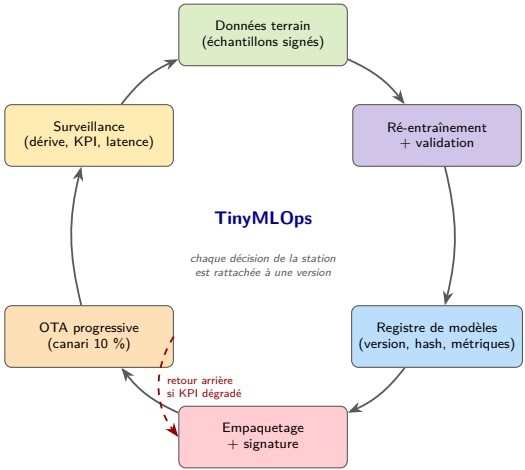
TinyMLOps (Leroux et al., Univ. Gand, 2022 ; Janapa Reddi, Harvard)

Spécificités de l'embarqué : parc hétérogène, connectivité intermittente, mémoire trop petite pour deux modèles, pas d'étiquettes en production, mise à jour **risquée** (une station « briquée » arrête une ligne).

> ! le jalon J6 a livré un modèle ; la lecture 7 livre un **processus**.

MLOps embarqué

La boucle TinyMLOps de la station



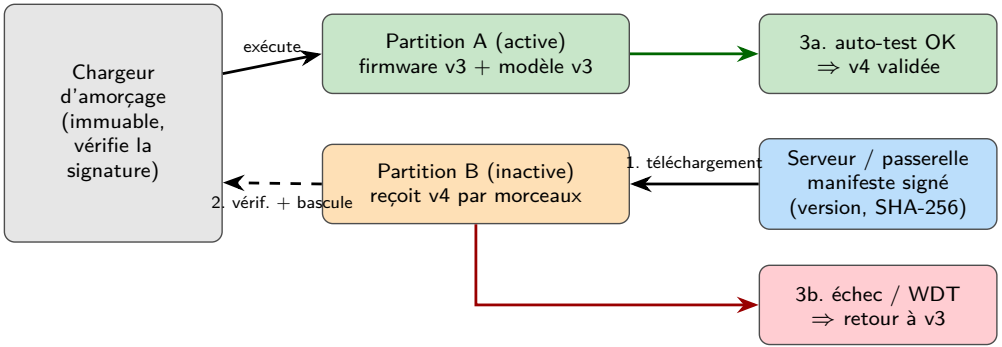
- **Données terrain** : la station conserve les cas DOUTE et un échantillon aléatoire (1 %) pour l'étiquetage.
- **Registre** : chaque modèle a un identifiant, un haché, ses métriques (précision, latence, pic RAM) et son *model card*.
- **Canari** : la nouvelle version part sur 10 % du parc ; on compare les KPI avant de généraliser.
- **Surveillance** : la station publie latences, confiance moyenne, taux de DOUTE (message JSON de J6).

```
{"modele": "mnv2a035-int8",
 "version": "4.1.0",
 "sha256": "9f2c...e1a7",
 "taille": 412736,
 "entree": {"forme": [1,96,96,1], "s": 0.00392, "z": -128},
 "classes": ["carton","metal","plastique","verre"],
 "T_cal": 1.8, "theta": 0.70,
 "firmware_min": "4.5.0",
 "dataset": "ecotri-v7 (2026-10-12)",
 "metriques": {"acc": 0.912, "lat_p95_ms": 182, "ram_ko":
      287},
 "signature": "MEUCIQ..."}
```

- **SemVer** : majeur = classes ou entrée changées (incompatible) ; mineur = ré-entraînement ; correctif = seuil ou T.
- Le manifeste porte **tout ce qui doit concorder** avec le prétraitement (forme, s, z) : la carte refuse un modèle incohérent.
- `sha256` détecte la corruption ; la **signature** (ECDSA P-256) prouve l'origine.
- Inspiré des *Model Cards* (Mitchell et al., Google, FAT* 2019).

MLOps embarqué

Mettre à jour sans briquer : OTA à deux partitions



Principe (MCUboot, ESP-IDF OTA) : on écrit la nouvelle version à côté de l'ancienne, on vérifie, on bascule, on **confirme** après un auto-test ; sinon le chargeur revient seul à l'ancienne.

! sur la Portenta (OpenMV), le modèle est un fichier : on applique le même schéma A/B à `modele_A.tflite` / `modele_B.tflite` et à un fichier `actif.json` (Tutorial 7).

$$T_{\text{OTA}} \approx \frac{S}{D_{\text{utile}}} + T_{\text{vérif}} + T_{\text{reboot}}$$

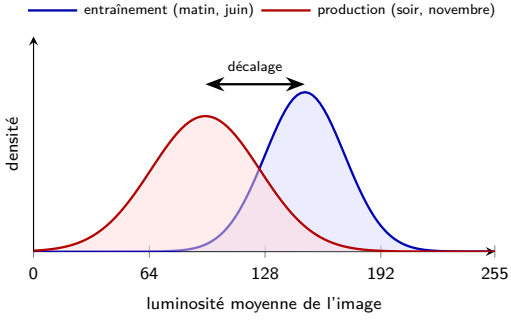
- Modèle INT8 de 410 Ko par BLE à 60 Ko/s utiles : ≈ 7 s ; firmware de 2 Mo : ≈ 35 s.
- **Mise à jour différentielle** (bsdiff, *delta*) : si seule la tête du réseau est ré-entraînée, le delta peut tomber sous 10 % de S.
- Vérification SHA-256 sur Cortex-M7 : quelques dizaines de ms par Mo.
- Planifier dans une **fenêtre de maintenance** (tapis à l'arrêt) : le MES fournit cette information.

Déploiement progressif

1. **Shadow** : v4 tourne en parallèle, ses décisions sont journalisées, pas appliquées.
2. **Canari** : v4 décide sur 10 % des stations.
3. **Généralisation** si $\Delta\text{KPI} \geq 0$ (test statistique).

Contrainte MCU

Le mode *shadow* exige deux modèles en mémoire : sur 1 Mo de SRAM, c'est souvent impossible ; on le fait sur la passerelle ou par alternance.



Soit $p(x, y) = p(x)\, p(y \mid x)$ (Quiñonero-Candela et al., *Dataset Shift in ML*, MIT Press 2009) :

- **Covariable** : $p(x)$ change (éclairage d'hiver, nouvelle caméra).
- **Prior** : $p(y)$ change (plus de verre après les fêtes).
- **Concept** : $p(y \mid x)$ change (une barquette « carton » devient plastifiée).

! en production, **pas d'étiquettes** : on surveille $p(x)$ et les **sorties** du modèle (confiance, entropie, répartition des classes).

Population Stability Index (histogrammes à B classes)

$$\mathrm{PSI} = \sum_{b=1}^{B} (q_b - p_b) \ln \frac{q_b}{p_b}$$

p_b : référence (validation), q_b : fenêtre courante. Règle d'usage : $< 0{,}1$ stable, 0,1–0,25 à surveiller, $> 0{,}25$ dérive.

Kolmogorov-Smirnov :
$D = \sup_t |F_{\mathrm{ref}}(t) - F_{\mathrm{cour}}(t)|$, seuil $\approx 1{,}36\sqrt{(n+m)/(nm)}$ à 5 %.

Page-Hinkley (détection séquentielle)

$$m_t = \sum_{i \le t} (x_i - \bar{x}_t - \delta), \quad \text{alerte si } m_t - \min_{i \le t} m_i > \lambda$$

Coût $O(1)$ par objet, quelques octets de RAM : idéal pour surveiller la **confiance moyenne** sur la Portenta.

> **!** la chute de $p_{\max}$ moyen et la hausse du taux de DOUTE précèdent la chute de précision.

Question flash

?

Référence de la luminosité en 4 classes : $p = (0{,}10\,;\,0{,}40\,;\,0{,}40\,;\,0{,}10)$. Fenêtre de novembre : $q = (0{,}30\,;\,0{,}45\,;\,0{,}20\,;\,0{,}05)$. Calculez le PSI. Faut-il ré-entraîner ?

Question flash

? Référence de la luminosité en 4 classes : $p = (0{,}10\,;\,0{,}40\,;\,0{,}40\,;\,0{,}10)$. Fenêtre de novembre : $q = (0{,}30\,;\,0{,}45\,;\,0{,}20\,;\,0{,}05)$. Calculez le PSI. Faut-il ré-entraîner ?

Réponse

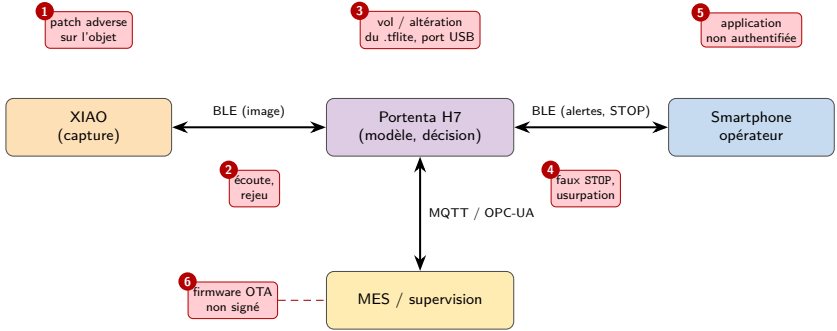
$0{,}2\ln 3 + 0{,}05\ln 1{,}125 - 0{,}2\ln 0{,}5 - 0{,}05\ln 0{,}5 \approx 0{,}220 + 0{,}006 + 0{,}139 + 0{,}035 = \mathbf{0{,}40} > 0{,}25$: dérive franche. Avant de ré-entraîner, on vérifie l'effet sur la **sortie** (taux de DOUTE) et on corrige d'abord ce qui est bon marché (exposition, éclairage) ; sinon on collecte et étiquette des images de novembre.

Sécuriser la station

Qui peut écouter, falsifier ou tromper EcoTri ?

Sécuriser la station

Modéliser les menaces : surface d'attaque et STRIDE (Microsoft)



STRIDE	Exemple EcoTri	Propriété violée	Parade
Spoofing	faux smartphone envoie STOP (4)	authenticité	appairage authentifié, liste blanche
Tampering	modèle remplacé sur la carte (3, 6)	intégrité	signature, démarrage sécurisé
Repudiation	« ce n'est pas moi qui ai arrêté »	traçabilité	journal horodaté signé
Info. disclosure	écoute des images BLE (2)	confidentialité	chiffrement AES-CCM
Denial of service	brouillage 2,4 GHz, inondation	disponibilité	mode dégradé local, WDT
Elevation	commande de maintenance via l'app (5)	autorisation	rôles, jeton par commande

Sécuriser la station

BLE : du « Just Works » aux LE Secure Connections

- **Legacy pairing** (BLE 4.0/4.1) : clé temporaire de 6 chiffres, cassable hors ligne en quelques secondes par écoute (Ryan, *Crackle*, USENIX WOOT 2013).
- **LE Secure Connections** (BLE 4.2+) : échange **ECDH P-256**, clé de lien jamais transmise, chiffrement **AES-128-CCM**.
- Méthode d'association : *Just Works* (pas de protection MITM), *Passkey*, *Numeric Comparison*, OOB (QR code).
- **Bonding** : les clés sont mémorisées, les reconnexions sont chiffrées d'emblée.

Pour EcoTri

- XIAO ↔ Portenta : appairage OOB en usine, **bonding**, caractéristiques en accès « chiffré + authentifié ».
- Commandes critiques (`STOP`, `MAJ`) : en plus, **HMAC-SHA256** avec compteur anti-rejeu.
- Ne pas oublier les **vulnérabilités de pile** (SweynTooth, 2020 ; BLURtooth, 2020) : la mise à jour du firmware *est* une mesure de sécurité.

Sécuriser la station

Authentifier une commande au niveau applicatif

```python
import hashlib, ubinascii
CLE = b"cle-32-octets-provisionnee-usine"   # stockée hors du dépôt
dernier_cpt = 0

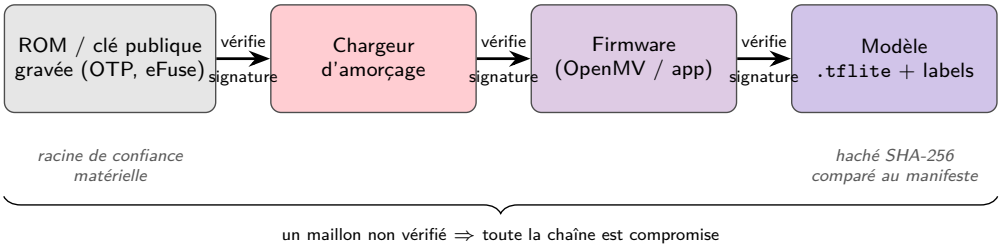
def hmac_sha256(k, m):                       # RFC 2104
    k = k + b"\x00" * (64 - len(k))
    i = hashlib.sha256(bytes(b ^ 0x36 for b in k) + m).digest()
    return hashlib.sha256(bytes(b ^ 0x5C for b in k) + i).digest()

def verifier(trame):        # "STOP|1043|<hex 16 o>"
    global dernier_cpt
    cmd, cpt, tag = trame.split("|"); cpt = int(cpt)
    attendu = hmac_sha256(CLE, ("%s|%d" % (cmd, cpt)).encode())[:16]
    if ubinascii.unhexlify(tag) != attendu: return None   # falsifiée
    if cpt <= dernier_cpt: return None                    # rejouée
    dernier_cpt = cpt; return cmd
```

- Le **compteur** monotone empêche le rejeu d'une trame enregistrée.
- On tronque à 16 octets : 128 bits d'authentification suffisent et tiennent dans une notification.
- Comparaison en **temps constant** en production (sinon attaque temporelle).
- La clé n'est **jamais** dans le code source : zone protégée, élément sécurisé (SE050 sur la Portenta).

Sécuriser la station

Démarrage sécurisé et intégrité du modèle

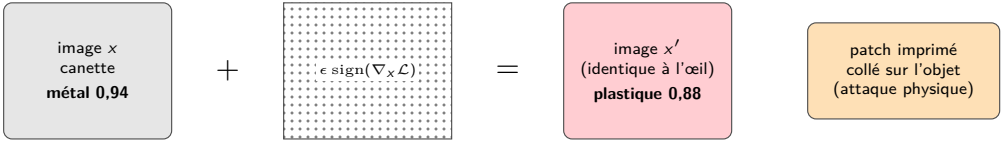


- **Portenta H7** : élément sécurisé NXP SE050 (clés ECC, stockage protégé) ; MCUboot pour la chaîne de confiance.
- **ESP32-S3** : *Secure Boot v2* (RSA-PSS ou ECDSA) + *Flash Encryption* (AES-XTS), clés en eFuse.

un `.tflite` modifié peut provoquer un mauvais tri ciblé (*porte dérobée*, Gu et al., BadNets, NYU 2017) : il doit être signé et vérifié **comme le firmware**. Le modèle est aussi une **propriété intellectuelle** : protection de la lecture (RDP, chiffrement).

Sécuriser la station

Attaques adverses : tromper le modèle sans toucher au système



$\|x' - x\|_\infty \leq \epsilon$ *(ex. 2/255)*

pas besoin d'accès au réseau ni au code

- **FGSM** (Goodfellow, Shlens, Szegedy, ICLR 2015) : $x' = x + \epsilon \operatorname{sign}(\nabla_x \mathcal{L}(f(x), y))$.
- **PGD** (Madry et al., MIT, ICLR 2018) : FGSM itéré et projeté, référence pour évaluer la robustesse.
- **Patch physique** (Brown et al., Google, 2017) : un autocollant suffit, imprimé et vu sous tous les angles.

Parades réalistes pour une station

- Entraînement adverse (PGD) : robustesse au prix de 2 à 5 points de précision.
- **Multi-capteurs** : vision + poids, ou vision + son de chute, plus durs à tromper ensemble.
- Rejet (DOUTE) et surveillance de la répartition des classes.
- La quantification INT8 **ne protège pas** : les attaques se transfèrent.

Question flash

?

Votre équipe a 2 jours pour sécuriser la station avant le pilote. Classez par rapport bénéfice/effort : (a) entraînement adverse PGD, (b) bonding BLE + HMAC des commandes, (c) signature du modèle vérifiée au démarrage, (d) chiffrement de la Flash. Justifiez.

Question flash

?

Votre équipe a 2 jours pour sécuriser la station avant le pilote. Classez par rapport bénéfice/effort : (a) entraînement adverse PGD, (b) bonding BLE + HMAC des commandes, (c) signature du modèle vérifiée au démarrage, (d) chiffrement de la Flash. Justifiez.

Réponse

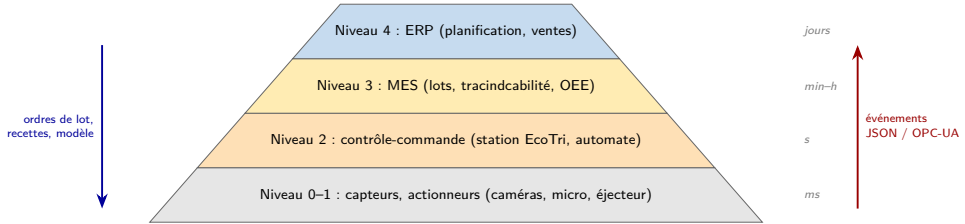
(b) d'abord : l'incident de décembre est réel, l'attaque est triviale et la parade coûte quelques heures. (c) ensuite : elle protège aussi contre la corruption accidentelle et prépare l'OTA. (d) protège la PI, utile si les stations sont accessibles. (a) en dernier : menace peu probable sur un tapis, coût élevé en précision et en temps de calcul.

Intégrer l'usine

Comment la station parle-t-elle à l'usine, et comment prouver sa valeur ?

Intégrer l'usine

La pyramide ISA-95 (IEC 62264) et la place de la station



La station EcoTri appartient aux niveaux **1–2** ; elle publie des **événements** (objet trié, arrêt, dérive) vers le **MES** (niveau 3), qui gère les lots, la traçabilité et calcule les indicateurs.

! on ne remonte pas les images (Mo/s) mais des **événements** (centaines d'octets) : c'est la promesse de la lecture 1, tenue jusqu'au MES.

Intégrer l'usine

Du message JSON au modèle d'information industriel

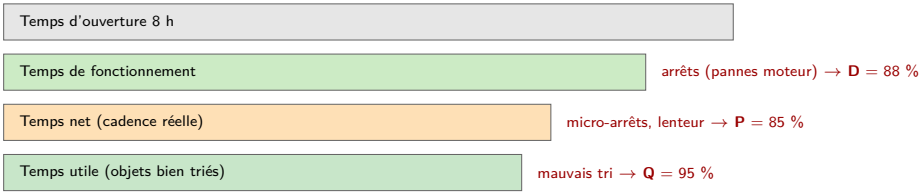
- **MQTT + Sparkplug B** (Eclipse) : sujets normalisés `spBv1.0/EcoTri/DDATA/station3/portenta`, états de naissance/mort, encodage Protobuf.
- **OPC UA** (IEC 62541) : modèle d'objets typé, sécurité intégrée (certificats X.509) ; *Companion Specifications* par métier.
- **Asset Administration Shell** (Plattform Industrie 4.0) : jumeau numérique normalisé de la station (identité, capacités, version du modèle).

```
Objects/
 EcoTri_Station3/          (StationType)
   Identification/  Serial, Firmware
   ModeleIA/        Version "4.1.0", Sha256
   Etat/            Mode {AUTO, ARRET, MAINT}
   Compteurs/       Tries[4], Doutes, Rejets
   KPI/             Disponibilite, Performance,
                    Qualite, OEE
   Derive/          PSI, TauxDoute
   Methodes/        Arreter(), MajModele(url)
```

Espace d'adresses OPC UA (esquisse). La passerelle (Portenta ou PC) traduit le JSON BLE en nœuds OPC UA.

Intégrer l'usine

L'OEE (TRS) : l'indicateur que la direction comprend



OEE = D × P × Q = 0,88 × 0,85 × 0,95 ≈ 71 %

$$\mathrm{OEE} = \underbrace{\frac{T_{\text{fonct}}}{T_{\text{ouv}}}}_{D} \times \underbrace{\frac{N\, t_{\text{cycle}}}{T_{\text{fonct}}}}_{P} \times \underbrace{\frac{N_{\text{bons}}}{N}}_{Q}$$

Référence usuelle : 85 % = classe mondiale (Nakajima, TPM, 1988). L'IA agit sur les trois termes : **D** (maintenance prédictive audio, lecture 4), **P** (latence, lecture 6), **Q** (précision et rejet, lectures 5–6).

Question flash

?

Poste de 8 h. Arrêts moteur : 40 min. Cadence nominale 1 objet/s ; 24 300 objets traités. Objets bien triés : 23 085. Calculez D, P, Q et l'OEE. Quel levier IA prioriser ?

Question flash

?

Poste de 8 h. Arrêts moteur : 40 min. Cadence nominale 1 objet/s ; 24 300 objets traités. Objets bien triés : 23 085. Calculez D, P, Q et l'OEE. Quel levier IA prioriser ?

Réponse

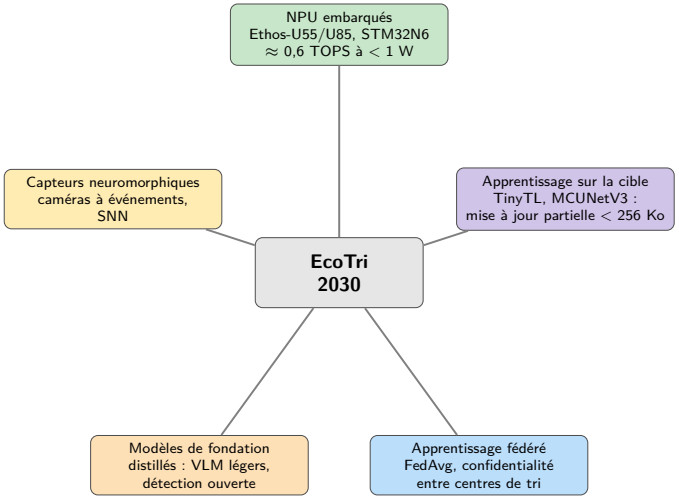
$T_{\text{fonct}} = 440$ min $= 26\,400$ s : $D = 0{,}917$. $P = 24\,300/26\,400 = 0{,}920$. $Q = 23\,085/24\,300 = 0{,}950$. OEE $\approx$ **80 %**. Le plus faible est D, à égalité avec P : la détection précoce d'anomalie moteur (planifier l'intervention avant la panne) rapporte le plus.

Perspectives

Que changent les dix prochaines années ?

Perspectives

Cinq ruptures à suivre



Perspectives

Les NPU pour microcontrôleurs

Plate-forme	Accélérateur	Ordre de grandeur
Portenta H7	aucun (M7 + DSP)	$\approx$ 0,5 GOPS
Alif Ensemble E7	Ethos-U55	$\approx$ 0,2–0,5 TOPS
STM32N6	Neural-ART	$\approx$ 0,6 TOPS
Ethos-U85 (IP)	NPU + Transformers	jusqu'à 4 TOPS

Valeurs annoncées par les fabricants, indicatives ; à vérifier sur la version courante des fiches.

- Gain typique de 10 à 100$\times$ en latence et en énergie sur les convolutions INT8.
- Le **compilateur** (Vela pour Ethos) répartit les opérateurs : ce qui n'est pas supporté retombe sur le CPU, et Amdahl revient.
- Conséquence pour EcoTri : la vision par **détection** (FOMO, YOLO-nano) devient possible à 30 FPS ; le goulot redevient la radio et la caméra.

Perspectives

Apprendre sur la cible (Lin et al., MIT, NeurIPS 2022 : MCUNetV3)

- L'entraînement complet coûte $\approx 3\times$ l'inférence en calcul et beaucoup plus en mémoire (activations à conserver pour la rétro-propagation).
- **Mise à jour partielle** : on ne ré-entraîne que la tête, ou les biais (TinyTL, Cai et al., MIT, 2020) : mémoire divisée par 10 environ.
- **MCUNetV3** : entraînement sous 256 Ko de SRAM par mise à jour éparse et optimisation tenant compte de la quantification.

Variante légère faisable sur la Portenta

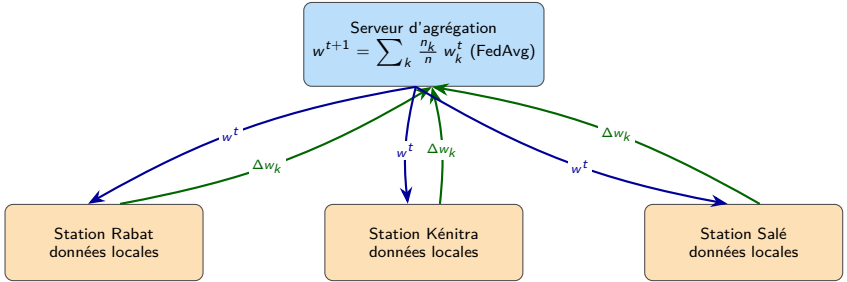
Prototypes : l'avant-dernière couche donne un vecteur $h(x)$; on stocke la moyenne μ_c par classe et l'on classe par $\arg\min_c \|h(x) - \mu_c\|$. Ajouter une classe = 1 vecteur, aucun gradient (Snell et al., Toronto, 2017).

Risque

l'apprentissage en ligne non supervisé peut **s'auto-empoisonner** : validation et retour arrière restent obligatoires.

Perspectives

L'apprentissage fédéré (McMahan et al., Google, AISTATS 2017)



les images ne quittent jamais la station : seuls les poids (ou mises à jour) circulent

Intérêt pour un réseau de centres de tri : chaque site voit des déchets différents ; on mutualise l'apprentissage sans partager les images (confidentialité industrielle, RGPD si des personnes apparaissent).

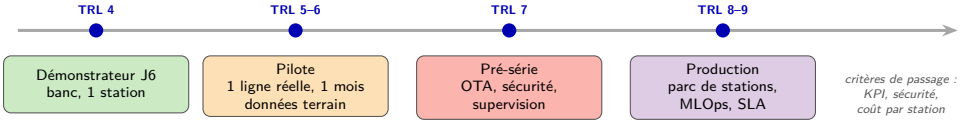
Limites : données non i.i.d. entre sites, coût radio des poids (410 Ko $\times$ tours), inversion de gradients possible : on ajoute agrégation sécurisée ou confidentialité différentielle.

Évaluer et défendre

Comment argumenter une architecture devant un jury ?

Évaluer et défendre

Du démonstrateur à la production : la feuille de route



Ce que le jury attend

- Une **position** claire sur le placement du calcul, étayée par **vos** mesures (J1, J5, J6).
- Les **limites** constatées, chiffrées, et ce qu'il faudrait pour passer au TRL suivant.
- Une analyse de **risques** : dérive, sécurité, maintenance.

Affirmation (« le tri doit rester sur la Portenta ») → **preuve** (mesure) → **garantie** (principe : Amdahl, énergie radio) → **réserve** (« sauf si…») (Toulmin, 1958).

Évaluer et défendre

Edge ou cloud : la grille de décision

Critère	Favorise l'Edge si…	Favorise le cloud si…
Latence	échéance $<$ 100 ms à 1 s (éjecteur)	réponse en secondes acceptable
Bande passante	flux continu d'images, liaison BLE/LPWAN	événements rares, fibre disponible
Énergie	batterie, radio coûteuse	alimentation secteur
Confidentialité	images de personnes, secret industriel	données anonymes
Modèle	tient en $<$ 1 Mo INT8	modèle de fondation, multi-tâches
Maintenance	parc stable, OTA maîtrisée	mises à jour quotidiennes
Disponibilité	la ligne ne doit pas s'arrêter si le réseau tombe	le service tolère les coupures



« hybride » : décision au bord, apprentissage et supervision au centre. La question est **où placer la frontière**, et elle se tranche par des mesures.

Évaluer et défendre

Si la bande passante BLE devient insuffisante (sujet de réflexion)

Agir sur le volume

- Envoyer la **décision** (20 o) ou des **caractéristiques** (vecteur $h(x)$, 64–256 o) au lieu de l'image (9 Ko).
- Compression : JPEG qualité 50 ($\approx 10\times$), mais attention au changement de domaine.
- Région d'intérêt seule (blob détecté à l'étage 1).

Agir sur le canal

- BLE 5 : PHY 2M, DLE (251 o), intervalle 7,5 ms : jusqu'à $\approx$ 1,3 Mb/s théoriques.
- Changer de lien : Wi-Fi (ESP32), filaire (SPI, UART) si les cartes sont proches.
- Déplacer le calcul : **inférence sur la XIAO** (TP6, partie 5).

! on compare chaque option sur latence p95, énergie par décision, précision et coût de maintenance, avec les chiffres mesurés en J3 et J6.

Évaluer et défendre

Les modalités de l'évaluation de la séance

Soutenance (25 %)

15 min de présentation + 5 min de démonstration en direct + 10 min de questions. Toute l'équipe parle ; chacun est interrogé.

Épreuve pratique (40 %)

1 h 15, individuelle, sur la station de l'équipe : une **variante** imposée (voir TP 7), code et mesures rendus.

Réflexion écrite

45 min, 2 pages : Edge contre cloud, et que faire si la bande passante BLE devient insuffisante. Intégrée à la note d'épreuve.

Les jalons J1–J6 comptent pour 35 %. Les grilles critériées sont dans le document du TP 7.

À retenir

- **MLOps embarqué** : tout est versionné (données, code, modèle, firmware) ; mise à jour A/B avec auto-test et retour arrière ; déploiement progressif.
- **Dérive** : sans étiquettes, on surveille $p(x)$ (PSI, KS) et les sorties (confiance, DOUTE) ; Page-Hinkley tient en quelques octets.
- **Sécurité** : STRIDE pour les menaces ; BLE Secure Connections + bonding, HMAC avec compteur, démarrage sécurisé, **modèle signé** ; l'adverse existe, mais ce n'est pas la première priorité.
- **Usine** : la station publie des événements vers le MES (ISA-95, OPC UA, MQTT Sparkplug) ; sa valeur se mesure en **OEE**.
- **Perspectives** : NPU, apprentissage sur la cible, fédéré ; chacun déplace la frontière Edge/cloud sans supprimer la question.
- **Défendre** : affirmation, preuve mesurée, principe, réserve.

Glossaire et références

Terme	Définition courte
OTA	mise à jour à distance
Canari	déploiement sur un sous-ensemble
PSI	indice de stabilité d'une population
STRIDE	typologie de menaces
HMAC	code d'authentification de message
MES	système d'exécution de la production
OEE	TRS = D × P × Q
FedAvg	moyenne fédérée des poids

- D. Sculley et al., « Hidden Technical Debt in Machine Learning Systems », NeurIPS 2015 (Google).
- V. Janapa Reddi et al., *Machine Learning Systems*, chap. « ML Operations », « Security & Privacy », « On-Device Learning », mlsysbook.ai (Harvard).
- S. Leroux, P. Simoens, M. Lootus, K. Thakore, A. Sharma, « TinyMLOps : Operational Challenges for Widespread Edge AI Adoption », IEEE IPDPSW 2022 (Univ. Gand).
- J. Quiñonero-Candela et al., *Dataset Shift in Machine Learning*, MIT Press, 2009.
- I. Goodfellow, J. Shlens, C. Szegedy, ICLR 2015 ; A. Madry et al., ICLR 2018 (MIT) ; T. Gu et al., « BadNets », 2017 (NYU).
- M. Ryan, « Bluetooth : With Low Energy comes Low Security », USENIX WOOT 2013 ; Bluetooth Core Spec. 5.x, vol. 3, part H.
- J. Lin, L. Zhu, W.-M. Chen, W.-C. Wang, C. Gan, S. Han, « On-Device Training Under 256KB Memory », NeurIPS 2022 (MIT).
- B. McMahan et al., « Communication-Efficient Learning of Deep Networks from Decentralized Data », AISTATS 2017.
- M. Mitchell et al., « Model Cards for Model Reporting », FAT* 2019 ; IEC 62264 (ISA-95), IEC 62541 (OPC UA).

Prochaine étape

Tutorial 7 : manifeste signé, mise à jour A/B et surveillance de dérive sur la Portenta. **TP 7** : soutenance, épreuve pratique et réflexion écrite.