Université Mohammed V de Rabat
École Nationale Supérieure d'Informatique et d'Analyse des Systèmes
Département Ingénierie des Systèmes Embarqués
Filière Smart Systems Engineering

TP 8 : Détecter, compter et déployer sur deux cartes avec Edge Impulse (FOMO, EON Tuner, EON Compiler)

Travaux pratiques, lecture 8 « Edge Impulse, plateforme MLOps pour le TinyML », jalon J8

Pr.Hassan BERBIA/Pr.Aissam BERRAHOU

2 novembre 2026

Objectifs du TP

Le deuxième centre de tri veut **compter** et **localiser** les déchets qui passent côte à côte sur le tapis. Votre équipe construit un détecteur FOMO avec Edge Impulse, l'optimise avec l'EON Tuner, puis le déploie sur la **XIAO ESP32-S3 Sense** (bibliothèque Arduino, EON Compiler) et sur la **Portenta H7** (bibliothèque OpenMV). Vous confrontez systématiquement les estimations du Studio à vos mesures.
À la fin de ce TP, vous serez capable de :

- Constituer et étiqueter un jeu de données de détection (boîtes englobantes).
- Entraîner un modèle FOMO et l'évaluer avec le score F1.
- Lancer et interpréter l'EON Tuner (front de Pareto sous contraintes).
- Comparer TFLite Micro et EON Compiler (RAM, Flash, latence).
- Déployer une même impulse sur deux cibles et mesurer les performances réelles.
- Versionner le projet et rédiger le rapport du jalon J8.

Durée : 2 h en séance + finalisation du rapport. **Prérequis :** Tutorial 8 terminé.

1 Contexte et cahier des charges

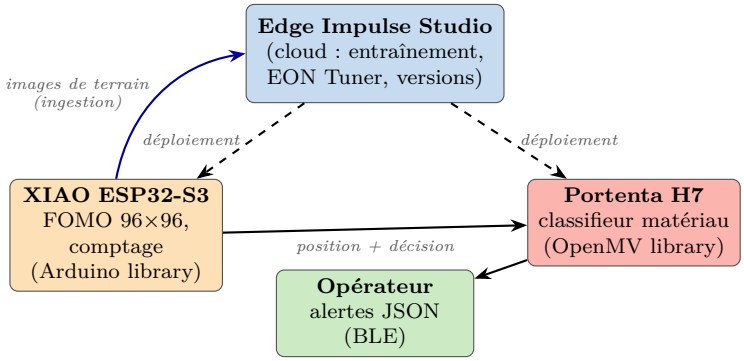


FIGURE 1 – *
Architecture visée : la XIAO localise et compte les objets avec FOMO ; la Portenta décide du matériau ; Edge Impulse sert à l'entraînement et aux versions.

Exigence	Énoncé	Vérification
EF-8.1	détecter et compter les objets de 4 classes, plusieurs par image	démonstration, F1 sur test
ENF-8.1	F1 $\geq$ 0,80 sur le jeu de test (modèle INT8)	Model testing
ENF-8.2	latence capture + inférence $\leq$ 250 ms sur la XIAO	mesure `r.timing` + `millis()`
ENF-8.3	RAM du modèle $\leq$ 200 Ko, Flash $\leq$ 1 Mo	estimation + compilation
ENF-8.4	le projet est versionné et reproductible	onglet Versions, export

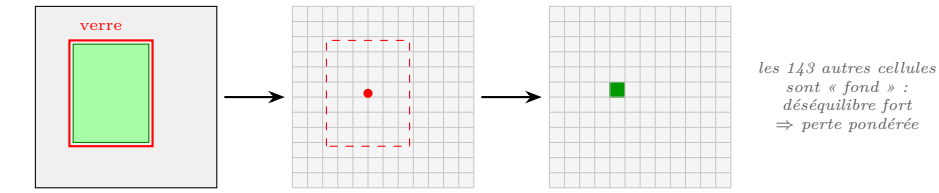
TABLE 1 – *
Exigences du jalon J8.

2 Partie A : Données de détection (35 min)

A.1 Projet et capture

1. Créez le projet `EcoTri-Vision-<equipe>`, *Labeling method* : **Bounding boxes (object detection)**, cible : **Espressif ESP-EYE (ESP32 240 MHz)** (la plus proche de la XIAO).
2. Capturez au moins **120 images** contenant chacune **1 à 4 objets**, avec la XIAO (exemple `CameraWebServer`, QVGA) ou avec la Portenta (Dataset Editor, script du Tutorial 8). Gardez des objets **séparés** d'au moins 2 cm.
3. Téléversez avec `edge-impulse-uploader -category split` (dossier non étiqueté).

A.2 Étiquetage



(a) boîte englobante annotée (b) centre de la boîte (c) cible : 1 cellule « verre »

FIGURE 2 – *
Vous dessinez des boîtes ; FOMO n'en gardera que le centre, placé dans une cellule de la grille.

1. Ouvrez **Labeling queue**, activez le suivi d'objets (*Track objects between frames*) et étiquetez toutes les images.
2. Comptez le nombre d'**objets** (pas d'images) par classe dans le jeu d'apprentissage et dans le jeu de test.

Question

Q1. Avec 120 images de 96×96 et en moyenne 2,5 objets par image, quelle proportion des cellules de la carte 12×12 sont « fond » ? Pourquoi la précision brute est-elle inutilisable ici ?

3 Partie B : Impulse FOMO de référence (30 min)

1. Impulse : entrée **96×96**, *Fit shortest*, bloc **Image** en **Grayscale**, bloc **Object Detection (Images)**.
2. Générez les caractéristiques et observez l'explorateur.
3. Modèle : **FOMO (Faster Objects, More Objects) MobileNetV2 0.35**, 60 cycles, taux 0,001. Entraînez.
4. Relevez le F1 de validation, puis le F1 de test dans **Model testing** (version INT8).

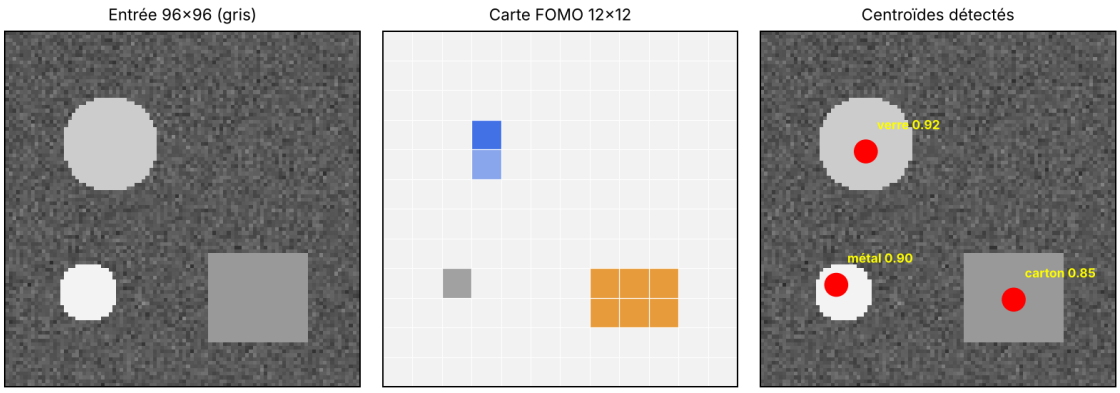


FIGURE 3 – *
Ce que calcule FOMO : une carte de scores 12×12 par classe, puis des centroïdes. Utilisez la vue *Live classification* pour observer la même chose sur vos images.

Question

Q2. Le test indique 180 objets réels, 166 détections dont 148 correctes. Calculez précision, rappel et F1. L'exigence ENF-8.1 est-elle respectée ?

Question

Q3. Trouvez dans le test un cas où deux objets proches ont été fusionnés. Quelle distance en pixels les sépare dans l'image 96×96 ? Reliez à la taille d'une cellule.

4 Partie C : EON Tuner et front de Pareto (25 min)

1. Ouvrez **EON Tuner**, cible **ESP-EYE**, latence maximale **200 ms**, tâche *Object detection*. Lancez une recherche courte (le Tuner s'exécute en tâche de fond ; poursuivez la partie D pendant ce temps).
2. Exportez ou recopiez les essais : F1, RAM, Flash, latence estimée (au moins 8 essais).
3. Tracez précision (F1) en fonction de la latence et entourez les points du front de Pareto.

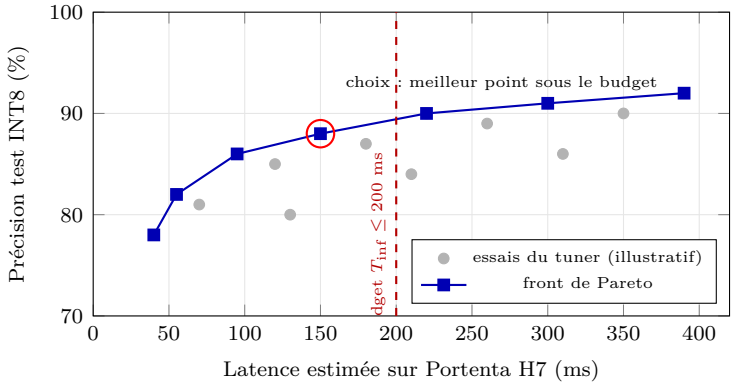


FIGURE 4 – *
Exemple de lecture attendue (valeurs illustratives). Votre graphique doit porter vos propres essais et le budget de l'exigence ENF-8.2.

Question

Q4. Un essai A (F1 0,86 ; 140 ms ; 150 Ko) et un essai B (F1 0,84 ; 90 ms ; 95 Ko). Aucun ne domine l'autre : justifiez. Lequel choisissez-vous pour la XIAO, sachant qu'elle doit aussi garder la pile BLE en mémoire ?

5 Partie D : Déploiement sur la XIAO avec EON (30 min)

D.1 TFLite Micro contre EON Compiler

Dans **Deployment**, choisissez **Arduino library**, version **Quantized (int8)**, et notez pour chaque option les estimations affichées :

Moteur	RAM (Ko)	Flash (Ko)	Latence est. (ms)	Latence mesurée (ms)
TFLite Micro				
EON Compiler				
EON Compiler (RAM optimized)				

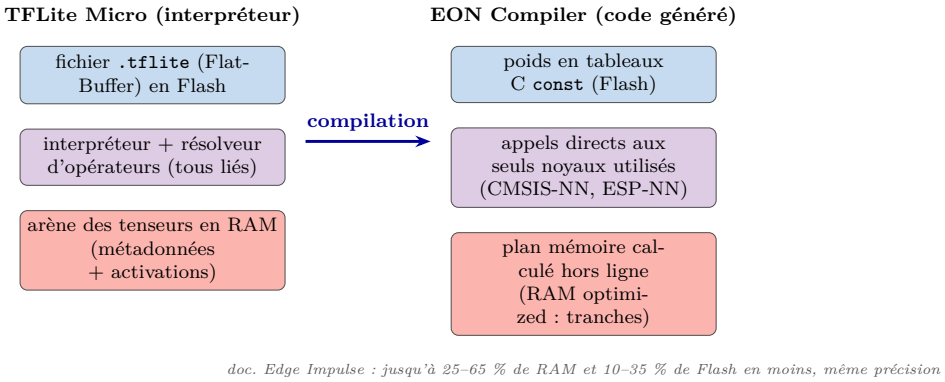


FIGURE 5 – *
Pourquoi EON réduit la mémoire : plus d'interpréteur, un plan mémoire calculé à la compilation.

D.2 Programme Arduino

Installez la bibliothèque (**Sketch → Include Library → Add .ZIP Library**), carte **XIAO_ESP32S3**, **PSRAM : OPI PSRAM**. Partez de l'exemple `esp32_camera` fourni par la bibliothèque, réglez la caméra de la XIAO, puis remplacez la boucle d'inférence par :

```
#include <EcoTri-Vision_inferencing.h>
// ... initialisation caméra de l'exemple (broches XIAO, QVGA, PSRAM)

void loop() {
  uint32_t t0 = millis();
  if (!ei_camera_capture(EI_CLASSIFIER_INPUT_WIDTH, EI_CLASSIFIER_INPUT_HEIGHT,
    snapshot_buf)) return;
  uint32_t t1 = millis();

  ei::signal_t signal;
  signal.total_length = EI_CLASSIFIER_INPUT_WIDTH * EI_CLASSIFIER_INPUT_HEIGHT;
  signal.get_data = &ei_camera_get_data;
  ei_impulse_result_t r = {0};
  if (run_classifier(&signal, &r, false) != EI_IMPULSE_OK) return;

  int compte[EI_CLASSIFIER_LABEL_COUNT] = {0};
  for (size_t i = 0; i < r.bounding_boxes_count; i++) {
    ei_impulse_result_bounding_box_t b = r.bounding_boxes[i];
    if (b.value < 0.5f) continue;
    for (int k = 0; k < EI_CLASSIFIER_LABEL_COUNT; k++)
      if (strcmp(b.label, ei_classifier_inferencing_categories[k]) == 0) compte[k]++;
    Serial.printf("%s %.2f (%u,%u)\n", b.label, b.value, b.x + b.width / 2, b.y + b.
    height / 2);
  }
  Serial.printf("capture %lu ms | DSP %d ms | NN %d ms | total %lu ms\n",
                t1 - t0, r.timing.dsp, r.timing.classification, millis() - t0);
  Serial.printf("{\"n\":[%d,%d,%d,%d]}\n", compte[0], compte[1], compte[2], compte
    [3]);
```

```
}
```

Astuce

L'ordre des classes est celui de `ei_classifier_inferencing_categories` (ordre alphabétique des étiquettes). Si la carte redémarre à l'allocation, vérifiez que la PSRAM est activée ou passez au FOMO $\alpha = 0{,}1$.

Question

Q5. Mesurez sur 50 inférences la latence moyenne et le 95e centile. L'exigence ENF-8.2 est-elle respectée au pire cas ? Quel terme du budget domine ?

6 Partie E : Même impulse sur la Portenta (20 min)

1. Ré-entraînez le même modèle en niveaux de gris si nécessaire (la Portenta est monochrome), déployez la **OpenMV library** et copiez `trained.tflite` et `labels.txt` sur la carte.
2. Exécutez le script ci-dessous, inspiré de `ei_object_detection.py`, qui dessine les centroïdes et compte les objets par classe.

```
import sensor, time, ml, math, image

sensor.reset()
sensor.set_pixformat(sensor.GRAYSCALE)
sensor.set_framesize(sensor.B320X320)
sensor.set_windowing((240, 240))
sensor.skip_frames(time=2000)

net = ml.Model("trained.tflite", load_to_fb=True)
labels = [l.rstrip("\n") for l in open("labels.txt")]
SEUIL = [(math.ceil(0.5 * 255), 255)]

def fomo_post(model, inputs, outputs):
    _, oh, ow, oc = model.output_shape[0]
    sx, sy = inputs[0].roi[2] / ow, inputs[0].roi[3] / oh
    res = [[] for _ in range(oc)]
    for k in range(oc):
        carte = image.Image(outputs[0][0, :, :, k] * 255)
        for b in carte.find_blobs(SEUIL, x_stride=1, area_threshold=1,
    pixels_threshold=1):
            x, y, w, h = b.rect()
            s = carte.get_statistics(thresholds=SEUIL, roi=b.rect()).l_mean() / 255
            res[k].append((int((x + w / 2) * sx), int((y + h / 2) * sy), s))
    return res

while True:
    t0 = time.ticks_ms()
    img = sensor.snapshot()
    dets = net.predict([img], callback=fomo_post)
    dt = time.ticks_diff(time.ticks_ms(), t0)
    compte = []
    for k, liste in enumerate(dets):
        if k == 0: continue                      # fond
        compte.append(len(liste))
        for (cx, cy, s) in liste:
```

```
            img.draw_circle(cx, cy, 12, color=255, thickness=2)
            img.draw_string(cx + 8, cy - 8, labels[k], color=255)
    print("%d ms" % dt, dict(zip(labels[1:], compte)))
```

Question

Q6. Comparez la latence de la Portenta (TFLite Micro dans OpenMV, Cortex-M7 480 MHz) à celle de la XIAO (EON, Xtensa LX7 240 MHz). L'écart s'explique-t-il seulement par la fréquence ? Citez deux autres facteurs.

7 Partie F : Versionner et rendre le jalon J8 (10 min)

1. Créez une version du projet « J8 : FOMO 0.35 int8 96x96 gris, EON » et rendez le projet visible par l'enseignant (**Dashboard** → **Collaborators**).
2. Exportez le jeu de données et le modèle INT8 (archive à joindre au rapport).

Livrables du jalon J8 (rapport de 4 pages maximum)

1. Fiche du jeu de données : nombre d'images et d'objets par classe, conditions de capture, découpage.
2. Impulse retenue et justification (taille, couleur, α), F1 de test, matrice de confusion ou exemples d'erreurs.
3. Graphique de l'EON Tuner avec le front de Pareto et le point choisi.
4. Tableau estimations contre mesures sur les deux cartes, avec analyse des écarts.
5. Vérification des exigences ENF-8.1 à ENF-8.4 (respectée / non respectée, preuve).
6. Une limite de la plateforme rencontrée et la parade adoptée (confidentialité, quotas, dépendance).

Critère	Points	Attendu
Qualité des données	4	équilibre, variété, absence de fuites, étiquetage vérifié
Modèle et évaluation	4	F1 calculé et interprété, erreurs analysées
Optimisation	4	front de Pareto lu correctement, choix argumenté
Déploiement double	5	deux cartes fonctionnelles, comptage correct en démonstration
Mesures et budget	3	estimations confrontées aux mesures, p95

TABLE 2 – *
Grille d'évaluation du jalon J8 (sur 20).

8 Ressources

— Documentation FOMO : docs.edgeimpulse.com.
— EON Compiler et EON Tuner : docs.edgeimpulse.com.
— M. Rovai (UNIFEI), *TinyML Made Easy : Object Detection with XIAO ESP32S3 Sense*, Hackster.io et mlsysbook.ai.
— S. Hymel et al., « Edge Impulse : An MLOps Platform for Tiny Machine Learning », MLSys 2023.