ENSIAS

Université Mohammed V de Rabat
École Nationale Supérieure
d'Informatique et d'Analyse des Systèmes

جامعة محمد الخامس بالرباط
Université Mohammed V de Rabat

Deep Learning – Lecture 4

Optimisation : SGD, momentum, Adam et calendriers du taux d'apprentissage

Pr. Aissam BERRAHOU

ENSIAS – Université Mohammed V de Rabat

Module Deep Learning – 2026-2027

Objectifs de la lecture

- comparer descente de gradient batch, stochastique et mini-batch ;
- diagnostiquer un taux d'apprentissage inadapté ;
- écrire les mises à jour du momentum, de Nesterov, de RMSProp et d'Adam ;
- expliquer la correction de biais d'Adam et la différence Adam / AdamW ;
- choisir un calendrier du taux d'apprentissage (paliers, cosinus, échauffement) ;
- configurer optimiseurs et calendriers dans Keras.

Plan de la lecture

1. Le problème d'optimisation

2. Momentum

3. Méthodes adaptatives

4. Calendriers du taux d'apprentissage

Plan

1. Le problème d'optimisation

2. Momentum

3. Méthodes adaptatives

4. Calendriers du taux d'apprentissage

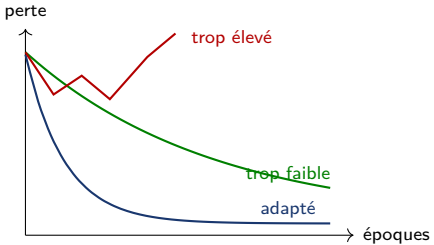
Un paysage non convexe

$$\theta^* = \arg\min_{\theta} J(\theta), \qquad \theta_{t+1} = \theta_t - \eta \nabla J(\theta_t)$$

- J n'est pas convexe : minima locaux, **plateaux**, **points selles**.
- Les vraies difficultés : plateaux, **ravins** (courbures très différentes), bruit des gradients.

Variante	**Exemples / pas**	**Propriétés**
Batch	n	exact, stable, coûteux
Stochastique	1	très bruité, peu parallèle
Mini-batch	32–512	compromis, GPU, le bruit aide à sortir des selles

Le taux d'apprentissage



Stabilité sur $J = \frac{a}{2}w^2$

$w_{t+1} = (1 - \eta a)w_t$: converge si $\eta < 2/a$.
Courbures 1 et 100 : $\eta < 0{,}02 \Rightarrow$ progression lente dans la direction plate : **ravin**.

Plan

1. Le problème d'optimisation

2. Momentum

3. Méthodes adaptatives

4. Calendriers du taux d'apprentissage

Momentum et Nesterov

Momentum

$\mathbf{v}_t = \beta \mathbf{v}_{t-1} + \mathbf{g}_t, \qquad \theta_{t+1} = \theta_t - \eta \mathbf{v}_t, \qquad \beta = 0{,}9$

- accélère quand les gradients gardent le signe (vitesse limite $\mathbf{g}/(1-\beta)$: $\times 10$) ;
- amortit les oscillations dans les ravins.

Trois pas : $g = (1; 1; -0{,}5)$, $\eta = 0{,}1$

$v = (1;\ 1{,}9;\ 1{,}21)$: le 3e pas poursuit dans la direction initiale.

Nesterov

Gradient évalué au point anticipé : $\mathbf{v}_t = \beta \mathbf{v}_{t-1} + \nabla J(\theta_t - \eta \beta \mathbf{v}_{t-1})$; moins de dépassements.

Plan

1. Le problème d'optimisation

2. Momentum

3. Méthodes adaptatives

4. Calendriers du taux d'apprentissage

AdaGrad et RMSProp

AdaGrad : un pas par paramètre

$$\mathbf{s}_t = \mathbf{s}_{t-1} + \mathbf{g}_t^2, \qquad \theta_{t+1} = \theta_t - \frac{\eta}{\sqrt{\mathbf{s}_t} + \epsilon} \odot \mathbf{g}_t$$

Bon pour les données creuses, mais le pas tend vers zéro.

RMSProp : moyenne mobile

$$\mathbf{s}_t = \rho \mathbf{s}_{t-1} + (1-\rho)\mathbf{g}_t^2, \qquad \rho \approx 0{,}9$$

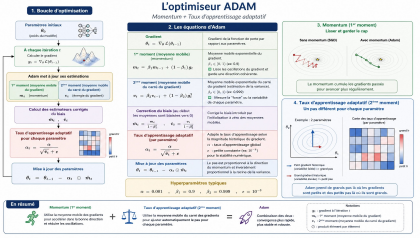
Oublie les gradients anciens ; efficace pour les RNN.

Adam = momentum + RMSProp + correction de biais

Mise à jour

$$\mathbf{m}_t = \beta_1 \mathbf{m}_{t-1} + (1-\beta_1)\mathbf{g}_t$$
$$\mathbf{v}_t = \beta_2 \mathbf{v}_{t-1} + (1-\beta_2)\mathbf{g}_t^2$$
$$\hat{\mathbf{m}}_t = \mathbf{m}_t/(1-\beta_1^t), \quad \hat{\mathbf{v}}_t = \mathbf{v}_t/(1-\beta_2^t)$$
$$\theta_{t+1} = \theta_t - \eta\, \hat{\mathbf{m}}_t/(\sqrt{\hat{\mathbf{v}}_t} + \epsilon)$$

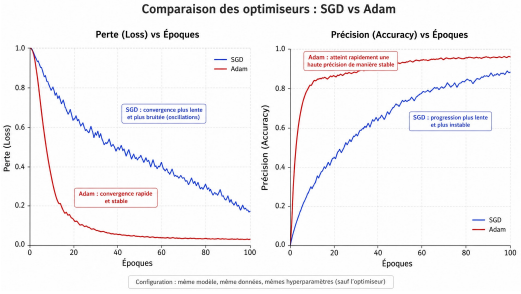
$\beta_1 = 0{,}9$, $\beta_2 = 0{,}999$, $\epsilon = 10^{-8}$, $\eta = 10^{-3}$



Pourquoi corriger le biais ? ($g_1 = 0{,}5$)

Sans correction : pas $\approx 3{,}2\eta$. Avec : $\hat{m}_1 = 0{,}5$, $\hat{v}_1 = 0{,}25$, pas $= \eta$.

SGD vs Adam, et AdamW



AdamW (découplage du weight decay)

$\theta_{t+1} = \theta_t - \eta\big(\hat{\mathbf{m}}_t/(\sqrt{\hat{\mathbf{v}}_t} + \epsilon) + \lambda\theta_t\big)$: standard des Transformers.

Comparatif

Optimiseur	**Idée**	**Usage**
SGD	pas fixe	référence
SGD + momentum	inertie	CNN, très bonne généralisation
AdaGrad	pas par paramètre, cumul	données creuses
RMSProp	pas par paramètre, moyenne mobile	RNN, RL
Adam	momentum + RMSProp + biais	choix par défaut
AdamW	Adam + weight decay découplé	Transformers

Plan

1. Le problème d'optimisation

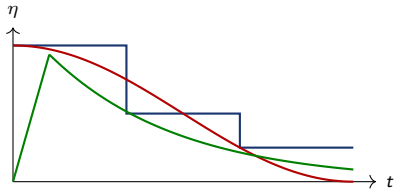
2. Momentum

3. Méthodes adaptatives

4. Calendriers du taux d'apprentissage

Faire varier η dans le temps

- **Paliers** : $\eta_0 \gamma^{\lfloor t/k \rfloor}$
- **Exponentiel** : $\eta_0 e^{-\lambda t}$
- **Cosinus** : $\eta_{\min} + \frac{1}{2}(\eta_0 - \eta_{\min})(1 + \cos \frac{\pi t}{T})$
- **Échauffement** : montée linéaire initiale
- **Plateau** : diviser si la validation stagne
- **One-cycle** : montée puis descente



Cosinus, $\eta_0 = 0{,}1$, $T = 100$

$\eta_{50} = 0{,}05$, $\eta_{75} \approx 0{,}0146$, $\eta_{100} = 0$.

Dans Keras

```
opt_sgd = tf.keras.optimizers.SGD(learning_rate=0.01, momentum=0.9, nesterov=True)
opt_adamw = tf.keras.optimizers.AdamW(learning_rate=1e-3, weight_decay=1e-4)

cos = tf.keras.optimizers.schedules.CosineDecay(initial_learning_rate=0.0,
       decay_steps=10 * 469, warmup_target=1e-3, warmup_steps=500)
opt = tf.keras.optimizers.Adam(learning_rate=cos)

plateau = tf.keras.callbacks.ReduceLROnPlateau(monitor='val_loss', factor=0.5, patience=3)
model.fit(x, y, epochs=10, validation_split=0.1, callbacks=[plateau])
```

Recommandations

Adam 10^{-3} par défaut ; SGD+momentum + calendrier pour les CNN ; AdamW + échauffement pour les Transformers ; lot $\times k \Rightarrow \eta \times k$.

À retenir

- Mini-batch SGD + **inertie** + **pas adaptatif** + **calendrier**.
- Le taux d'apprentissage est l'hyperparamètre le plus influent.
- Optimiser n'est pas généraliser $\Rightarrow$ régularisation (L5).

Questions de révision

1. $J = (w-3)^2$, $w_0 = 0$, $\eta = 0{,}25$: w_1, w_2 ? Et $\eta = 1{,}1$?
2. Montrer que la vitesse du momentum tend vers $g/(1-\beta)$.
3. Deux pas d'Adam avec $g = (0{,}5;\ -0{,}5)$.