Université Mohammed V de Rabat
École Nationale Supérieure
d'Informatique et d'Analyse des Systèmes

Deep Learning – Lecture 7

Architectures CNN modernes et apprentissage par transfert

Pr. Aissam BERRAHOU

ENSIAS – Université Mohammed V de Rabat

Module Deep Learning – 2026-2027

Objectifs de la lecture

- retracer l'évolution LeNet $\rightarrow$ AlexNet $\rightarrow$ VGG $\rightarrow$ Inception $\rightarrow$ ResNet $\rightarrow$ EfficientNet ;
- expliquer petits filtres empilés, convolutions 1×1 et pooling global ;
- expliquer pourquoi les connexions résiduelles rendent possibles les réseaux très profonds ;
- calculer le gain d'une convolution séparable en profondeur ;
- choisir entre extraction de caractéristiques et fine-tuning ;
- mettre en œuvre le transfert avec Keras.

Plan de la lecture

1. Le défi ImageNet
2. AlexNet et VGG
3. Inception et convolution 1×1
4. ResNet
5. Architectures efficaces
6. Apprentissage par transfert

Plan

1. Le défi ImageNet

2. AlexNet et VGG

3. Inception et convolution 1×1

4. ResNet

5. Architectures efficaces

6. Apprentissage par transfert

Dix ans d'architectures

Modèle	Année	Couches	Paramètres	Top-5
LeNet-5	1998	5	60 k	(MNIST)
AlexNet	2012	8	60 M	16,4 %
VGG-16	2014	16	138 M	7,3 %
GoogLeNet	2014	22	6,8 M	6,7 %
ResNet-152	2015	152	60 M	3,6 %
MobileNetV2	2018	53	3,5 M	$\approx$10 %
EfficientNet-B7	2019	–	66 M	2,9 %

ImageNet (ILSVRC)

1,2 M d'images, 1 000 classes ; erreur top-5 : la bonne classe parmi les 5 premières.

Plan

1. Le défi ImageNet

2. AlexNet et VGG

3. Inception et convolution 1×1

4. ResNet

5. Architectures efficaces

6. Apprentissage par transfert

AlexNet et VGG

AlexNet (2012)

Schéma LeNet à grande échelle + **ReLU**, **Dropout**, augmentation, **GPU**.

VGG (2014) : uniquement des 3×3

Blocs de convolutions 3×3 + max pooling ; filtres $64 \to 128 \to 256 \to 512$.

Trois 3×3 valent une 7×7

Même champ récepteur 7×7 ; $27C^2$ paramètres contre $49C^2$ ($-45\,\%$) ; 3 non-linéarités au lieu d'une.

Le coût de la tête dense

VGG-16 : $7 \cdot 7 \cdot 512 \times 4\,096 \approx 102{,}8$ M paramètres dans la première couche dense.

Plan

1. Le défi ImageNet

2. AlexNet et VGG

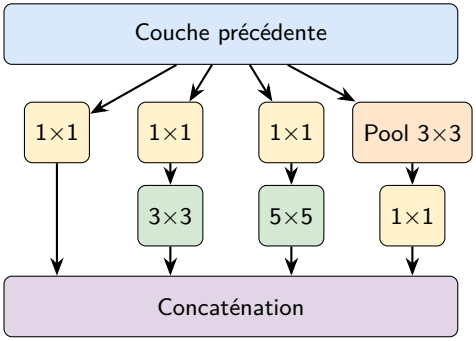
3. Inception et convolution 1×1

4. ResNet

5. Architectures efficaces

6. Apprentissage par transfert

Module Inception



Convolution 1×1

Mélange les canaux sans mélange spatial : réduit les canaux (*bottleneck*).

Gain

$28 \times 28 \times 192 \to 32$ canaux en 5×5 : 120 M multiplications ;
avec réduction à 16 : 12,4 M ($\div 10$).

Pooling global moyen

$7 \times 7 \times 2048 \to 2048$, sans paramètre.

Plan

1. Le défi ImageNet

2. AlexNet et VGG

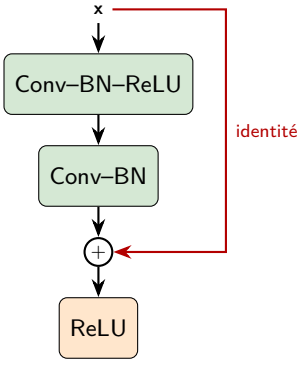
3. Inception et convolution 1×1

4. ResNet

5. Architectures efficaces

6. Apprentissage par transfert

Connexions résiduelles



Problème de dégradation

Au-delà de $\sim$20 couches, l'erreur *d'entraînement* d'un réseau simple augmente.

Bloc résiduel

$\mathbf{y} = F(\mathbf{x}) + \mathbf{x}$: on apprend le **résidu**.

- identité facile : $F = 0$;
- $\partial \mathbf{y}/\partial \mathbf{x} = I + \partial F/\partial \mathbf{x}$: le gradient traverse ;
- projection 1×1 si les dimensions changent ;
- même idée de chemin additif que LSTM et Transformers.

Plan

1. Le défi ImageNet

2. AlexNet et VGG

3. Inception et convolution 1×1

4. ResNet

5. Architectures efficaces

6. Apprentissage par transfert

DenseNet, MobileNet, EfficientNet

DenseNet

$\mathbf{x}_l = H_l([\mathbf{x}_0, \ldots, \mathbf{x}_{l-1}])$: réutilisation des caractéristiques par concaténation.

MobileNet : convolution séparable en profondeur

$F \times F$ par canal, puis 1×1 : $F^2 C_{in} + C_{in} C_{out}$ au lieu de $F^2 C_{in} C_{out}$.

3×3, $256 \to 256$

Standard : 589 824 ; séparable : 67 840 ($\div 8{,}7$).

EfficientNet

Mise à l'échelle **composée** : profondeur, largeur et résolution ensemble.

Plan

1. Le défi ImageNet

2. AlexNet et VGG

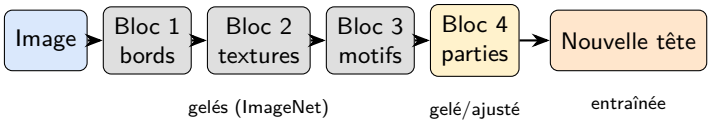
3. Inception et convolution 1×1

4. ResNet

5. Architectures efficaces

6. Apprentissage par transfert

Principe



1. Extraction de caractéristiques

Base gelée, seule la tête est entraînée.

2. Fine-tuning

Dégeler les derniers blocs, $\eta = 10^{-5}$ à 10^{-4}.

	Données proches	**Données différentes**
Peu	tête seule	couches plus basses, prudence
Beaucoup	fine-tuning des derniers blocs	fine-tuning profond

Transfert avec MobileNetV2

```
base = tf.keras.applications.MobileNetV2(input_shape=(160,160,3),
                                         include_top=False, weights='imagenet')
base.trainable = False # étape 1
inputs = layers.Input((160, 160, 3))
x = tf.keras.applications.mobilenet_v2.preprocess_input(inputs)
x = base(x, training=False) # BN en mode inférence
x = layers.GlobalAveragePooling2D()(x)
outputs = layers.Dense(5, activation='softmax')(layers.Dropout(0.2)(x))
model = tf.keras.Model(inputs, outputs)
model.compile(tf.keras.optimizers.Adam(1e-3), 'sparse_categorical_crossentropy', ['accuracy'])
model.fit(train_ds, validation_data=val_ds, epochs=10)

base.trainable = True # étape 2 : fine-tuning
for l in base.layers[:-30]: l.trainable = False
model.compile(tf.keras.optimizers.Adam(1e-5), 'sparse_categorical_crossentropy', ['accuracy'])
model.fit(train_ds, validation_data=val_ds, epochs=10)
```

À retenir

- Petits filtres empilés, 1×1, pooling global, résiduels, séparables.
- Le transfert est l'approche par défaut en vision appliquée.
- Même prétraitement qu'au pré-entraînement ; taux faible en fine-tuning.

Questions de révision

1. Champ récepteur après conv 3×3, pool 2×2, conv 3×3 ? (8×8)
2. Dix blocs de dérivée 0,9 (résiduel) vs 0,1 (simple) ? (0,35 vs 10^{-10})
3. 800 radiographies, 2 classes : quelle démarche ?