Université Mohammed V de Rabat
École Nationale Supérieure
d'Informatique et d'Analyse des Systèmes

جامعة محمد الخامس بالرباط
Université Mohammed V de Rabat

Deep Learning – Lecture 10

Modèles génératifs : autoencodeurs, VAE et GAN

Pr. Aissam BERRAHOU

ENSIAS – Université Mohammed V de Rabat

Module Deep Learning – 2026-2027

Objectifs de la lecture

- distinguer modèles discriminants et génératifs ;
- construire un autoencodeur : compression, débruitage, détection d'anomalies ;
- écrire la perte d'un VAE et l'astuce de reparamétrisation ;
- décrire le jeu minimax d'un GAN et son entraînement alterné ;
- reconnaître les difficultés des GAN et leurs remèdes ;
- comparer AE, VAE, GAN et modèles de diffusion.

Plan de la lecture

1. Modélisation générative

2. Autoencodeurs

3. Autoencodeurs variationnels

4. Réseaux antagonistes génératifs

5. Ouverture : diffusion

Plan

1. Modélisation générative

2. Autoencodeurs

3. Autoencodeurs variationnels

4. Réseaux antagonistes génératifs

5. Ouverture : diffusion

Discriminant ou génératif ?

Discriminant

Estime $p(y \mid \mathbf{x})$: classer, prédire.

Génératif

Estime $p(\mathbf{x})$: échantillonner de nouveaux exemples.

Variable latente

$\mathbf{z} \sim \mathcal{N}(\mathbf{0}, I)$ (faible dimension) $\rightarrow$ $\mathbf{x} = g_\theta(\mathbf{z})$

Applications : synthèse d'images et de sons, augmentation, super-résolution, molécules, anomalies.

Plan

1. Modélisation générative

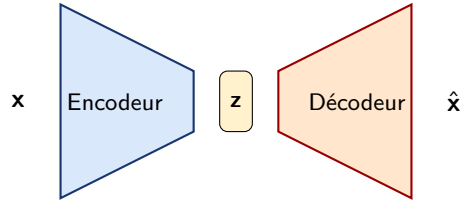
2. Autoencodeurs

3. Autoencodeurs variationnels

4. Réseaux antagonistes génératifs

5. Ouverture : diffusion

Autoencodeur



Reconstruction

$\mathbf{z} = e_\phi(\mathbf{x}), \quad \hat{\mathbf{x}} = d_\theta(\mathbf{z}), \quad L = \|\mathbf{x} - \hat{\mathbf{x}}\|^2$ (ou BCE)

- **sous-complet** (linéaire = ACP)
- **débruiteur** : $\tilde{\mathbf{x}} \to \mathbf{x}$
- **parcimonieux**, **convolutif**

Anomalies

Entraîné sur le normal ; erreur de reconstruction $>$ seuil $\Rightarrow$ anomalie.

Pourquoi pas pour générer ?

Espace latent non organisé

Des codes tirés au hasard ou entre deux codes appris se décodent en images incohérentes.

Idée du VAE

Forcer l'espace latent à suivre une loi simple $\mathcal{N}(\mathbf{0}, I)$, continue et « remplie ».

Plan

1. Modélisation générative

2. Autoencodeurs

3. Autoencodeurs variationnels

4. Réseaux antagonistes génératifs

5. Ouverture : diffusion

VAE (Kingma et Welling, 2014)

Encodeur probabiliste

$q_\phi(\mathbf{z} \mid \mathbf{x}) = \mathcal{N}(\boldsymbol{\mu}(\mathbf{x}), \operatorname{diag} \boldsymbol{\sigma}^2(\mathbf{x}))$, a priori $p(\mathbf{z}) = \mathcal{N}(\mathbf{0}, I)$

ELBO

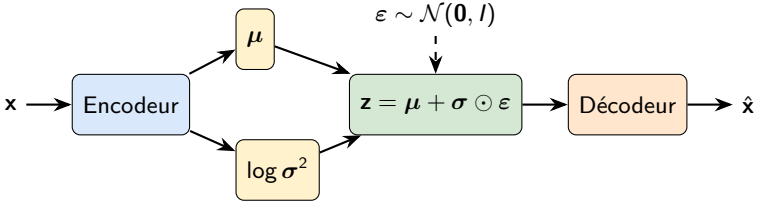
$\log p(\mathbf{x}) \geq \mathbb{E}_q[\log p_\theta(\mathbf{x} \mid \mathbf{z})] - D_{KL}(q \,\|\, p)$

$L = \text{reconstruction} + D_{KL}$, $D_{KL} = -\frac{1}{2} \sum_j (1 + \log \sigma_j^2 - \mu_j^2 - \sigma_j^2)$

$\mu = 1$, $\sigma^2 = 0{,}5$

$D_{KL} = -\frac{1}{2}(1 - 0{,}693 - 1 - 0{,}5) = 0{,}597$; nul si et seulement si $\mu = 0$, $\sigma = 1$.

Astuce de reparamétrisation



- L'aléa est isolé dans ε : $\mathbf{z}$ devient dérivable en $\boldsymbol{\mu}, \boldsymbol{\sigma}$.
- Génération : $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, I) \rightarrow$ décodeur ; interpolations progressives.
- Images souvent un peu **floues**.

Plan

1. Modélisation générative

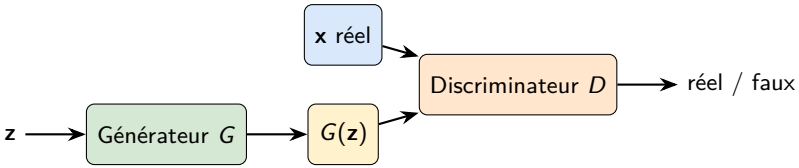
2. Autoencodeurs

3. Autoencodeurs variationnels

4. Réseaux antagonistes génératifs

5. Ouverture : diffusion

GAN (Goodfellow et al., 2014)



Jeu minimax

$\min_G \max_D \ \mathbb{E}_{\mathbf{x}}[\log D(\mathbf{x})] + \mathbb{E}_{\mathbf{z}}[\log(1 - D(G(\mathbf{z})))]$; optimum : $D = \frac{1}{2}$

Entraînement alterné

(1) D : vrais $\to 1$, faux $\to 0$; (2) G : minimiser $-\log D(G(\mathbf{z}))$ (non saturant), D figé.

Difficultés, remèdes, variantes

Difficultés

- effondrement de modes ;
- instabilité, oscillations ;
- évaluation : FID.

Lecture des pertes

$D(\mathbf{x}) = 0{,}9$, $D(G(\mathbf{z})) = 0{,}2$:
perte $D = 0{,}33$, perte $G = 1{,}61$.

Remèdes

DCGAN (conv à pas, BN, LeakyReLU), lissage des étiquettes, Adam 2×10^{-4}, $\beta_1 = 0{,}5$, WGAN-GP, normalisation spectrale.

Variantes

GAN conditionnel, Pix2Pix, CycleGAN, StyleGAN.

Plan

1. Modélisation générative

2. Autoencodeurs

3. Autoencodeurs variationnels

4. Réseaux antagonistes génératifs

5. Ouverture : diffusion

Modèles de diffusion et comparaison

Diffusion

Bruiter progressivement en T étapes, puis apprendre à débruiter (U-Net ou Transformer prédit le bruit). Stable, diversifié ; génération plus lente.

	Qualité	**Diversité**	**Entraînement**
AE	reconstruction	–	simple
VAE	floue	bonne, latent structuré	stable
GAN	très nette	risque d'effondrement	instable
Diffusion	très haute	très bonne	stable, lente

Keras : VAE et pas de GAN

```
class Echantillonnage(layers.Layer):
    def call(self, inputs):
        mu, log_var = inputs
        return mu + tf.exp(0.5 * log_var) * tf.random.normal(tf.shape(mu))

kl = -0.5 * tf.reduce_sum(1 + log_var - mu**2 - tf.exp(log_var), axis=1)

@tf.function
def pas_gan(reels):
    z = tf.random.normal((tf.shape(reels)[0], 100))
    with tf.GradientTape() as tg, tf.GradientTape() as td:
        faux = G(z, training=True)
        d_r, d_f = D(reels, training=True), D(faux, training=True)
        perte_d = bce(tf.ones_like(d_r) * 0.9, d_r) + bce(tf.zeros_like(d_f), d_f)
        perte_g = bce(tf.ones_like(d_f), d_f)
    opt_d.apply_gradients(zip(td.gradient(perte_d, D.trainable_variables), D.trainable_variables))
    opt_g.apply_gradients(zip(tg.gradient(perte_g, G.trainable_variables), G.trainable_variables))
```

À retenir

- AE : compresser par reconstruction ; VAE : latent probabiliste, ELBO ; GAN : compétition G/D ; diffusion : débruitage itératif.

Questions de révision

1. D_{KL} pour $\mu = 2$, $\sigma^2 = 1$? (2)
2. $\mu = 0{,}5$, $\log \sigma^2 = -1{,}386$, $\varepsilon = 1{,}2$: z ? (1,1)
3. Perte de D quand G est parfait ? ($2 \ln 2$)
4. Quel modèle pour détecter des pièces défectueuses ? pour des visages HD ?

Fin du module – merci !