

Lecture2: Evaluation des modèles d'apprentissage

Aissam BERRAHOU

Aissam.berrahou@ensias.um5.ac.ma

Laboratoire Smart Systems Lab

Plan

- Types de validation
- Métriques d'évaluation

Types de validation

1. Hold-out Method
2. Validation Croisée (Cross-Validation)
3. Validation avec Ensemble Learning (Bootstrap Validation)
4. ...

Types de validation

1. Hold-out Method:

Principe: On divise le dataset en deux parties :


- Train Set (70-80%) : utilisé pour entraîner le modèle.
- Test Set (30-20%) : utilisé pour évaluer la performance finale.

Avantages :

- ✓ Facile à mettre en œuvre.
- ✓ Rapide et efficace pour les grands datasets.

Limites :

- ✗ La performance dépend du choix du découpage.
- ✗ Moins fiable si le dataset est petit.







Types de validation

1. Hold-out Method:

Exemple: Dataset composée de 100 observations, partitionnée aléatoirement en deux sous-ensembles:

- Ensemble d'entraînement: 80% des observations
- Ensemble de test: 30% des observations



2. Validation Croisée (Cross-Validation)

Principe: On divise le dataset en k sous-ensembles (folds) et on entraîne le modèle k fois, en utilisant à chaque fois $k-1$ folds pour l'entraînement et 1 fold pour la validation.

Types de Validation Croisée :

- a. K-Fold Cross Validation*
- b. Stratified K-Fold Cross Validation*
- c. leave-p-out Cross Validation*



Types de validation

2. Validation Croisée (Cross-Validation)

a. K-Fold Cross Validation

Principe:

- Divise les données en k partitions égales (Fold).
- Chaque partition est utilisée k fois comme validation.




Types de validation

2. Validation Croisée (Cross-Validation)

a. K-Fold Cross Validation

Exemple : Dataset composée de 100 observations, $k=5$ (Fold=20 observations)




Types de validation

2. Validation Croisée (Cross-Validation)

b. Stratified Cross Validation

Principe:

- Divise les données en k partitions égales (Fold).
- Chaque partition est utilisée k fois comme validation.
- Assure que chaque fold respecte la **distribution des classes**.




Types de validation

2. Validation Croisée (Cross-Validation)

b. Stratified Cross Validation

Exemple : Dataset composée de 100 observations, $k=5$ (Fold=20 observations)





Types de validation

2. Validation Croisée (Cross-Validation)

b. leave-p-out Cross Validation

Principe:

- On sélectionne p exemples comme ensemble de test.
- On entraîne le modèle sur le reste des données.
- On répète cette opération pour toutes les combinaisons possibles de p observations.
- On mesure ensuite la moyenne des performances sur ces tests.



Métriques d'évaluation

1. Matrice de confusion
2. Accuracy, Precision, sensibilité, F1 score
3. ROC et AUC

1. Matrice de confusion

La **matrice de confusion** est un tableau qui permet d'évaluer la performance d'un modèle de classification. Elle compare les **prédictions du modèle** avec les **valeurs réelles**.

		Prédiction	
		Classe=Yes	Classe=No
Valeurs réelles	Classe=Yes	a	b
	Classe=No	c	d

Interprétation:



- Au niveau du diagonal:
 - a*: *TP(True Positive)* est le nombre d'exemples bien classés comme positifs.
 - d*: *TN(True Negative)* est le nombre d'exemples bien classés comme négatifs.
- Autre valeurs
 - b*: *FN(False Negative)* est le nombre d'exemples positifs mal classés comme négatifs.
 - c*: *FP(False Positive)* est le nombre d'exemples négatifs mal classés comme positifs.

Métriques d'évaluation

1. Matrice de confusion

Exemple

Distribution des Classes - Ensemble de test



Métriques d'évaluation

2. Accuracy(Précision globale)

L'Accuracy (ou **taux de précision globale**) est une **mesure d'évaluation** d'un modèle de classification qui indique le **pourcentage de prédictions correctes** par rapport au nombre total d'échantillons.


		Prédiction	
		Classe=Yes	Classe=No
Valeurs réelles	Classe=Yes	a (TP)	b (FN)
	Classe=No	c (FP)	d (TN)

$$\begin{aligned} accuracy &= \frac{\text{Nombre de prédictions correctes}}{\text{Nombre total d'échantillons}} \\ &= \frac{TP + TN}{TP + TN + FP + FN} \end{aligned}$$

Métriques d'évaluation

2. Accuracy (Précision globale)

Exemple



$$\begin{aligned} accuracy &= \frac{\text{Nombre de prédictions correctes}}{\text{Nombre total d'échantillons}} \\ &= \frac{20 + 4}{20 + 4 + 3 + 1} \\ &= 0.86 \end{aligned}$$

2. Accuracy (Précision globale)

Interprétation

- **Accuracy élevée (proche de 1 ou 100%)** → Le modèle fait très peu d'erreurs globalement.
- **Accuracy faible** → Le modèle fait trop d'erreurs, donc il n'est pas performant.

Limite de l'Accuracy :

Si les classes sont **déséquilibrées**, l'Accuracy peut être trompeuse.

Exemple :

Un modèle qui prédit toujours la classe majoritaire aura une **accuracy élevée** mais sera **inutilisable** pour détecter la classe minoritaire.

3. Précision

La **précision** mesure la **qualité des prédictions positives** du modèle.

$$\textit{Precision} = \frac{TP}{TP + FP}$$

		Prédiction	
		Classe=Yes	Classe=No
Valeurs réelles	Classe=Yes	a (TP)	b (FN)
	Classe=No	c (FP)	d (TN)

Interprétation

- Une **précision élevée** signifie que les **prédictions positives sont fiables** (faible taux de FP).
- Une **précision faible** signifie que **beaucoup de prédictions positives sont erronées** (fort taux de FP).

3. Précision

Dans le cas de la classification multiclass:

La **précision** d'une classe i ($Precision_i$) mesure la proportion d'éléments correctement classés dans cette classe par rapport à tous les éléments prédis comme appartenant à cette classe.

$$Precision_i = \frac{TP_i}{TP_i + FP_i}$$

FP_i : Faux positifs (éléments d'autres classes incorrectement classés comme i)

Exemple

- Pour la classe A : $Precision_A = \frac{TP_A}{TP_A + FP_A} = \frac{50}{50+3+4} \approx 87.7\%$
- Pour la classe B : $Precision_B = \frac{TP_B}{TP_B + FP_B} = \frac{40}{40+5+6} \approx 78.4\%$
- Pour la classe C : $Precision_C = \frac{TP_C}{TP_C + FP_C} = \frac{45}{45+2+10} \approx 78.9\%$

		Prédiction		
		Classe=A	Classe=B	Classe=C
Valeurs réelles	Classe=A	50	5	2
	Classe=B	3	40	10
	Classe=C	4	6	45

4. Sensibilité

La **sensibilité** (aussi appelée **recall** ou **taux de vrais positifs**) mesure la **capacité du modèle à détecter les cas positifs**.

$$\text{Recall} = \frac{TP}{TP + FP}$$

		Prédiction	
		Classe=Yes	Classe=No
Valeurs réelles	Classe=Yes	a (TP)	b (FN)
	Classe=No	c (FP)	d (TN)

Interprétation

- Un **recall élevé** signifie que le modèle détecte **presque tous les cas positifs** (faible taux de FN).
- Un **recall faible** signifie que **beaucoup de positifs sont ignorés** (fort taux de FN).

4. Sensibilité

Dans le cas de la classification multiclass:

Le Recall d'une classe i ($Recall_i$) mesure la proportion d'éléments de cette classe bien prédits par rapport à tous les éléments réels de cette classe.

$$Recall_i = \frac{TP_i}{TP_i + FN_i}$$

FN_i : Faux négatifs (éléments de la classe i classés ailleurs)

Exemple

- Pour la classe A : $Recall_A = \frac{TP_A}{TP_A + FN_A} = \frac{50}{50 + 5 + 2} \approx 87.7\%$
- Pour la classe B : $Recall_B = \frac{TP_B}{TP_B + FN_B} = \frac{40}{40 + 3 + 10} \approx 75.5\%$
- Pour la classe C : $Recall_C = \frac{TP_C}{TP_C + FN_C} = \frac{45}{45 + 4 + 6} \approx 81.8\%$


	Prédiction		
	Classe=A	Classe=B	Classe=C
	50	5	2
	3	40	10
Valeurs réelles	4	6	45

Métriques d'évaluation

Précision Vs Sensibilité

Limites du Recall et de la Précision

- Dilemme Recall vs Précision :
 - Maximiser la sensibilité (Recall) → Augmente les faux positifs (FP).
 - Maximiser la précision (Precision) → Augmente les faux négatifs (FN).
- Besoin d'un équilibre → On utilise le **F1-Score** pour trouver un compromis entre les deux



5. F1-score

Le **F1-Score** est une métrique qui combine **Précision (Precision)** et **Rappel (Recall)** en un seul indicateur. Il est particulièrement utile lorsque les classes sont **déséquilibrées** ou lorsque l'on veut un bon compromis entre **faux positifs (FP)** et **faux négatifs (FN)**.

$$f1 - score = 1x \frac{Precision \times Recall}{Precision + Recall}$$

- F1-Score = **Moyenne harmonique** entre la précision et le rappel
- Il équilibre les deux métriques : **un F1-score élevé** signifie que **Précision et Recall sont élevés** en même temps.

5. F1-score

Dans le cas de la classification multiclass:

$$F1_i = 2 \times \frac{Precision_i \times Recall_i}{Precision_i + Recall_i}$$

FN_i : Faux négatifs (éléments de la classe i classés ailleurs)

Exemple

- Pour la classe A : $F1_A = 2 \times \frac{Precision_A \times Recall_A}{Precision_A + Recall_A} = 2 \times \frac{87.7 \times 87.7}{87.7 + 87.7} \approx 87.7\%$
- Pour la classe B : $F1_B = 2 \times \frac{Precision_B \times Recall_B}{Precision_B + Recall_B} = 2 \times \frac{78.4 \times 75.5}{78.4 + 75.5} \approx 76.9\%$
- Pour la classe C : $F1_C = 2 \times \frac{Precision_C \times Recall_C}{Precision_C + Recall_C} = 2 \times \frac{78.9 \times 81.8}{78.9 + 81.8} \approx 80.3\%$


6. Courbe ROC et AUC

La **courbe ROC**(Receiver Operating Characteristic :caractéristique de **fonctionnement du récepteur**) est un graphique qui permet d'évaluer la performance d'un modèle de classification binaire. Elle représente la capacité du modèle à distinguer entre les classes positives et négatives en fonction d'un seuil de décision variable.

Elle est obtenue en traçant le **Taux de Vrais Positifs (TPR ou Recall)** contre le **Taux de Faux Positifs (FPR)** pour différents seuils de probabilité.
où

$$\text{Recall} = \text{TPR} = \frac{TP}{TP+FN}$$


$$\text{FPR} = 1 - \text{Specificité} = 1 - \frac{TN}{TN+FP} = \frac{FP}{TN+FP}$$



		Prédiction	
		Classe=Yes	Classe=No
Valeurs réelles	Classe=Yes	a (TP)	b (FN)
	Classe=No	c (FP)	d (TN)

Il représente la proportion des éléments de la classe négative qui ont été mal classés comme positifs.

6. Courbe ROC et AUC




- 10 personnes souffrent de la maladie, représentée par des points verts.
- 14 n'ont pas la maladie, représentée par les points rouges

	Positive	Negative
Positive	True Positive (TP)  9	False Positive (FP)  11
Negative	False Negative (FN)  1	True Negative (TN)  3


Métriques d'évaluation

6. Courbe ROC et AUC


- On choisit n'importe quel nombre de seuils et on calcul le TPR-FPR pour chacun d'eux (Ex: seuil=1,0, 0,75, 0,5, 0,35, 0,15 et 0).
- 0,75, s'il s'agissait d'une valeur de confiance d'un modèle, cela signifie que la prédiction devrait être supérieure au seuil de 75 % pour être prédite comme positive.



6. Courbe ROC et AUC




6. Courbe ROC et AUC



6. Courbe ROC et AUC

L'**AUC** (**A**rea **U**nder the **C**urve **R**OC) est une mesure de performance qui représente l'aire sous la courbe ROC. Elle quantifie la capacité du modèle à distinguer entre les classes positives et négatives.

- **AUC = 1** → Modèle parfait (sépare complètement les classes).
- **AUC = 0.5** → Modèle aléatoire (ne fait pas mieux que le hasard).
- **AUC < 0.5** → Modèle inversé (les prédictions sont opposées à la réalité).



6. Courbe ROC et AUC

L'AUC peut être interprétée comme la probabilité qu'un modèle classe un exemple positif avec un score plus élevé qu'un exemple négatif.

Exemple :

Si on tire au hasard un élément de chaque classe :

- **Un AUC de 0.9** signifie que dans 90% des cas, le modèle classe correctement l'exemple positif au-dessus du négatif.
- **Un AUC de 0.6** signifie qu'il réussit dans 60% des cas, ce qui est faible.

