Machine learning

Lecture2: Evaluation des modèles d'apprentissage

Prof: Aissam BERRAHOU
Aissam.berrahou@ensias.um5.ac.ma
Laboratoire Smart Systems Lab

ENSIAS

جامعة محمد الخامس بالرباط
Université Mohammed V de Rabat

Plan

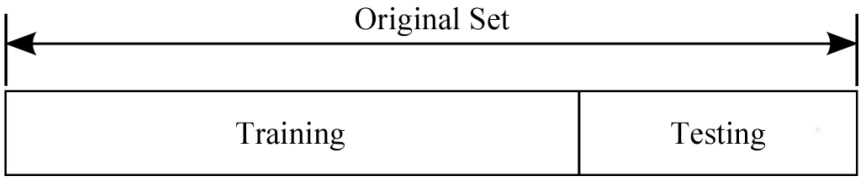
- Types de validation
- Métriques d'évaluation

Types de validation

1. Hold-out Method
2. Validation Croisée (Cross-Validation)
3. Validation avec Ensemble Learning (Bootstrap Validation)
4. ...

Types de validation

1. Hold-out Method:



Principe: On divise le dataset en deux parties :

- Train Set (70-80%) : utilisé pour entraîner le modèle.
- Test Set (30-20%) : utilisé pour évaluer la performance finale.

Avantages :

✓ Facile à mettre en œuvre.
✓ Rapide et efficace pour les grands datasets.

Limites :

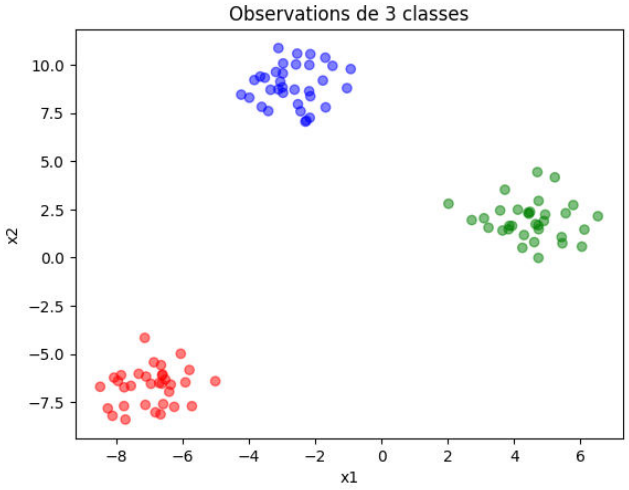
× La performance dépend du choix du découpage.
× Moins fiable si le dataset est petit.

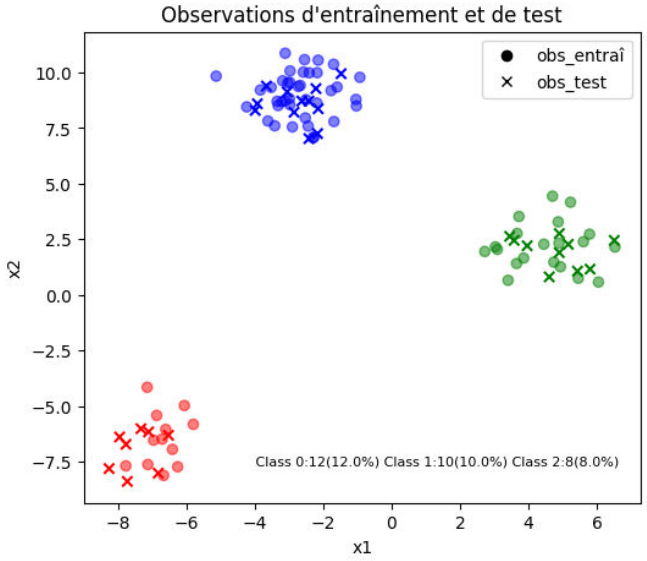
Types de validation

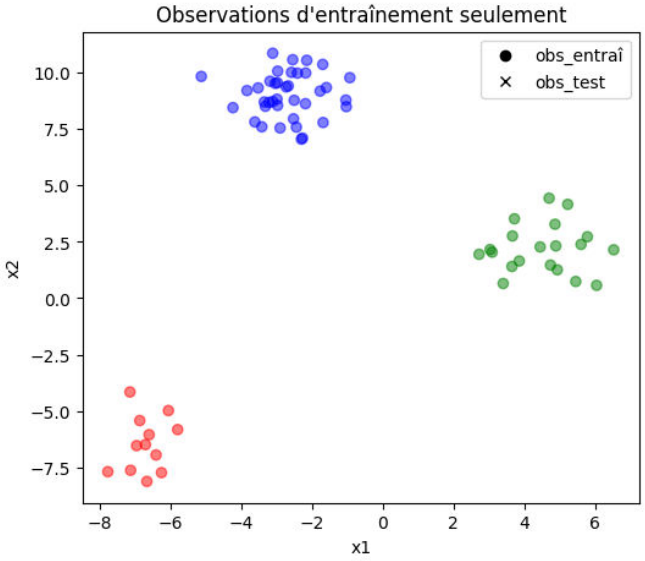
1. Hold-out Method:

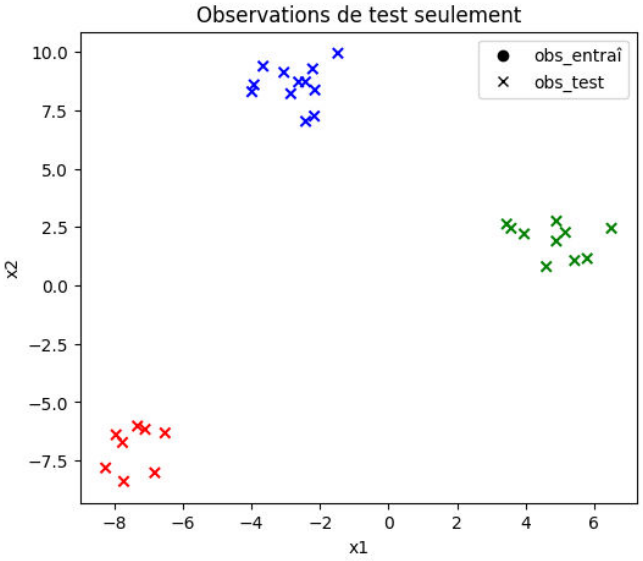
Exemple: *Dataset composée de 100 observations, partitionnée aléatoirement en deux sous-ensembles:*

- Ensemble d'entraînement: 80% des observations
- Ensemble de test: 30% des observations









Types de validation

2. Validation Croisée (Cross-Validation)

Principe: On divise le dataset en k **sous-ensembles (folds)** et on entraîne le modèle k fois, en utilisant à chaque fois $k-1$ folds pour l'entraînement et 1 fold pour la validation.

Types de Validation Croisée :

a. ***K-Fold Cross Validation***

b. Stratified K-Fold Cross Validation

c. leave-p-out Cross Validation

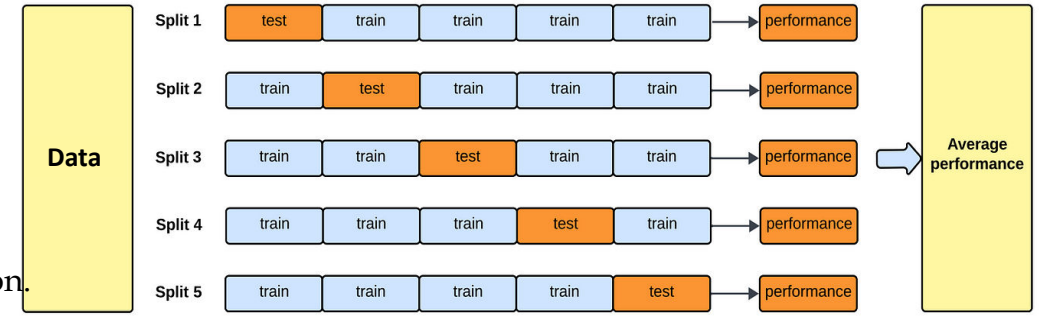
Types de validation

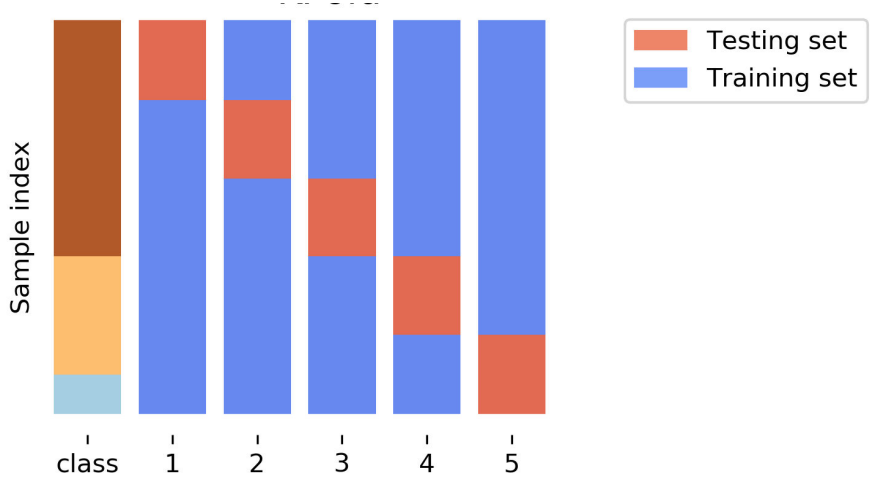
2. Validation Croisée (Cross-Validation)

a. K-Fold Cross Validation

Principe:

- Divise les données en *k* partitions égales(Fold).
- Chaque partition est utilisée *k* fois comme validation.



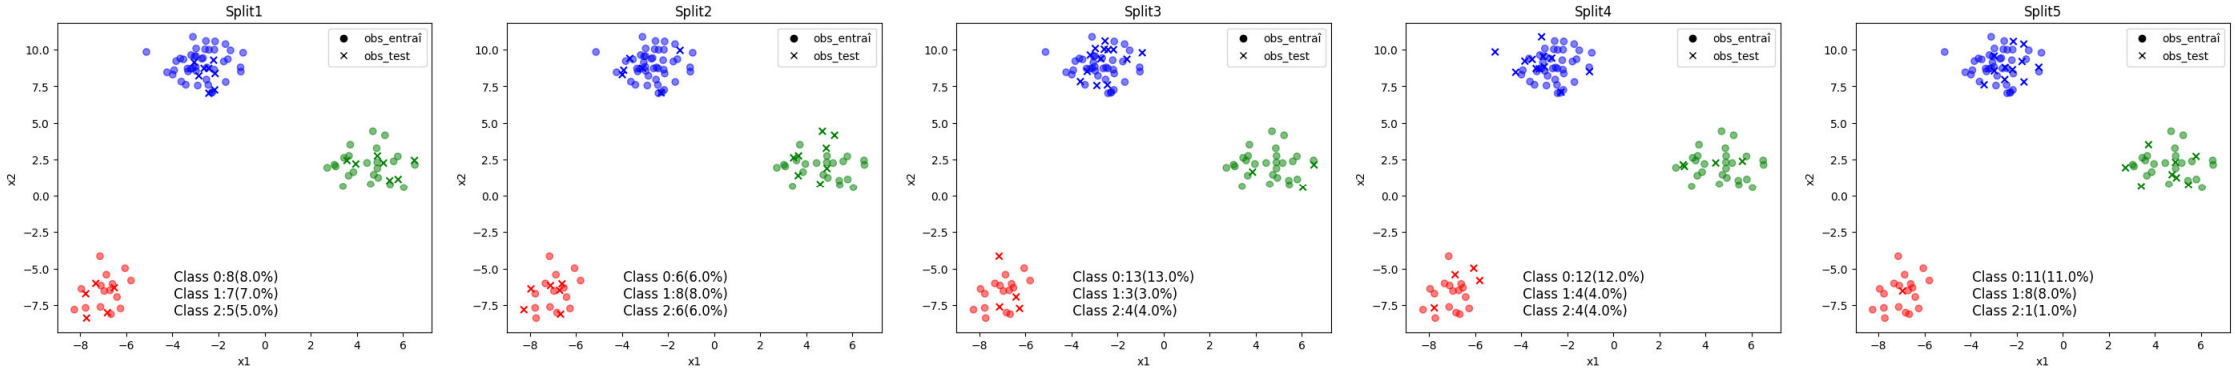


Types de validation

2. Validation Croisée (Cross-Validation)

a. K-Fold Cross Validation

Exemple : *Dataset composée de 100 observations, k=5 (Fold=20 observations)*



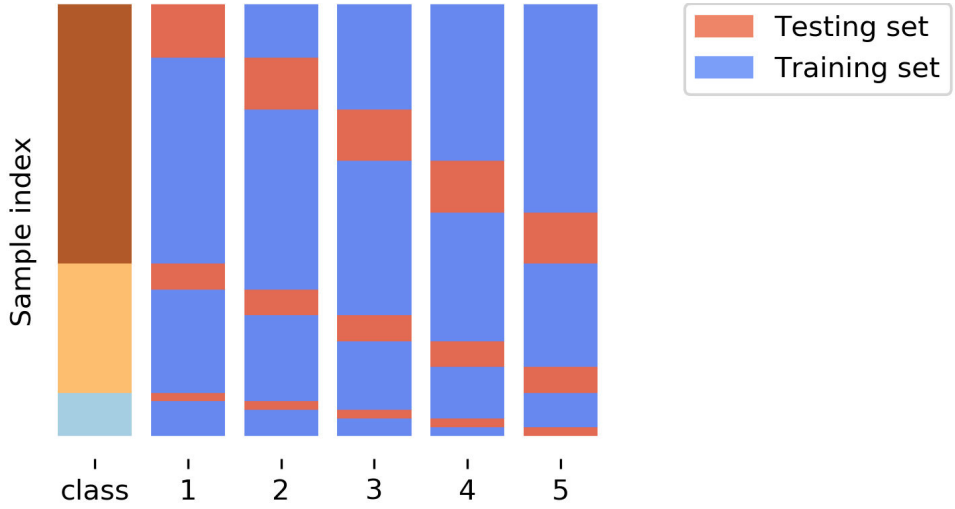
Types de validation

2. Validation Croisée (Cross-Validation)

b. Stratified Cross Validation

Principe:

- Divise les données en *k* partitions égales(Fold).
- Chaque partition est utilisée *k* fois comme validation.
- Assure que chaque fold respecte **la distribution des classes**.



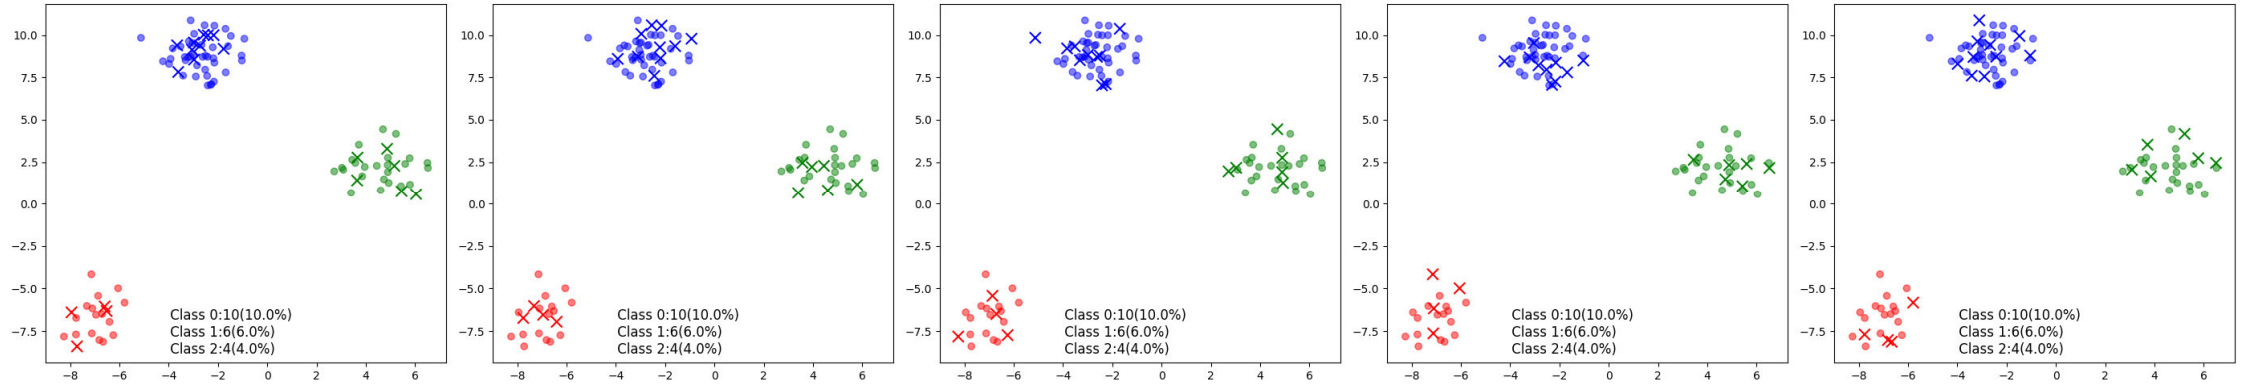
Types de validation

2. Validation Croisée (Cross-Validation)

b. Stratified Cross Validation

.

Exemple : *Dataset composée de 100 observations, k=5 (Fold=20 observations)*



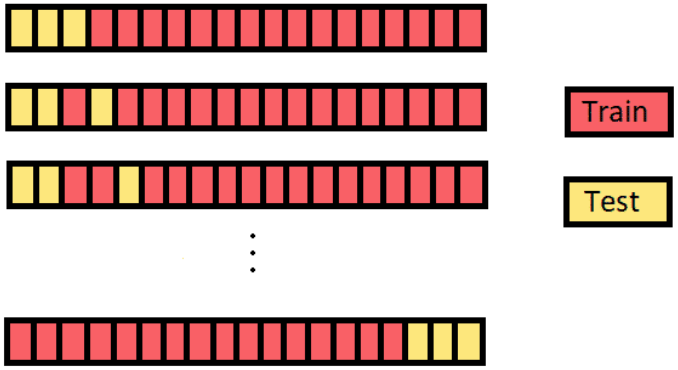
Types de validation

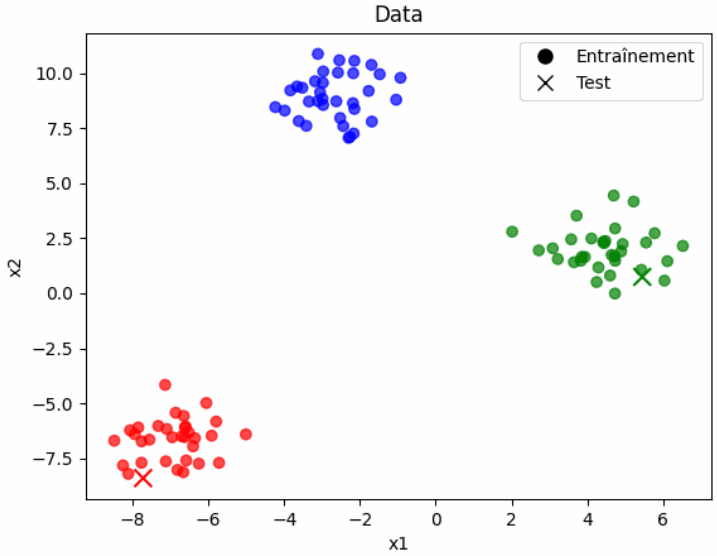
2. Validation Croisée (Cross-Validation)

b. leave-p-out Cross Validation

Principe:

- On sélectionne p exemples comme ensemble de test.
- On entraîne le modèle sur le reste des données.
- On répète cette opération pour toutes les combinaisons possibles de p observations.
- On mesure ensuite la moyenne des performances sur ces tests.





Métriques d'évaluation

1. Matrice de confusion
2. Accuracy, Precision, sensibilité, F1 score
3. ROC et AUC

Métriques d'évaluation

1. Matrice de confusion

La **matrice de confusion** est un tableau qui permet d'évaluer la performance d'un modèle de classification. Elle compare les **prédictions du modèle** avec les **valeurs réelles**.

		Prédiction	
		Classe=Yes	Classe=No
Valeurs réelles	Classe=Yes	a	b
	Classe=No	c	d

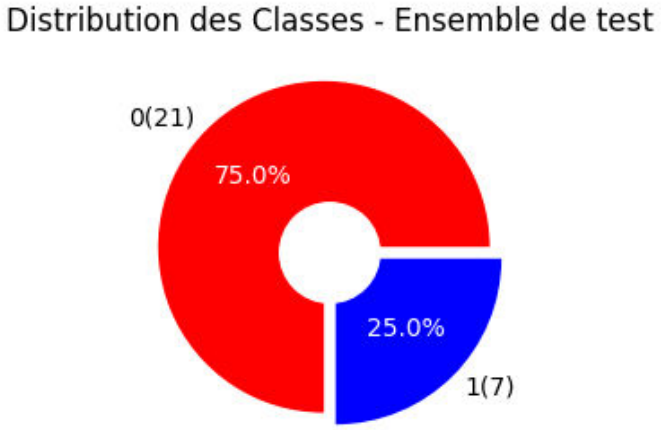
Interprétation:

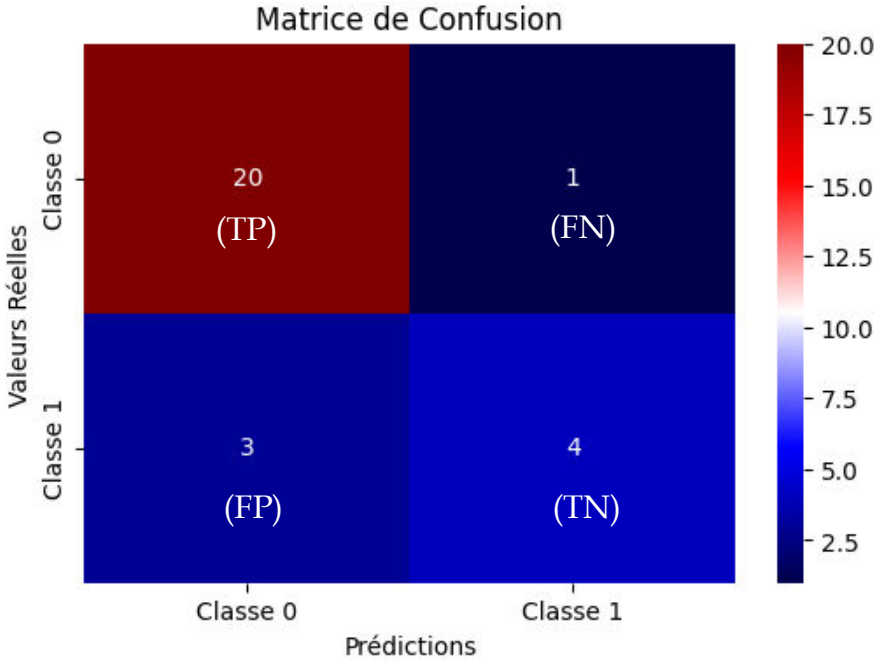
- Au niveau du diagonal:
  - *a: TP(True Positive)* est le nombre d'exemples bien classés comme positifs.
  - *d: TN(True Negative)* est le nombre d'exemples bien classés comme négatifs.
- Autre valeurs
  - *b: FN(False Negative)* est le nombre d'exemples positifs mal classés comme négatifs.
  - *c: FP(False Positive)* est le nombre d'exemples négatifs mal classés comme positifs.

Métriques d'évaluation

1. Matrice de confusion

Exemple





Métriques d'évaluation

2. Accuracy(Précision globale)

L'**Accuracy** (ou **taux de précision globale**) est une **mesure d'évaluation** d'un modèle de classification qui indique le **pourcentage de prédictions correctes** par rapport au nombre total d'échantillons.

Prédiction

Valeurs réelles	Classe=Yes	Classe=No
Classe=Yes	a (TP)	b (FN)
Classe=No	c (FP)	d (TN)

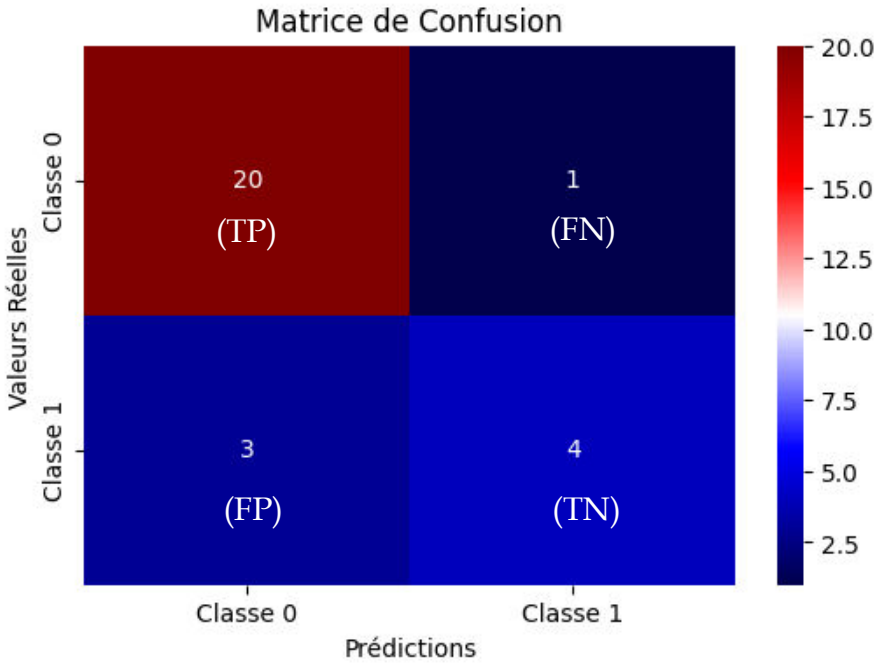
$$accuracy = \frac{\text{Nombre de prédictions correctes}}{\text{Nombre total d'échantillons}}$$

$$= \frac{TP + TN}{TP + TN + FP + FN}$$

Métriques d'évaluation

2. Accuracy(Précision globale)

Exemple



$$accuracy = \frac{\text{Nombre de prédictions correctes}}{\text{Nombre total d'échantillons}}$$

$$= \frac{20 + 4}{20 + 4 + 3 + 1}$$

$$= 0.86$$

Métriques d'évaluation

2. Accuracy(Précision globale)

Interprétation

- **Accuracy élevée (proche de 1 ou 100%)** → Le modèle fait très peu d'erreurs globalement.
- **Accuracy faible** → Le modèle fait trop d'erreurs, donc il n'est pas performant.

Limite de l'Accuracy :

Si les classes sont **déséquilibrées**, l'Accuracy peut être trompeuse.

Exemple :

Un modèle qui prédit toujours la classe majoritaire aura une **accuracy élevée** mais sera **inutilisable** pour détecter la classe minoritaire.

Métriques d'évaluation

3. Précision

La **précision** mesure la **qualité des prédictions positives** du modèle.

$$Precision = \frac{TP}{TP + FP}$$

		Prédiction	
		Classe=Yes	Classe=No
Valeurs réelles	Classe=Yes	a (TP)	b (FN)
	Classe=No	c (FP)	d (TN)

Interprétation

- **Une précision élevée** signifie que les **prédictions positives sont fiables** (faible taux de FP).
- **Une précision faible** signifie que **beaucoup de prédictions positives sont erronées** (fort taux de FP).

Métriques d'évaluation

3. Précision

Dans le cas de la classification multiclasses:

La **précision** d'une classe i ($Precision_i$) mesure la proportion d'éléments correctement classés dans cette classe par rapport à tous les éléments prédis comme appartenant à cette classe.

$$Precision_i = \frac{TP_i}{TP_i + FPi}$$

FP_i : Faux positifs (éléments d'autres classes incorrectement classés comme i)

Exemple

- Pour la classe A : $Precision_A = \frac{TP_A}{TP_A+FP_A} = \frac{50}{50+3+4} \approx 87.7\%$
- Pour la classe B : $Precision_B = \frac{TP_B}{TP_B+FP_B} = \frac{40}{40+5+6} \approx 78.4\%$
- Pour la classe C : $Precision_C = \frac{TP_C}{TP_C+FP_C} = \frac{45}{45+2+10} \approx 78.9\%$

		Prédiction		
		Classe=A	Classe=B	**Classe=C**
Valeurs réelles	Classe=A	50	5	2
	Classe=B	3	40	10
	Classe=C	4	6	45

Métriques d'évaluation

4. Sensibilité

La **sensibilité** (aussi appelée **recall** ou **taux de vrais positifs**) mesure la **capacité du modèle à détecter les cas positifs**.

$$Recall = \frac{TP}{TP + FN}$$

		Prédiction	
		Classe=Yes	Classe=No
Valeurs réelles	Classe=Yes	a (TP)	b (FN)
	Classe=No	c (FP)	d (TN)

Interprétation

- Un **recall élevé** signifie que le modèle détecte **presque tous les cas positifs** (faible taux de FN).
- Un **recall faible** signifie que **beaucoup de positifs sont ignorés** (fort taux de FN).

Métriques d'évaluation

4. Sensibilité

Dans le cas de la classification multiclasses:

Le Recall d'une classe i ($Recall_i$) mesure la proportion d'éléments de cette classe bien prédits par rapport à tous les éléments réels de cette classe.

$$Recall_i = \frac{TP_i}{TP_i + FNi}$$

FN_i : Faux négatifs (éléments de la classe i classés ailleurs)

Exemple

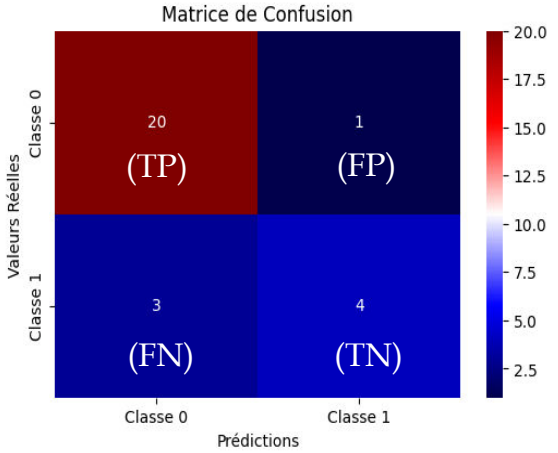
- Pour la classe A : $Recall_A = \frac{TP_A}{TP_A+FN_A} = \frac{50}{50+5+2} \approx 87.7\%$
- Pour la classe B : $Recall_B = \frac{TP_B}{TP_B+FN_B} = \frac{40}{40+3+10} \approx 75.5\%$
- Pour la classe C : $Recall_C = \frac{TP_C}{TP_C+FN_C} = \frac{45}{45+4+6} \approx 81.8\%$

		Prédiction		
		Classe=A	Classe=B	**Classe=C**
Valeurs réelles	Classe=A	50	5	2
	Classe=B	3	40	10
	Classe=C	4	6	45

Métriques d'évaluation

Précision Vs Sensibilité

Limites du Recall et de la Précision



- **Dilemme Recall vs Précision** :
  - **Maximiser la sensibilité (Recall)** → Augmente les faux positifs (FP).
  - **Maximiser la précision (Precision)** → Augmente les faux négatifs (FN).
- **Besoin d'un équilibre** → On utilise le **F1-Score** pour trouver un compromis entre les deux

Métriques d'évaluation

5. F1-score

Le **F1-Score** est une métrique qui combine **Précision (Precision)** et **Rappel (Recall)** en un seul indicateur. Il est particulièrement utile lorsque les classes sont **déséquilibrées** ou lorsque l'on veut un bon compromis entre **faux positifs (FP)** et **faux négatifs (FN)**.

$$f1 - score = 1x \frac{Precision\ x\ Recall}{Precision + Recall}$$

- F1-Score = **Moyenne harmonique entre la précision et le rappel**
- Il équilibre les deux métriques : **un F1-score élevé** signifie que **Précision et Recall sont élevés** en même temps.

Métriques d'évaluation

5. F1-score

Dans le cas de la classification multiclasses:

$$F1_i = 2 \times \frac{Precision_i \times Recall_i}{Precision_i + Recall_i}$$

FN_i : Faux négatifs (éléments de la classe i classés ailleurs)

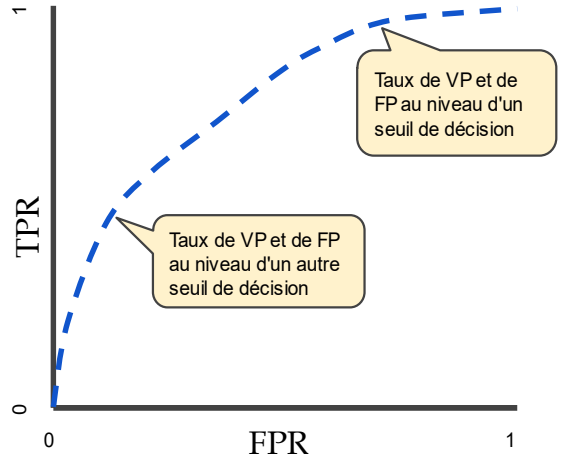
Exemple

- Pour la classe A : $F1_A = 2 \times \frac{Precision_A \times Recall_A}{Precision_A + Recall_A} = 2 \times \frac{87.7 \times 87.7}{87.7 + 87.7} \approx 87.7\%$
- Pour la classe B : $F1_B = 2 \times \frac{Precision_A \times Recall_A}{Precision_A + Recall_A} = 2 \times \frac{78.4 \times 75.5}{78.4 + 75.5} \approx 76.9\%$
- Pour la classe C : $F1_C = 2 \times \frac{Precision_A \times Recall_A}{Precision_A + Recall_A} = 2 \times \frac{78.9 \times 81.8}{78.9 + 81.8} \approx 80.3\%$

Métriques d'évaluation

6. Courbe ROC et AUC

La **courbe ROC(Receiver Operating Characteristic :caractéristique de fonctionnement du récepteur)** est un graphique qui permet d'évaluer la performance d'un modèle de classification binaire. Elle représente la capacité du modèle à distinguer entre les classes positives et négatives en fonction d'un seuil de décision variable.



Elle est obtenue en traçant le **Taux de Vrais Positifs (TPR ou Recall)** contre le **Taux de Faux Positifs (FPR)** pour différents seuils de probabilité.

où

$$\text{Recall} = \boldsymbol{TPR} = \frac{\boldsymbol{TP}}{\boldsymbol{TP+FN}}$$

$$\boldsymbol{FPR} = \mathbf{1} - \boldsymbol{Specificité} = \mathbf{1} - \frac{\boldsymbol{TN}}{\boldsymbol{TN+FP}} = \frac{\boldsymbol{FP}}{\boldsymbol{TN+FP}}$$

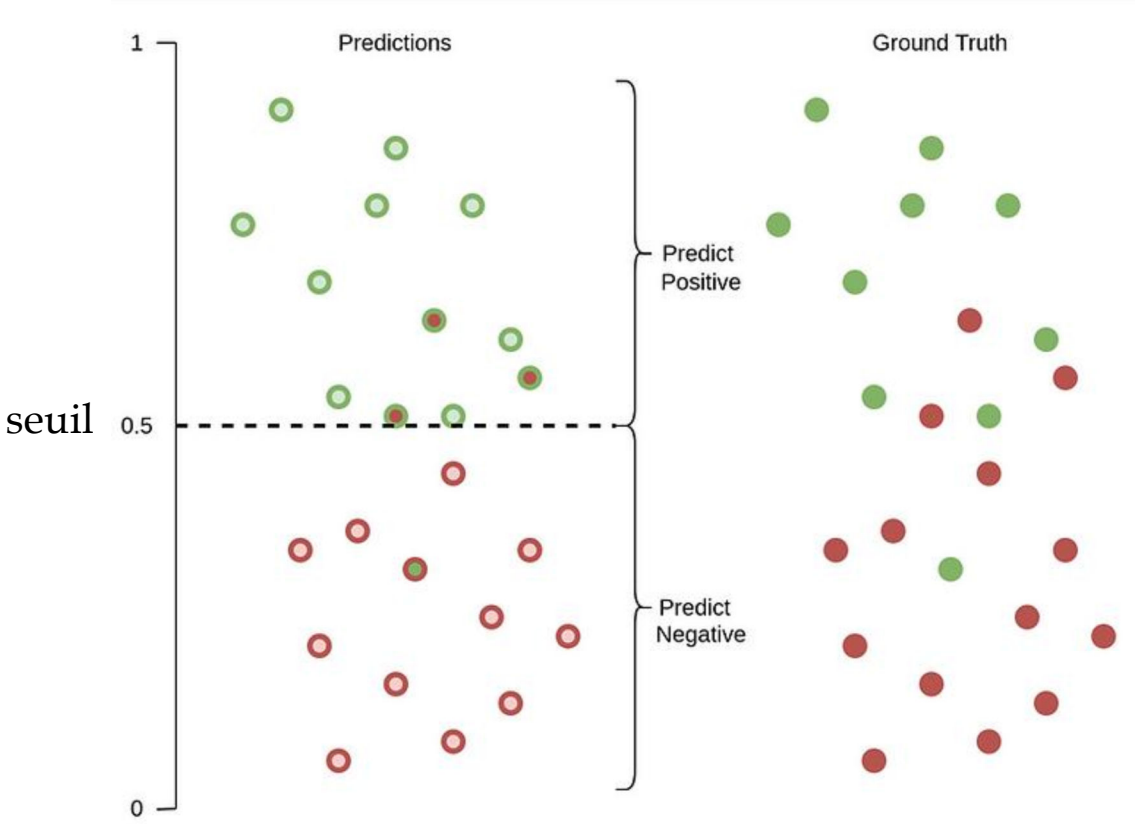
Prédiction

Valeurs réelles	Classe=Yes	Classe=No
Classe=Yes	a (TP)	b (FN)
Classe=No	c (FP)	d (TN)

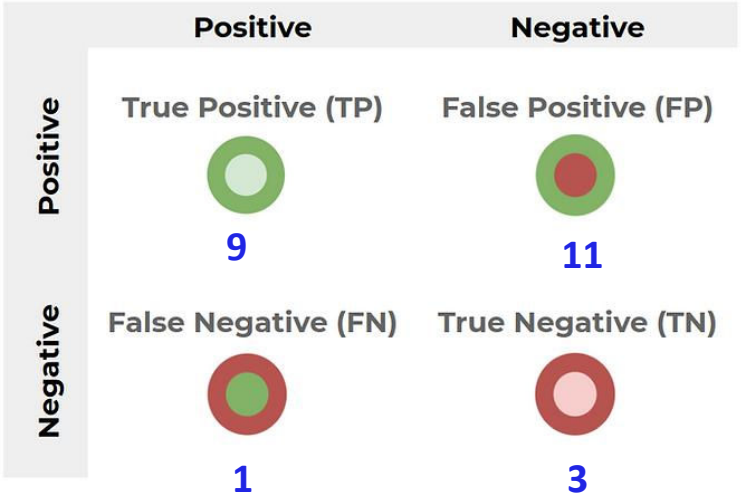
Il représente la proportion des éléments de la classe négative qui ont été mal classés comme positifs.

Métriques d'évaluation

6. Courbe ROC et AUC



- 10 personnes souffrent de la maladie, représentée par des points verts.
- 14 n'ont pas la maladie, représentée par les points rouges

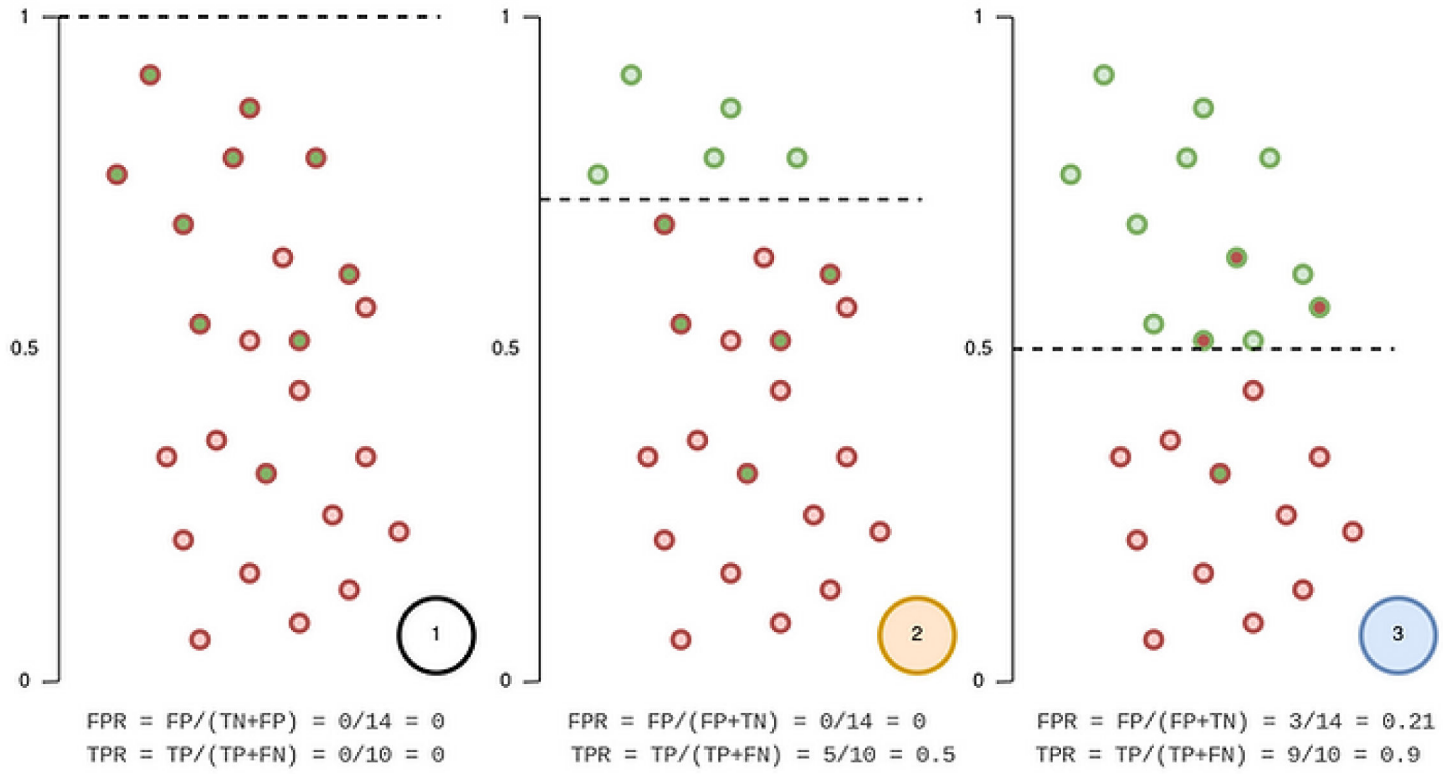


Métriques d'évaluation

6. Courbe ROC et AUC

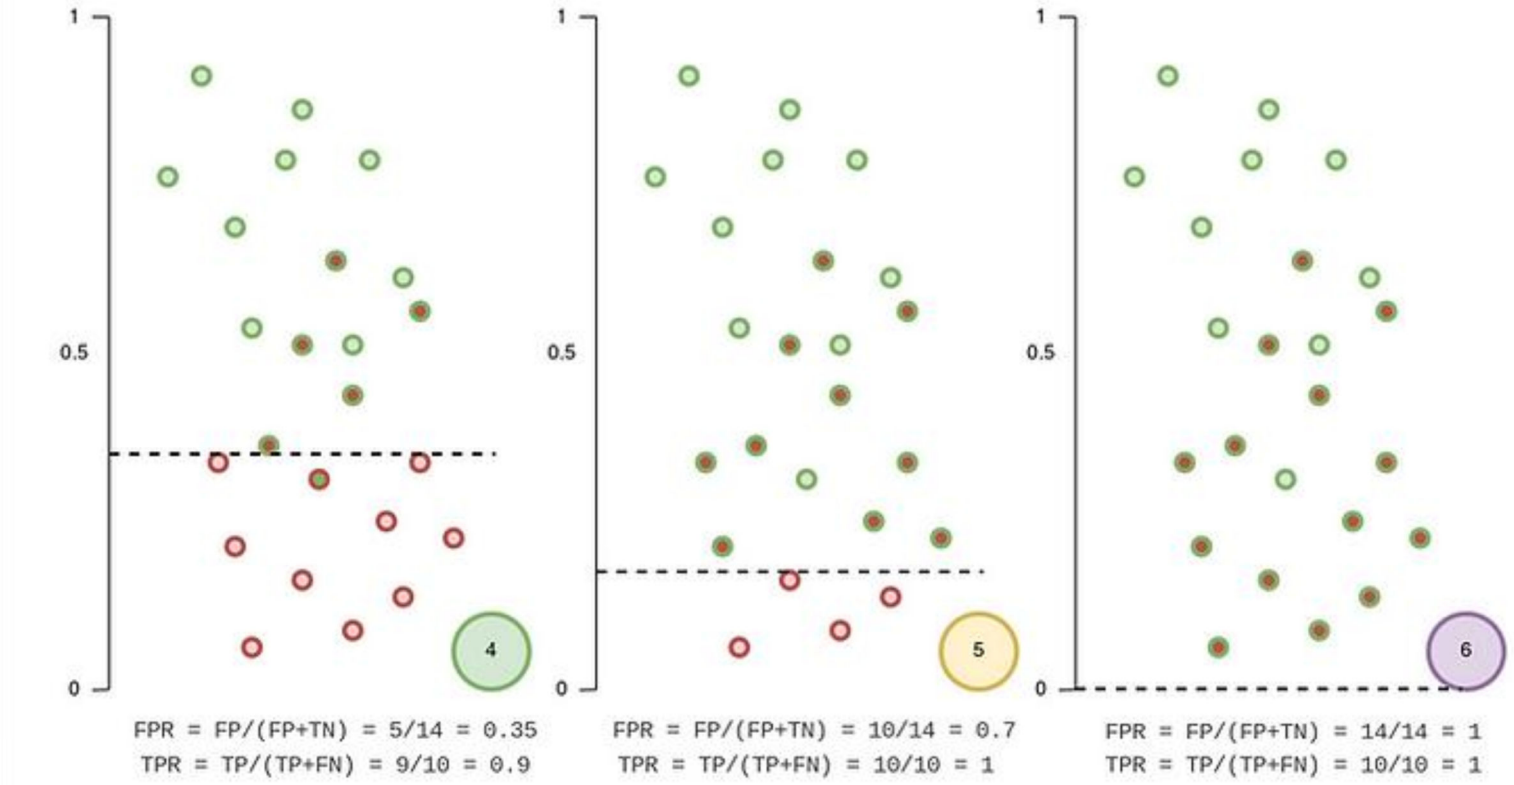
- On choisit n'importe quel nombre de seuils et on calcul le TPR-FPR pour chacun d'eux(Ex: seuil=1,0, 0,75, 0,5, 0,35, 0,15 et 0).

- 0,75, s'il s'agissait d'une valeur de confiance d'un modèle, cela signifie que la prédiction devrait être supérieure au seuil de 75 % pour être prédite comme positive.



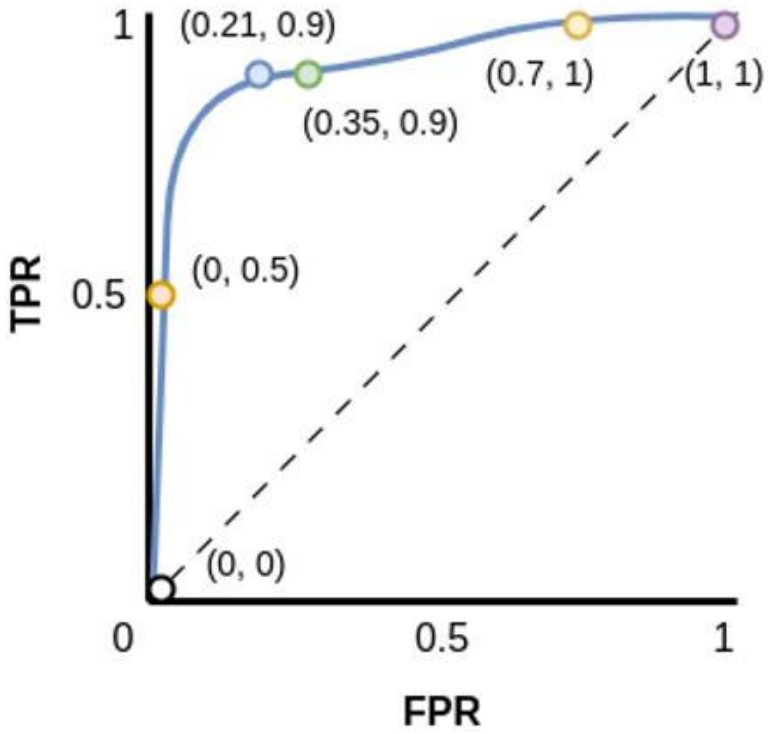
Métriques d'évaluation

6. Courbe ROC et AUC



Métriques d'évaluation

6. Courbe ROC et AUC

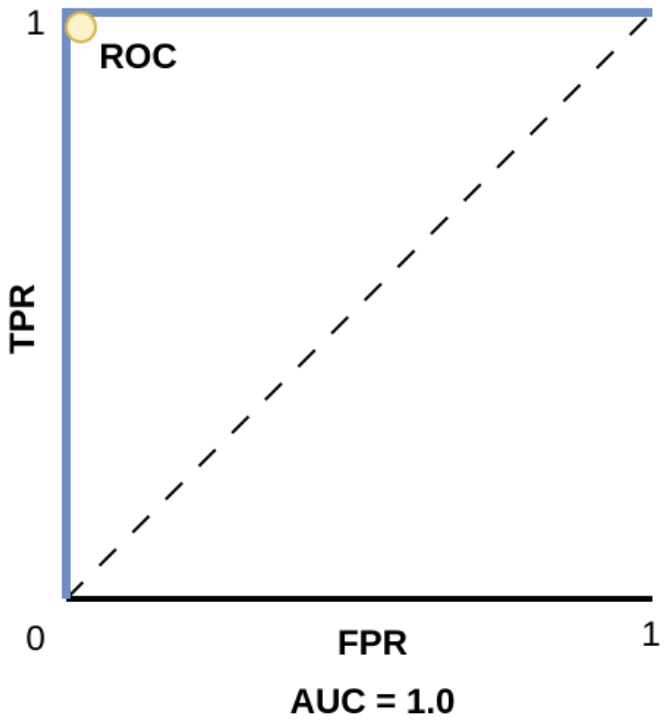


Métriques d'évaluation

6. Courbe ROC et AUC

L'**AUC (Area Under the Curve ROC)** est une mesure de performance qui représente l'aire sous la courbe ROC. Elle quantifie la capacité du modèle à distinguer entre les classes positives et négatives.

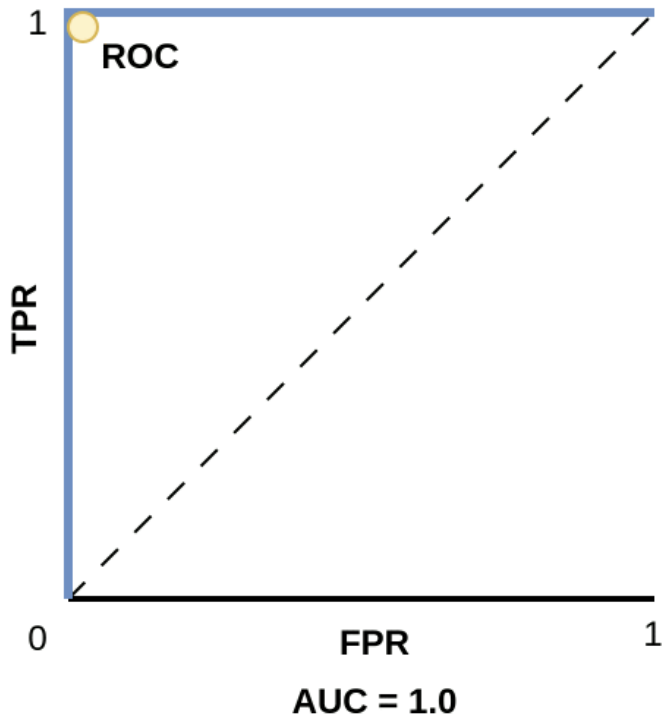
- **AUC = 1** → Modèle parfait (sépare complètement les classes).
- **AUC = 0.5** → Modèle aléatoire (ne fait pas mieux que le hasard).
- **AUC < 0.5** → Modèle inversé (les prédictions sont opposées à la réalité).



Métriques d'évaluation

6. Courbe ROC et AUC

L'AUC peut être interprétée comme la probabilité qu'un modèle classe un exemple positif avec un score plus élevé qu'un exemple négatif.



Exemple :

Si on tire au hasard un élément de chaque classe :

- **Un AUC de 0.9** signifie que dans 90% des cas, le modèle classe correctement l'exemple positif au-dessus du négatif.
- **Un AUC de 0.6** signifie qu'il réussit dans 60% des cas, ce qui est faible.