Machine learning

Lecture 3 : Régression

Prof: Aissam BERRAHOU
Aissam.berrahou@ensias.um5.ac.ma
Laboratoire Smart Systems Lab

ENSIAS

جامعة محمد الخامس بالرباط
Université Mohammed V de Rabat

2020-2021

Objectifs du cours

Comment prévoir le rendement d'un champ à partir de la température ?

C'est un problème de **régression** : prédire un nombre à partir d'autres variables. À la fin de la séance, vous saurez :

- estimer à la main β_0 et β_1 par les **moindres carrés** ;
- dérouler quelques itérations de **descente de gradient** ;
- juger la qualité d'un modèle avec la **MSE** et le **R^2** ;
- passer de la régression simple aux régressions **polynomiale** et **multiple**.

Plan

1) **Origine et applications**

2) **Notations et vocabulaire**

3) **Régression linéaire simple**

4) **Régression polynomiale**

5) **Régression multiple**

1. Origine et applications

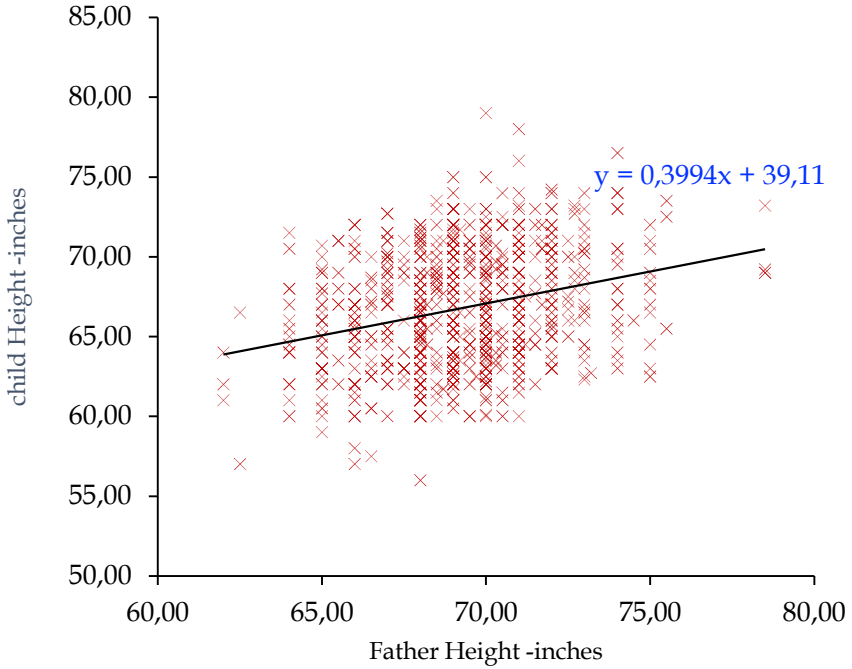
Origine et applications

❖ Origine

Francis Galton 1822-1911



Regression towards mediocrity stature
Journal of the Antropological Institue 15: 246-63(1886)



La **taille des enfants nés** des **parents très grands(ou petits)** se rapproche de la taille moyenne de la population

→ elle régresse

Origine et applications

❖ Objectif

Analyser la **relation** entre

- Une **variable expliquée**
  - Une variable dépendante
  - Réponse
  - Variable endogène

Et

- Une ou plusieurs **variables explicatives**
  - Variable indépendantes
  - Prédicteurs
  - Variables exogènes

Exemple de Galton :

- Taille des pères: **variable explicative**
- Tailles des enfants: **variable expliquée**

dans un but

- explicatif
- de prévision
- …

sous l'hypothèse que la **relation** est **linéaire en ses paramètres (et pas forcément qu'il existe une linéarité entre les variables)**.

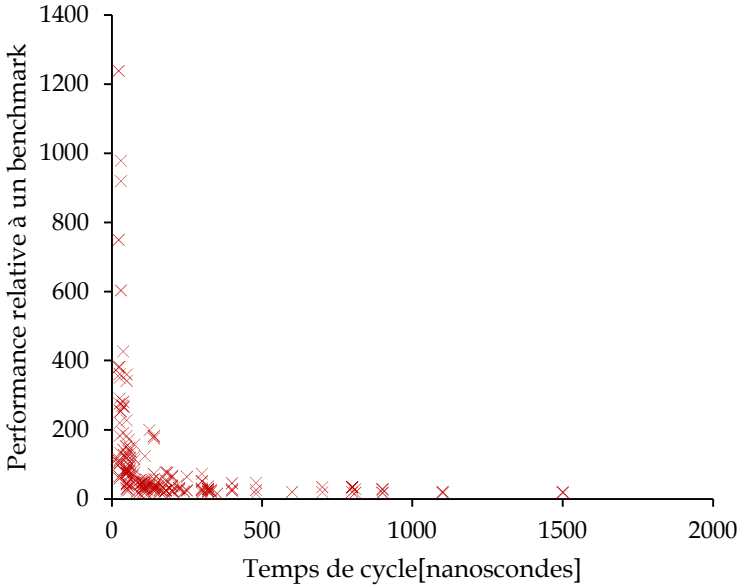
Et

À partir de données

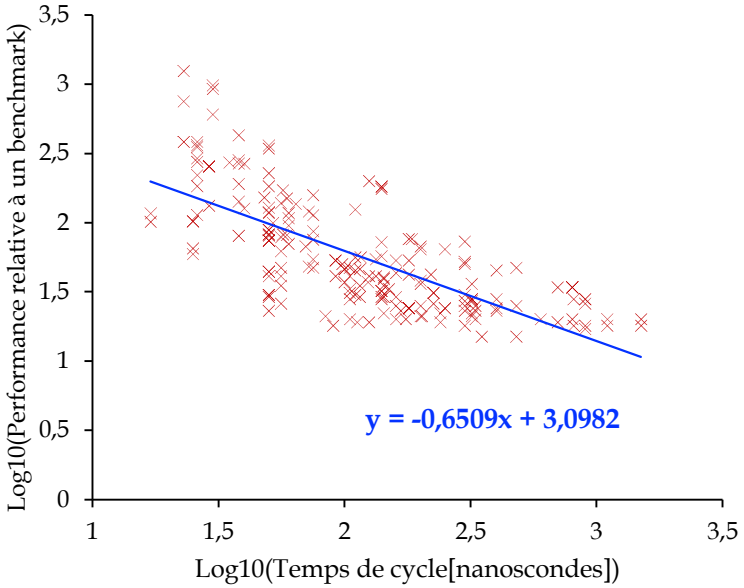
Origine et applications

❖ Exemples: Industrie

Performances des ordinateurs (P. Ein-Dor, J. Feldmesser(1987))

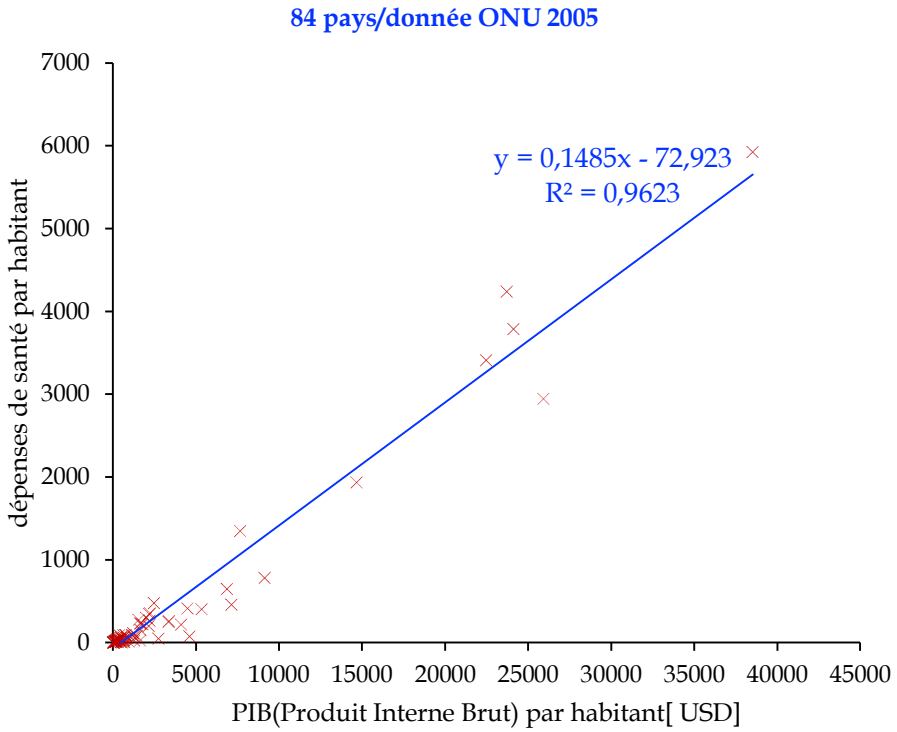


Performances des ordinateurs (P. Ein-Dor, J. Feldmesser(1987))



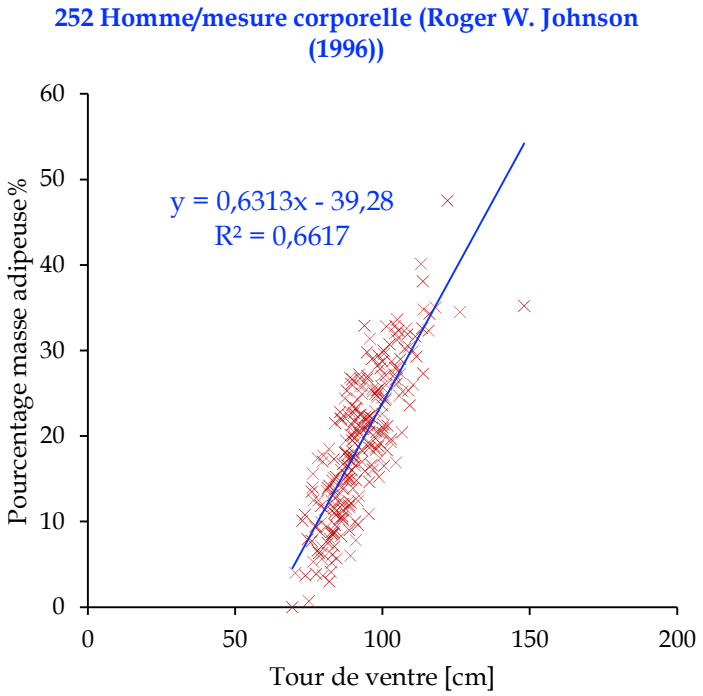
Origine et applications

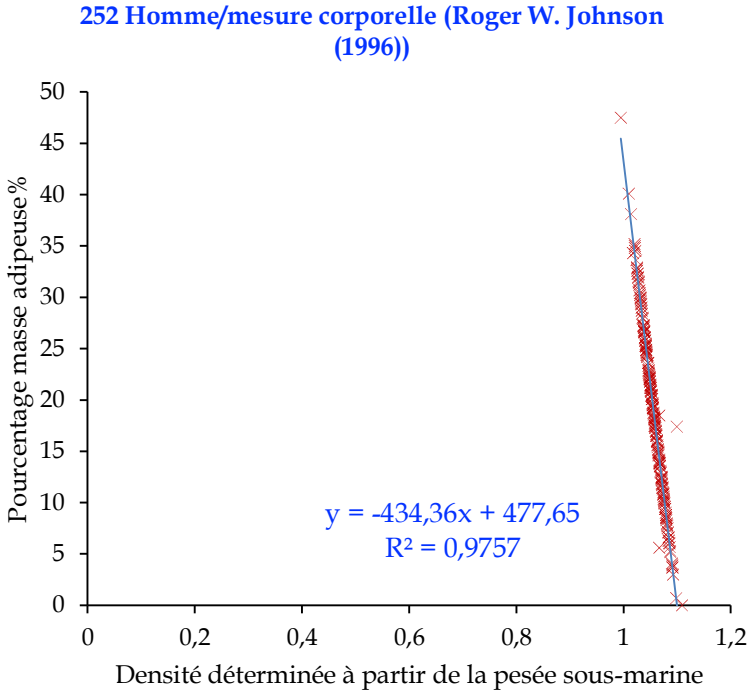
❖ Exemples: Economie



Origine et applications

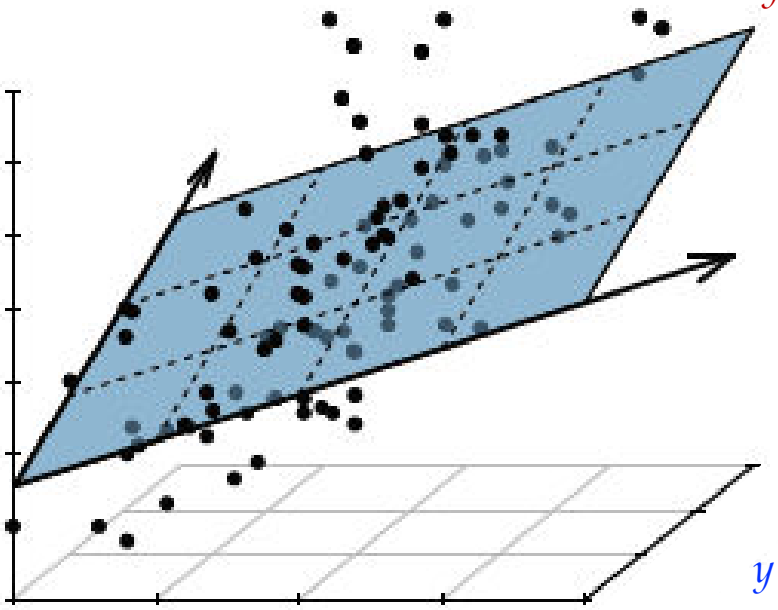
❖ Exemples: Médecine





Origine et applications

❖ Exemples: Médecine



$z \approx f(x, y)$

y Densité déterminée à partir de la pesée sous-marine

2. Notation et vocabulaire

Notations et Vocabulaire

❖ Vocabulaire

- Régression linéaire simple Régression polynomiale
  - Une seule variable expliquée
  - Une seule variable explicative

- Régression linéaire multiple
  - Une seule variable expliquée
  - Plusieurs variables explicatives

Notations et Vocabulaire

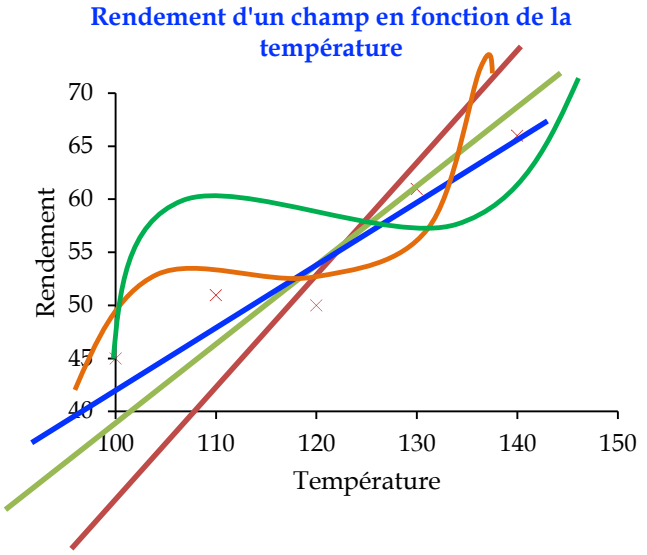
❖ Notations

- y est la variable expliquée(à valeurs dans $\mathbb{R}$).
- x est la variable explicative (à valeurs dans $\mathbb{R}$).
- $y \approx \beta_0 + \beta_1 x$, la relation approximative entre x et y.
- β_0, β_1: les paramètres(les coefficients)du modèle.
- $\hat{\beta}_0, \hat{\beta}_1$: les estimations des paramètres.
- $y = \beta_0 + \beta_1 x + \varepsilon$ avec ε le terme d'erreur aléatoire du modèle.
- $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$: la prédiction de la variable expliquée.

Régression

❖ **Exemple**

Température (x_i)	*Rendement(y_i)*
100	45
110	51
120	50
130	61
140	66



Notations et Vocabulaire

❖ **Etude de la relation de linéarité entre deux variables quantitatives:**

Coefficient de corrélation linéaire (Pearson)

$$r_{XY} = \frac{S_{XY}}{S_X S_Y}, \qquad \text{où } -1 \leq r_{XY} \leq 1$$

Variance :

$$S_X^2 = \frac{1}{n}\sum_{i=1}^{n}(x_i - \bar{x})^2 = \frac{1}{n}\sum_{i=1}^{n} x_i^2 - \bar{x}^2 ,$$

$$S_Y^2 = \frac{1}{n}\sum_{i=1}^{n}(y_i - \bar{y})^2 .$$

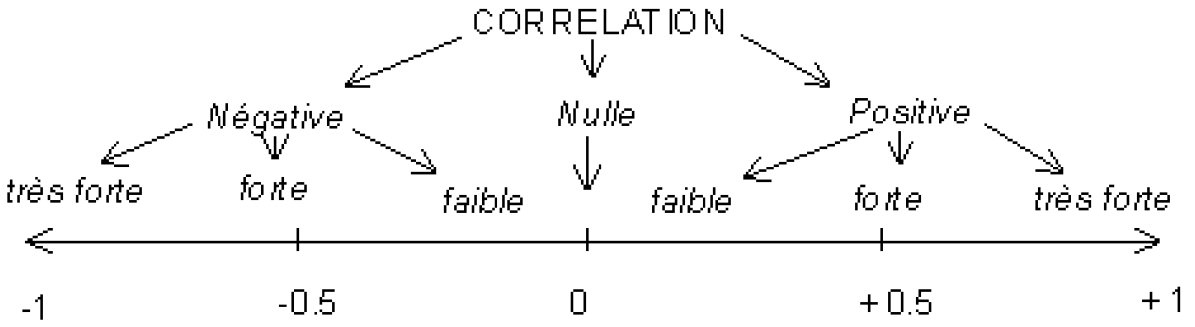
Covariance :

$$S_{XY} = \frac{1}{n}\sum_{i=1}^{n}(x_i - \overline{x})(y_i - \overline{y}) = \frac{1}{n}\sum_{i=1}^{n} x_i y_i - \bar{x}\bar{y}$$

Notations et Vocabulaire

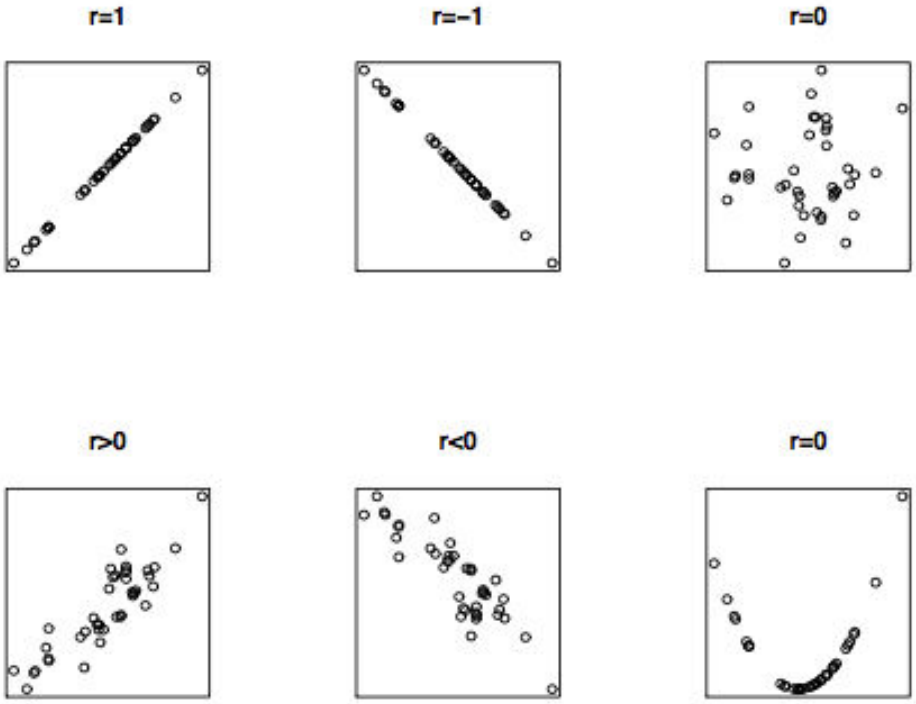
❖ **Etude de la relation de linéarité entre deux variables quantitatives:**

- **Interprétation du coefficient de corrélation linéaire (Pearson)**
  - Si r est proche de 0, il n'y a pas de relation linéaire entre X et Y.
  - Si r est proche de -1, il existe une forte relation linéaire négative entre X et Y .
  - Si r est proche de 1, il existe une forte relation linéaire positive entre X et Y



Notations et Vocabulaire

❖ **Etude de la relation de linéarité entre deux variables quantitatives:**



2. Régression linéaire simple

a. Formulation d'un modèle de régression linéaire simple

Régression

❖ **Comment trouver un modèle de régression pour un problème donné?**

1. **Dataset (X,Y)**
   - variables explicatives (features)
   - variable expliquée (target)

2. **Modèle**

   - Régression: Modèle de régression linéaire simple/ linéaire multiple/polynomiale

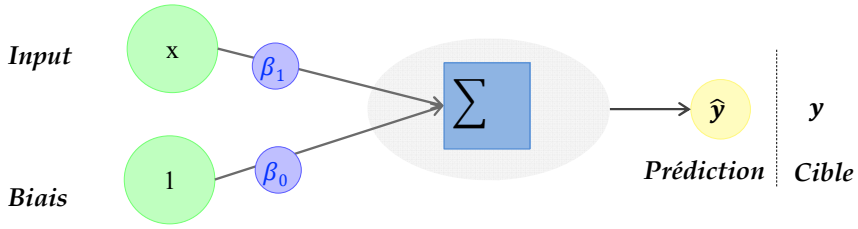
3. **Fonction coût**

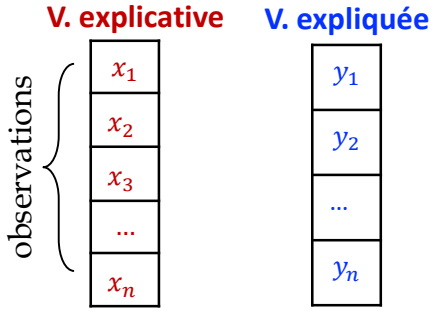
   - Erreur quadratique $L(y_i, f(x_i)) = (y_i - f(x_i))^2$
   - Ecart absolu : $L(y_i, f(x_i)) = |y_i - f(x_i)|$
   - …

4. **Algorithme d'optimisation**
   - Méthode moindre carrés
   - Descente de gradient
   - Maximum de vraisemblance

Régression linéaire simple

❖ **Modèle de régression simple**





Modèle de régression linéaire simple $(y = \beta_1 x + \beta_0 + \varepsilon)$

Régression linéaire simple

❖ **Estimation des paramètres β_0, β_1**

1. **Dataset (X,Y)**
   - variable explicative (feature)
   - variable expliquée (target)

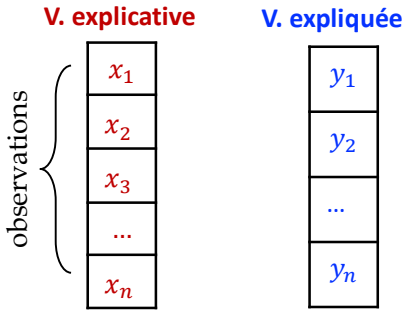
2. **Modèle**
   - Régression: Modèle linéaire simple. $Y = \beta X + \varepsilon$

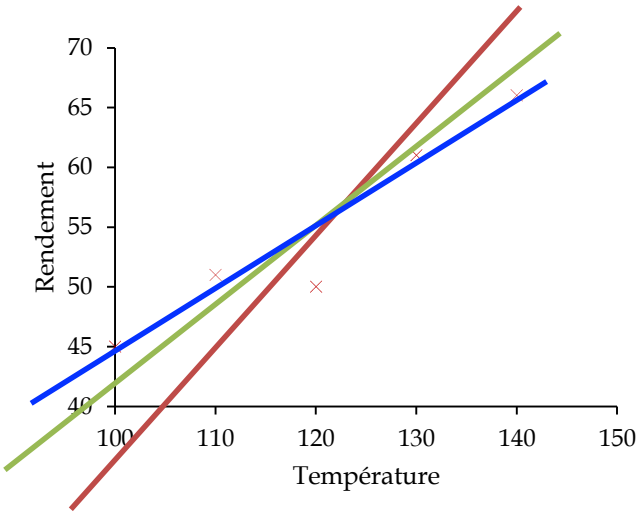
$$(Y \approx \beta X) \text{ où } \boldsymbol{Y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}, \ \boldsymbol{X} = \begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix}, \boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix}, \text{ et } \boldsymbol{\varepsilon} = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$

3. **Fonction coût**
   - Erreur quadratique

$$\boldsymbol{Li}(\beta_0, \beta_1) = (y_i - f(x_i))^2$$
$$\boldsymbol{L}(\beta_0, \beta_1) = \frac{1}{n}(X\beta - Y)^T(X\beta - Y)$$

4. **Algorithme d'optimisation**
   - Méthode des moindre carrés
   - Descente de gradient





b. Estimation ponctuelle des paramètres d'un modèle de régression linéaire simple

Régression linéaire simple

❖ **Estimation des paramètres β_0 et β_1**

- On cherche $\widehat{\beta_0}$ $et\widehat{\beta_1}$(estimateurs respectivement de $\boldsymbol{\beta_0}$ et $\boldsymbol{\beta_1}$)qui minimisent la somme des carrés des résidus

- Selon la méthode des moindres carrés on doit résoudre le **problème d'optimisation** suivant :

$$\underset{(\boldsymbol{\beta_0},\boldsymbol{\beta_1})\epsilon\mathbb{R}^2}{\boldsymbol{argmin}}\, \boldsymbol{L(\beta_0,\beta_1)}$$

Problème à optimiser

avec $\boldsymbol{L(\beta_0,\beta_1)} = 1/n\sum_{i=1}^{n}\varepsilon_i^2 = 1/n\sum_{i=1}^{n}[y_i - (\beta_0 + \beta_1 x_i)]^2$

Fonction coût

Régression linéaire simple

❖ **Estimation des paramètres β_0 et β_1**

A partir d'un échantillon (aléatoire) de **n observations $\{(x_i,y_i), i = 1,...,n\}$,** on veut **estimer** les paramètres **β_0 et β_1 .**

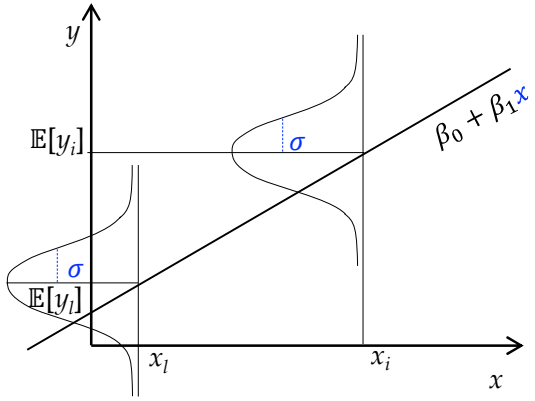
- la méthode des moindres carrés
- La méthode de gradient descente

} Méthodes d'optimisation

Régression linéaire simple

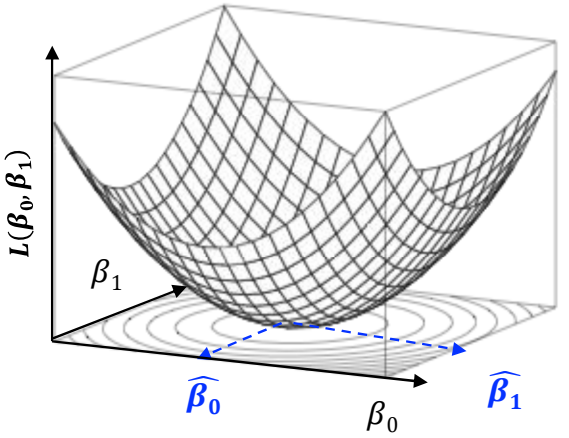
❖ **Estimation des paramètres β_0 et β_1 par la méthode des moindres carrés.**

$$\nabla L(\boldsymbol{\beta_0}, \boldsymbol{\beta_1}) = 0 \Rightarrow \begin{cases} \dfrac{\partial L(\boldsymbol{\beta_0}, \boldsymbol{\beta_1})}{\partial \boldsymbol{\beta_1}} = -\sum_{i=1}^{n} [\boldsymbol{y_i} - (\widehat{\boldsymbol{\beta_0}} + \widehat{\boldsymbol{\beta_1}} \boldsymbol{x_i})] = 0, \\ \dfrac{\partial L(\boldsymbol{\beta_0}, \boldsymbol{\beta_1})}{\partial \boldsymbol{\beta_0}} = -\sum_{i=1}^{n} [\boldsymbol{y_i} - (\widehat{\boldsymbol{\beta_0}} + \widehat{\boldsymbol{\beta_1}} \boldsymbol{x_i})] \boldsymbol{x_i} = 0. \end{cases}$$



On en déduit après quelques manipulations:

$$\begin{cases} \widehat{\boldsymbol{\beta_1}} = \dfrac{\frac{1}{n}\sum_{i=1}^{n}(x_i - \overline{X})(y_i - \overline{Y})}{\frac{1}{n}\sum_{i=1}^{n}(x_i - \overline{X})^2} = \dfrac{\boldsymbol{Cov(X,Y)}}{\boldsymbol{S_X^2}}, \\ \widehat{\boldsymbol{\beta_0}} = \overline{\boldsymbol{Y}} - \widehat{\boldsymbol{\beta_1}}\overline{\boldsymbol{X}} \end{cases}$$



Régression linéaire simple

❖ **Estimation des paramètres β_0 et β_1 par la méthode des moindres carrés (Formulation matricielle).**

Formulation matricielle de la fonction coût

$$L(\beta_0, \beta_1) = \frac{1}{n}\sum_{i=0}^{n} \varepsilon_i^2 = \frac{1}{n}\sum_{i=1}^{n} [y_i - (\beta_0 + \beta_1 x_i)]^2$$

où $\mathbf{X}=\begin{pmatrix} x_1 & \mathbf{1} \\ x_2 & \mathbf{1} \\ \vdots & \vdots \\ x_n & \mathbf{1} \end{pmatrix}$ $\mathbf{Y}=\begin{pmatrix} y_1 \\ y_1 \\ \vdots \\ y_1 \end{pmatrix}$ $\boldsymbol{\beta}=\begin{pmatrix} \boldsymbol{\beta}_1 \\ \boldsymbol{\beta}_0 \end{pmatrix}$

$$= \frac{\mathbf{1}}{\boldsymbol{n}} (\boldsymbol{X\beta} - \boldsymbol{Y})^{\boldsymbol{T}} (\boldsymbol{X\beta} - \boldsymbol{Y})$$

Donc

$$\frac{\partial L(\beta)}{\partial \beta} = 0 \quad \Leftrightarrow \quad \frac{\partial L(\beta)}{\partial \beta} = \frac{2}{n} X^T (X\beta - Y)$$

$$\widehat{\boldsymbol{\beta}} = \left(\boldsymbol{X}^{\boldsymbol{T}}\boldsymbol{X}\right)^{-\mathbf{1}}\boldsymbol{X}^{\boldsymbol{T}}\mathrm{Y}$$

Régression linéaire simple

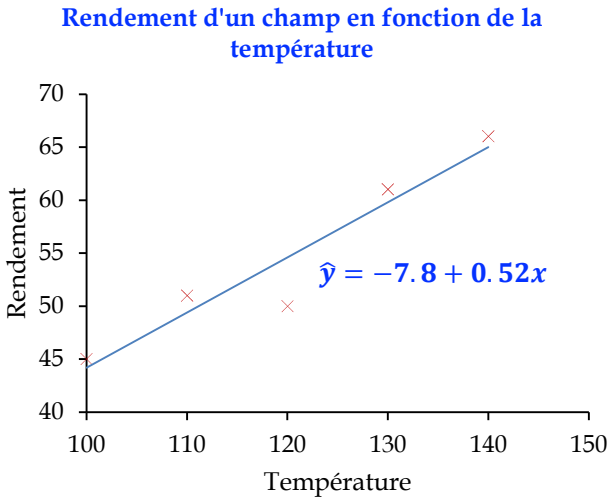
❖ **Estimation des paramètres β_0 et β_1 par la méthode des moindres carrés.**

Les paramètres du modèle sont estimer à partir des données $(x_i, y_i)i=1,\ldots,n$

Température (x_i)	*Rendement(y_i)*
100	45
110	51
120	50
130	61
140	66

$$\begin{cases} \widehat{\beta_0} = -7,8 \\ \widehat{\beta_1} = 0,52 \end{cases}$$

$$\hat{y} = -7.8 + 0.52x$$



Régression linéaire simple

❖ **Exemple1 : Estimation des paramètres β_0 et β_1 par la méthode des moindres carrés.**

Les paramètres du modèle sont estimer à partir des données $(x_i, y_i)i=1,\ldots,n$

N°obs	x_i	y_i
1	-1	-1
2	0	-1
3	1	1
Moyenne	$\bar{X} = 0$	$\bar{Y} = -1/3$
Variance	$S_X^2 = 2/3$	$S_Y^2 = 8/9$

$$\widehat{\beta_1} = \frac{Cov(X,Y)}{S_X^2} = \frac{\frac{2}{3}}{\frac{2}{3}} = 1,$$

$$\widehat{\beta_0} = \bar{Y} - \widehat{\beta_1}\bar{X} = \frac{-1}{3}$$

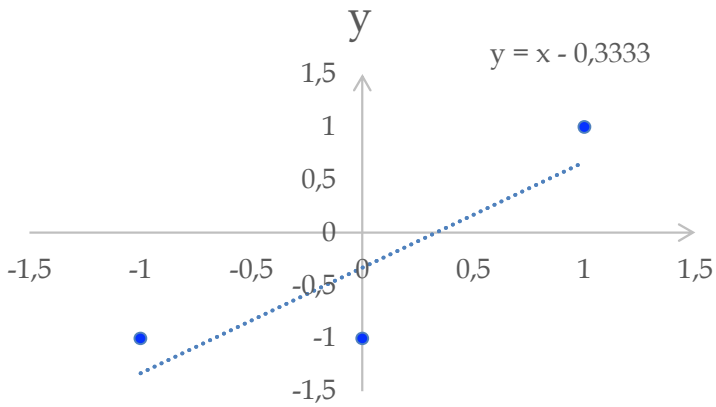
$$\hat{y} = \mathbb{E}[y] = \widehat{\beta_0} + \widehat{\beta_1}x = \frac{-1}{3} + x$$

Régression linéaire simple

❖ **Exemple1 : Estimation des paramètres β_0 et β_1 par la méthode des moindres carrés.**

N°obs	x_i	y_i	$\hat{y}_i$	$e_i = yi - \hat{y}_i$ (résidu)
1	-1	-1	-4/3	1/3
2	0	-1	-1/3	-2/3
3	1	1	2/3	1/3
Moyenne	$\bar{X}$ =0	$\bar{Y} = -1/3$	$\bar{\hat{Y}} = -1/3$	0
Variance	S_X^2=2/3	S_Y^2=8/9		

$$\hat{y} = \mathbb{E}[y] = \widehat{\beta_0} + \widehat{\beta_1} x = \frac{-1}{3} + x$$



Régression linéaire simple

❖ **Tutorial d'implémentation:**

- Implémentation à partir de zéro: ***TutorialRegressionLineaireSimple_moindrescarres.ipynb***
- Implémentation à base de la bibliothèque scikit-learn

Régression linéaire simple

❖ **Estimation des paramètres β_0 et β_1 avec la méthode de descente gradient**

- **Rappel sur l'apprentissage supervisé**

1. **Dataset (X,Y)**
   - variable explicative(feature)
   - variable expliquée(target)

2. **Modèle**
   - Régression: Modèle linéaire simple

3. **Fonction coût**
   - Erreur quadratique moyenne

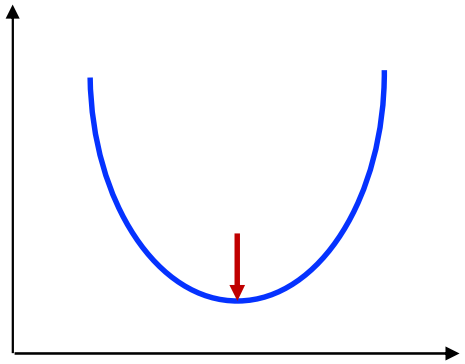
$$\boldsymbol{L(\beta_0, \beta_1)} = \frac{1}{2}\sum_{i=0}^{n} \varepsilon_i^2 = \frac{1}{2}\sum_{i=1}^{n} [y_i - (\beta_0 + \beta_1 x_i)]^2$$

4. **Algorithme d'optimisation**
   - Descente de gradient

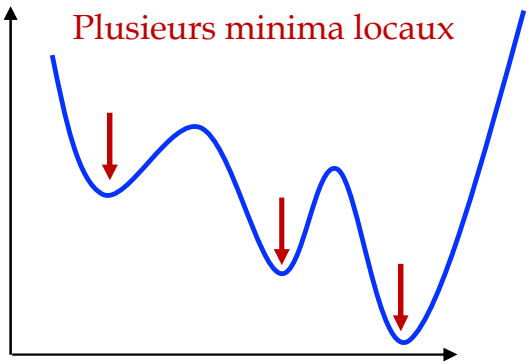
Régression linéaire simple

❖ **Estimation des paramètres β_0 et β_1 avec la <u>méthode de descente gradient</u>**

- Descente de gradient est une méthode d'optimisation **itérative** qui converge vers **un seul minimum** d'une **fonction convexe**.



Forme convexe



Forme non convexe

Régression linéaire simple

❖ **Estimation des paramètres β_0 et β_1 avec la méthode de descente gradient**

- **Principe**

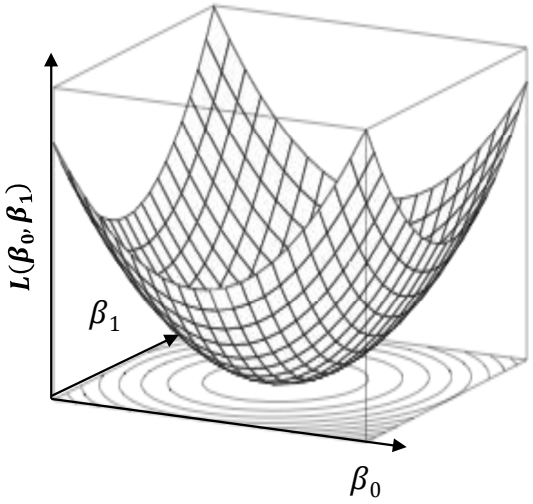


Régression linéaire simple

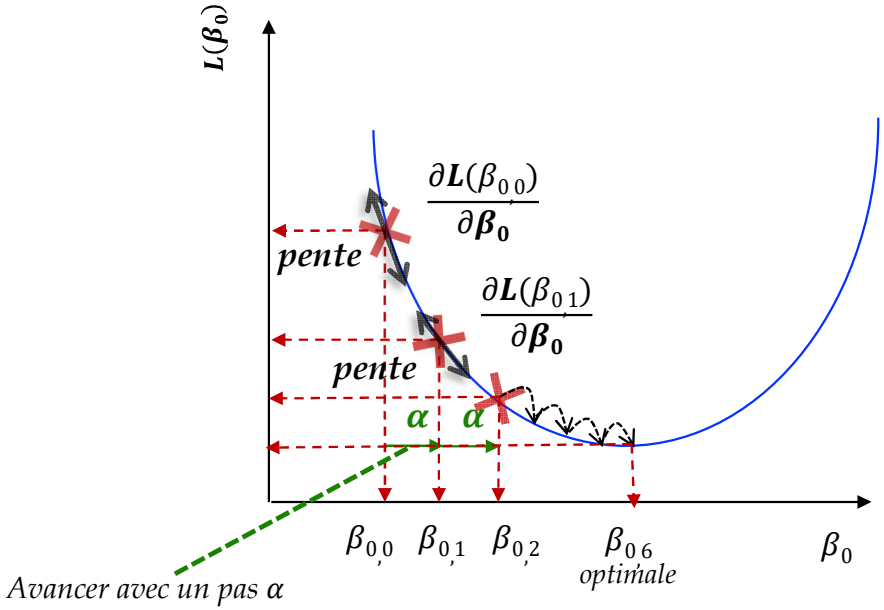
❖ **Estimation des paramètres β_0 et β_1 avec la méthode de descente gradient**

- **Fonction coût**

$$L(\beta_0, \beta_1) = \frac{1}{n}\sum_{i=0}^{n} \varepsilon_i^2 = \frac{1}{n}\sum_{i=1}^{n} [y_i - (\beta_0 + \beta_1 x_i)]^2$$



$L(\beta_0, \beta_1)$ *fonction convexe*

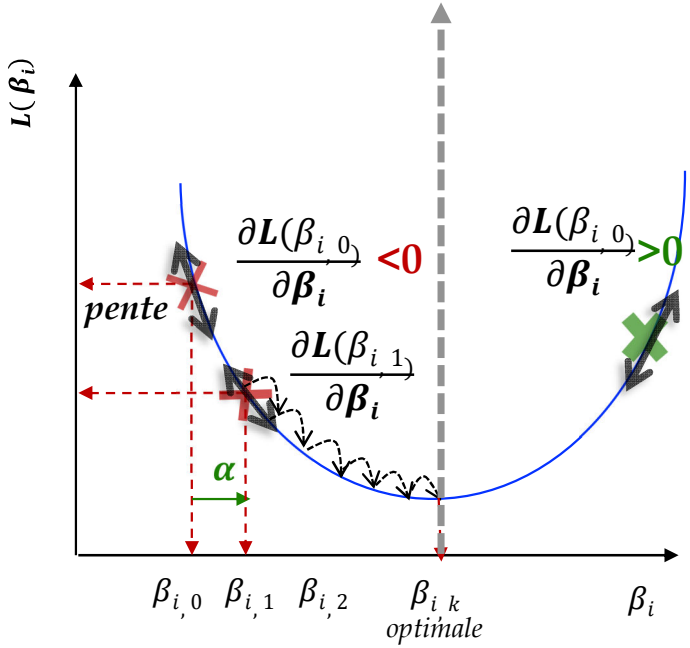


α : la vitesse d'apprentissage(Learning rate)

Régression linéaire simple

❖ **Estimation des paramètres β_0 et β_1 avec la méthode de descente gradient**

Comment calculer les estimateurs de β_0, β_1?



Pourquoi le -?

Tantque (j< k) faire

$$\beta_{0,i+1} \leftarrow \beta_{0,i} - \alpha \frac{\partial L(\beta_{0i})}{\partial \beta_0'}$$

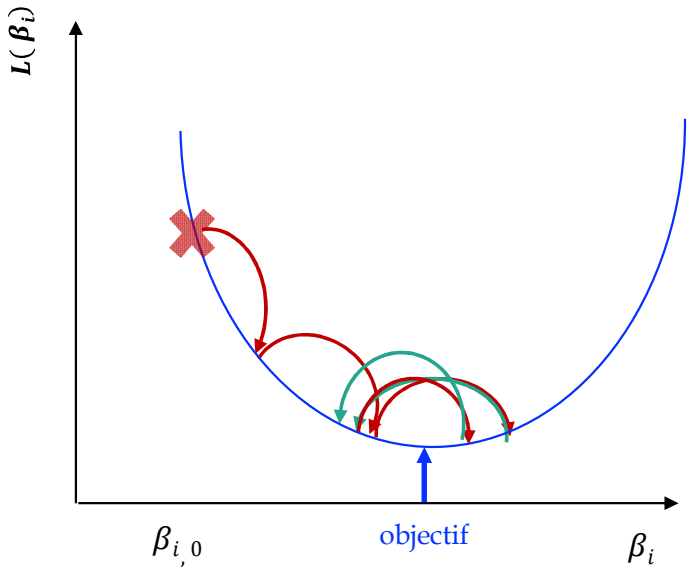
$$\beta_{1,i+1} \leftarrow \beta_{1,i} - \alpha \frac{\partial L(\beta_{1i})}{\partial \beta_1'}$$

FinTantque

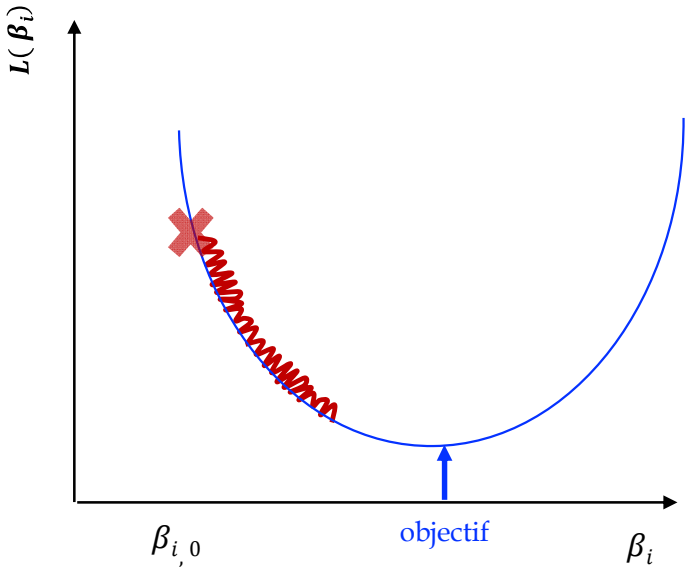
Régression linéaire simple

❖ **Estimation des paramètres β_0 et β_1 avec la méthode de descente gradient**

- **Comment choisir la valeur de la vitesse d'apprentissage $\alpha(toujours\ positive)$?**



Si la valeur de α est grande(**Allez plus vite**)



Si la valeur de α est trop petite(**Allez doucement**)

Régression linéaire simple

❖ **Estimation des paramètres β_0 et β_1 avec la <u>méthode de descente gradient</u>**

- **Comment choisir la valeur de la vitesse d'apprentissage $\alpha(toujours\ positive)$?**

1.Si α est trop petit :

- L'algorithme converge lentement, car les pas sont très petits.
- Risque de rester coincé dans un minimum local ou de ne pas converger dans un temps raisonnable.

2.Si α est trop grand :

- L'algorithme peut diverger, car les pas sont trop grands et dépassent le minimum.
- Risque d'osciller autour du minimum sans jamais converger.

3.Si α est bien choisi :

- L'algorithme converge rapidement et de manière stable vers le minimum global.

Régression linéaire simple

❖ **Estimation des paramètres β_0 et β_1 avec la méthode de descente gradient**

- **Formulation matricielle de la fonction coût**

X= $\begin{bmatrix} x_1 & 1 \\ x_2 & 1 \\ x_3 & 1 \\ \dots & \\ x_n & 1 \end{bmatrix}$ Y= $\begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ \dots \\ y_n \end{bmatrix}$ $\boldsymbol{\beta}$= $\begin{bmatrix} \beta_1 \\ \beta_0 \end{bmatrix}$

Fonction coût

$$L(\beta_0, \beta_1) = \frac{1}{n}\sum_{i=0}^{n} \varepsilon_i^2 = \frac{1}{n}\sum_{i=1}^{n}[y_i - (\beta_0 + \beta_1 x_i)]^2 = \frac{1}{n}(\boldsymbol{X\beta - Y})^T(\boldsymbol{X\beta - Y})$$

Et le gradient

$$\frac{\partial L(\boldsymbol{\beta})}{\partial \boldsymbol{\beta}} = \frac{2}{n} \boldsymbol{X}^T(\boldsymbol{X\beta - Y})$$

Régression linéaire simple

❖ **Estimation des paramètres β_0 et β_1 avec la méthode de descente gradient**

- **Rappel sur l'apprentissage supervisé(Avec la formulation matricielle)**

1. **Dataset (X,Y)**
   - variable explicative(feature)
   - variable expliquée(target)

2. **Modèle**
   - Régression: Modèle linéaire simple. $Y = \beta X + \varepsilon$

3. **Fonction coût**
   - Erreur quadratique moyenne

$$L(\beta_0, \beta_1) = \frac{1}{n}(X\beta - Y)^T(X\beta - Y)$$

4. **Algorithme d'optimisation:** Descente de gradient

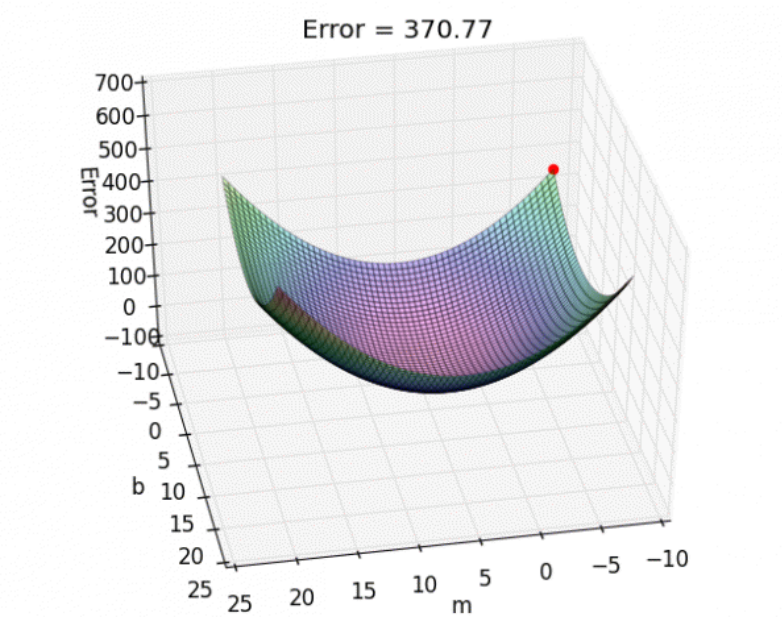
Tantque (j< k) faire

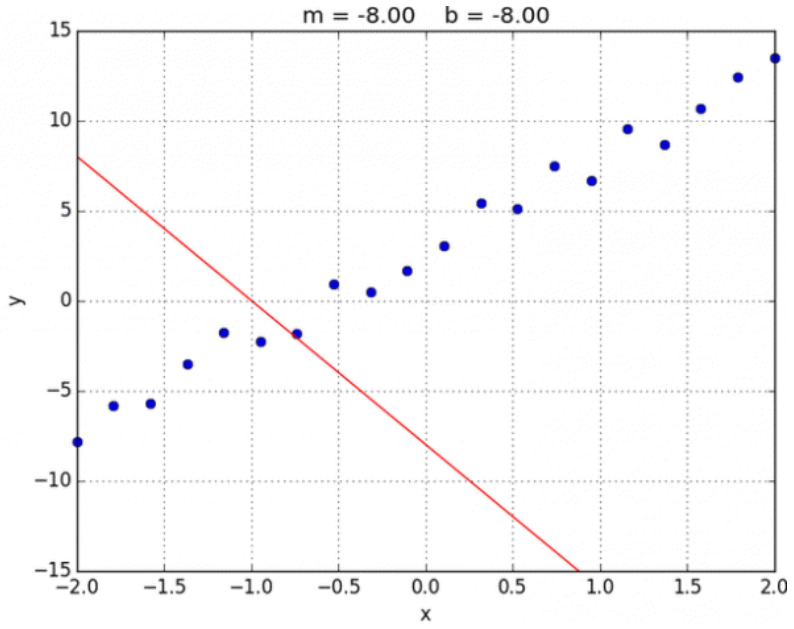
$$\beta = \beta - \alpha \frac{\partial L(\beta)}{\partial \beta} \qquad \text{Gradient: } \frac{\partial L(\beta)}{\partial \beta} = \frac{2}{n} X^T(X\beta - Y)$$

FinTantque

c. Implémentation et simulation

Simulation


Error = 370.77
Error
700
600
500
400
300
200
100
0
−100
b
−10
−5
0
5
10
15
20
25
m
25
20
15
10
5
0
−5
−10


m = -8.00 b = -8.00
y
15
10
5
0
−5
−10
−15
x
−2.0
−1.5
−1.0
−0.5
0.0
0.5
1.0
1.5
2.0

TP1: Régression linéaire simple

1. **Dataset (X,Y)**
   - variable explicative(feature)
   - variable expliquée(target)

2. **Modèle**
   - Régression: Modèle linéaire simple. $Y = \beta X + \varepsilon$

3. **Fonction coût**
   - Erreur quadratique moyenne

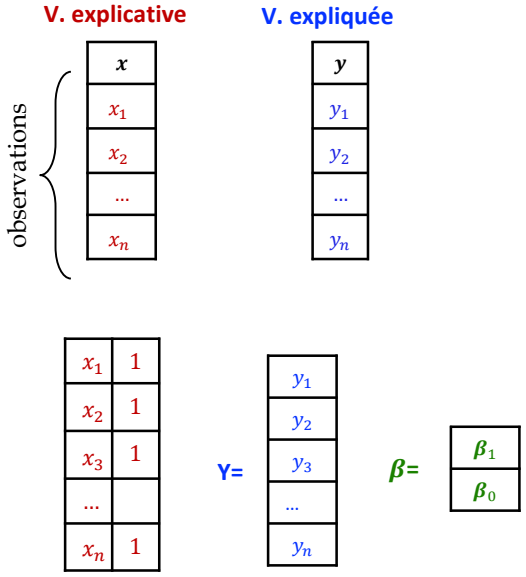
$$L(\beta_0, \beta_1) = \frac{1}{n}(X\beta - Y)^T(X\beta - Y)$$

4. **Algorithme d'optimisation:** Descente de gradient

Tantque (j< k) faire

$$\beta = \beta - \alpha \frac{\partial L(\beta)}{\partial \beta} \qquad \text{//Gradient: } \frac{\partial L(\beta)}{\partial \beta} = \frac{2}{n} X^T(X\beta - Y)$$

FinTantque



Création/ lecture d'une BD(X,y)

Splitting de la BD(E. Apprentissage, Ens. Test)

Initialisation des paramètres d'un modèle

Modèle

Fonction coût

Entraînement

Gradients

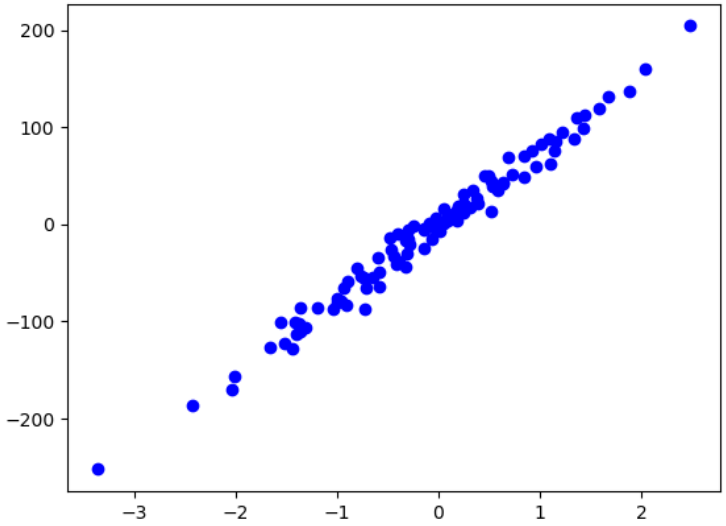
Mise à jour des paramètres

Test

TP1: Régression linéaire simple

Création/ lecture d'une BD(X,y)

```
import numpy as np
from sklearn.datasets import make_regression
import matplotlib.pyplot as plt
```



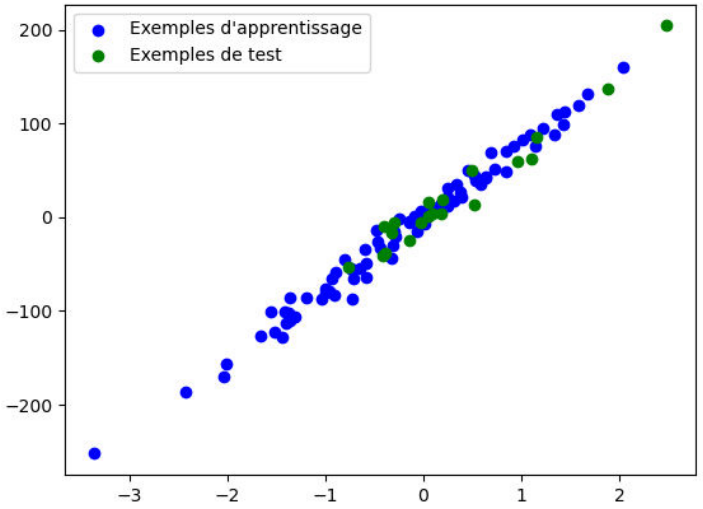

```
x,y=make_regression(n_samples=100, n_features=1, noise=10)
y=y.reshape(100,1)
plt.scatter(x,y)
```

TP1: Régression linéaire simple

Splitting de la BD(E. Apprentissage, Ens. Test)

```
from sklearn.model_selection import train_test_split

x_train,x_test,y_train,y_test=train_test_split(x,y,test_size=0.2
, random_state=42)
```




```
trPlot=plt.scatter(x_train,y_train,c='b')
tePlot=plt.scatter(x_test,y_test,c='g')
plt.legend([trPlot,tePlot],["Exemples d'apprentissage","Exemples de test"])
plt.show()
```

TP1: Régression linéaire simple

Initialisation des paramètres d'un modèle

X= $\begin{bmatrix} x_1 & 1 \\ x_2 & 1 \\ x_3 & 1 \\ \dots & \\ x_n & 1 \end{bmatrix}$ Y= $\begin{bmatrix} y_1 \\ y_2 \\ \dots \\ y_m \end{bmatrix}$ β= $\begin{bmatrix} \beta_1 \\ \beta_0 \end{bmatrix}$

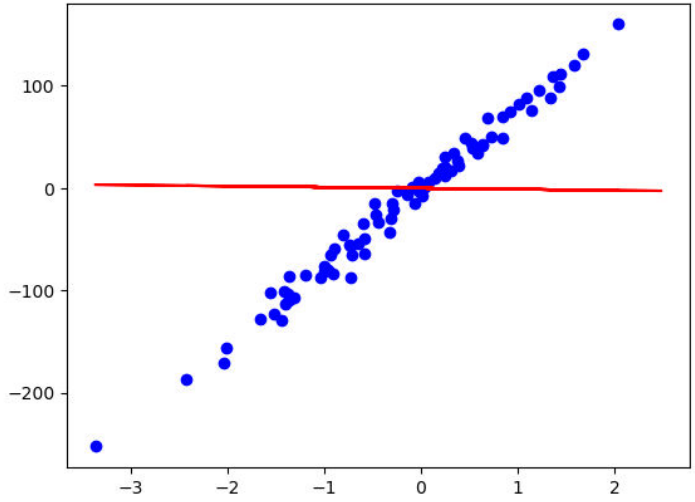
```
X_train=np.hstack((x_train,np.ones((np.shape(x_train)[0],1))))
X_test=np.hstack((x_test,np.ones((np.shape(x_test)[0],1))))

beta=np.random.randn(2,1)
```

Modèle

```
def model(X,beta):
 return X.dot(beta)

y_pred_train=model(X_train,beta)
plt.scatter(x_train,y_train)
plt.plot(x_train,y_pred_train, c='r')
plt.show()
```



TP1: Régression linéaire simple

Fonction coût

X=

x_1	1
x_2	1
x_3	1
...	
x_n	1

β=

β_1
β_0

$$L(\beta_0,\beta_1) = \frac{1}{n}\sum_{i=0}^{n} \varepsilon_i^2 = \frac{1}{n}\sum_{i=1}^{n}[y_i - (\beta_0 + \beta_1 x_i)]^2 = \frac{1}{n}(\boldsymbol{X\beta} - \boldsymbol{Y})^T(\boldsymbol{X\beta} - \boldsymbol{Y})$$

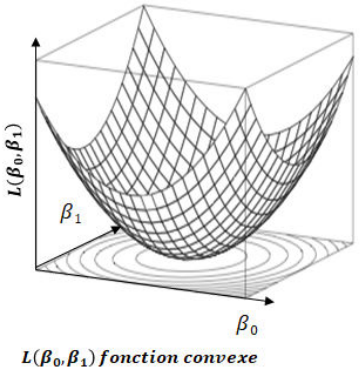
```
def fonction_cout(X,beta,y):
    n=len(y)
    term=model(X,beta)-y
    return (1/n)*term.T.dot(term)[0,0]
print("mse:", function_cout(X_train,y_train,beta))
```

TP1: Régression linéaire simple

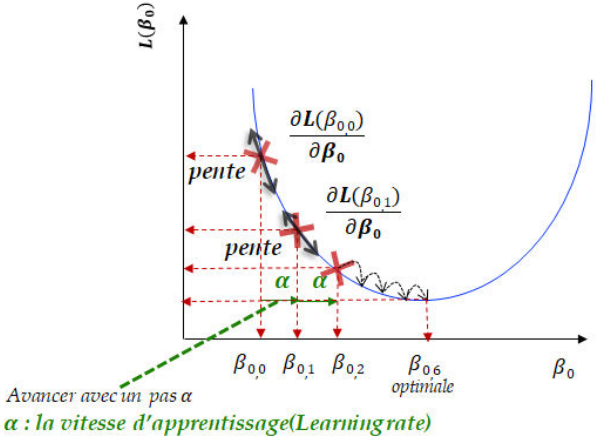
Gradient

Gradient: $\frac{\partial L(\beta)}{\partial \beta} = \frac{2}{n} XT(X\beta - Y)$

```
def grad(X,y,beta):
  n=len(y)
  return (2/n)*X.T.dot(model(X,beta)-y)
```



$L(\beta_0,\beta_1)$ *fonction convexe*



α : *la vitesse d'apprentissage(Learning rate)*

Mise à jour des paramètres

Tantque (j< k) faire

$$\beta = \beta - \alpha \frac{\partial L(\beta)}{\partial \beta}$$

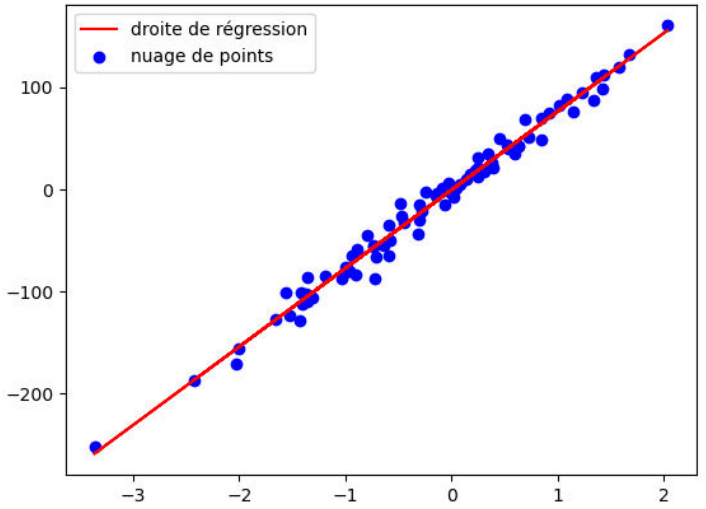
FinTantque

//Gradient: $\frac{\partial L(\beta)}{\partial \beta} = \frac{2}{n} X^T(X\beta - Y)$

```
def gradient_descent(X,y,beta,learning_rate=0.001, n_iteration=1000):
   for i in range(n_iteration):
      beta=beta-learning_rate*grad(X,y,beta)
   return beta
```

TP1: Régression linéaire simple

Apprentissage



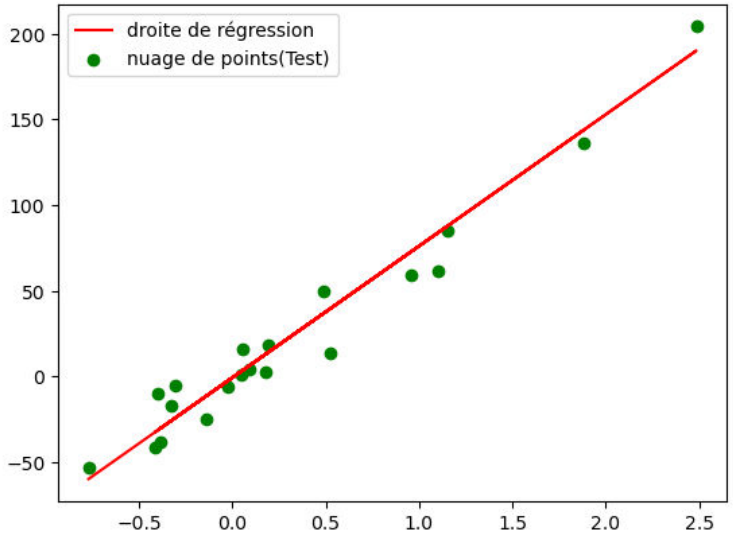

```
beta_estimer=gradient_descent(X_train,y_train,beta,learning_rate=0.01, n_iteration=2000)
```

```
y_pred_train=model(X_train,beta_estimer)
plt.scatter(x_train,y_train,c='b',label="nuage de points(Apprentissage)")
plt.plot(x_train,y_pred_train, c='r',label="droite de régression" )
plt.legend()
plt.show()
```

TP1: Régression linéaire simple

Test

```
y_pred_test=model(X_test,beta_estimer)
plt.scatter(x_test,y_test,c='g',label="nuage de points(Test)")
plt.plot(x_test,y_pred_test, c='r',label="droite de régression" )
plt.legend()
plt.show()
```

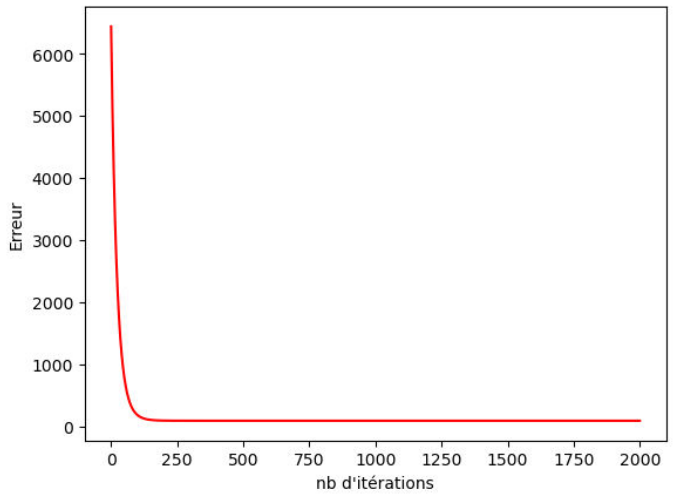


TP1: Régression linéaire simple

Courbe d'apprentissage

```
def gradient_descent_with_cost_history(X,y,beta,learning_rate=0.001, n_iteration=1000):
  cost_history=[]
  for i in range(n_iteration):
     beta=beta-learning_rate*grad(X,y,beta)
     cost_history.append(fonction_cout(X,beta,y))
  return beta, cost_history
```

```
beta_estimer,cost_history=gradient_descent_with_cost_history(X_train,y_train,beta,learning_rate=0.01,
n_iteration=2000)
plt.plot(cost_history,c='r')
plt.xlabel("nb d'itérations")
plt.ylabel("Erreur")
plt.show()
```

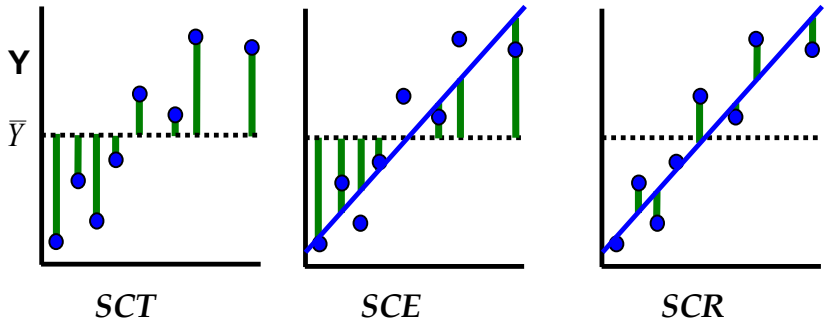


TP1: Régression linéaire simple

Evaluation du modèle par l'analyse de la variance(**Coefficient de détermination**)

```
def coef_determination(y,y_pred):
  u=((y-y_pred)**2).sum()
  v=((y-y.mean())**2).sum()
  return 1-u/v

print(coef_determination(y_train,y_pred_train))
print(coef_determination(y_test,y_pred_test))
```



❖ **Indicateur de qualité d'ajustement(de régression) :**

- Coefficient de détermination R^2

$$R^2 = \frac{\sum_{i=1}^{n}(\hat{y}_i - \bar{Y})^2}{\sum_{i=1}^{n}(yi - \bar{Y})^2} = \frac{SCE}{SCT} = 1 - \frac{SCR}{SCT}$$

- Somme des carrés totale: $SCT = \sum_{i=1}^{n}(yi - \bar{Y})^2$
- Somme des carrés expliqués: $SCE = \sum_{i=1}^{n}(\hat{y}_i - \bar{Y})^2$
- Somme des carrés résiduels: $SCR = \sum_{i=1}^{n}(\hat{y}_i - yi)2$

Commentaire. Le coefficient $\boldsymbol{R^2}$ donne la proportion de variabilité de y qui est expliquée par le modèle. Plus le $\boldsymbol{R^2}$ est proche de 1, plus une meilleure adéquation du modèle aux données

Problème d'estimation ponctuelle

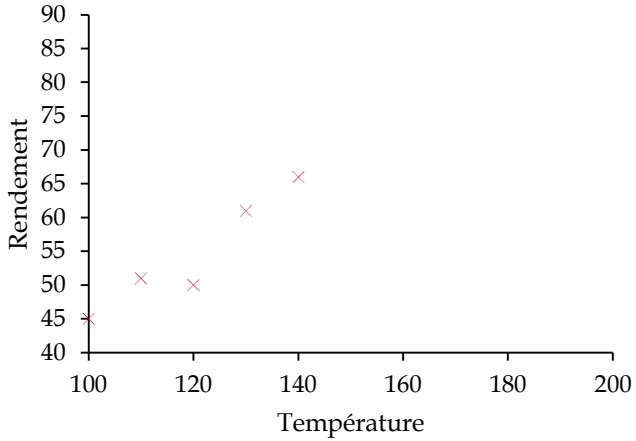
❖ **Problématique:**

Et si on avait plusieurs jeu de données

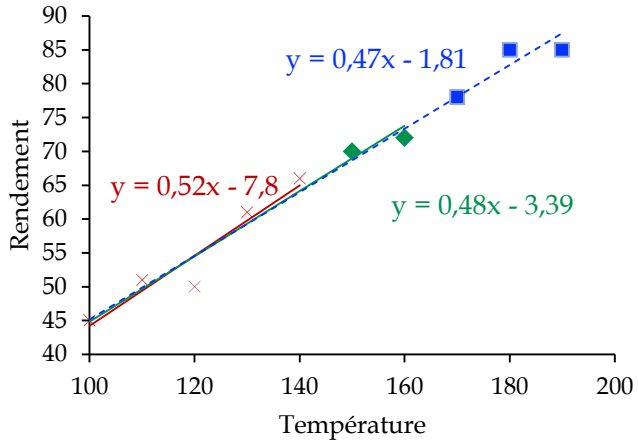
$\begin{cases} \widehat{\beta_0} = -7{,}8 \\ \widehat{\beta_1} = 0{,}52 \end{cases}$ $\begin{cases} \widehat{\beta_0} = -3{,}39 \\ \widehat{\beta_1} = 0{,}48 \end{cases}$ $\begin{cases} \widehat{\beta_0} = -1{,}81 \\ \widehat{\beta_1} = 0{,}47 \end{cases}$

Température (x_i)	*Rendement(y_i)*
100	45
110	51
120	50
130	61
140	66
150	**70**
160	**72**
170	**78**
180	**85**
190	**85**

Rendement d'un champ en fonction de la température



Rendement d'un champ en fonction de la température



d. Estimation des paramètres par intervalle de confiance

Estimation des paramètres par intervalle de confiance

❖ **Propriétés statistiques de la droite des moindres carrés:**

- **(A1)** L'erreur $\boldsymbol{\varepsilon}$ est une v.a.r non observée avec $\mathbb{E}[\boldsymbol{\varepsilon}] = 0, \mathbb{V}(\boldsymbol{\varepsilon}) = \sigma^2$.

  σ paramètre à estimer en plus de β_0, β_1

- **(A2)** $\boldsymbol{Cov}(\boldsymbol{\varepsilon_i}, \boldsymbol{\varepsilon_j}) = 0, \forall i \neq j$

- **(A3)** $\boldsymbol{\varepsilon} \sim \boldsymbol{N}(\mathbf{0}, \sigma^2)$

Commentaires sur l'hypothèse:

- On parle d'hypothèse **d'homoscédasticité A2** (homogénéité des variances).
- Cette variance est supposée **constante et indépendante de x_i**.
- Cette variance σ^2 est un **paramètre du modèle qu'il faudra estimer.**
- $\boldsymbol{Cov}(\boldsymbol{\varepsilon_i}, \boldsymbol{\varepsilon_j}) = 0$, **les termes d'erreur ε_i sont non corrélés**.

Estimation des paramètres par intervalle de confiance

❖ **Propriétés des estimateurs paramètres $\widehat{\beta 0}$ et $\widehat{\beta 1}$:**

Théorème:

- $\mathbb{E}[\widehat{\beta_1}] = \beta_1$ et $\mathbb{E}[\widehat{\beta_0}] = \beta_0$ (estimateurs sans biais)
- $S^2_{\widehat{\beta_0}} = \mathbb{V}[\widehat{\beta_0}] = \sigma^2\left(\frac{1}{n} + \frac{(\bar{X})^2}{\sum_{i=1}^{n}(x_i-\bar{x})^2}\right) = \sigma^2\left(\frac{1}{n} + \frac{(\bar{X})^2}{nS_X^2}\right)$
- $S^2_{\widehat{\beta_1}} = \mathbb{V}[\widehat{\beta_1}] = \left(\frac{\sigma^2}{\sum_{i=1}^{n}(x_i-\bar{x})^2}\right) = \frac{\sigma^2}{nS_X^2}$
- $Cov(\widehat{\beta 0}, \widehat{\beta 1}) = -\frac{n\,\sigma^2\bar{X}}{S_X^2}$

Commentaires

- Les estimateurs $\widehat{\beta_0}$ et $\widehat{\beta_1}$ sont **sans biais**.
- Ils sont aussi de **variance minimale** parmi tous les estimateurs linéaires.

Estimation des paramètres par intervalle de confiance

❖ Estimation de la variance σ^2 par la variation résiduelle

Le paramètre σ^2 est défini par

$$\sigma^2 = \mathbb{V}(\varepsilon_i) = \mathbb{E}(\varepsilon_i^2)$$

En prenant $\hat{y}_i = \widehat{\beta_0} + \widehat{\beta_1} x_i$ comme estimateur de $E[y_i]$, il apparaît naturel d'estimer par σ^2

$$S_\varepsilon^2 = \hat{\sigma}^2 = \frac{\sum_{i=1}^{n} (y_i - \hat{y}_i)^2}{n-2} = \frac{\sum_{i=1}^{n} e_i^2}{n-2} = \frac{SCR}{n-2}$$

Commentaires

- $\hat{\sigma}^2$ est un estimateur sans biais de σ^2
- La perte de deux degrés de liberté dans l'expression de S_ε^2 est le "coût" de l'estimation de β_0 et de β_1 nécessaire pour obtenir les $\hat{y}_i$.
- **SCR**: Somme des Carrés Résiduelle (Variabilité résiduelle).

Estimation des paramètres par intervalle de confiance

❖ **Exemple: calcul des estimateurs des paramètres β0, β1**

N°obs	x_i	y_i	$\hat{y}_i$	$\varepsilon_i = yi - \hat{y}_i$	ε_i^2
1	-1	-1	-4/3	1/3	1/9
2	0	-1	-1/3	-2/3	4/9
3	1	1	2/3	1/3	1/9
Moyenne	$\bar{X}$ =0	$\bar{Y} = -1/3$	$\bar{\hat{Y}} = -1/3$	0	2/3
Variance	S_X^2=2/3	S_Y^2=8/9	-	-	$\hat{\sigma}^2 = S_\varepsilon^2$=2/3

Estimation des paramètres par intervalle de confiance

❖ Lois des estimateurs $\hat{\sigma}^2$, $\widehat{\beta_0}$ et $\widehat{\beta_1}$

Sous les hypothèses (A1)-(A2), on a :

- **Lois de l'estimateur de** σ^2

$$\frac{(n-2)\hat{\sigma}^2}{\sigma^2} \sim \chi^2_{n-2}$$

Loi de χ^2 à n-2 degrés de libertés

- **Lois des estimateurs** $\widehat{\beta_0}$ et $\widehat{\beta_1}$

$$\hat{\beta}_i \sim \mathcal{N}(\beta_i, \mathbb{V}[\hat{\beta}_i])$$

$$\sigma^2 \longrightarrow \hat{\sigma}^2$$

$$\mathbb{V}[\hat{\beta}_i] \rightarrow S^2_{\hat{\beta}_i}$$

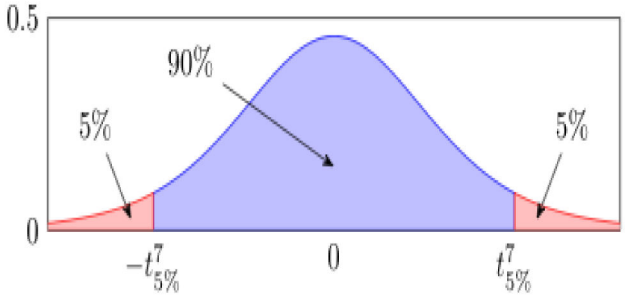
Un rappel de probabilité

- Si U$\sim\mathcal{N}(0,1)$, V$\sim\chi^2(v)$ et U indépendant de V, alors $\frac{U}{\sqrt{\frac{V}{v}}} \sim \mathcal{T}(v)$.

Estimation des paramètres par intervalle de confiance

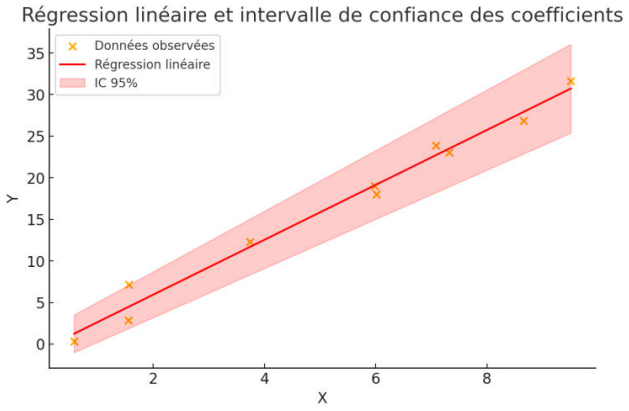
❖ **Estimation des β_i par intervalle de confiance au niveau de confiance 1-α**

$$\mathbb{P}\left(-t_{1-\frac{\alpha}{2};n-2} \leq \frac{\widehat{\beta}_i - \beta_i}{S_{\widehat{\beta}_i}} \leq t_{1-\frac{\alpha}{2};n-2}\right) = 1-\alpha$$



Avec $t_{1-\frac{\alpha}{2};n-2}$ la valeur telle que $\mathbb{P}(T \leq t_{1-\frac{\alpha}{2};n-2}) = 1-\alpha/2$ et T de la loi de Student $\mathcal{T}(n-2)$

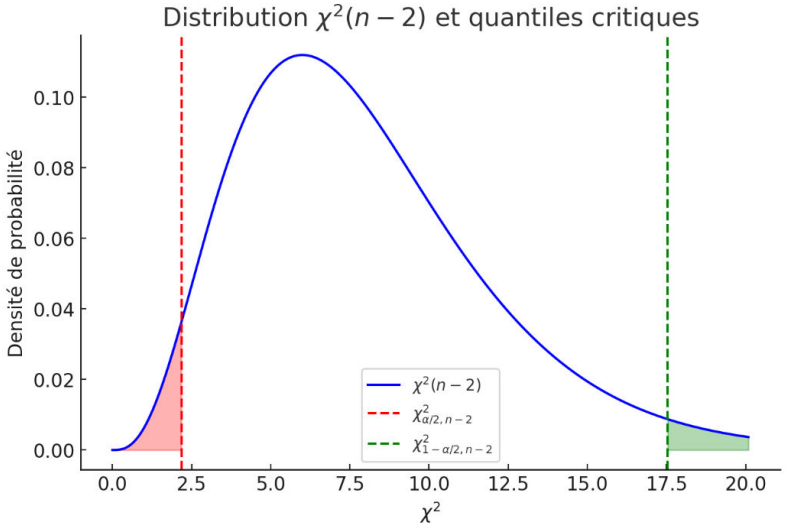
$$IC(\beta_i) = \left[\widehat{\beta}_i \pm t_{1-\frac{\alpha}{2};n-2} S_{\widehat{\beta}_i}\right]$$



Estimation des paramètres par intervalle de confiance

❖ **Estimation de σ^2 par intervalle de confiance au niveau de confiance 1-α/2**

$$\mathbb{P}\left(\chi^2_{\alpha/2} \leq \frac{(n-2)\hat{\sigma}^{*2}}{\sigma^2} \leq \chi^2_{1-\alpha/2}\right) = 1-\alpha$$



$$IC(\sigma^2) = \left[\frac{(n-2)\hat{\sigma}^{2}}{\chi^2_{\alpha/2}}, \frac{(n-2)\hat{\sigma}^{2}}{\chi^2_{1-\alpha/2}}\right]$$

Estimation des paramètres par intervalle de confiance

❖ **Exemple:**

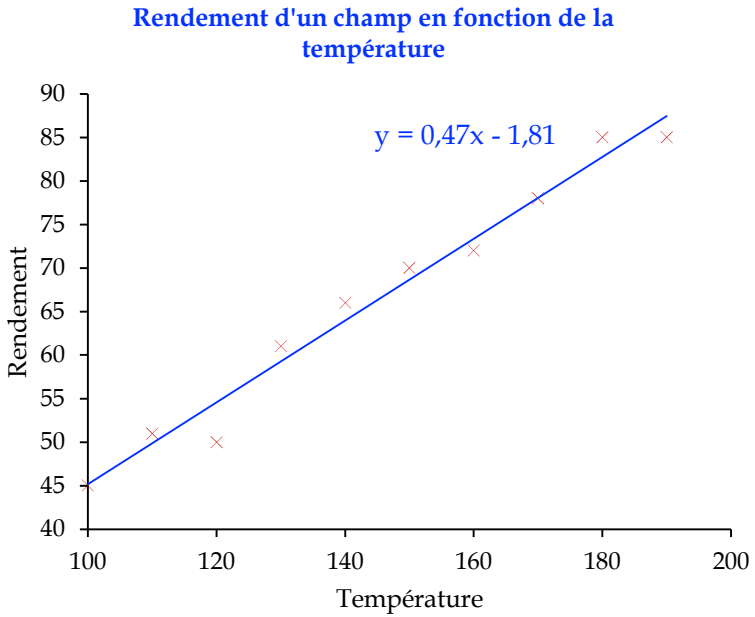
Température (x_i)	*Rendement(y_i)*
100	45
110	51
120	50
130	61
140	66
150	70
160	72
170	78
180	85
190	85

$\bar{X} = 145;\ \bar{Y} = 66.3;$

$S_X^2 = 825;\ S_Y^2 = 186.41;$

$Cov(X,Y) = 387.5$

$$\begin{cases} \widehat{\beta_1} = \dfrac{Cov(X,Y)}{S_X^2} \approx 0.47, \\ \widehat{\beta_0} = \bar{Y} - \widehat{\beta_1}\bar{X} \approx -1.81 \end{cases}$$



Estimation des paramètres par intervalle de confiance

❖ **Exemple:**

$\bar{X} = 145;\ \bar{Y} = 66.3;$

$S_X^2 = 825;\ S_Y^2 = 186.41;$

$Cov(X,Y) = 387.5$

$$\begin{cases} \widehat{\beta_1} = \dfrac{Cov(X,Y)}{S_X^2} \approx 0.47, \\ \widehat{\beta_0} = \bar{Y} - \widehat{\beta_1}\bar{X} \approx -1.81 \end{cases}$$

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^{n}\left(Y_i - \widehat{Y}_i\right)^2}{n-2} = \frac{1}{n-2}\sum_{i=1}^{n}\left(Y_i - \hat{\beta}_0 + \hat{\beta}_1 x_i\right)^2 \approx 5.5$$

$$S_{\widehat{\beta_1}}^2 = \frac{\widehat{\sigma}^2}{nS_X^2} \approx 0.001;\ \ S_{\widehat{\beta_0}}^2 = \widehat{\sigma}^2\left(\frac{\sum_{i=1}^{n} x_i^2}{n\sum_{i=1}^{n}(x_i - \bar{x})^2}\right) \approx 14.57$$

Estimation des paramètres par intervalle de confiance

❖ **Exemple:**

Calcul des intervalles de confiance des estimateurs au niveau 1-0.05=0.95

$$\chi_1^2 = \chi^2_{0,025;10-2} = 2.18; \chi_2^2 = \chi^2_{1-0,025;10-2} = 17.13; t_{1-\alpha/2;10-2} = 2.306$$

$$IC(\beta_1) = \left[\widehat{\beta_1} \pm t_{1-\frac{\alpha}{2};n-2} S_{\widehat{\beta_1}}\right] = \left[0.47 \pm 2.306 * \sqrt{0.001}\right] = [0.41, 0.53]$$

$$IC(\beta_0) = \left[\widehat{\beta_0} \pm t_{1-\frac{\alpha}{2};n-2} S_{\widehat{\beta_0}}\right] = \left[-1.81 \pm 2.306 * \sqrt{14,57}\right] = [-10.61, 7.00]$$

$$IC(\sigma^2) = \left[\frac{(n-2)\hat{\sigma}^2}{\chi^2_{\alpha/2}}, \frac{(n-2)\hat{\sigma}^2}{\chi^2_{1-\alpha/2}}\right] = [-2.51, 20.2]$$

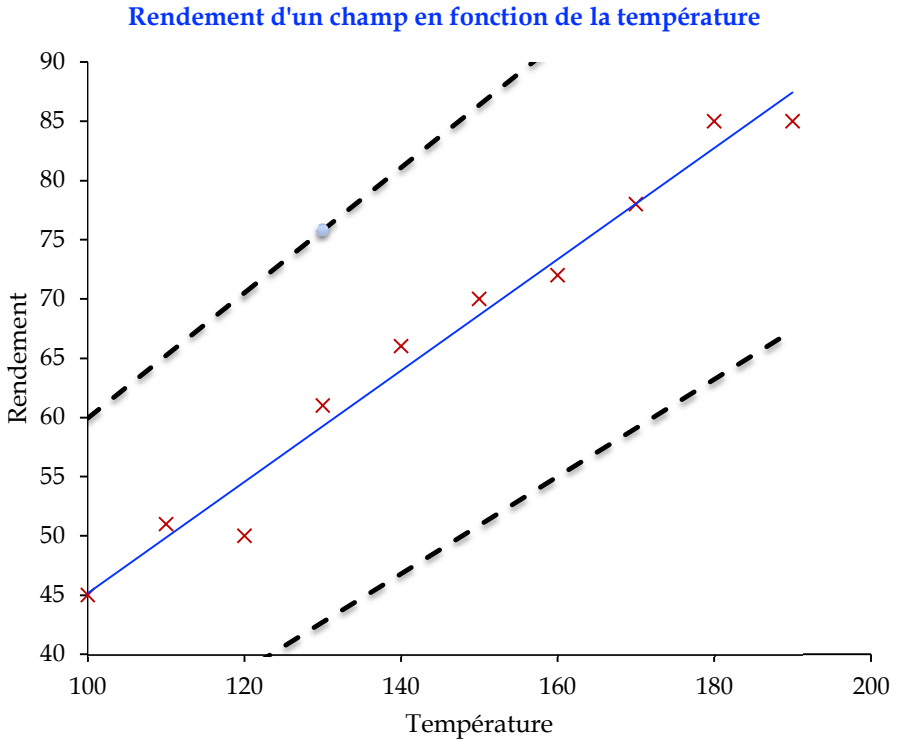
$$\begin{cases} \widehat{\beta_1} = \dfrac{Cov(X,Y)}{S_X^2} \approx 0.47, \\ \widehat{\beta_0} = \bar{Y} - \widehat{\beta_1}\bar{X} \approx -1.81 \end{cases}$$

Table de student: https://www.supagro.fr/cnam-lr/statnet/tables.htm#student

Estimation des paramètres par intervalle de confiance

❖ **Exemple:**

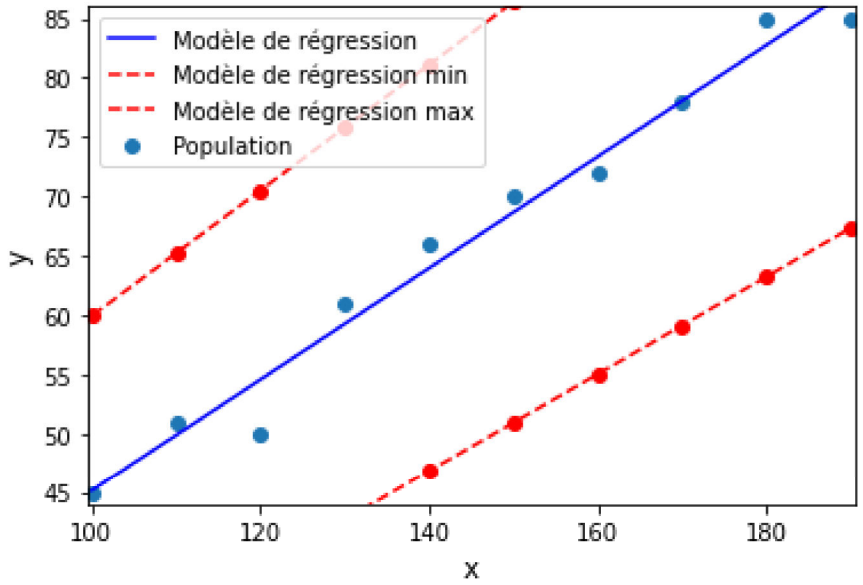
$$IC(\beta_1) = [0.41, 0.53] \quad IC(\beta_0) = [-10.61, 7.00]$$



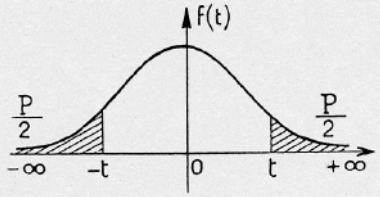
Estimation des paramètres par intervalle de confiance

❖ **Exemple:**

$$IC(\beta_1) = [0.41, 0.53] \quad IC(\beta_0) = [-10.61, 7.00]$$



Estimation des paramètres par intervalle de confiance



ν \ P	0,90	0,80	0,70	0,60	0,50	0,40	0,30	0,20	0,10	0,05	0,02	0,01	0,001
1	0,158	0,325	0,510	0,727	1,000	1,376	1,963	3,078	6,314	12,706	31,821	63,657	636,619
2	0,142	0,289	0,445	0,617	0,816	1,061	1,386	1,886	2,920	4,303	6,965	9,925	31,598
3	0,137	0,277	0,424	0,584	0,765	0,978	1,250	1,638	2,353	3,182	4,541	5,841	12,929
4	0,134	0,271	0,414	0,569	0,741	0,941	1,190	1,533	2,132	2,776	3,747	4,604	8,610
5	0,132	0,267	0,408	0,559	0,727	0,920	1,156	1,476	2,015	2,571	3,365	4,032	6,869
6	0,131	0,265	0,404	0,553	0,718	0,906	1,134	1,440	1,943	2,447	3,143	3,707	5,959
7	0,130	0,263	0,402	0,549	0,711	0,896	1,119	1,415	1,895	2,365	2,998	3,499	5,408
8	0,130	0,262	0,399	0,546	0,706	0,889	1,108	1,397	1,860	2,306	2,896	3,355	5,041
9	0,129	0,261	0,398	0,543	0,703	0,883	1,100	1,383	1,833	2,262	2,821	3,250	4,781
10	0,129	0,260	0,397	0,542	0,700	0,879	1,093	1,372	1,812	2,228	2,764	3,169	4,587
11	0,129	0,260	0,396	0,540	0,697	0,876	1,088	1,363	1,796	2,201	2,718	3,106	4,437
12	0,128	0,259	0,395	0,539	0,695	0,873	1,083	1,356	1,782	2,179	2,681	3,055	4,318
13	0,128	0,259	0,394	0,538	0,694	0,870	1,079	1,350	1,771	2,160	2,650	3,012	4,221
14	0,128	0,258	0,393	0,537	0,692	0,868	1,076	1,345	1,761	2,145	2,624	2,977	4,140
15	0,128	0,258	0,393	0,536	0,691	0,866	1,074	1,341	1,753	2,131	2,602	2,947	4,073
16	0,128	0,258	0,392	0,535	0,690	0,865	1,071	1,337	1,746	2,120	2,583	2,921	4,015
17	0,128	0,257	0,392	0,534	0,689	0,863	1,069	1,333	1,740	2,110	2,567	2,898	3,965
18	0,127	0,257	0,392	0,534	0,688	0,862	1,067	1,330	1,734	2,101	2,552	2,878	3,922
19	0,127	0,257	0,391	0,533	0,688	0,861	1,066	1,328	1,729	2,093	2,539	2,861	3,883
20	0,127	0,257	0,391	0,533	0,687	0,860	1,064	1,325	1,725	2,086	2,528	2,845	3,850
21	0,127	0,257	0,391	0,532	0,686	0,859	1,063	1,323	1,721	2,080	2,518	2,831	3,819
22	0,127	0,256	0,390	0,532	0,686	0,858	1,061	1,321	1,717	2,074	2,508	2,819	3,792
23	0,127	0,256	0,390	0,532	0,685	0,858	1,060	1,319	1,714	2,069	2,500	2,807	3,767
24	0,127	0,256	0,390	0,531	0,685	0,857	1,059	1,318	1,711	2,064	2,492	2,797	3,745
25	0,127	0,256	0,390	0,531	0,684	0,856	1,058	1,316	1,708	2,060	2,485	2,787	3,725
26	0,127	0,256	0,390	0,531	0,684	0,856	1,058	1,315	1,706	2,056	2,479	2,779	3,707
27	0,127	0,256	0,389	0,531	0,684	0,855	1,057	1,314	1,703	2,052	2,473	2,771	3,690
28	0,127	0,256	0,389	0,530	0,683	0,855	1,056	1,313	1,701	2,048	2,467	2,763	3,674
29	0,127	0,256	0,389	0,530	0,683	0,854	1,055	1,311	1,699	2,045	2,462	2,756	3,659
30	0,127	0,256	0,389	0,530	0,683	0,854	1,055	1,310	1,697	2,042	2,457	2,750	3,646
40	0,126	0,255	0,388	0,529	0,681	0,851	1,050	1,303	1,684	2,021	2,423	2,704	3,551
80	0,126	0,254	0,387	0,527	0,679	0,848	1,046	1,296	1,671	2,000	2,390	2,660	3,460
120	0,126	0,254	0,386	0,526	0,677	0,845	1,041	1,289	1,658	1,980	2,358	2,617	3,373
∞	0,126	0,253	0,385	0,524	0,674	0,842	1,036	1,282	1,645	1,960	2,326	2,576	3,291

e. Tests d'hypothèse

Tests d'hypothèses

❖ **Test sur β_i (test bilatéral) :**

$$\mathcal{H}_0 : "\beta_i = 0" \quad \textbf{contre} \quad \mathcal{H}_1 : "\beta_i \neq 0"$$

Fixer le risque α

Statistique de test : $T_{\widehat{\beta}_i} = \frac{\widehat{\beta}_i}{S_{\widehat{\beta}_1}} \sim \mathcal{T}(n-2)$

Décision: un niveau de test α (usuellement 0,05 ou 0,01), On calcule $T_{\widehat{\beta}_i}$

- **Si** $\left|T_{\widehat{\beta}_i}\right| > \boldsymbol{t_{n-2;(1-\alpha/2)}}$, alors H_0 est rejetée
- **Sinon** H_0 est acceptée

où $\boldsymbol{t}$ est la réalisation de $\boldsymbol{T_n}$ et $\boldsymbol{t_{n-2;(1-\alpha)/2}}$ est le fractile d'ordre $1 - \alpha/2$ de la loi $\mathcal{T}(n-2)$.

.

Tests d'hypothèses

❖ **Test sur β_i (test unilatéral) :**

Exemple de vérifier si β_1 est positive

$$\mathcal{H}_0 : "\boldsymbol{\beta_1 \geq 0}" \quad \textbf{contre} \quad \mathcal{H}_1 : "\boldsymbol{\beta_1 < 0}"$$

Fixer le risque α

Statistique de test : $T_{\widehat{\beta}_1} = \frac{\widehat{\beta}_1}{S_{\widehat{\beta}_i}} \sim \mathcal{T}(n-2)$

Décision: un niveau de test α (usuellement 0,05 ou 0,01), On calcule $T_{\widehat{\beta}_i}$

- **Si** $\left|T_{\widehat{\beta}_1}\right| \geq \boldsymbol{t_{n-2;(1-\alpha/2)}}$, alors $H0$ est acceptée
- **Sinon** $H0$ est rejetée

où $\boldsymbol{t}$ est la réalisation de $\boldsymbol{T_n}$ et $\boldsymbol{t_{n-2;(1-\alpha)/2}}$ est le fractile d'ordre $1 - \alpha/2$ de la loi $\mathcal{T}(n-2)$.

.

Tests d'hypothèses

❖ **Test sur β_0 (test de passage par l'origine) :**

Exemple de vérifier si β_0 est nul

$$\mathcal{H}_0 : "\boldsymbol{\beta_0 = 0}" \quad \textbf{contre} \quad \mathcal{H}_1 : "\boldsymbol{\beta_0 \neq 0}"$$

Fixer le risque α

Statistique de test : $T_{\widehat{\beta}_0} = \frac{\widehat{\beta}_0}{S_{\widehat{\beta}_0}} \sim \mathcal{T}(n-2)$

Décision: un niveau de test α (usuellement 0,05 ou 0,01), On calcule $T_{\widehat{\beta}_0}$

- **Si** $\left|T_{\widehat{\beta}_0}\right| > \boldsymbol{t_{n-2;(1-\alpha/2)}}$, alors $H0$ est rejetée
- **Sinon** $H0$ est acceptée

où $\boldsymbol{t}$ est la réalisation de $\boldsymbol{T_n}$ et $\boldsymbol{t_{n-2;(1-\alpha)/2}}$ est le fractile d'ordre $1 - \alpha/2$ de la loi $\mathcal{T}(n-2)$.

.

Tests d'hypothèses

❖ **Test de fisher :**

Significativité de la régression en utilisant l'analyse de la variance

$$\mathcal{H}_0 : "\beta_1 = 0" \quad \textbf{contre} \quad \mathcal{H}_1 : "\beta_1 \neq 0"$$

Fixer le risque α

Statistique de test : $F = \frac{SCE}{SCR/(n-2)} \sim F_{n-2}^{1}$

Décision: rejet ou pas de $\mathcal{H}_0$ si $F > f_{n-2}^{2}(1-\alpha)$

Où $f_{n-2}^{2}(1-\alpha)$ est le quantile de niveau $(1-\alpha)$ d'une loi $F_{n-2}^{2}(1-\alpha)$

.

f. Prévision

Prévision

❖ Prévision d'une valeur ultérieure

On désire prévoir à l'aide du modèle la valeur de la variable y pour une valeur non observé x_{n+1} de x.

D'après le modèle on a $y_{n+1} = \beta_0 + \beta_1 x_{n+1} + \varepsilon_{n+1}$, où y_{n+1} et ε_{n+1} sont des variables aléatoires. La prédiction naturelle est alors :

$$\widehat{\boldsymbol{y}}_{\boldsymbol{n+1}} = \widehat{\boldsymbol{\beta}_0} + \widehat{\boldsymbol{\beta}_1}\boldsymbol{x}_{\boldsymbol{n+1}}$$

L'erreur de prédiction est définie par $\widehat{\boldsymbol{y}}_{\boldsymbol{n}+1} - \boldsymbol{y}_{\boldsymbol{n+1}}$ et on peut montrer que sous les hypothèses du modèle (incluant l'hypothèse de normalité), on a :

$$\widehat{\boldsymbol{y}}_{\boldsymbol{n+1}} - \boldsymbol{y}_{\boldsymbol{n+1}} \sim \mathcal{N}\left(0, \sigma^2\left(1 + \frac{1}{n} + \frac{(x_{n+1} - \overline{\boldsymbol{X}}_n)^2}{\sum_{i=1}^{n}(x_i - \overline{\boldsymbol{X}}_n)^2}\right)\right)$$

Prévision

❖ **Prévision d'une valeur ultérieure**

Avec les notations et hypothèses précédentes, on obtient:

$$\frac{\widehat{y}_{n+1} - y_{n+1}}{\widehat{\sigma}\sqrt{1 + \frac{1}{n} + \frac{(x_{n+1} - \bar{X}_n)^2}{\sum_{i=1}^{n}(x_i - \bar{X}_n)^2}}} \sim \mathcal{T}(n-2)$$

On utilise ce résultat pour construire un intervalle de prédiction pour y_{n+1}, c'est à dire l'intervalle [A,B] tel que

$$\mathbb{P}(A \leq y_{n+1} \leq B) = 1 - \alpha.$$

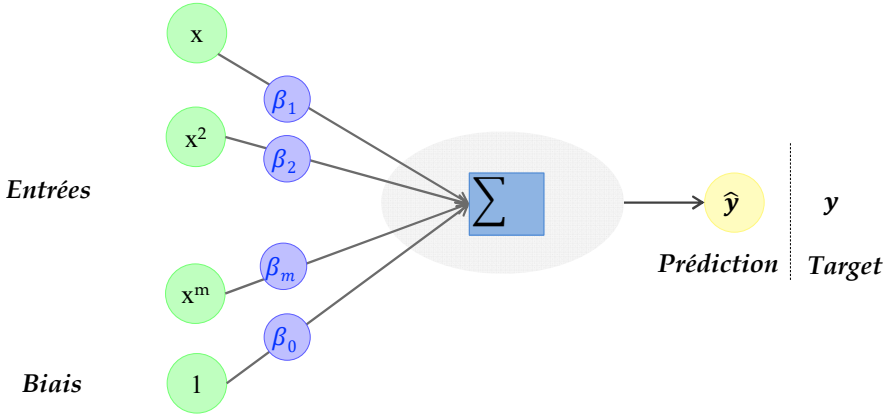
On en déduit l'intervalle de prédiction pour y0 au niveau de confiance 1 − α suivant :

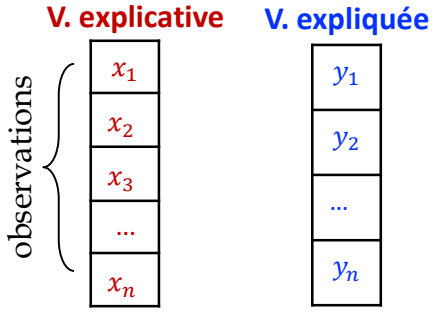
$$y_{n+1} \in \left[\widehat{y}_{n+1} \pm t_{1-\frac{\alpha}{2};n-2}\widehat{\sigma}\sqrt{1 + \frac{1}{n} + \frac{(x_{n+1} - \bar{X}_n)^2}{\sum_{i=1}^{n}(x_i - \bar{X}_n)^2}}\right]$$

3. Régression polynomiale

Régression polynomiale

❖ **Modèle de régression polynomiale**





Modèle de régression polynomiale de degré m

$$\boldsymbol{y} = (\beta_1\ x + \beta_2\ x^2 + \cdots + \beta_m\ x^m + \beta_0 + \varepsilon)$$

$X = (1, x\ , x^2, \ldots, x^m)$, *vecteur des entrées + biais*

$\beta = (\beta_0, \beta_1, \beta_2, \ldots, \beta_m)$, *vecteur de poids*

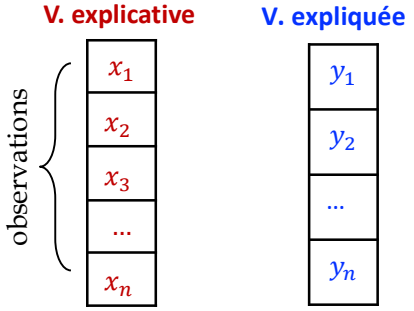
Régression polynomiale

❖ **Estimation des paramètres $\beta_0, \beta_1, ..., \beta_m$**

1. **Dataset (X,Y)**
   - variable explicative (feature)
   - variable expliquée (target)

2. **Modèle**
   - Régression: Modèle linéaire simple. $Y = \beta X + \varepsilon$

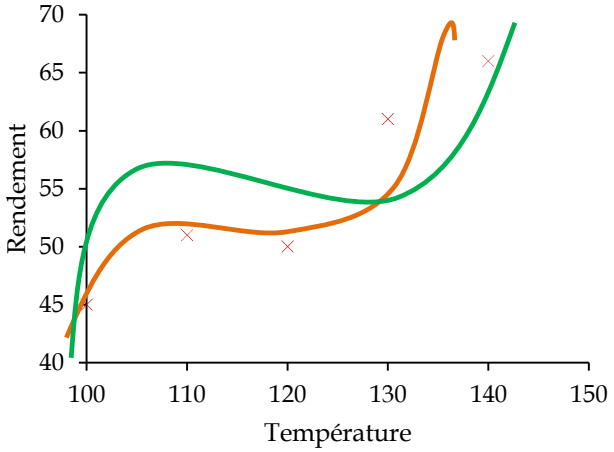
$$(Y \approx \beta X) \text{ où } \boldsymbol{Y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}, \boldsymbol{X} = \begin{pmatrix} \mathbf{1} & \boldsymbol{x_1} & \boldsymbol{x_1^2} & \cdots & \boldsymbol{x_1^m} \\ \mathbf{1} & \boldsymbol{x_2} & \boldsymbol{x_2^2} & \vdots & \boldsymbol{x_2^m} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ \mathbf{1} & \boldsymbol{x_n} & \boldsymbol{x_n^2} & \cdots & \boldsymbol{x_n^m} \end{pmatrix}, \boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_m \end{pmatrix}, \text{ et } \boldsymbol{\varepsilon} = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$



3. **Fonction coût**
   - Erreur quadratique moyenne

$$\boldsymbol{L(\beta_0, \beta_1 \quad \beta_m) = \frac{1}{n}(X\beta - Y)^T(X\beta - Y)}$$

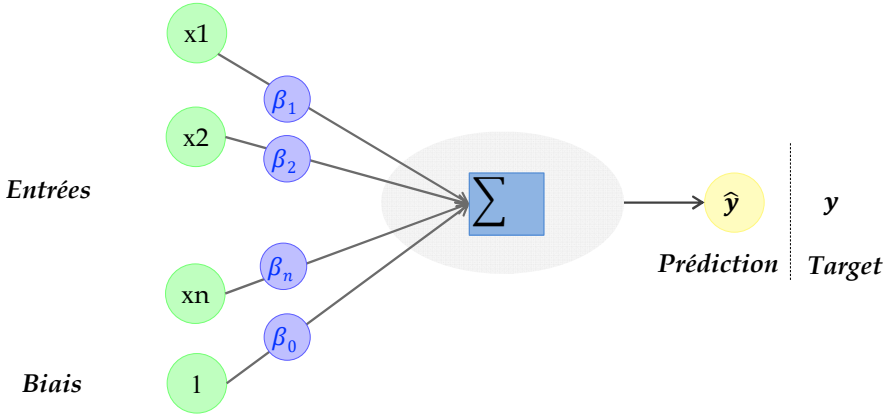
4. **Algorithme d'optimisation**
   - Méthode des moindre carrés
   - Descente de gradient

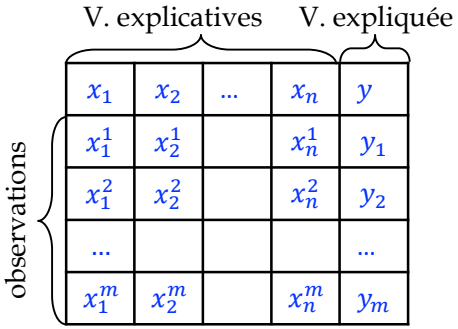


4. Régression multiple

Régression linéaire multiple

❖ Modèle de régression linéaire multiple

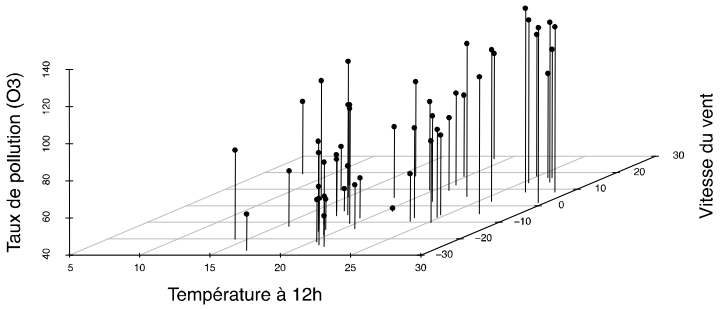




Modèle de régression linéaire multiple $y = (\beta_1\ x_1 + \beta_2\ x_2 + \cdots + \beta_n\ x_n + \beta_0 + \varepsilon)$

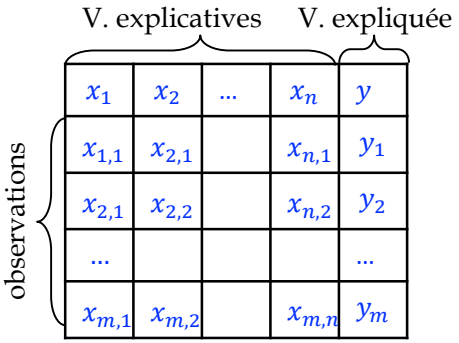
$X = (1, x_1, x_2, \ldots, x_n)$, *vecteur des entrées + biais*

$\beta = (\beta_0, \beta_1, \beta_2, \ldots, \beta_n)$, *vecteur de poids*



Régression linéaire multiple

❖ **Estimation des paramètres $\beta_0, \beta_1, ..., \beta_m$**



1. **Dataset (X,Y)**
   - variables explicatives (features)
   - variable expliquée (target)

2. **Modèle**
   - Régression: Modèle linéaire simple. $Y = \beta X + \varepsilon$

$$(Y \approx \beta X) \text{ où } \boldsymbol{Y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}, \ \boldsymbol{X} = \begin{pmatrix} \mathbf{1} & \boldsymbol{x_{1,1}} & \boldsymbol{x_{1,2}} & \cdots & \boldsymbol{x_{1,n}} \\ \mathbf{1} & \boldsymbol{x_{2,1}} & \boldsymbol{x_{2,2}} & \vdots & \boldsymbol{x_{2,n}} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & \boldsymbol{x_{m,1}} & \boldsymbol{x_{m,2}} & \cdots & \boldsymbol{x_{m,n}} \end{pmatrix}, \boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_n \end{pmatrix}, \text{ et } \boldsymbol{\varepsilon} = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_m \end{pmatrix}$$

3. **Fonction coût**
   - Erreur quadratique moyenne

$$\boldsymbol{L(\beta_0, \beta_1) = \frac{1}{n}(X\beta - Y)^T(X\beta - Y)}$$

4. **Algorithme d'optimisation**
   - Méthode des moindre carrés
   - Descente de gradient

