Machine learning

Lecture6: K-means

Prof: Aissam BERRAHOU
Aissam.berrahou@ensias.um5.ac.ma
Laboratoire Smart Systems Lab

ENSIAS

جامعة محمد الخامس بالرباط
Université Mohammed V de Rabat

2020-2021

Objectifs du cours

Comment une machine peut-elle former des groupes cohérents sans qu'on lui donne la réponse ?

C'est la question à laquelle répond ce cours. À la fin de la séance, vous saurez :

- expliquer le principe de **K-means** et le dérouler à la main, itération par itération ;
- calculer l'**inertie intra-classe W** et le **score de silhouette** ;
- choisir le nombre de groupes **K** de façon argumentée ;
- reconnaître les pièges de l'algorithme (**minima locaux**) et les éviter avec **K-means++**.

Plan

1) Introduction
2) Principe
3) Points forts et faibles
4) Implémentation avec python

Introduction

Introduction

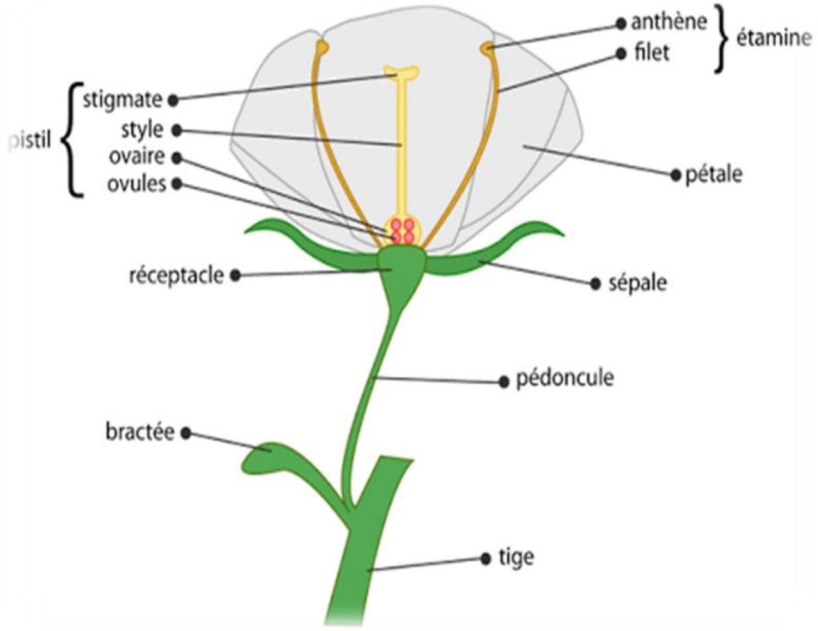
- K-means en français **k-moyenne ou encore méthode des centres mobiles**.
  - MacQueen en 1967.
  - Algorithme d'**apprentissage** automatique non **supervisé**.
  - **Classification automatique.**
  - **Prédiction sur des variables qualitatives et quantitatives.**
  - Méthode **non paramétrique.**

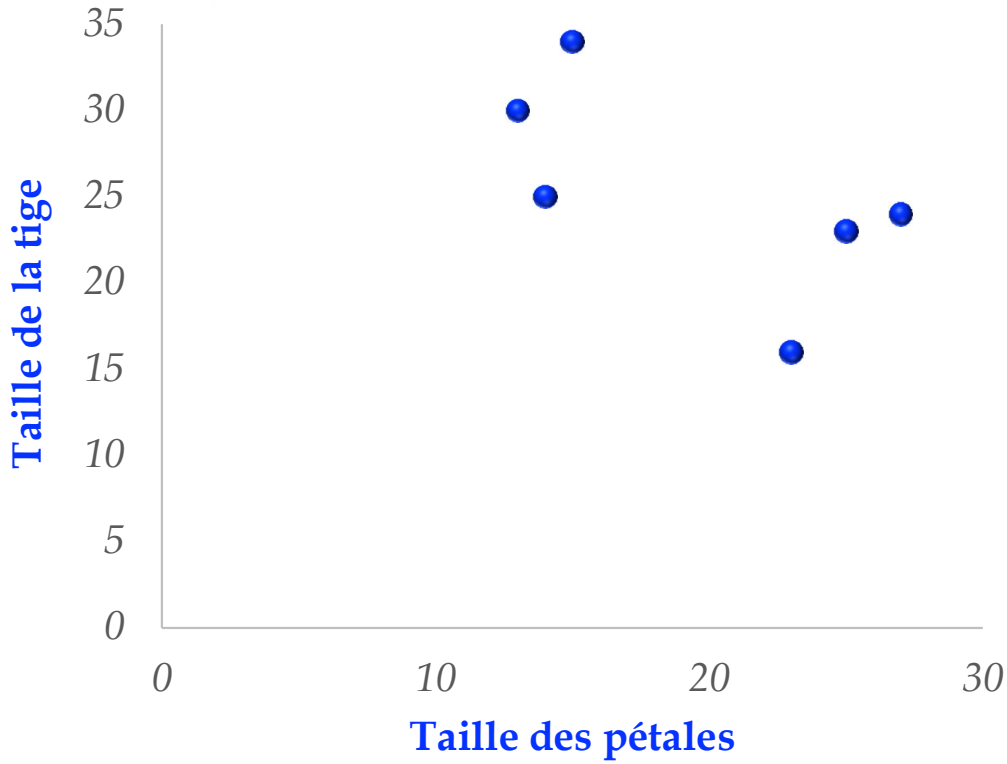
Introduction

- **Objectif** : identifier des groupes d'observations ayant des caractéristiques similaires (ex. comportement d'achats de clients, caractère « polluant » de véhicules, etc.)
- **On veut que :**
  - Les individus dans un même groupe se ressemblent le plus possible.
  - Les individus dans des groupes différents se démarquent le plus possible.
- **Pourquoi ?**
  - Identifier des structures sous-jacentes dans les données;
  - Résumer des comportements;
  - Affecter de nouveaux individus à des catégories;
  - Identifier les cas totalement atypiques.

Introduction

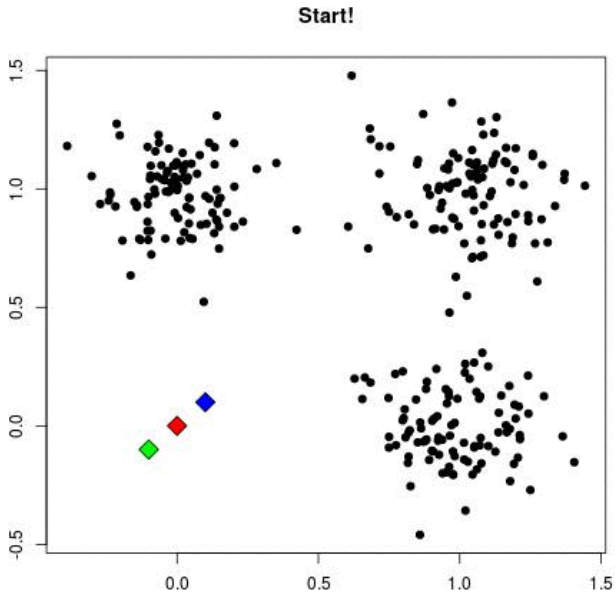
Taille des pétales	Taille de la tige
22	17
27	25
25	24
15	35
13	25
12	30





Principe

Principe



Algorithme: K-means( )

1 ▷ **Entrées:** ***E:*** *ensemble d'individus, K: nb de groupes cherchés*

2 ▷ **Sortie:** ***C:*** *Centroides*$\{\mu_1, \ldots, \mu_K\}$

3 **Début**

4 **Choisir aléatoirement les centres des groupes(Centroides)**

5 **Répéter**

6 i. Affecter chaque individu de E au groupe dont il est le plus proche au son

7 centre(distance min entre individu x_i et le centroide C_l)

8 $$x_i \in C_l \;\; si \; \forall_{j \leq K} \; d(x_i, \mu_l) = \min \; d(x_i, \mu_j)$$

9 ii. Calculer le critère $J_w = \sum_{j=1}^{K} \sum_{i \in C_j} d^2(x_i, \mu_j)$

10 iii. Recalculer le centre de chaque groupe

11

12 $$\mu_l = \frac{1}{N_l} \sum_{i \epsilon C_l} x_i \, , avec N_l = Card(C_l)$$

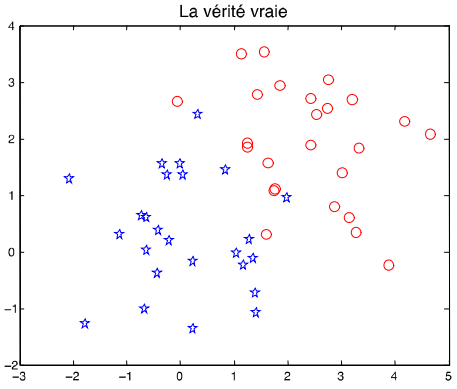
13 **Tant que (Centres ne sont pas** stables($\|\Delta\mu\| > \varepsilon$) **ou** nombre d'itération ==t **ou** stabilisation de l'inertie totale de la population ($\|J_w\| > \varepsilon$)).

14 **Fin**

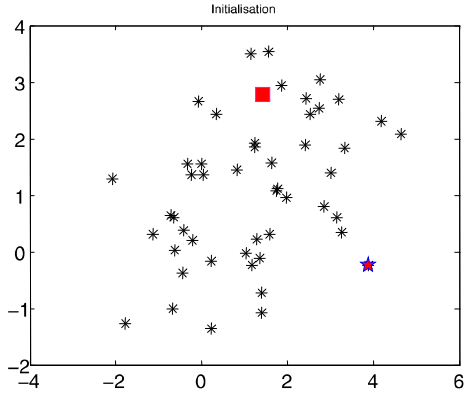
Principe

❖ **Illustration:** Clustering en K = 2 classes

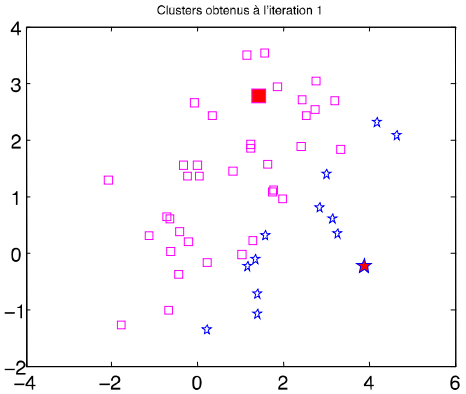
Données



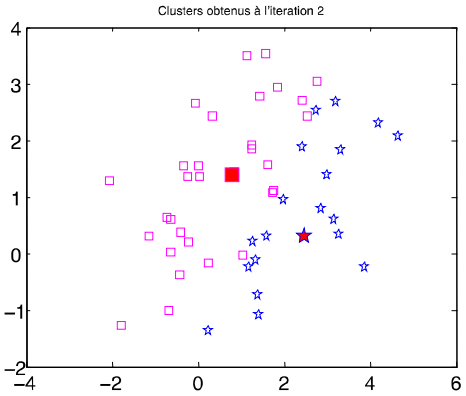
Initialisation



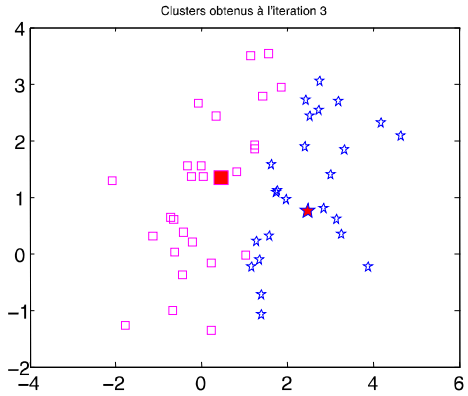
Itération 1



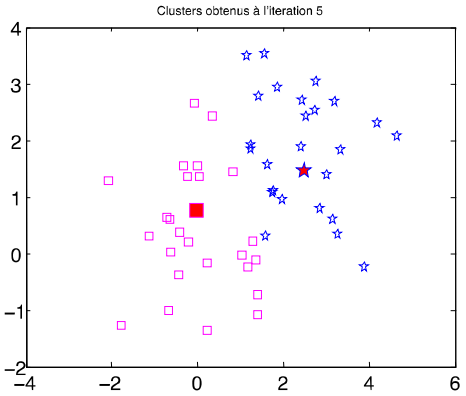
Itération 2



Itération 3



Itération 5

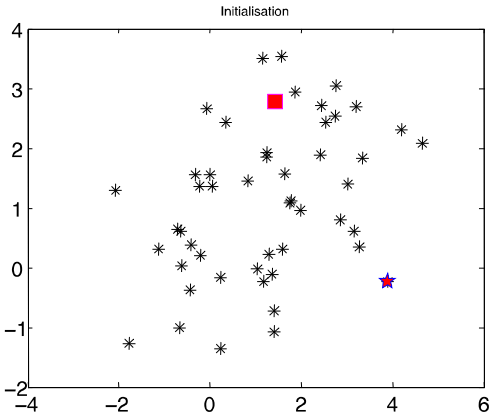


(Visualisation de la simulation)

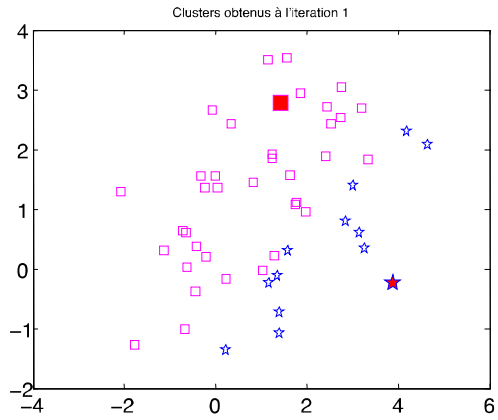
Principe

❖ **Illustration:** Clustering en K = 2 classes avec l'évolution de J_w

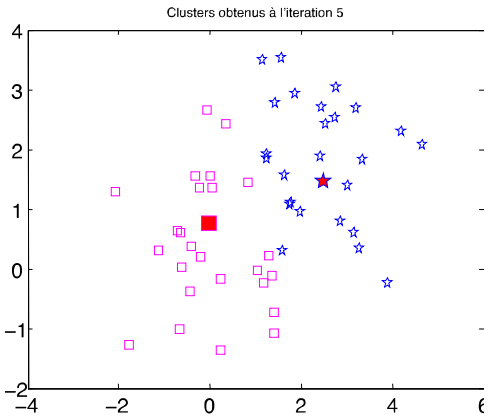
Initialisation

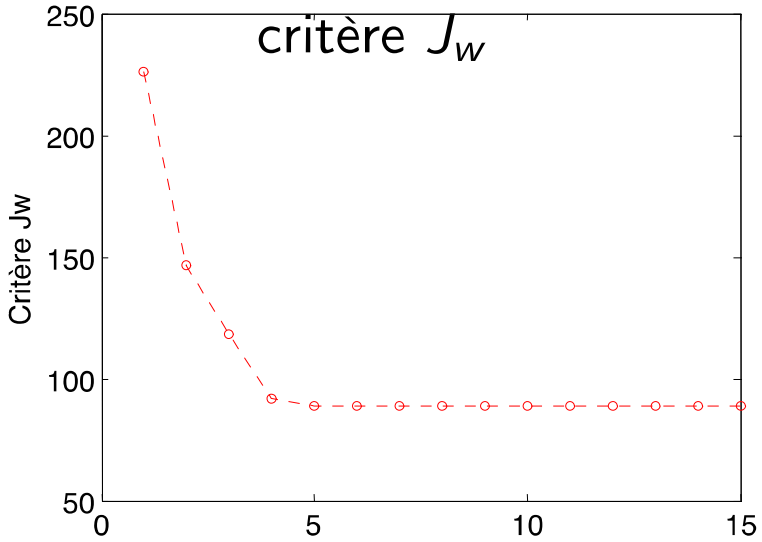


Itération 1



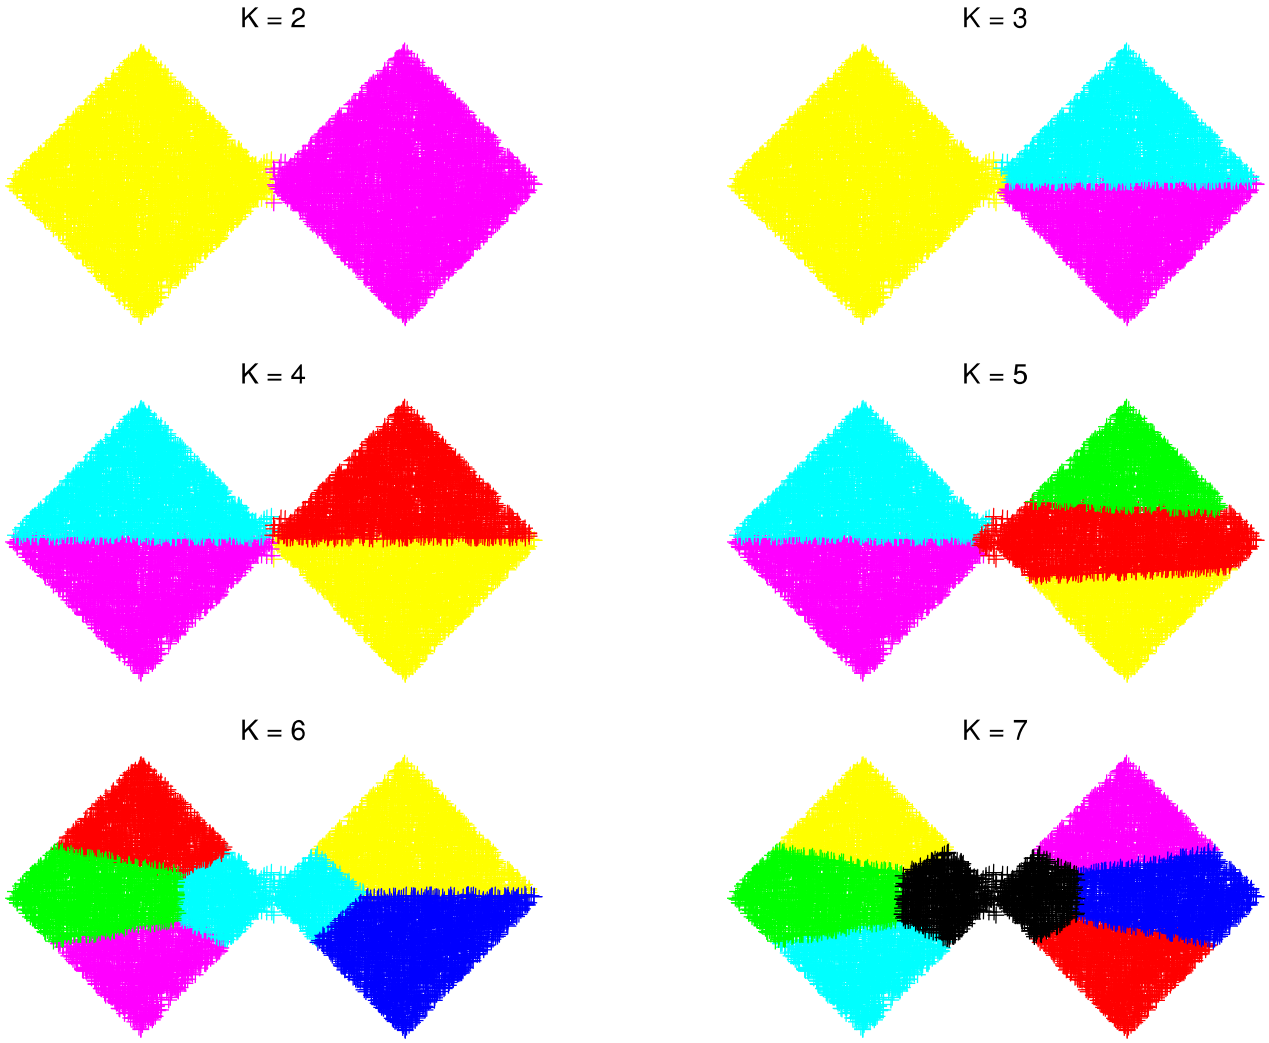
Itération 5





Principe

❖ **Exemple1:** Variation du paramètre K = 2



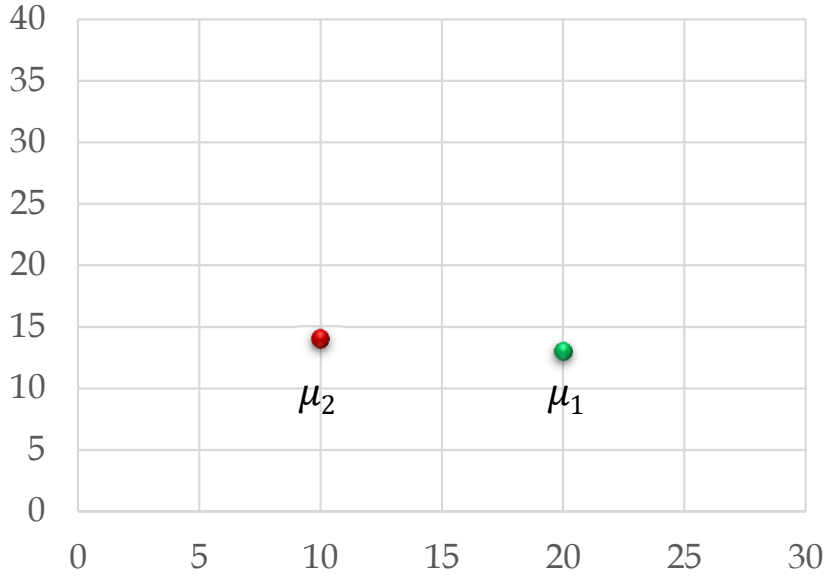
Principe

Initialisation

$K = 2$

$\mu_1 = (20,13)\ et\ \mu_2 = (10,14)$

$d = distance\ euclidienne$



Itération 1

Obs	(T. des pétales, T. de la tige)	$d(O_i, \mu_1)$	$d(O_i, \mu_2)$
O1	(22, 17)	**4,47**	**12,37**
O2	(27, 25)	**13,89**	**20,25**
O3	(25, 24)	**12,08**	**18,03**
O4	(15, 35)	**22,56**	**21,59**
O5	(13, 25)	**13,89**	**11,40**
O6	(12, 30)	**18,79**	**16,12**

$C_1 = \{O_1, O_2, O_3\},$

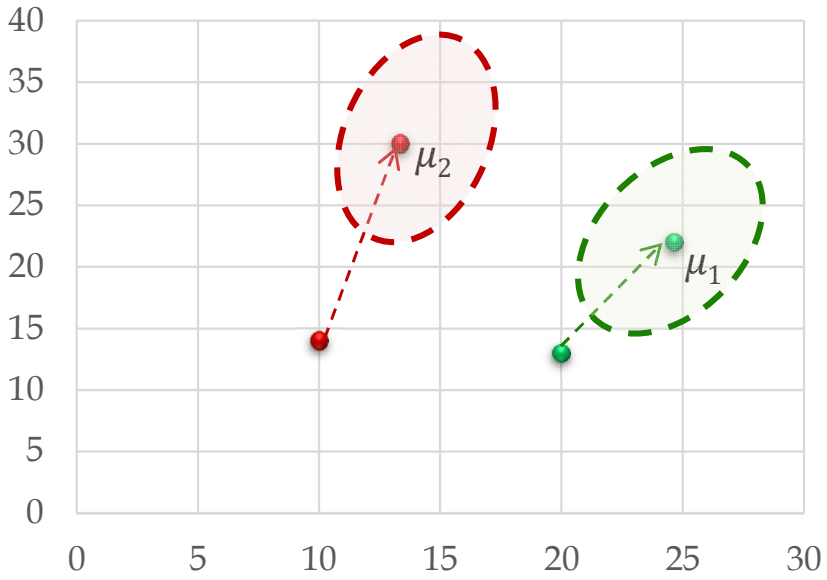
$C_2 = \{O_4, O_5, O_6\},$

$\mu_1 = \left(\frac{22+27+25}{3}, \frac{17+25+24}{3}\right) = (\mathbf{24.67, 22})$

$\mu_2 = \left(\frac{15+13+12}{3}, \frac{35+25+30}{3}\right) = (\mathbf{13.33, 30})$

$J_w = 4,47+13,89+12,08+21,59+11,4+16,12 = \mathbf{79.55}$

Principe



Itération 1

$\mu_1 = (24.67, 22)$ *et* $\mu_2 = (13.33, 30)$

Itération 2

Obs	(T. des pétales, T. de la tige)	$d(O_i, \mu_1)$	$d(O_i, \mu_2)$
O1	(22, 17)	**5,67**	**15,62**
O2	(27, 25)	**3,80**	**14,55**
O3	(25, 24)	**2,03**	**13,12**
O4	(15, 35)	**16,20**	**5,27**
O5	(13, 25)	**12,05**	**5,01**
O6	(12, 30)	**14,98**	**1,33**

$C_1 = \{O_1, O_2, O_3\}$,

$C_2 = \{O_4, O_5, O_6\}$,

$\mu_1 = \left(\frac{22+27+25}{3}, \frac{17+25+24}{3}\right) = (\mathbf{24.67, 22})$

$\mu_2 = \left(\frac{15+13+12}{3}, \frac{35+25+30}{3}\right) = (\mathbf{13.33, 30})$

J_w= 4,47+13,89+12,08+21,59 +11,4 +16,12=**79.55**

Remarque: pas de changement des positions de centres des groupes.

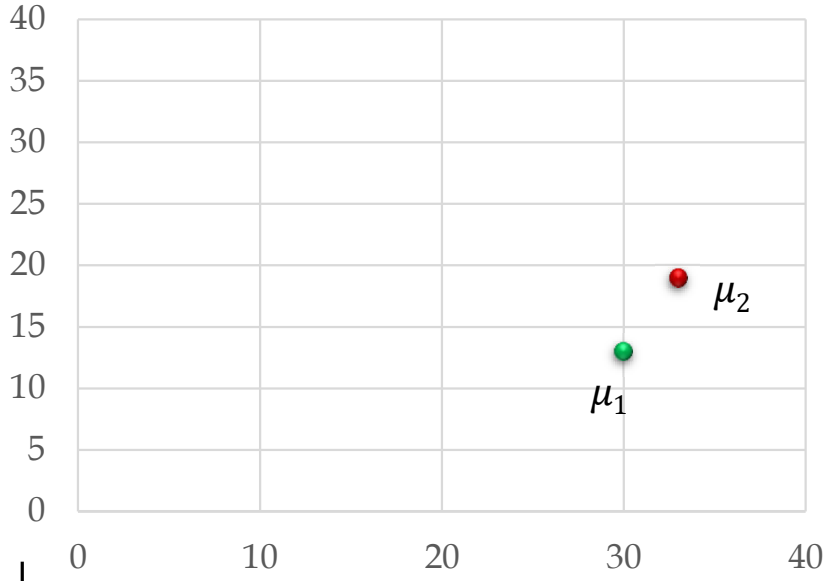
Principe

Initialisation

$K = 2$

$\mu_1 = (30,13)$ *et* $\mu_2 = (33,19)$

$d =$ *distance euclidienne*



Itération 1

Obs	(T. des pétales, T. de la tige)	$d(O_i, \mu_1)$	$d(O_i, \mu_2)$
O1	(22, 17)	**8,94**	**11,18**
O2	(27, 25)	**12,37**	**8,49**
O3	(25, 24)	**12,08**	**9,43**
O4	(15, 35)	**26,63**	**24,08**
O5	(13, 25)	**20,81**	**20,88**
O6	(12, 30)	**24,76**	**23,71**

$C_1 = \{O_1, O_5\},$

$C_2 = \{O_2, O_3, O_4, O_6\},$

$\mu_1 = \left(\frac{22+13}{2}, \frac{17+25}{2}\right) = (17.5, 21)$

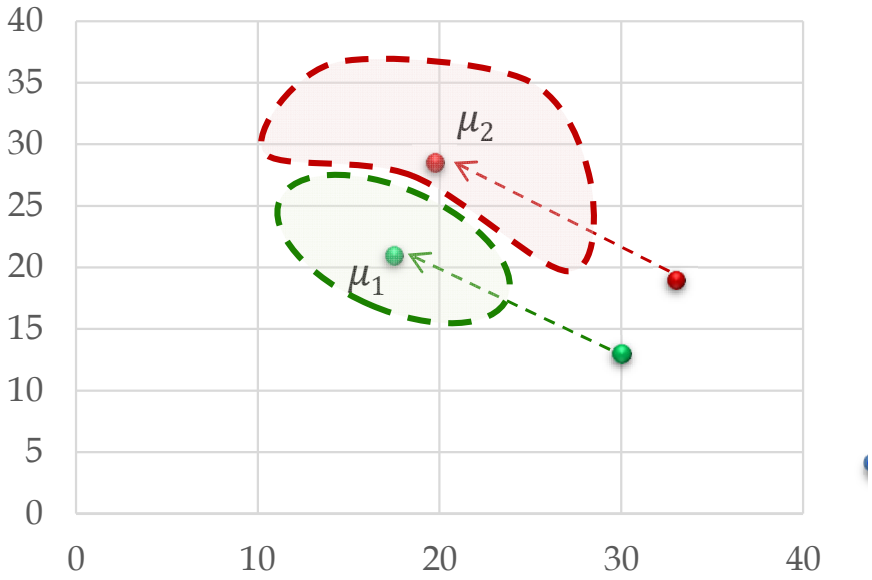
$\mu_2 = \left(\frac{27+25+15+12}{4}, \frac{25+24+35+30}{4}\right) = (19.75, 28.5)$

$J_w = 8,94+8,49+9,43+24,08+20,81+23,71 = \mathbf{95,46}$

Principe

Itération 1

$\mu_1 = (24.67, 22)$ *et* $\mu_2 = (13.33, 30)$



Itération 2

Obs	(T. des pétales, T. de la tige)	$d(O_i, \mu_1)$	$d(O_i, \mu_2)$
O1	(22, 17)	**6.02**	**11.72**
O2	(27, 25)	**10,31**	**8,05**
O3	(25, 24)	**9,08**	**6.91**
O4	(15, 35)	**14.22**	**8.05**
O5	(13, 25)	**6.02**	**7.6**
O6	(12, 30)	**10.55**	**7.89**

$C_1 = \{O_1, O_5\}$,

$C_2 = \{O_2, O_3, O_4, O_6\}$,

$\mu_1 = \left(\frac{22+13}{2}, \frac{17+25}{2}\right) = (17.5, 21)$

$\mu_2 = \left(\frac{27+25+15+12}{4}, \frac{25+24+35+30}{4}\right) = (19.75, 28.5)$

$J_w = 6.02+8,05+6,91+8.05+6.02+7.89 = \mathbf{43,39}$

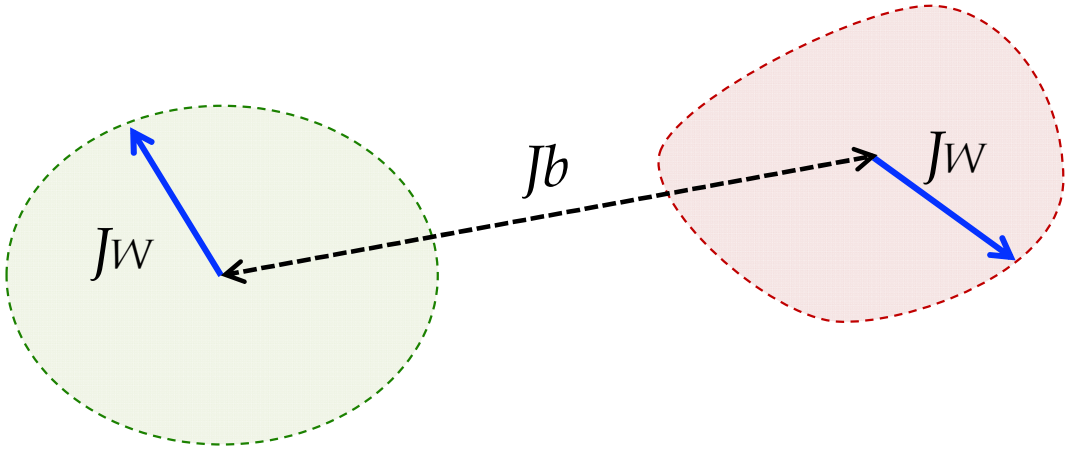
Remarque: pas de changement des positions de centres des groupes.

Principe

❖ Critère de validité de partitionnement

- Distance inter-cluster(J_b): la distance entre les moyennes de deux clusters
- Distance intra-cluster (J_w): la distance moyenne entre les points de données et la moyenne dans un cluster spécifique

Un grand rapport J_b / J_w suggère une bonne compacité à l'intérieur des clusters et une bonne séparabilité entre les différents clusters!



Principe

❖ Remarque et problème

- A chaque itération de l'algorithme le critère J_w diminue.
  - L'algorithme **converge au moins vers un minimum local de J_w**
  - Convergence rapide.

- Initialisation des μ_k :
  - aléatoirement dans l'intervalle de définition des x_i .
  - aléatoirement dans l'ensemble des x_i.

Des initialisations différentes peuvent mener à des clusters différents (problèmes de minima locaux).

Principe

❖ Solutions ± fiables

- Solution au problème de stabilité des résultats: Méthode générale pour obtenir des clusters **"stables" = formes fortes**

  - **Méthode itérative**

    - On **répète l'algorithme *r* fois**.

    - On **regroupe ensemble les x_i** qui se retrouvent toujours dans les mêmes clusters.

  - **Initialisation avec la méthode K-means ++** à la place de la méthode aléatoire.

Principe

❖ Solutions ± fiables

- Méthodes d'évaluation et de détection du nombre de classes

Le but ici n'est pas seulement de créer des clusters, mais de **créer de bons clusters significatifs**. Le clustering de qualité est lorsque les points de données d'un cluster sont proches les uns des autres et éloignés des autres clusters.

Les deux méthodes de mesure de la qualité du cluster sont :

- Méthode du coude ou elbow : Graphique de l'inertie intra-classes *W*
- Méthode score de silhouette.

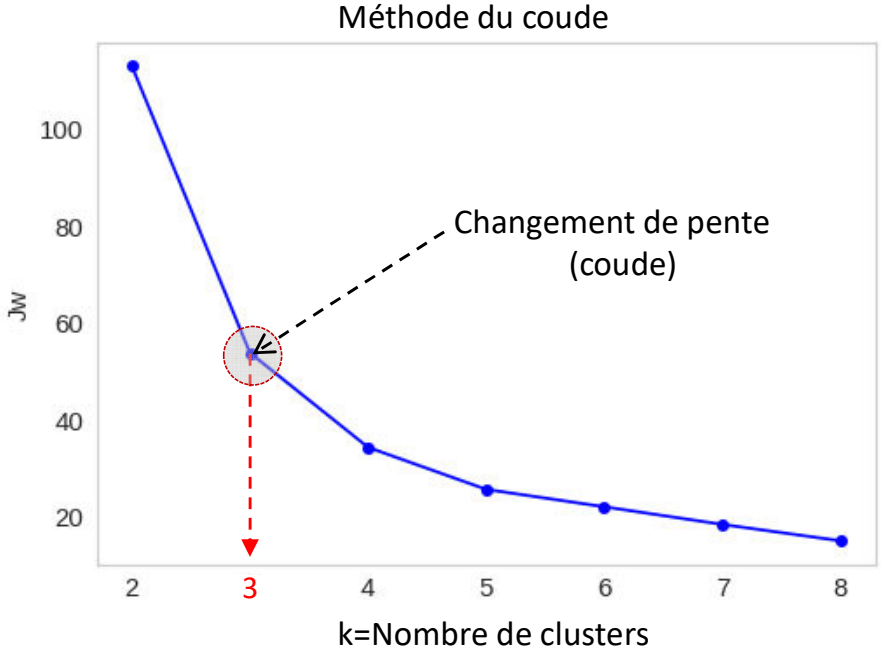
Principe

❖ Solutions ± fiables

- Méthodes de détection du nombre de classes

  - Méthode du coude ou elbow : Graphique de l'inertie intra-classes W

    Une stratégie simple pour identifier le nombre de classes consiste à faire varier K et surveiller l'évolution de l'inertie Jw.



Remarque: La valeur retenue pour *k* est celle qui marque le début d'un pallier.

Principe

❖ Solutions ± fiables

- Méthodes de détection du nombre de classes

  - Méthode score de silhouette

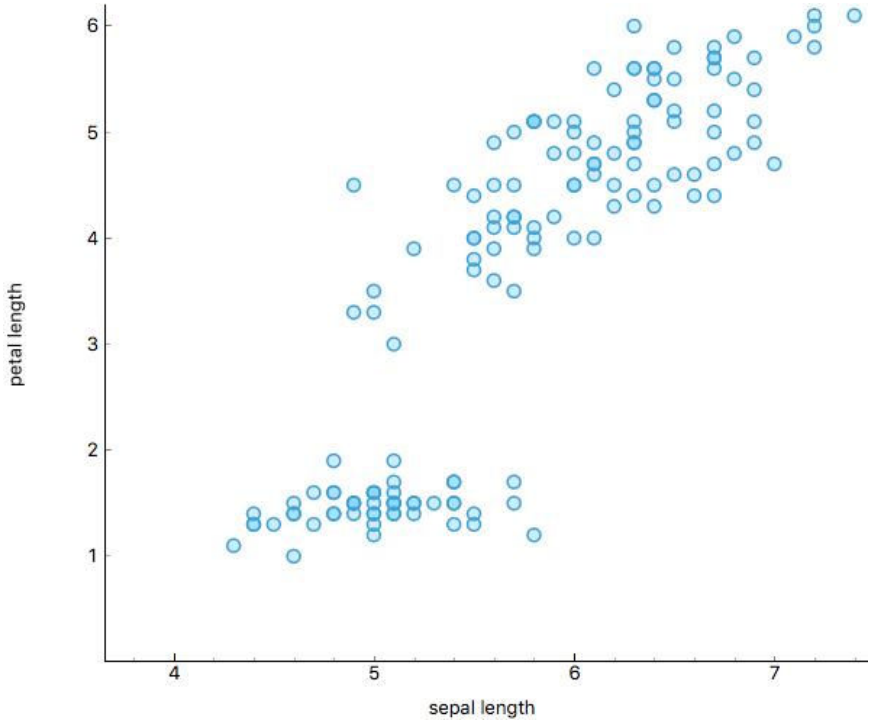
Score de silhouette: le score de silhouette indique à quelle distance les points de données d'un cluster sont éloignés des points de données d'un autre cluster. La plage de score de silhouette va de -1 à 1. Le score devrait être plus proche de 1 que -1.

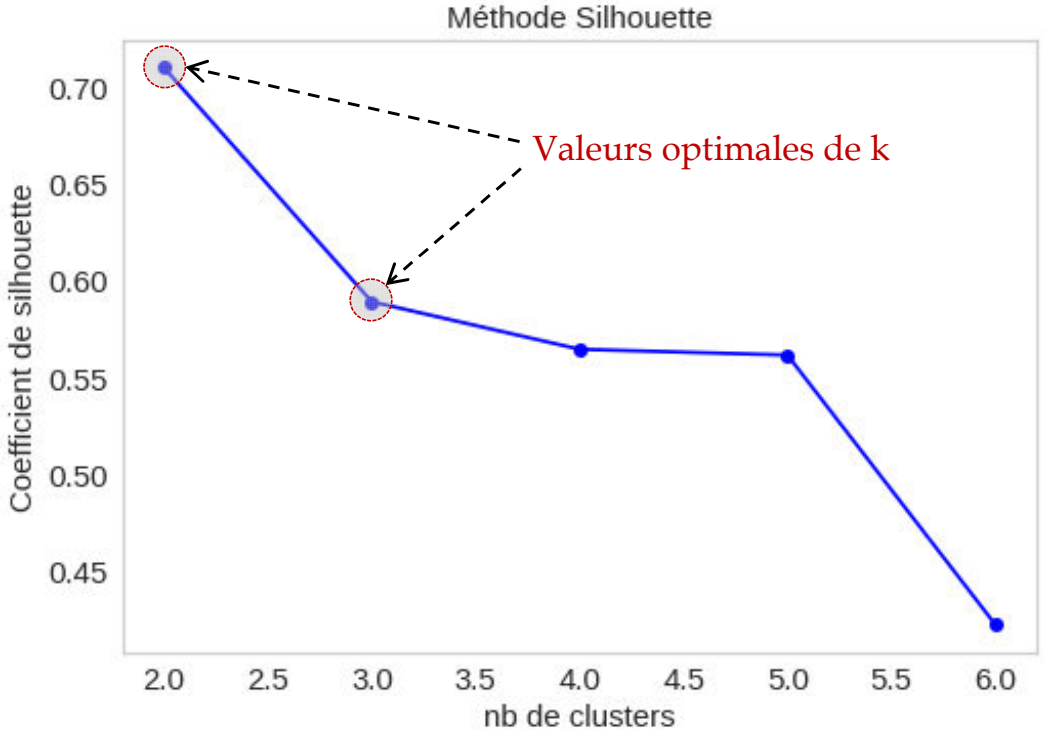
Principe

❖ Solutions ± fiables

- Méthodes de détection du nombre de classes

  - Méthode silhouette: Exemple classification de la BD Iris



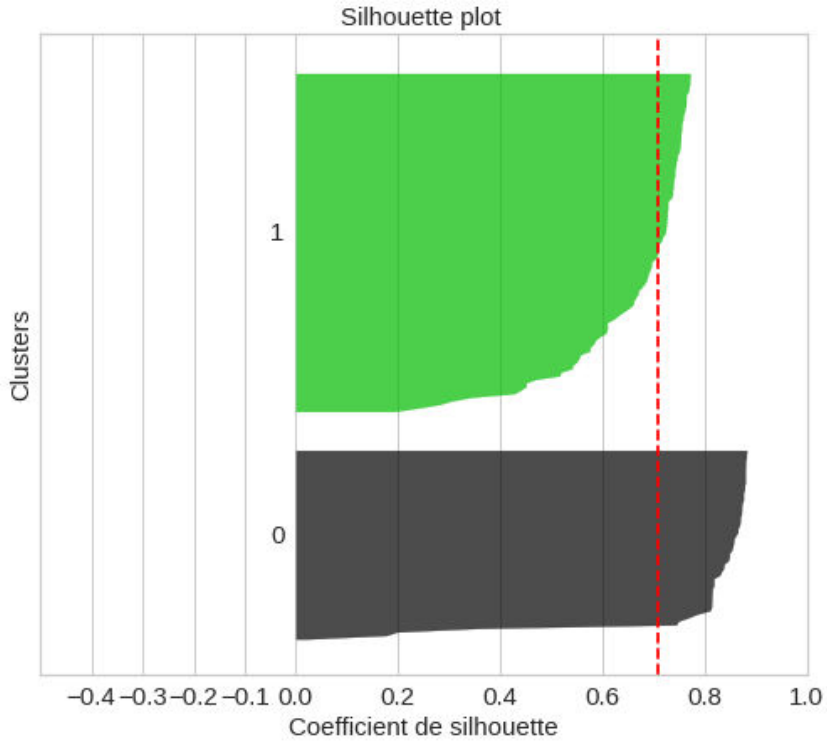


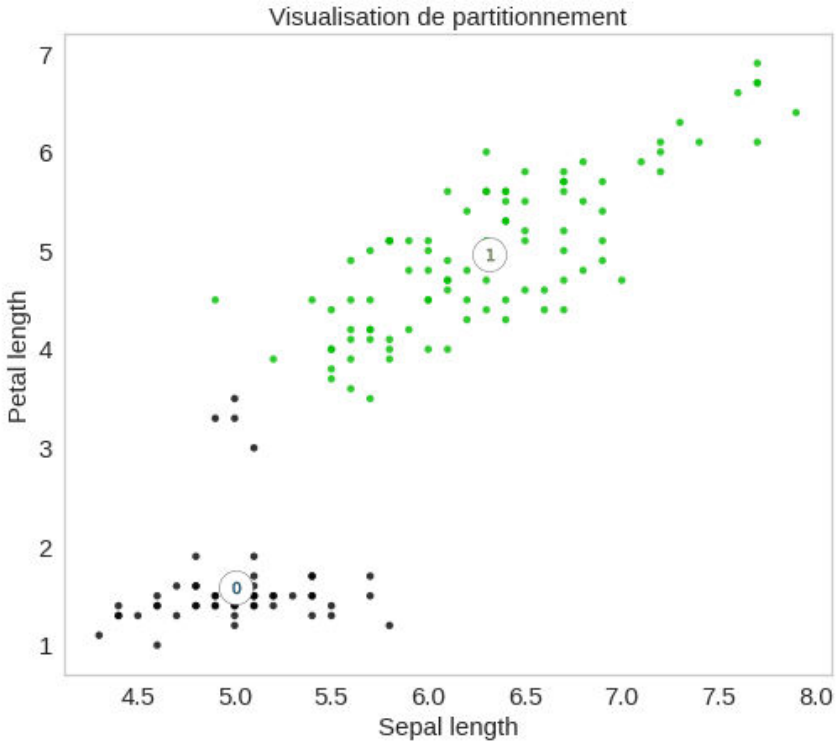
Principe

❖ Solutions ± fiables

- Méthodes de détection du nombre de classes

  - Méthode silhouette pour k=2



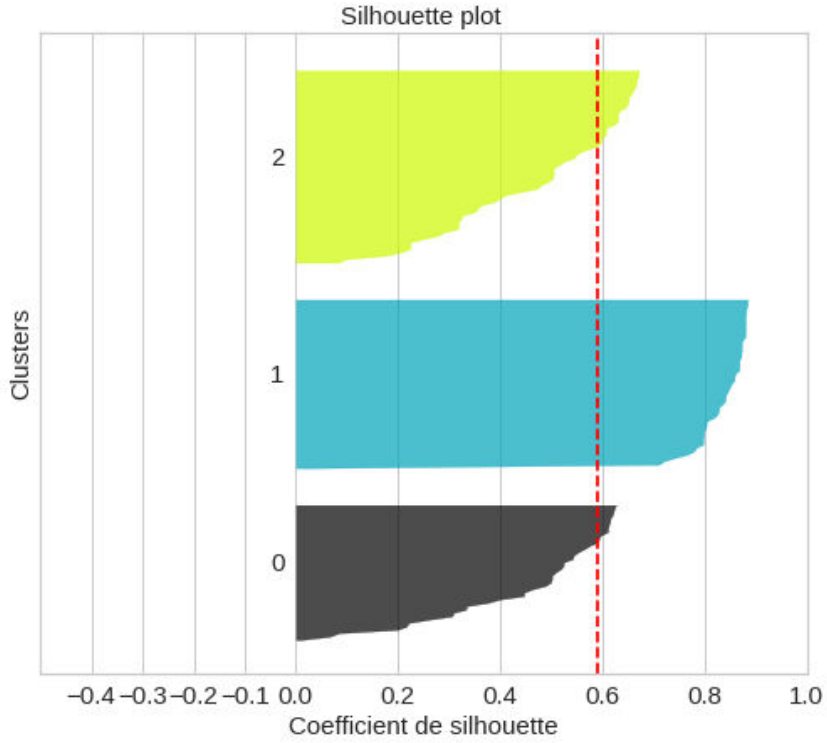


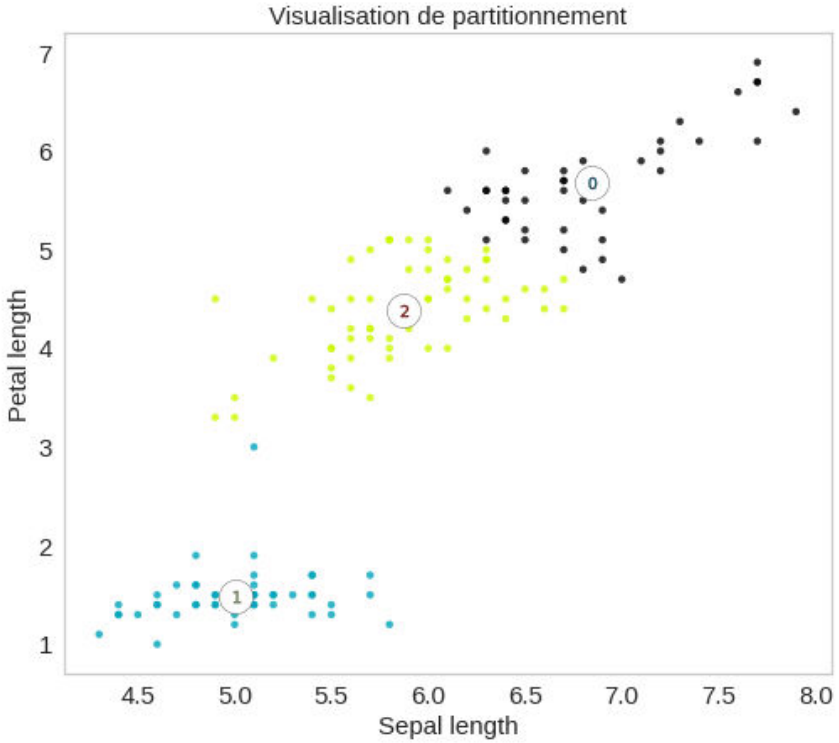
Principe

❖ Solutions ± fiables

- Méthodes de détection du nombre de classes

  - Méthode silhouette pour k=3



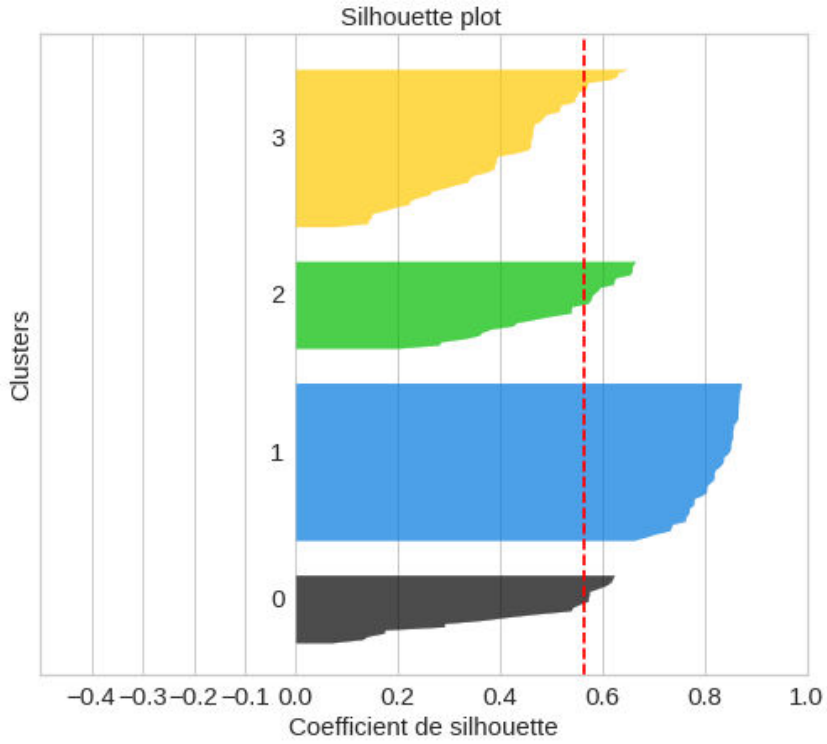


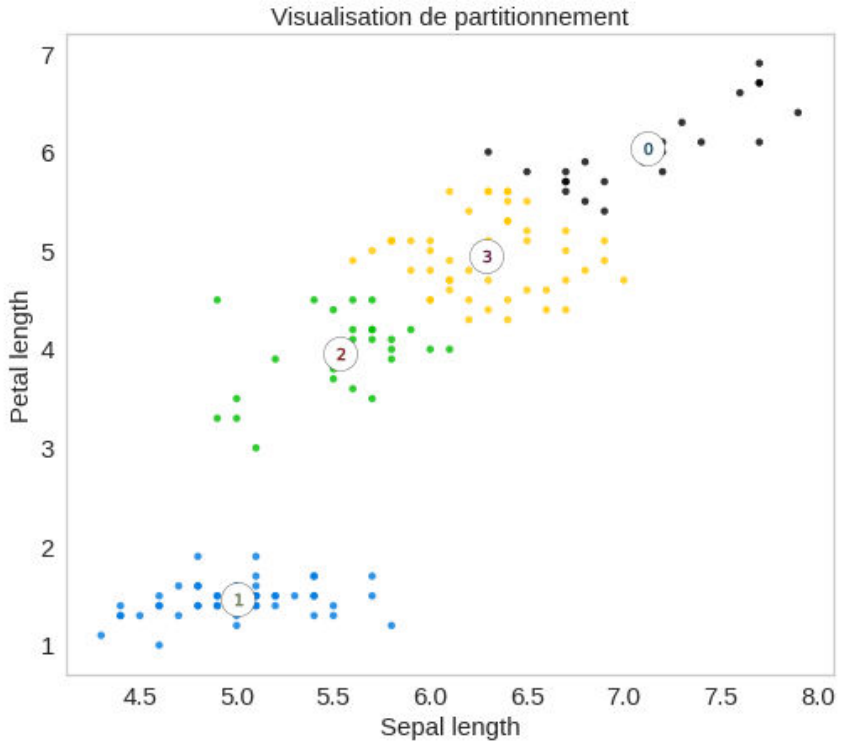
Principe

❖ Solutions ± fiables

- Méthodes de détection du nombre de classes

  - Méthode silhouette pour k=4



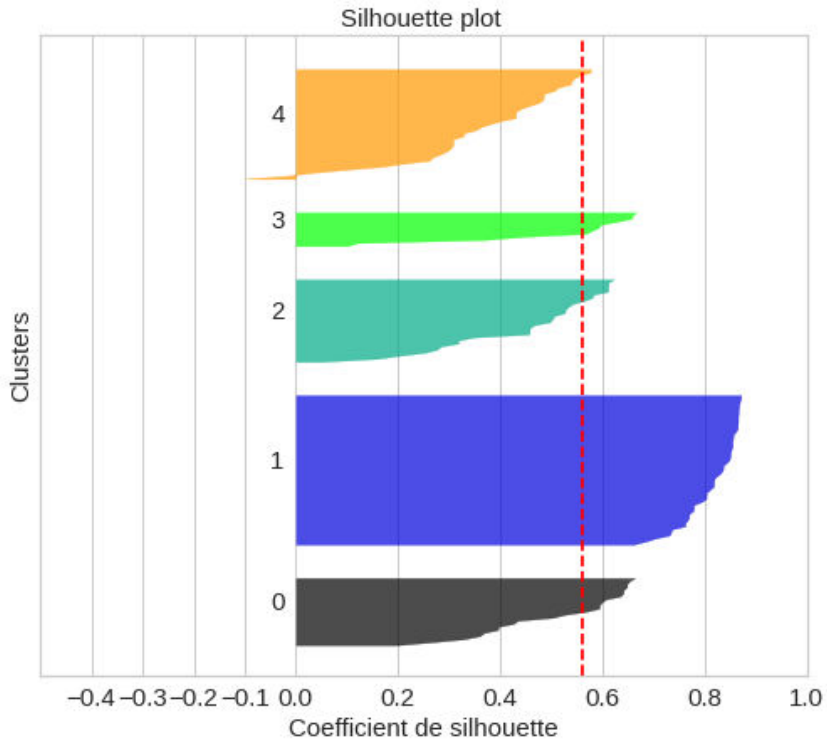


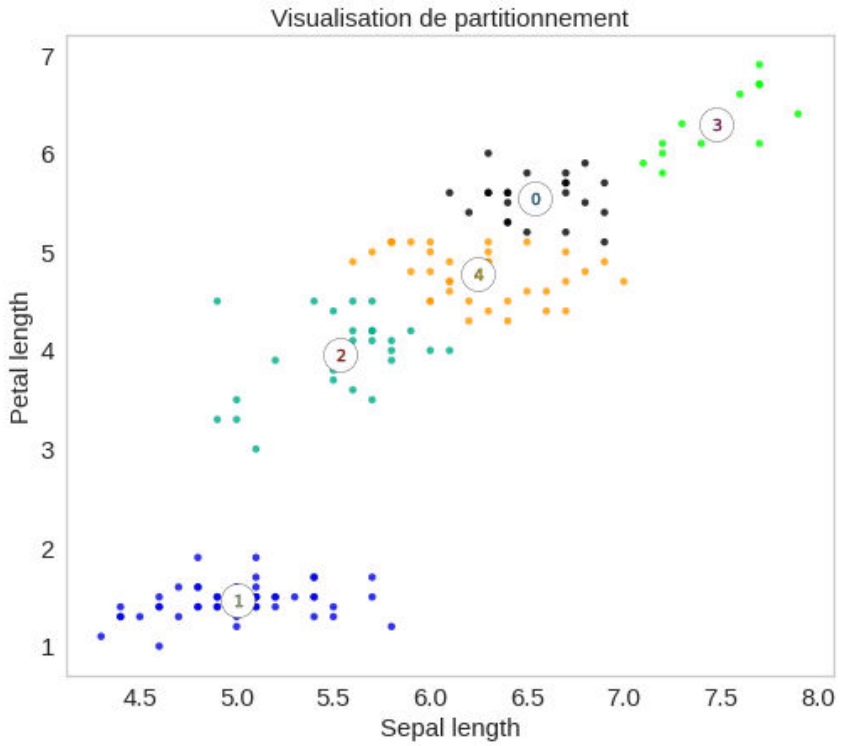
Principe

❖ Solutions ± fiables

- Méthodes de détection du nombre de classes

  - Méthode silhouette pour k=5





Points forts et points faibles

Points forts et points faibles

❖ Points forts

- **Scalabilité**: Capacité à traiter les très grandes bases. Seuls les vecteurs des moyennes sont à conserver en mémoire centrale.
- **Complexité** linéaire par rapport au nombre d'observations (pas de calcul des distances deux à deux des individus, cf. CAH)

❖ Points faibles

- Le choix du nombre de groupes est subjectif dans le cas où le nombre de classes est inconnu au sein de l'échantillon.
- Les résultats de l'algorithme du K-Means sont sensibles à l'initialisation aléatoires des centres.

Implémentation avec python

Allez voir le fichier ***TutorialClustering.ipynb*** *sur modlle*

Etapes de l'implémentation

