Machine learning

Lecture 5 : Support Vector Machine (SVM)

Prof: Aissam BERRAHOU
Aissam.berrahou@ensias.um5.ac.ma
Laboratoire Smart Systems Lab

ENSIAS

جامعة محمد الخامس بالرباط
Université Mohammed V de Rabat

2026-2027

Objectifs du cours

Parmi toutes les droites qui séparent deux classes, laquelle choisir ?

Les SVM (Support Vector Machines) répondent : celle qui laisse **le plus de place** de chaque côté. À la fin de la séance, vous saurez :

- expliquer la **marge maximale** et le rôle des **vecteurs de support** ;
- calculer à la main l'hyperplan et la marge sur un petit exemple ;
- interpréter le paramètre **C** et le **kernel trick** ;
- régler C et γ avec scikit-learn.

Plan

1) Introduction

2) SVM linéaire à marge dure

3) Exemple pas à pas

4) Marge souple et paramètre C

5) Kernel trick

6) Avantages et limites

7) Mise en pratique

1. Introduction

Introduction

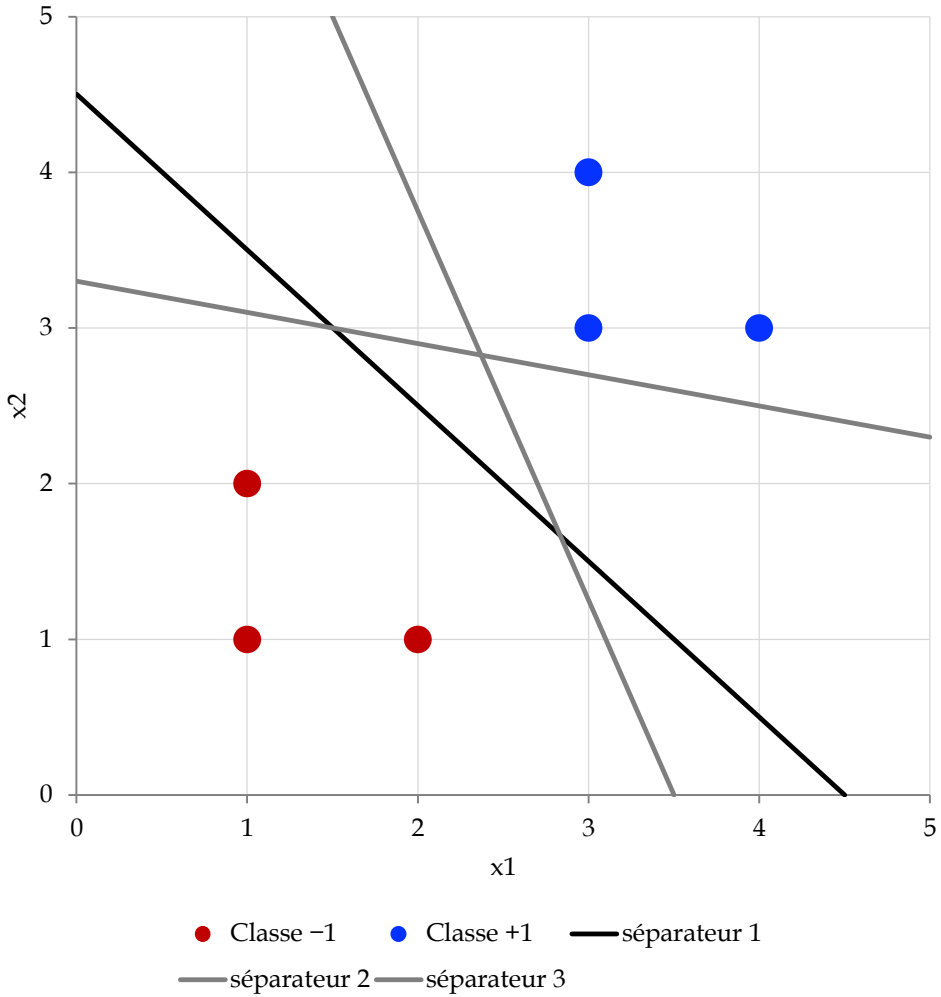
Plusieurs droites séparent parfaitement ces points. Sont-elles toutes aussi bonnes ?

Non. Une droite qui frôle les points risque de mal classer le prochain exemple, même légèrement différent.

Le SVM, introduit par Vapnik et ses collègues dans les années 1990, choisit la droite **la plus éloignée** des points les plus proches de chaque classe : c'est la **marge maximale**.

C'est une méthode **supervisée**, surtout utilisée en classification (sa variante SVR traite la régression).

Une grande marge donne en général une meilleure généralisation.



2. SVM linéaire à marge dure

Formulation

Comment écrire « la droite la plus éloignée » en équations ?

Un hyperplan s'écrit **$w \cdot x + b = 0$** ; on prédit la classe par le **signe** de $f(x) = w \cdot x + b$, avec des étiquettes $y_i \in \{-1, +1\}$.

On règle l'échelle pour que les points les plus proches vérifient $|w \cdot x + b| = 1$. La marge, entre les droites $w \cdot x + b = -1$ et $+1$, vaut alors :

$$\text{marge} = 2 / \|w\|$$

Maximiser la marge revient donc à **minimiser $\|w\|$**, en classant tous les points correctement :

$$\min_{w,\,b} \tfrac{1}{2} \|w\|^2 \quad \text{sous} \quad y_i (w \cdot x_i + b) \geq 1 \quad \text{pour tout } i$$

Vecteurs de support

Tous les points comptent-ils pour placer la frontière ?

Non, et c'est la grande élégance du SVM. Seuls les points situés **sur les bords de la marge** déterminent l'hyperplan : ce sont les **vecteurs de support**.

On pourrait supprimer tous les autres points sans rien changer au résultat.

Dans la forme duale, la décision s'écrit $f(x) = \Sigma_i \alpha_i y_i (x_i \cdot x) + b$, avec $\alpha_i > 0$ uniquement pour les vecteurs de support.

Elle ne dépend des données qu'à travers des produits scalaires $x_i \cdot x$: c'est la porte ouverte au kernel trick.

3. Exemple pas à pas

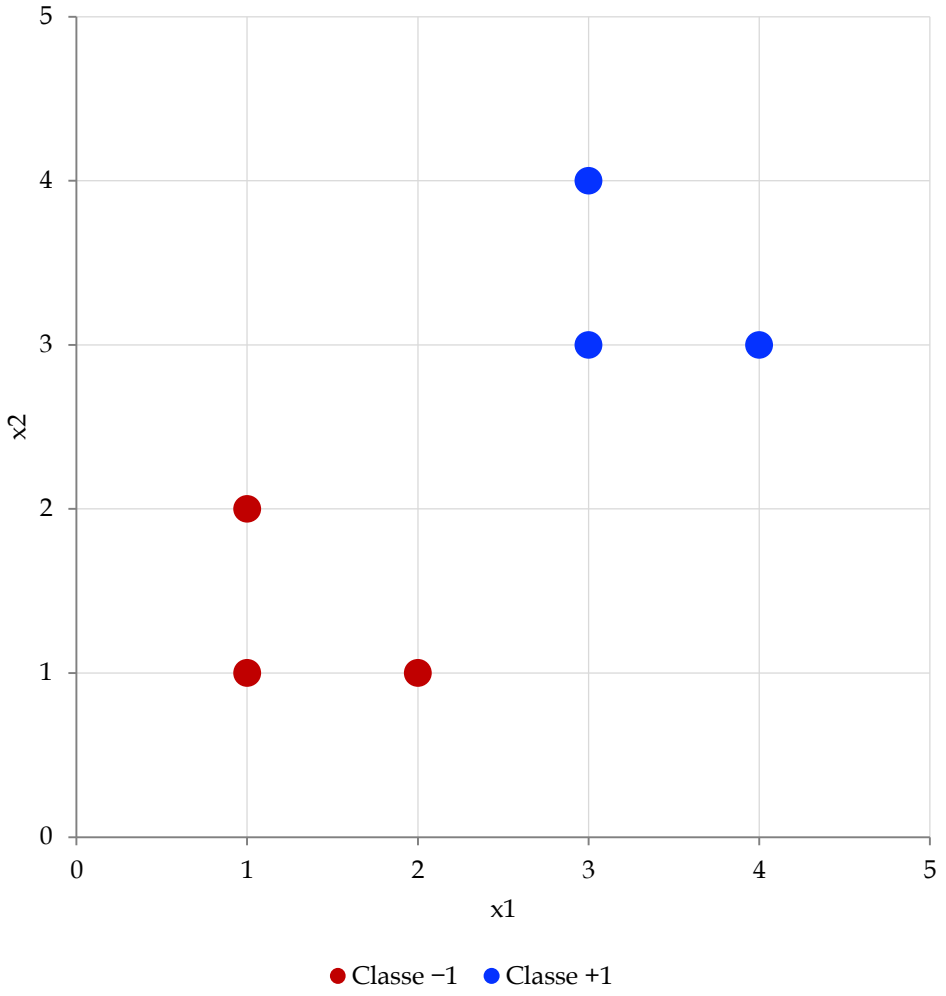
Exemple : les données

Cherchons l'hyperplan optimal pour ces six points.

Trois points dans chaque classe.

Point	x1	x2	Classe y
P1	1	1	−1
P2	2	1	−1
P3	1	2	−1
P4	3	3	+1
P5	4	3	+1
P6	3	4	+1

Une piste : la classe −1 vérifie $x1 + x2 \leq 3$ et la classe +1 vérifie $x1 + x2 \geq 6$. Par symétrie, le meilleur séparateur est parallèle à ces droites : $w = (a, a)$.



Exemple : calcul de l'hyperplan

Quels points vont « tenir » la marge ?

Les plus proches de l'autre classe : P2 (2, 1) et P3 (1, 2) d'un côté, P4 (3, 3) de l'autre.

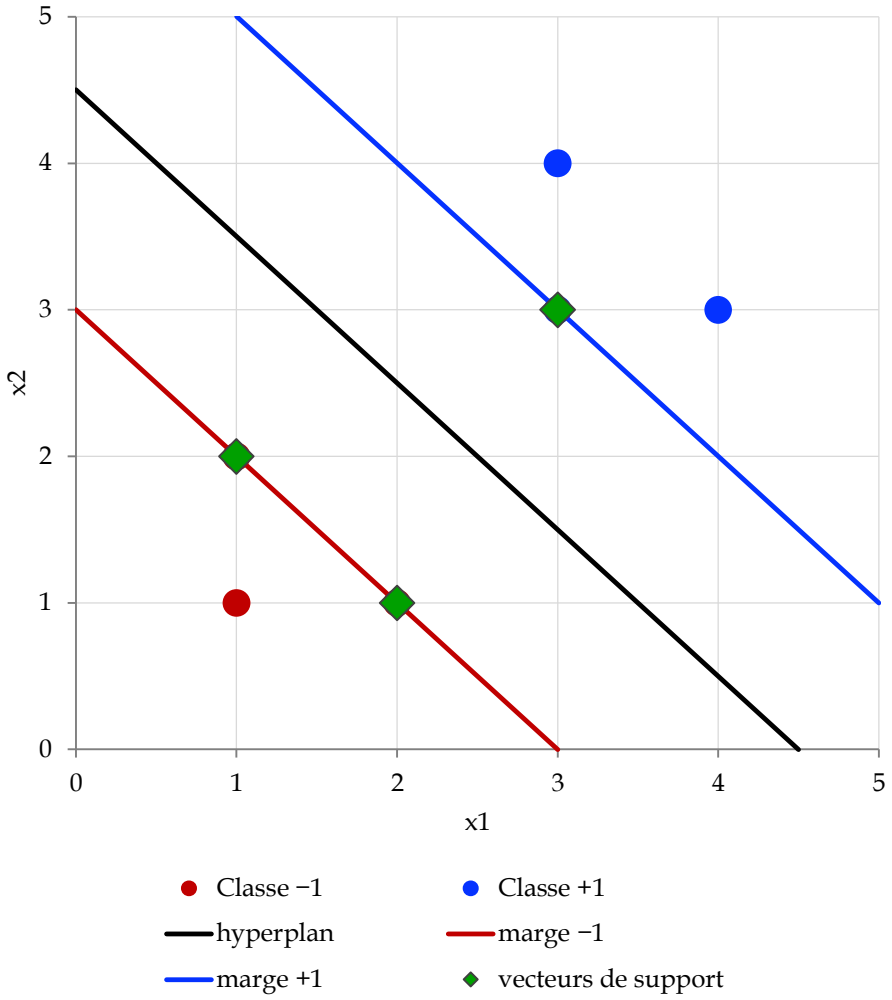
On impose $w \cdot x + b = \pm 1$ sur ces points, avec $w = (a, a)$:

$$P2 : \; 3a + b = -1 \qquad P4 : \; 6a + b = +1$$

$$\Rightarrow \; a = 2/3, \;\; b = -3, \;\; w = (2/3, 2/3)$$

La marge vaut $2 / \|w\| = 3 / \sqrt{2} \approx$ **2.12**.

Hyperplan : x1 + x2 = 4.5, exactement à mi-chemin entre les deux classes.



Exemple : vérification et prédiction

❖ **Vérifions que tous les points respectent la marge**

Point	Classe y	f(x) = (2/3)x1 + (2/3)x2 − 3	y ·f(x)	Contrainte ≥ 1	Vecteur de support
P1 (1, 1)	−1	-5/3	5/3	oui	non
P2 (2, 1)	−1	-1	1	oui	**oui**
P3 (1, 2)	−1	-1	1	oui	**oui**
P4 (3, 3)	+1	1	1	oui	**oui**
P5 (4, 3)	+1	5/3	5/3	oui	non
P6 (3, 4)	+1	5/3	5/3	oui	non

Et pour un nouveau point x = (2, 3) ?

$$f(x) = (2/3)\times 2 + (2/3)\times 3 - 3 = 1/3 > 0 \Rightarrow \text{classe } +1$$

Le point tombe à l'intérieur de la marge ($|f(x)| < 1$) : la décision est correcte, mais moins « sûre ».

4. Marge souple et paramètre C

Marge souple (soft margin)

Que faire quand aucune droite ne sépare parfaitement les classes ?

C'est le cas le plus courant : il y a du bruit, des exemples mal étiquetés. On autorise alors quelques violations de la marge, mesurées par des variables d'écart $\xi_i \geq 0$:

$$\min_{w,\, b,\, \xi} \ \tfrac{1}{2} \|w\|^2 + C \sum_i \xi_i \quad \text{sous} \quad y_i \, (w \cdot x_i + b) \geq 1 - \xi_i$$

Le paramètre **C** fixe le prix d'une erreur.

C grand : les erreurs coûtent cher, la marge se resserre pour bien classer chaque point, au risque de **surapprendre**.

C petit : on tolère des erreurs pour garder une marge large et un modèle plus régulier, au risque de **sous-apprendre**.

Exemple : influence de C

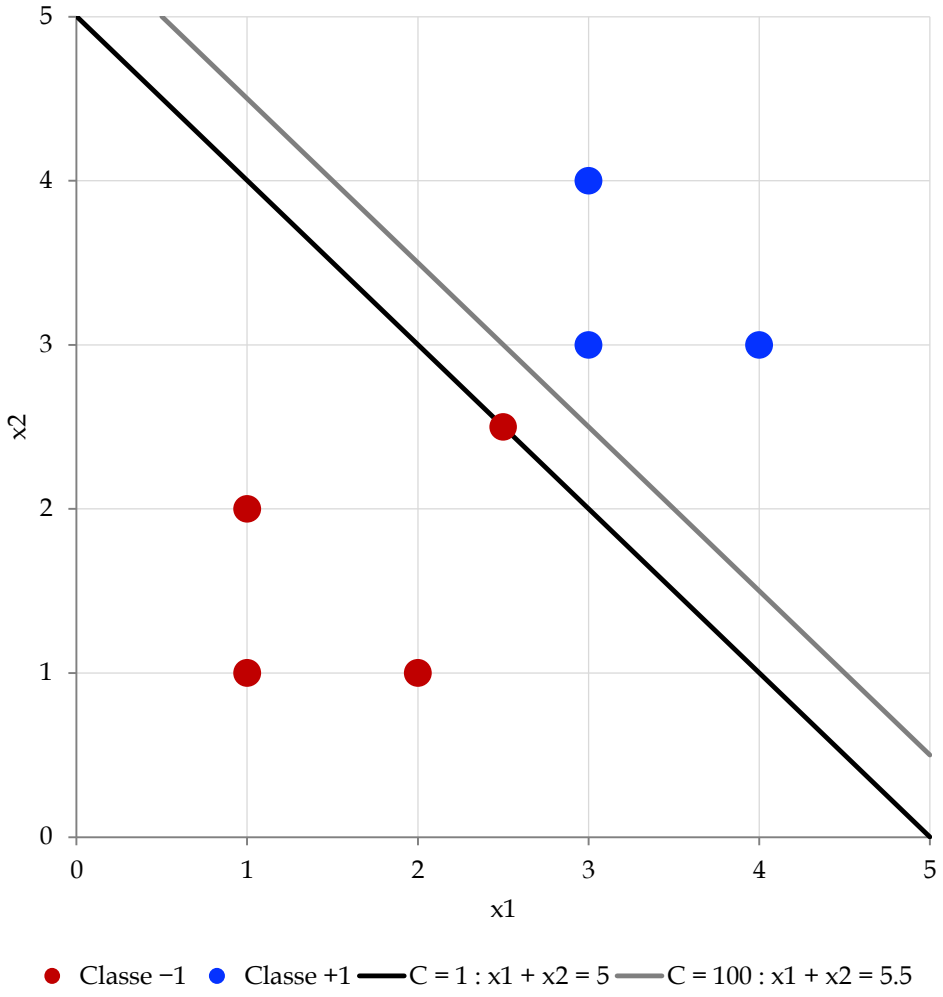
Un point gênant P7 (2.5, 2.5) de classe −1 s'invite. Que fait le SVM ?

C	w	b	Marge 2/‖w‖	Exactitude
0.1	(0.45, 0.45)	−2.25	3.14	6/7
1	(0.50, 0.50)	−2.50	2.83	6/7
100	(2, 2)	−11	**0.71**	**7/7**

Avec **C = 100**, le SVM classe P7 correctement, mais la marge tombe à 0.71 : le modèle « s'accroche » à un seul point.

Avec **C = 1**, il accepte de se tromper sur P7 et garde une marge large : il généralisera sans doute mieux.

C se règle par validation croisée.



5. Kernel trick

Kernel trick : exemple en dimension 1

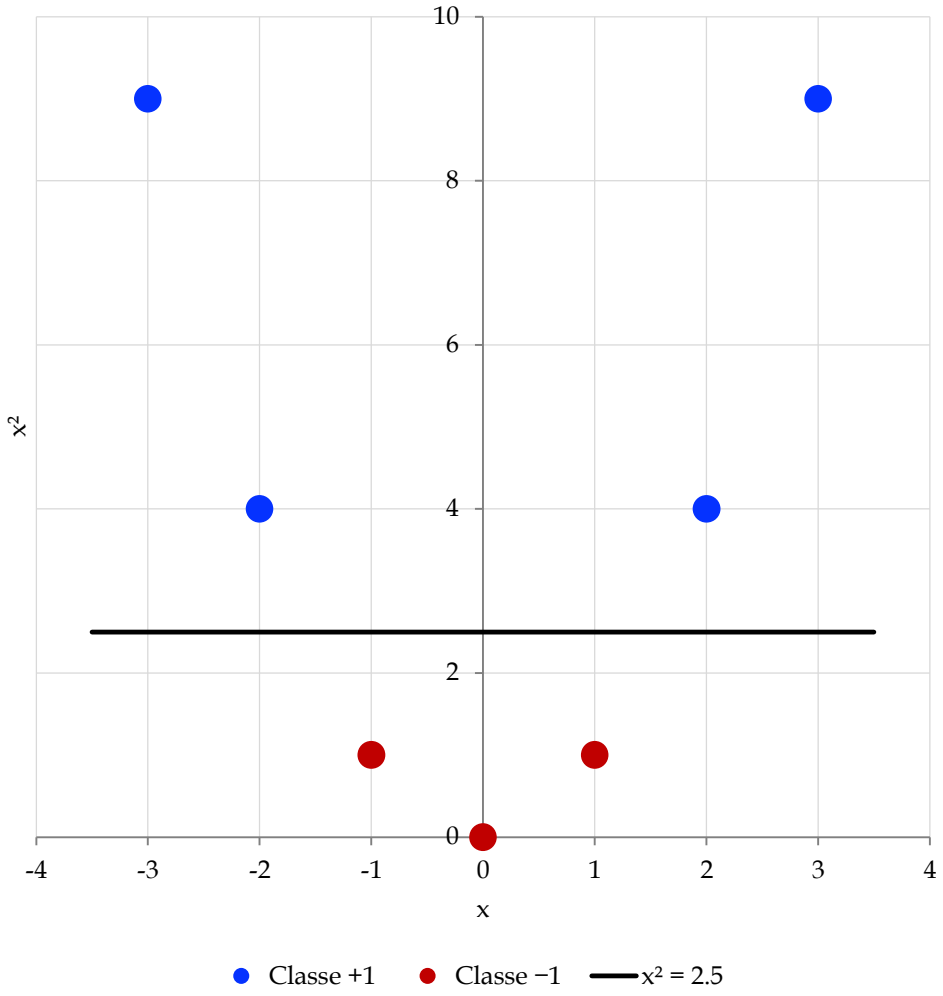
Comment séparer des données qu'aucun seuil ne sépare ?

Ici, la classe +1 est aux deux extrémités, la classe −1 au centre : aucun seuil sur x ne convient.

L'astuce : ajouter une dimension. Avec $\varphi(x) = (x, x^2)$, les points se répartissent sur une parabole.

Dans ce nouveau plan, la droite horizontale **$x^2 = 2.5$** sépare parfaitement les deux classes.

x	−3	−2	−1	0	1	2	3
Classe	+1	+1	−1	−1	−1	+1	+1
x^2	9	4	1	0	1	4	9



Kernel trick : les noyaux

Faut-il vraiment calculer ces nouvelles coordonnées ?

Non, et c'est tout l'intérêt du **kernel trick**. Le SVM n'a besoin que de produits scalaires : on les remplace par une fonction **noyau** $K(x, x') = \varphi(x) \cdot \varphi(x')$.

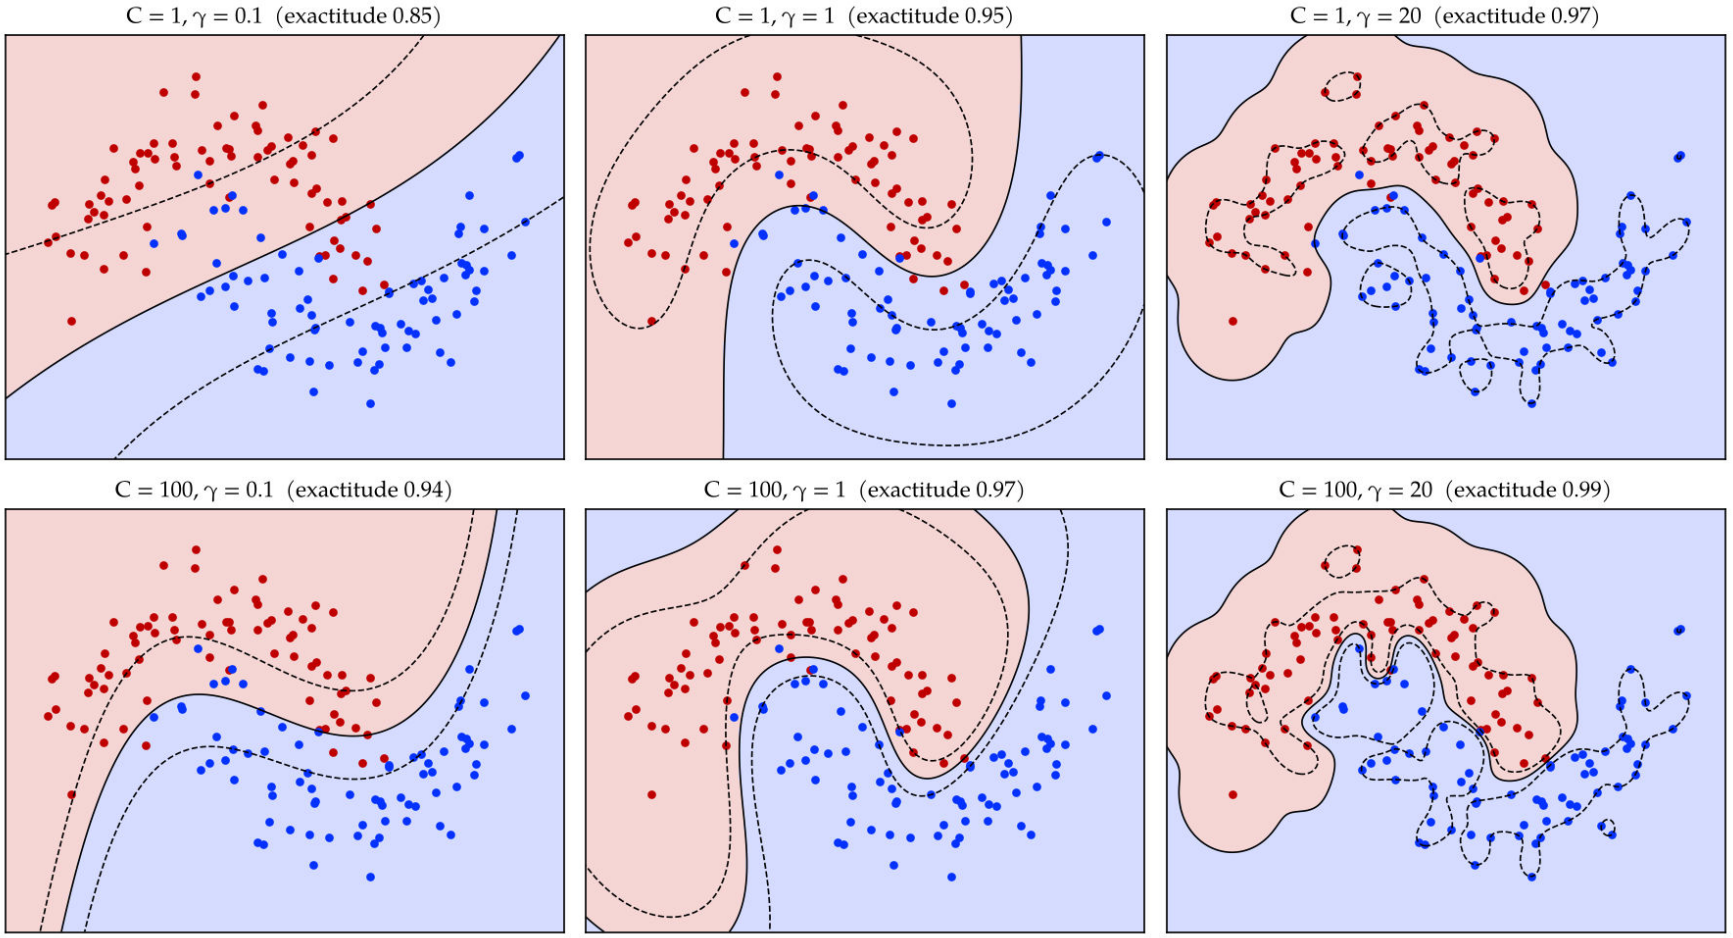
Exemple : pour $\varphi(x) = (x, x^2)$, on a directement $K(x, x') = x\,x' + x^2\,x'^2$.

- **Les noyaux les plus utilisés**

$$\text{Linéaire} : x \cdot x' \qquad \text{Polynomial} : (x \cdot x' + c)^d \qquad \text{RBF} : \exp(-\gamma \, \|x - x'\|^2)$$

Avec le noyau RBF (gaussien), **γ grand** donne une frontière très souple (risque de surapprentissage) et **γ petit** une frontière lisse.

Influence de C et γ (noyau RBF)



SVM multi-classes

Le SVM ne sépare que deux classes. Comment faire avec trois ou plus ?

On combine plusieurs SVM binaires. En **un contre un** (one-vs-one), on entraîne un SVM pour chaque paire de classes, puis on vote : c'est ce que fait SVC.

En **un contre tous** (one-vs-rest), on entraîne un SVM par classe et on garde le score le plus élevé : c'est le choix de LinearSVC.

Deux bonnes pratiques à retenir : **standardiser** les variables, et régler C et γ par **validation croisée** (GridSearchCV).

6. Avantages et limites

Avantages et limites du SVM

Quand le SVM est-il un bon choix ?

❖ **Ses atouts**

Grâce à la marge maximale, il **généralise** bien. Il reste efficace en **grande dimension** (texte, génomique), le modèle est compact (seuls les vecteurs de support comptent) et les noyaux donnent des frontières **non linéaires**.

❖ **Ses limites**

Il devient **lent** sur de très grands jeux de données.

Le choix du noyau et le réglage de C et γ demandent du soin.

Il ne fournit pas directement de probabilité, et un modèle à noyau est peu **interprétable**.

À retenir

1. Le SVM cherche l'hyperplan $w \cdot x + b = 0$ de **marge maximale** $2/\|w\|$.
2. Seuls les **vecteurs de support**, sur les bords de la marge, définissent la frontière.
3. Avec une marge souple, **C** arbitre entre une marge large (C petit) et peu d'erreurs (C grand).
4. Le **kernel trick** donne des frontières non linéaires : noyaux polynomial et **RBF** (paramètre γ).
5. Toujours **standardiser** les données et régler C et γ par **validation croisée**.

Mise en pratique

À vous de jouer !

Le notebook **TP_5_SVM.ipynb** (sur Moodle) reprend le cours sur machine :

- retrouver w, b, la marge et les vecteurs de support de l'exemple ;
- observer l'effet de C sur le point gênant ;
- passer en dimension 2 avec $\varphi(x) = (x, x^2)$, puis utiliser le noyau RBF ;
- régler C et γ sur la base Breast Cancer.

```
from sklearn.svm import SVC

svm = SVC(kernel="linear", C=1e6).fit(X, y)     # marge dure
print(svm.coef_, svm.intercept_)                 # [[0.667 0.667]] [-3.]
print(svm.support_vectors_)                      # (2,1) (1,2) (3,3)
```