Machine learning

Lecture7: Clustering Hiérarchique Ascendant (CHA)

Prof: Aissam BERRAHOU
Aissam.berrahou@ensias.um5.ac.ma
Laboratoire Smart Systems Lab

ENSIAS

جامعة محمد الخامس بالرباط
Université Mohammed V de Rabat

2020-2021

Plan

1) Introduction
2) Principe
3) Points forts et faibles
4) Implémentation avec python

Introduction

Introduction

❖ **Définitions :**

- Classification non supervisée : action de constituer ou construire des classes
- Classe : ensemble d'individus (ou d'objets) possédant des traits de caractères communs (groupe, catégorie)

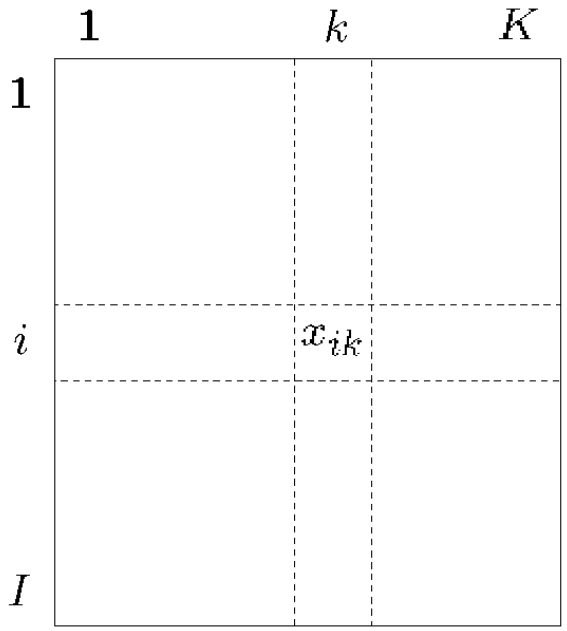
❖ **Exemples:**

- de classification : règne animal, disque dur d'un ordinateur, division géographique, etc.
- de classe : classe sociale, classe politique, etc.

❖ **Deux approches de classification non supervisée** :

- Clustering hiérarchique : arbre, CHA(Clustering hiérarchique ascendant).
- Clustering par partitionnement.

Introduction

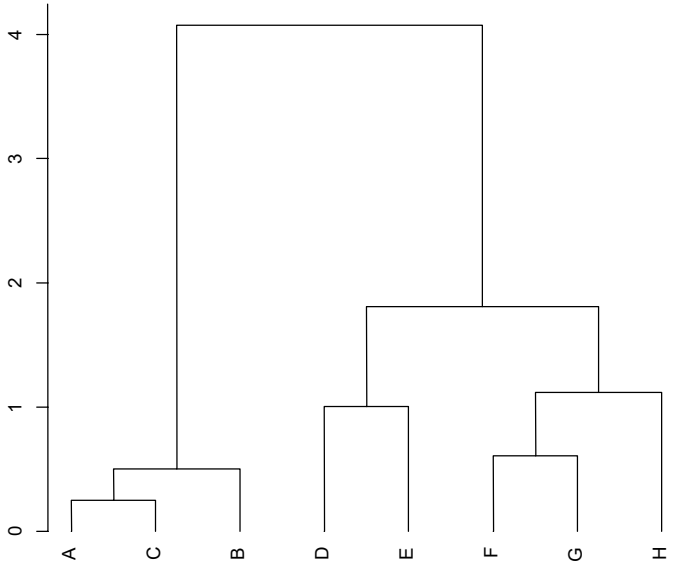


❖ **Données:**

- La classification s'intéresse à des tableaux de données individus X variables quantitatives

❖ **Objectifs**: production d'une structure **arborescente** permettant :

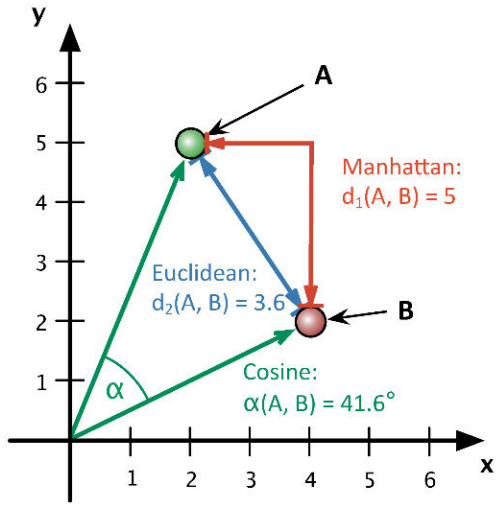
- la mise en évidence de liens hiérarchiques entre individus ou groupes d'individus.
- la détection d'un nb de classes « naturel » au sein de la population.



Introduction

❖ **Notion de proximité:**

- **Ressemblance entre individus**:
  - Distance euclidienne
  - Distance de Manhattan
  - Cosine similarité
  - …
- **Ressemblance entre groupes d'individus(Linkage methods)**:
  - Saut minimum ou lien simple(single distance): plus petite distance.
  - Lien complet: plus grande distance.
  - Lien moyen: moyenne de la distance.
  - distance de Ward.



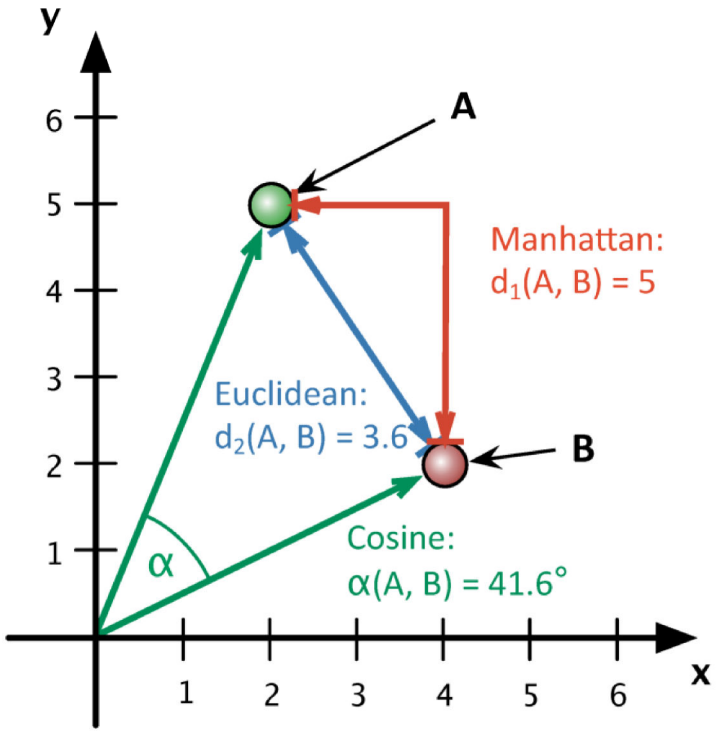
Principe

❖ Notion de proximité entre deux individus:

- **Mesure de la distance D(A, B) entre 2 individus A et B**

  - Distance euclidienne:

$$D_e(A,B) = \sqrt{\sum_{i=1}^{n}(A_i - B_i)^2}$$



  - Distance de manhattan:

$$D_m(A,B) = \sum_{i=1}^{n}|(Ai - B_i)|$$

  - Distance cosine :

$$D_c(A,B) = 1 - \frac{\sum_{i=1}^{n} A_i * Bi}{\sqrt{\sum_{i=1}^{n} {A_i}^2} * \sqrt{\sum_{i=1}^{n} {B_i}^2}}$$

$$= 1 - \frac{A * B^T}{\|A\| * \|B\|} = 1 - Cos(\alpha)$$

Introduction

❖ Notion de proximité entre clusters:

- **Mesure de la distance D(C1,C2) entre 2 classes C1 et C2**
  - Lien simple (plus proche voisin) :

$$D_{min}(C_1, C_2) = \min\{D(x_i, xj), xi \in C_1, xj \in C_2\}$$

  - Lien complet (diamètre maximum):

$$D_{max}(C_1, C_2) = \max\{D(x_i, xj), xi \in C_1, xj \in C_2\}$$

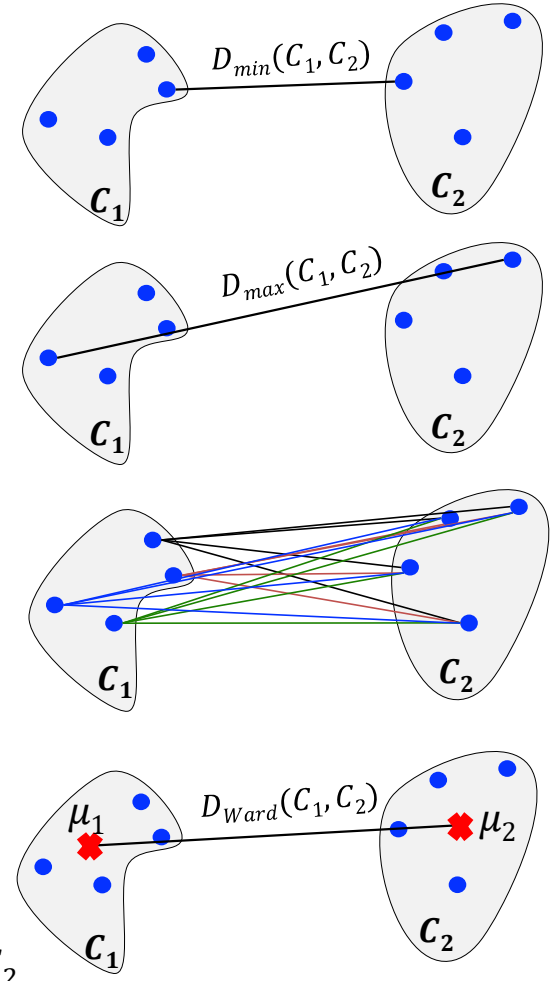
  - Lien moyen (distance moyenne) :

$$D_{moy}(C_1, C_2) = \frac{\sum_{x_i \in C_1} \sum_{x_j \in C_2} D(x_i, xj)}{n1 \times n2}$$

  - Distance de Ward :

$$D_{Ward}(C_1, C_2) = \frac{n1 \times n2}{n1 + n2} D(\mu_1, \mu_2)$$

Où μ_1 centre de gravité de C_1 et μ_2 centre de gravité de C_2



Introduction

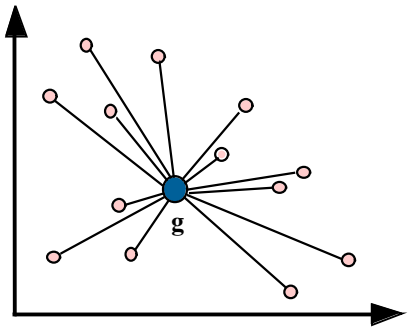
❖ Qualité de clustering:

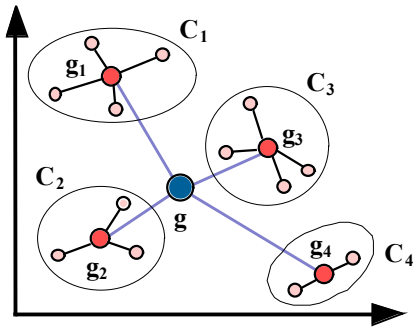
- **Caractéristique d'un cluster**
  - Chaque cluster C_k est caractérisé par
    - Son centre de gravité : $\mu_k = \frac{1}{N_k}\sum_{i\in C_k} x_i \ avec\ Nk = card(Ck)$
    - Son inertie : $J_k = \sum_{i\in C_k} D \ (x_i, \mu_k)$
  - L'inertie mesure la concentration des points autour de μ_k. Plus J_k est faible, plus on a une petite dispersion des points autour de μ_k
- **Inertie intra-cluster**

$$J_w = \sum_k \sum_{i\in C_k} D \ (x_i, \mu_k) = \sum_k J_k$$

- **Inertie inter-cluster**

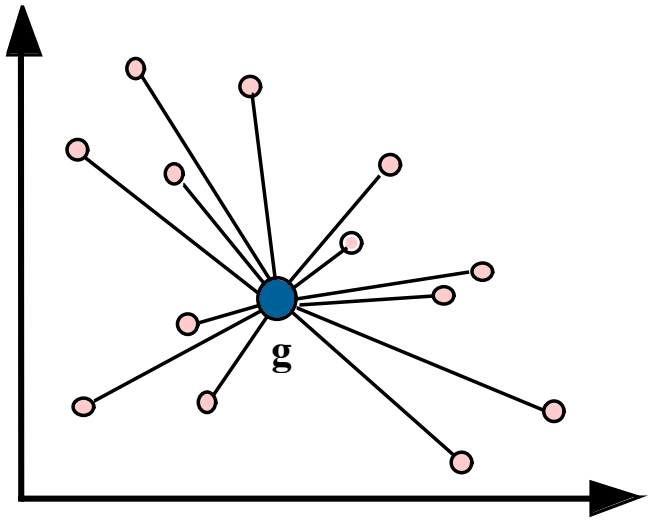
$$J_b = \sum_k N_k D \ (\mu_k, \mu \ )$$

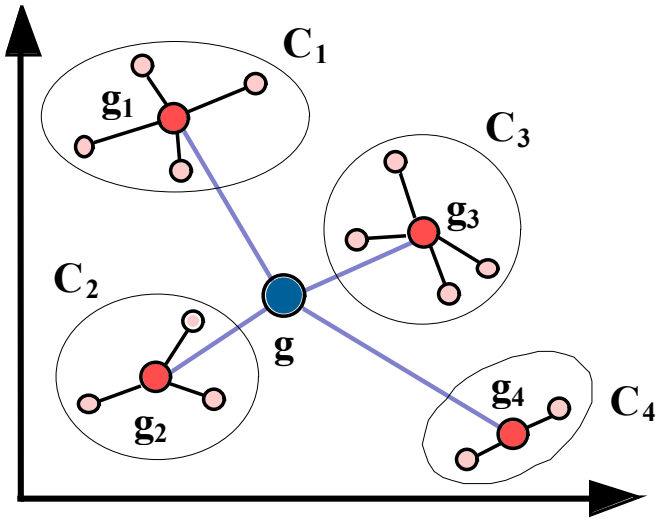




Introduction

❖ **Qualité de clustering:**





Inertie totale des points = Inertie Intra-cluster + Inertie Inter-cluster

Comment obtenir une bonne partition ?

Il faut minimiser l'inertie intra-cluster et maximiser l'inertie inter-cluster

Introduction

❖ Approches de clustering:

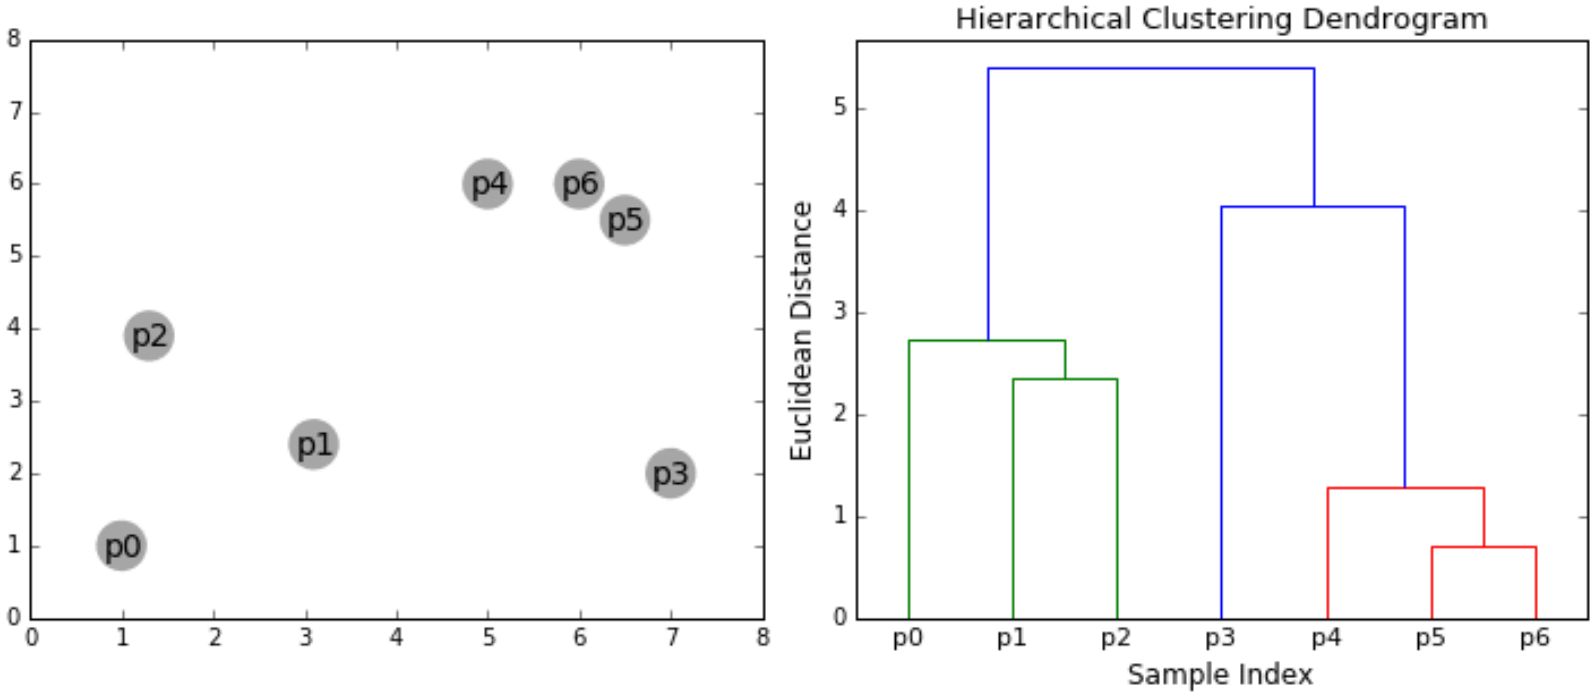
- **Clustering hiérarchique**
  - Clustering hiérarchique ascendant (CHA) et variantes

- **Clustering par partitionnement**
  - Algorithme des K-means

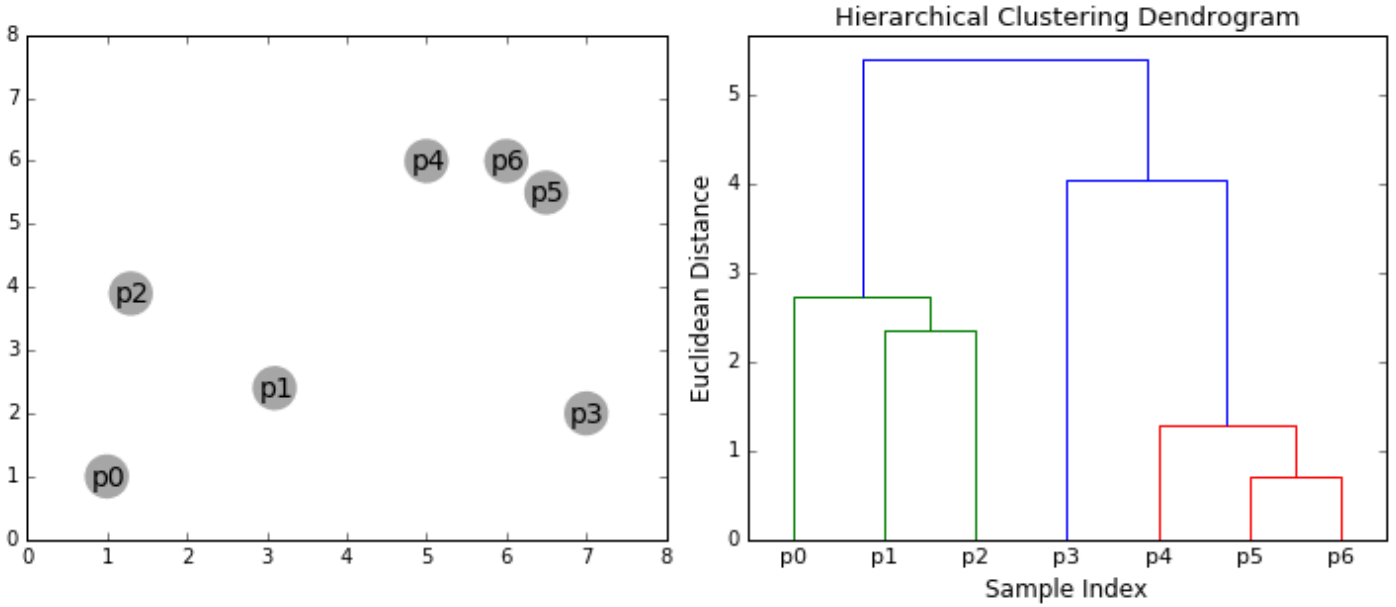
Principe

Principe

Chaque point ou cluster est progressivement "absorbé" par le cluster le plus proche.



Principe



Algorithme:

Initialisation

i. Chaque point forme un cluster

ii. Calcul de la matrice de distance M entre chaque couple de clusters

Répéter

i. Sélection dans M des deux clusters les plus proches Ci et Cj

ii. Fusion de Ci et Cj pour former un cluster Ck

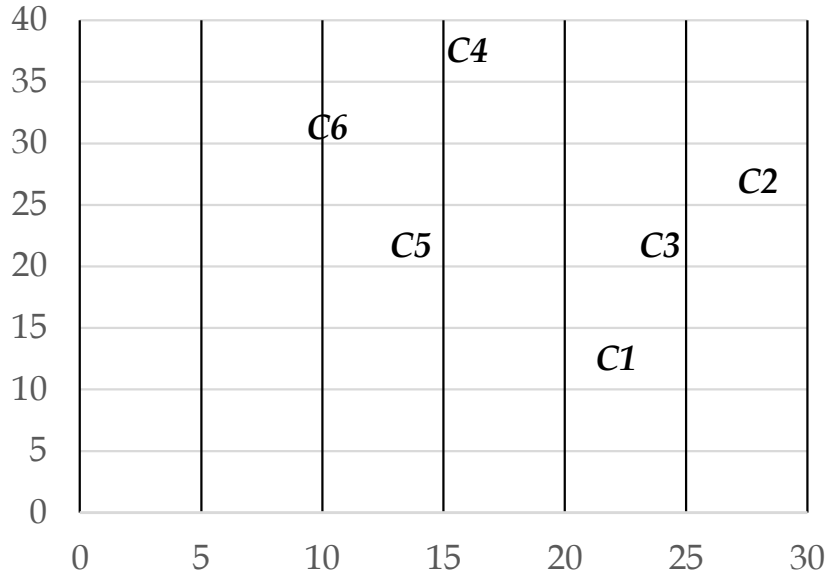
iii. Mise à jour de M en calculant la distance Ck et les autres clusters

Jusqu'à la fusion des deux derniers clusters

Principe

Exemple

Obs	(T. des pétales, T. de la tige)
O1	(22, 17)
O2	(27, 25)
O3	(25, 24)
O4	(15, 35)
O5	(13, 25)
O6	(12, 30)



Initialisation

Distance entre clusters: Lien simple à base de la distance euclidienne.

$M =$

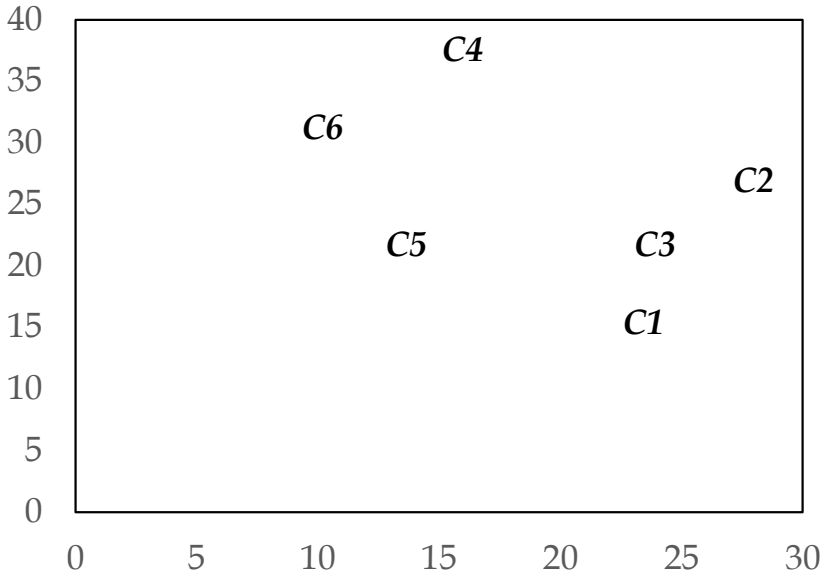
	C1	C2	C3	C4	C5	C6
C1	0	9,43	7,62	19,31	12,04	16,4
C2		0	2,24	15,62	14	15,8
C3			0	14,87	12,04	14,3
C4				0	10,2	5,83
C5					0	5,1
C6						0

Principe

Initialisation

$M =$

	C1	C2	C3	C4	C5	C6
C1	0	9,43	7,62	19,31	12,04	16,4
C2		0	2,24	15,62	14	15,8
C3			0	14,87	12,04	14,3
C4				0	10,2	5,84
C5					0	5,1
C6						0



Itération1

$d_{min} = d_{min}(C2, C3) \Rightarrow$ C7={C2, C3}

$d_{min}(C1, C7) = \min(d_{min}(C1, C2), d_{min}(C1, C3))$
$= \min(9.43, 7.62) = 7.62$

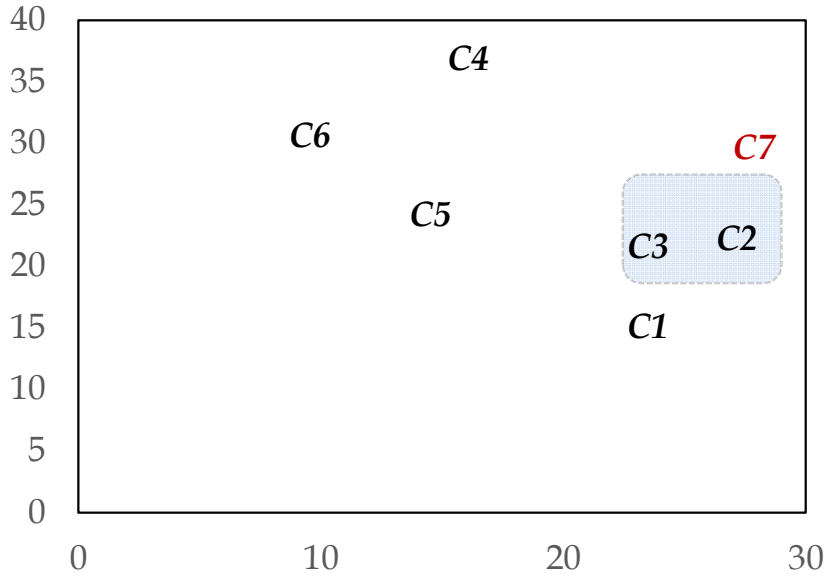
	C1	C7	C4	C5	C6
C1	0	7.62	19,31	12,04	16,4
C7		0	14,87	12,04	14,3
C4			0	10,2	5,84
C5				0	5,1
C6					0

Principe

Itération 1

$M =$

	C1	C7	C4	C5	C6
C1	0	7,62	19,31	12,04	16,4
C7		0	14,87	12,04	14,3
C4			0	10,2	5,84
C5				0	5,1
C6					0



Itération2

$d_{min} = d_{min}(C5, C6) \Rightarrow$ C8={C5, C6}

$d_{min}(C7, C8) = \min(d_{min}(C7, C5), d_{min}(C7, C6))$
$= \min(12.04, 14.3) = 12.04$

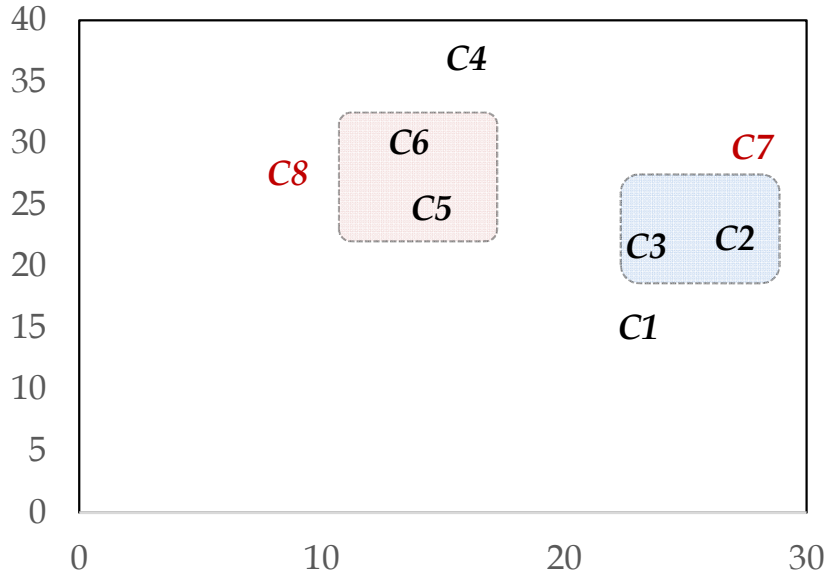
	C1	C7	C4	C8
C1	0	7,62	19,31	12,04
C7		0	14,87	12,04
C4			0	5,84
C8				0

Principe

Itération 2

$M =$

	C1	C7	C4	C8
C1	0	7,62	19,31	12,04
C7		0	14,87	12,04
C4			0	5,84
C8				0



Itération 3

$d_{min} = d_{min}(C4, C8) \Rightarrow$ C9={C4, C8}

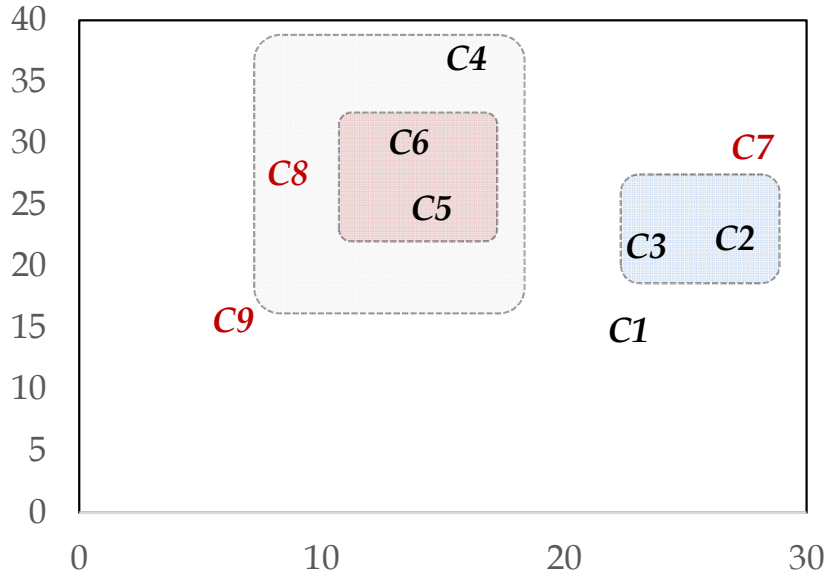
	C1	C7	C9
C1	0	7,62	12,04
C7		0	12,04
C9			0

Principe

Itération 3

$M =$

	C1	C7	C9
C1	0	7,62	12,04
C7		0	12,04
C9			0



Itération 4

$d_{min} = d_{min}(C1, C7) \Rightarrow$ C10={C1, C7}

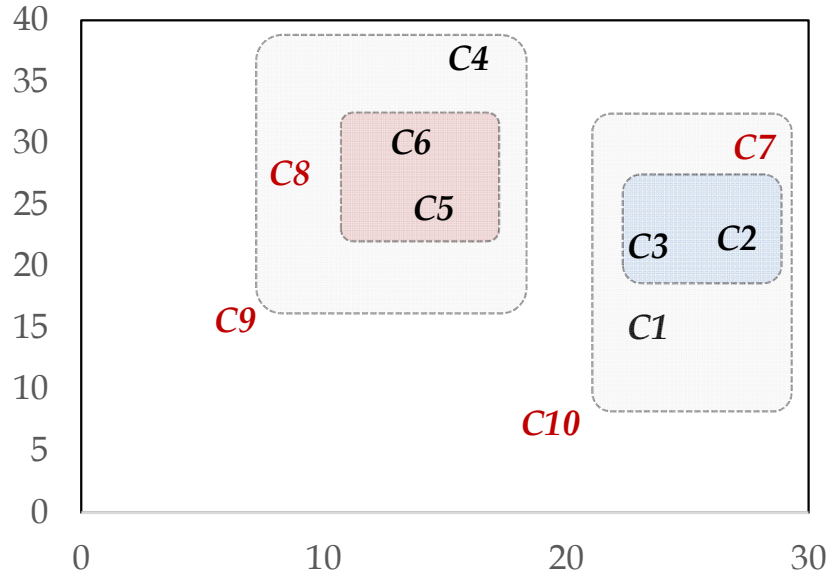
	C10	C9
C10	0	12,04
C9		0

Principe

Itération 4

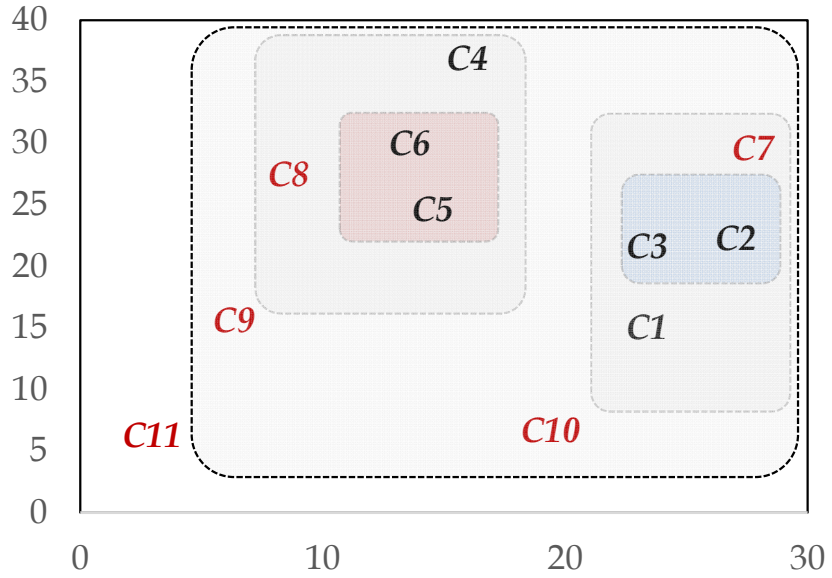
$M =$

	C10	C9
C10	0	12,04
C9		0



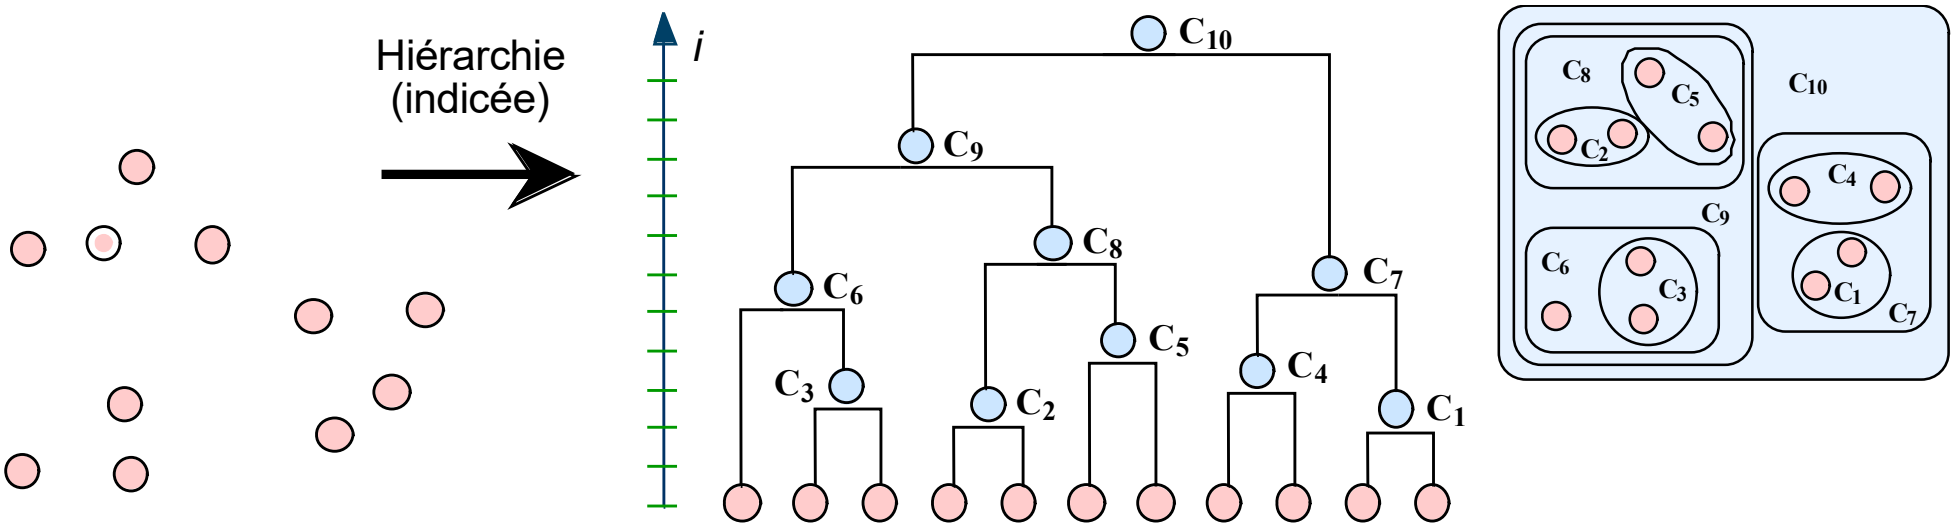
Itération 5

$d_{min} = d_{min}(C10, C9) \Rightarrow$ C11={C10, C9}



Principe

❖ Dendrogramme

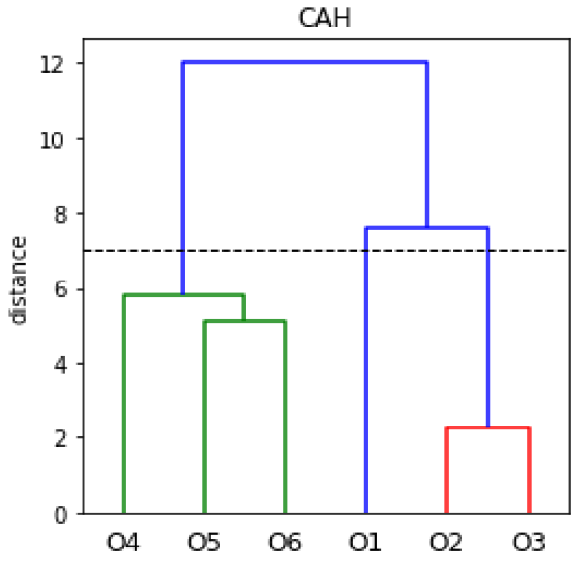


- Schéma du milieu : dendrogramme = représentation des fusions successives.

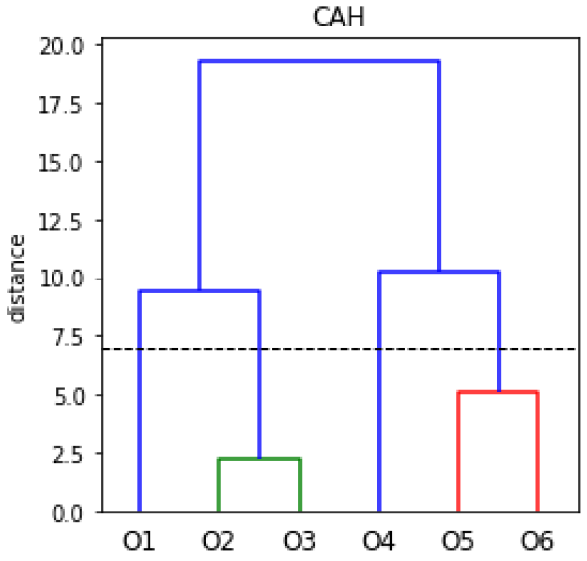
- Hauteur d'un cluster dans le dendrogramme = distance entre les 2 clusters avant fusion...

Principe

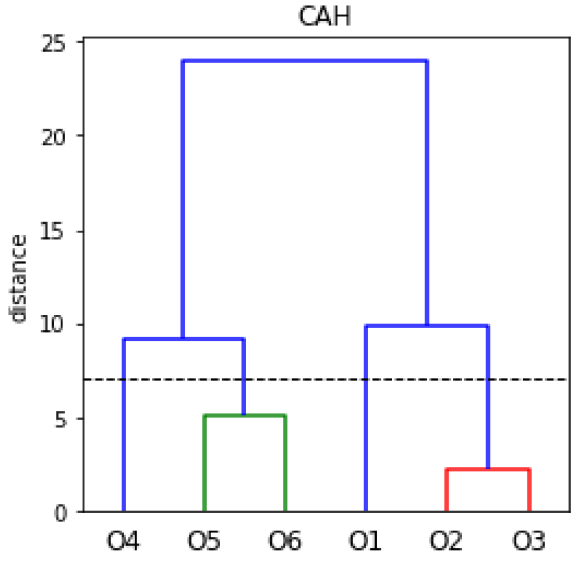
❖ **Dendrogramme: Exemple**



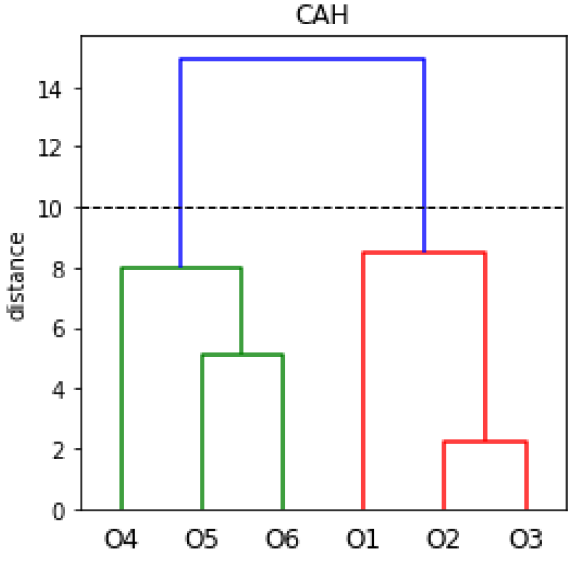
Distance:
lien simple



Distance:
lien complet



Distance de ward



Distance:
lien moyen

Principe

❖ Choix de l'ultramétrique (distance entre les clusters)

- Saut minimal (Lien simple) basé sur la distance $\boldsymbol{D_{min}(C1, C2)}$
  - Tendance à produire des classes générales (par effet de chainage).
  - Sensibilité aux individus bruites.
- Saut maximal (Lien complete) basé sur la distance $\boldsymbol{D_{max}(C1, C2)}$
  - Tendance à produire des classes spécifiques (on ne regroupe que des classes très proches)
  - Sensibilité aux individus bruites.
- Saut moyen basé sur la distance $\boldsymbol{D_{moy}(C1, C2)}$
  - tendance à produire des classes de variance proche.
- Barycentre basé sur la distance $\boldsymbol{D_{Ward}(C1, C2)}$
  - bonne résistance au bruit.

Points forts et points faibles

Points forts et points faibles

❖ Points forts

- Pas de dépendance au choix de centres initiaux.
- Pas de fixation à priori du nombre de classes.
- Détecte des classes de forme diverse.

❖ Points faibles

- Complexité algorithmique (non linéaire)
- A chaque étape, le critère de partitionnement n'est pas global mais dépend des classes déjà obtenues

Implémentation avec python

Allez voir le fichier ***TutorialClustering.ipynb*** *sur moodle*

Etapes de l'implémentation

