ENSIAS

Lecture 8: DBSCAN (Density-Based Spatial Clustering of Applications with Noise)

Introduction au Machine Learning

Prof. Aissam BERRAHOU

Département des systèmes embarqués et mobile

30 août 2026

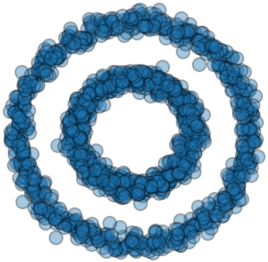
Plan

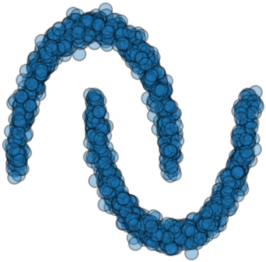
- Introduction
- Principe
- Implémentation avec Python
- Points forts et faibles de DBSCAN
- TP

Motivation

Considérons un jeu de données $D = \{x_1, x_2, ..., x_N\}$ de N observations bi-dimensionnelles

Comment partitionner ce jeu de données ?

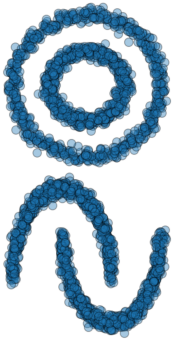


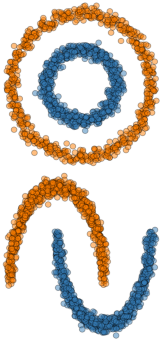


Motivation

Considérons un jeu de données $D = \{x_1, x_2, ..., x_N\}$ de N observations bi-dimensionnelles

Comment partitionner ce jeu de données ? **Une proposition naturelle**



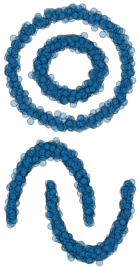


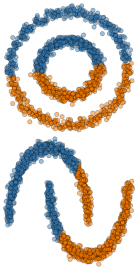
Le partitionnement proposé ci-dessus semble être évident mais peut-on l'obtenir automatiquement ?

Motivation

Hypothèses de k-means

- Clusters symétriques = il n'y pas de direction privilégiée dans un groupe.
- Compacts = les observations sont proches du centre de leur groupe.
- Convexes = il n'y a pas de « trou » dans les groupes.
- Linéairement séparables (deux à deux).





Quand k-means ne suffit plus. . . : la non-convexité et/ou la non-linéarité

Introduction

DBSCAN (Density-Based Spatial Clustering of Applications with Noise) est un algorithme de clustering qui identifie les groupes de points dans des régions denses :

- Proposé par Martin Ester, Hans-Peter Kriegel, Jörg Sander et Xiaowei Xu en 1996.
- Méthode de clustering non supervisée Basée sur la densité des points plutôt que sur des distances centroïdes comme k-means.
- Permet d'identifier des clusters de forme complexes(non convexes) et des points de bruit (outliers).
- Pas besoin de spécifier le nombre de clusters (k).

Principe

Taxonomie des observations selon DBSCAN

DBSCAN considère trois types de points selon les propriétés de leur voisinage :

Les points centraux (core points)

- Ce sont les points qui se trouvent au cœur d'un groupe.
- Leur voisinage doit contenir plus que minPts points.

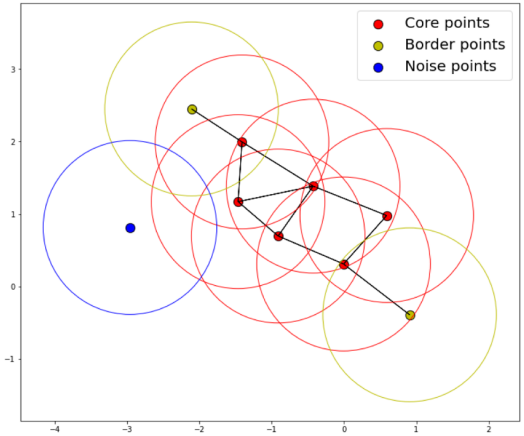
Les points frontière (border points)

- Ce sont les points qui bordent un groupe.
- Ils sont voisins d'un point central mais ne sont pas centraux eux-mêmes.

Les points aberrants ou isolés ou « bruit » (noise points)

- Ce sont les points isolés.
- Ils ne sont ni centraux, ni frontière.

Principe



Principe

Algorithm 1 DBSCAN

Choisir un point $x \in \mathcal{D}$ **pas encore visité**
Marquer x **comme visité**
Trouver le ϵ**-voisinage de** x **et mettre les voisins dans une liste**
Si le voisinage est m**-dense (si le nombre de voisins est supérieur à** m**) Alors**
    Assigner x **à un nouveau cluster**
    Pour chaque voisin x' **de** x **Faire**
        marquer x' **comme visité**
        Si le voisinage de x' **est dense Alors**
            ajouter ses voisins à la liste
        Fin Si
        Si x' **n'a pas encore de groupe Alors**
            l'ajouter au cluster
        Fin Si
    Fin Pour
Sinon
    Marquer x **comme aberrant**
Fin Si
Retour à 1 tant que tous les points n'ont pas été visités

Principe

Propriétés permettant à l'algorithme de réaliser un partitionnement par densité Soit un espace métrique $(\mathcal{X}, d)$, par exemple un espace vectoriel muni de la distance euclidienne, et $\mathcal{D} = \{x_1, \ldots, x_N\} \subset \mathcal{X}$ un jeu de données de N observations.

$\epsilon - voisinage$

On appelle ε**-voisinage** de x le sous-ensemble $V_\varepsilon(x) \subset \mathcal{D}$ tel que :

$$V_\varepsilon(x) = \{x' \in \mathcal{D} \mid d(x, x') < \varepsilon\}$$

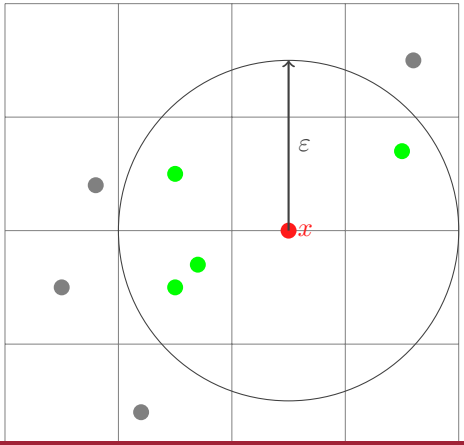
c'est-à-dire l'ensemble des observations qui sont à distance inférieure à ε de x. Autrement dit, ce sont les observations du jeu de données contenues dans la boule (ouverte) de rayon ε centrée sur x.

m-densité

Ce voisinage est m**-dense** s'il contient au moins m points.

Illustration de l'ε-voisinage

L'ϵ-voisinage ci-dessous est 4-dense : l'observation x (en rouge) possède 4 voisins (en vert) à distance inférieure à ϵ



Quels paramètres pour DBSCAN ?

L'exécution de l'algorithme DBSCAN nécessite de régler deux paramètres :

- ε, la taille du voisinage et donc le rayon de la boule dans laquelle on peut passer d'un point à un autre sans changer de groupe.
- m (ou minPts), le nombre minimum de voisins pour qu'un voisinage soit qualifié de dense.

ε

- Si ε est trop faible, alors aucune observation n'est voisine d'aucune autre $\Rightarrow$ uniquement des points aberrants.
- Si ε est trop grand, trop de points sont voisins entre eux $\Rightarrow$ un seul groupe qui recouvre toutes les observations.

m ou ($minPts$)

- Si m est faible, tous les voisinages sont denses : il suffit d'un seul voisin en commun pour relier deux groupes.
- Si m est grand, peu de voisinages sont denses : beaucoup de points seront points

Points forts et faibles de DBSCAN

Points forts.

- ✔ Ne nécessite pas de spécifier le nombre de clusters.
- ✔ Gère efficacement les données bruitées (outliers).
- ✔ Identifie des clusters de formes complexes.

Points faibles.

- ✖ Sensible au choix des paramètres (epsilon et MinPts).
- ✖ Performances réduites sur des données de très grande dimension.

TP à faire

1. Implémenter DBSCAN from scratch sans utiliser `scikit-learn`.
2. Appliquer DBSCAN à des problèmes concrets sur des bases de données.