

Lecture2: Régression

Aissam BERRAHOU

Aissam.berrahou@ensias.um5.ac.ma

Laboratoire Smart Systems Lab

Plan

- 1) **Origine et applications**
- 2) **Notations et vocabulaire**
- 3) **Régression linéaire simple**
- 4) **Régression polynomiale**
- 5) **Régression multiple**

1. Origine et applications

Origine et applications


❖ Origine

Francis Galton 1822-1911



Regression towards mediocrity stature

Journal of the Antropological Institue 15: 246-63(1886)



La taille des enfants nés des parents très grands(ou petits)

se rapproche de la taille moyenne de la population

→ elle régresse

❖ Objectif

Analyser la **relation** entre

- Une **variable expliquée**
 - Une variable dépendante
 - Réponse
 - Variable endogène

Et

- Une ou plusieurs **variables explicatives**
 - Variable indépendantes
 - Prédicteurs
 - Variables exogènes

Exemple de Galton :

- Taille des pères: **variable explicative**
- Tailles des enfants: **variable expliquée**

dans un but

- explicatif
- de prévision
- ...



sous l'hypothèse que la **relation** est **linéaire en ses paramètres (et pas forcément qu'il existe une linéarité entre les variables)**.

Et


À partir de données

Origine et applications

❖ Exemples: Industrie





❖ Exemples: Economie




Origine et applications

❖ Exemples: Médecine



Origine et applications

❖ Exemples: Médecine



2. Notation et vocabulaire

❖ Vocabulaire


- Régression linéaire simple Régression polynomiale
 - Une seule variable expliquée
 - Une seule variable explicative
- Régression linéaire multiple
 - Une seule variable expliquée
 - Plusieurs variables explicatives

❖ Notations

- y est la **variable expliquée** (à valeurs dans $\mathbb{R}$).
- x est la **variable explicative** (à valeurs dans $\mathbb{R}$).
- $y \approx \beta_0 + \beta_1 x$, la **relation approximative** entre x et y .
- β_0, β_1 : les **paramètres** (les coefficients) du modèle.
- $\hat{\beta}_0, \hat{\beta}_1$: les **estimations** des paramètres.
- $y = \beta_0 + \beta_1 x + \varepsilon$ avec ε le **terme d'erreur** aléatoire du modèle.
- $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$: la **prédiction de la variable expliquée**.

❖ Exemple

<i>Température (x_i)</i>	<i>Rendement(y_i)</i>
100	45
110	51
120	50
130	61
140	66



❖ Etude de la relation de linéarité entre deux variables quantitatives:

Coefficient de corrélation linéaire (Pearson)

$$r_{XY} = \frac{S_{XY}}{S_X S_Y}, \quad \text{où } -1 \leq r_{XY} \leq 1$$

Variance :

$$S_X^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2,$$
$$S_Y^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2.$$


Covariance :

$$S_{XY} = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \frac{1}{n} \sum_{i=1}^n x_i y_i - \bar{x} \bar{y}$$

❖ Etude de la relation de linéarité entre deux variables quantitatives:


- Interprétation du coefficient de corrélation linéaire (Pearson)

- Si r est proche de 0, il n'y a pas de relation linéaire entre X et Y .
- Si r est proche de -1, il existe une forte relation linéaire négative entre X et Y .
- Si r est proche de 1, il existe une forte relation linéaire positive entre X et Y .



Notations et Vocabulaire

❖ Etude de la relation de linéarité entre deux variables quantitatives:



2. Régression linéaire simple

a. Formulation d'un modèle de régression linéaire simple

❖ Comment trouver un modèle de régression pour un problème donné?

1. Dataset (X,Y)

- variables explicatives (features)
- variable expliquée (target)

2. Modèle

- Régression: Modèle de régression linéaire simple/ linéaire multiple/ polynomiale

3. Fonction coût


- Erreur quadratique $L(y_i, f(x_i)) = (y_i - f(x_i))^2$
- Ecart absolu : $L(y_i, f(x_i)) = |y_i - f(x_i)|$
- ...

4. Algorithme d'optimisation

- Méthode moindres carrés
- Descente de gradient
- Maximum de vraisemblance

Régression linéaire simple

❖ Modèle de régression simple



Modèle de régression linéaire simple ($y = \beta_1 x + \beta_0 + \varepsilon$)

Régression linéaire simple

❖ Estimation des paramètres β_0, β_1

1. Dataset (X,Y)

- variable explicative (feature)
- variable expliquée (target)

2. Modèle

- Régression: Modèle linéaire simple. $Y = \beta X + \varepsilon$

$$(Y \approx \beta X) \text{ où } \mathbf{Y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}, \mathbf{X} = \begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix}, \boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix}, \text{ et } \boldsymbol{\varepsilon} = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$

3. Fonction coût



- Erreur quadratique

$$Li(\beta_0, \beta_1) = (y_i - f(x_i))^2$$

$$L(\beta_0, \beta_1) = \frac{1}{n} (\mathbf{X}\boldsymbol{\beta} - \mathbf{Y})^T (\mathbf{X}\boldsymbol{\beta} - \mathbf{Y})$$

4. Algorithme d'optimisation

- Méthode des moindres carrés
- Descente de gradient



b. Estimation ponctuelle des paramètres d'un modèle de régression linéaire simple

Régression linéaire simple

❖ Estimation des paramètres β_0 et β_1

- On cherche $\widehat{\beta}_0$ et $\widehat{\beta}_1$ (estimateurs respectivement de β_0 et β_1) qui minimisent la somme des carrés des résidus
- Selon la méthode des moindres carrés on doit résoudre le **problème d'optimisation** suivant :

$$\underset{(\beta_0, \beta_1) \in \mathbb{R}^2}{\operatorname{argmin}} L(\beta_0, \beta_1)$$

$$\text{avec } L(\beta_0, \beta_1) = 1/n \sum_{i=1}^n \varepsilon_i^2 = 1/n \sum_{i=1}^n [y_i - (\beta_0 + \beta_1 x_i)]^2$$

Problème à optimiser

Fonction coût

Régression linéaire simple

❖ Estimation des paramètres β_0 et β_1

A partir d'un échantillon (aléatoire) de **n observations** $\{(x_i, y_i), i = 1, \dots, n\}$, on veut **estimer** les paramètres **β_0 et β_1** .


- la méthode des moindres carrés
- La méthode de gradient descente

} Méthodes d'optimisation

Régression linéaire simple


- ❖ Estimation des paramètres β_0 et β_1 par la méthode des moindres carrés.

$$\nabla L(\beta_0, \beta_1) = 0 \Rightarrow \begin{cases} \frac{\partial L(\beta_0, \beta_1)}{\partial \beta_1} = - \sum_{i=1}^n [y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i)] = 0, \\ \frac{\partial L(\beta_0, \beta_1)}{\partial \beta_0} = - \sum_{i=1}^n [y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i)] x_i = 0. \end{cases}$$



On en déduit après quelques manipulations:

$$\begin{cases} \hat{\beta}_1 = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{X})(y_i - \bar{Y})}{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{X})^2} = \frac{Cov(X, Y)}{S_X^2}, \\ \hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X} \end{cases}$$



Régression linéaire simple

- ❖ Estimation des paramètres β_0 et β_1 par la méthode des moindres carrés (Formulation matricielle).

Formulation matricielle de la fonction coût

$$L(\beta_0, \beta_1) = \frac{1}{n} \sum_{i=0}^n \varepsilon_i^2 = \frac{1}{n} \sum_{i=1}^n [y_i - (\beta_0 + \beta_1 x_i)]^2 \quad \text{où} \quad \mathbf{X} = \begin{pmatrix} x_1 & \mathbf{1} \\ x_2 & \mathbf{1} \\ \vdots & \vdots \\ x_n & \mathbf{1} \end{pmatrix} \quad \mathbf{Y} = \begin{pmatrix} y_1 \\ y_1 \\ \vdots \\ y_1 \end{pmatrix} \quad \boldsymbol{\beta} = \begin{pmatrix} \beta_1 \\ \beta_0 \end{pmatrix}$$
$$= \frac{1}{n} (\mathbf{X}\boldsymbol{\beta} - \mathbf{Y})^T (\mathbf{X}\boldsymbol{\beta} - \mathbf{Y})$$

Donc

$$\frac{\partial L(\boldsymbol{\beta})}{\partial \boldsymbol{\beta}} = 0 \quad \Leftrightarrow \quad \frac{\partial L(\boldsymbol{\beta})}{\partial \boldsymbol{\beta}} = \frac{2}{n} \mathbf{X}^T (\mathbf{X}\boldsymbol{\beta} - \mathbf{Y})$$

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{Y}$$

Régression linéaire simple


- ❖ Estimation des paramètres β_0 et β_1 par la méthode des moindres carrés.

Les paramètres du modèle sont estimés à partir des données $(x_i, y_i)_{i=1, \dots, n}$

Température (x_i)	Rendement(y_i)
100	45
110	51
120	50
130	61
140	66

$$\begin{cases} \hat{\beta}_0 = -7,8 \\ \hat{\beta}_1 = 0,52 \end{cases}$$

$$\hat{y} = -7.8 + 0.52x$$



Régression linéaire simple

- ❖ Exemple1 : Estimation des paramètres β_0 et β_1 par la méthode des moindres carrés.

Les paramètres du modèle sont estimés à partir des données $(x_i, y_i)_{i=1, \dots, n}$

N°obs	x_i	y_i
1	-1	-1
2	0	-1
3	1	1
Moyenne	$\bar{X} = 0$	$\bar{Y} = -1/3$
Variance	$S_X^2 = 2/3$	$S_Y^2 = 8/9$

$$\widehat{\beta}_1 = \frac{\text{Cov}(X, Y)}{S_X^2} = \frac{\frac{2}{3}}{\frac{2}{3}} = 1,$$
$$\widehat{\beta}_0 = \bar{Y} - \widehat{\beta}_1 \bar{X} = \frac{-1}{3}$$


$$\hat{y} = \mathbb{E}[y] = \widehat{\beta}_0 + \widehat{\beta}_1 x = \frac{-1}{3} + x$$

Régression linéaire simple

❖ Exemple1 : Estimation des paramètres β_0 et β_1 par la méthode des moindres carrés.

N°obs	x_i	y_i	$\hat{y}_i$	$e_i = y_i - \hat{y}_i$ (résidu)
1	-1	-1	-4/3	1/3
2	0	-1	-1/3	-2/3
3	1	1	2/3	1/3
Moyenne	$\bar{X} = 0$	$\bar{Y} = -1/3$	$\bar{\hat{Y}} = -1/3$	0
Variance	$S_X^2 = 2/3$	$S_Y^2 = 8/9$		

$$\hat{y} = \mathbb{E}[y] = \hat{\beta}_0 + \hat{\beta}_1 x = \frac{-1}{3} + x$$



Régression linéaire simple

❖ Tutorial d'implémentation:

- Implémentation à partir de zéro: *TutorialRegressionLineaireSimple_moindrescarres.ipynb*
- Implémentation à base de la bibliothèque scikit-learn

Régression linéaire simple

❖ Estimation des paramètres β_0 et β_1 avec la méthode de descente gradient

- Rappel sur l'apprentissage supervisé

1. Dataset (X,Y)

- variable explicative(feature)
- variable expliquée(target)

2. Modèle

- Régression: Modèle linéaire simple

3. Fonction coût

- Erreur quadratique moyenne

$$L(\beta_0, \beta_1) = \frac{1}{2} \sum_{i=0}^n \varepsilon_i^2 = \frac{1}{2} \sum_{i=1}^n [y_i - (\beta_0 + \beta_1 x_i)]^2$$


4. Algorithme d'optimisation

- Descente de gradient


Régression linéaire simple

❖ Estimation des paramètres β_0 et β_1 avec la méthode de descente gradient

- Descente de gradient est une méthode d'optimisation **itérative** qui converge vers **un seul minimum** d'une **fonction convexe**.



Forme convexe



Forme non convexe

Régression linéaire simple

❖ Estimation des paramètres β_0 et β_1 avec la méthode de descente gradient

- Principe




Régression linéaire simple


❖ Estimation des paramètres β_0 et β_1 avec la méthode de descente gradient

- Fonction coût

$$L(\beta_0, \beta_1) = \frac{1}{n} \sum_{i=0}^n \varepsilon_i^2 = \frac{1}{n} \sum_{i=1}^n [y_i - (\beta_0 + \beta_1 x_i)]^2$$



$L(\beta_0, \beta_1)$ fonction convexe




Avancer avec un pas α

α : la vitesse d'apprentissage (Learning rate)

Régression linéaire simple

- ❖ Estimation des paramètres β_0 et β_1 avec la méthode de descente gradient

Comment calculer les estimateurs de β_0, β_1 ?



Tantque ($j < k$) faire

$$\beta_{0,i+1} \leftarrow \beta_{0,i} - \alpha \frac{\partial L(\beta_{0,i})}{\partial \beta_0}$$


$$\beta_{1,i+1} \leftarrow \beta_{1,i} - \alpha \frac{\partial L(\beta_{1,i})}{\partial \beta_1}$$

FinTantque


Régression linéaire simple

❖ Estimation des paramètres β_0 et β_1 avec la méthode de descente gradient

- Comment choisir la valeur de la vitesse d'apprentissage α (*toujours positive*) ?



Si la valeur de α est grande (Allez plus vite)



Si la valeur de α est trop petite (Allez doucement)

Régression linéaire simple

❖ Estimation des paramètres β_0 et β_1 avec la méthode de descente gradient

- Comment choisir la valeur de la vitesse d'apprentissage α (*toujours positive*) ?

1. Si α est trop petit :

- L'algorithme converge lentement, car les pas sont très petits.
- Risque de rester coincé dans un minimum local ou de ne pas converger dans un temps raisonnable.

2. Si α est trop grand :

- L'algorithme peut diverger, car les pas sont trop grands et dépassent le minimum.
- Risque d'osciller autour du minimum sans jamais converger.

3. Si α est bien choisi :

- L'algorithme converge rapidement et de manière stable vers le minimum global.

Régression linéaire simple

❖ Estimation des paramètres β_0 et β_1 avec la méthode de descente gradient

- Formulation matricielle de la fonction coût

Fonction coût

$$\mathbf{X} = \begin{bmatrix} x_1 & 1 \\ x_2 & 1 \\ x_3 & 1 \\ \dots & \\ x_n & 1 \end{bmatrix} \quad \mathbf{Y} = \begin{bmatrix} y_1 \\ y_2 \\ y_3 \\ \dots \\ y_n \end{bmatrix} \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_1 \\ \beta_0 \end{bmatrix}$$

$$L(\beta_0, \beta_1) = \frac{1}{n} \sum_{i=1}^n \varepsilon_i^2 = \frac{1}{n} \sum_{i=1}^n [y_i - (\beta_0 + \beta_1 x_i)]^2 = \frac{1}{n} (\mathbf{X}\boldsymbol{\beta} - \mathbf{Y})^T (\mathbf{X}\boldsymbol{\beta} - \mathbf{Y})$$

Et le gradient

$$\frac{\partial L(\boldsymbol{\beta})}{\partial \boldsymbol{\beta}} = \frac{2}{n} \mathbf{X}^T (\mathbf{X}\boldsymbol{\beta} - \mathbf{Y})$$

Régression linéaire simple

❖ Estimation des paramètres β_0 et β_1 avec la méthode de descente gradient

- Rappel sur l'apprentissage supervisé(Avec la formulation matricielle)

1. Dataset (X,Y)

- variable explicative(feature)
- variable expliquée(target)

2. Modèle

- Régression: Modèle linéaire simple. $Y = \beta X + \varepsilon$

3. Fonction coût

- Erreur quadratique moyenne

$$L(\beta_0, \beta_1) = \frac{1}{n} (X\beta - Y)^T (X\beta - Y)$$

4. Algorithme d'optimisation: Descente de gradient

Tantque (j < k) faire



$$\beta = \beta - \alpha \frac{\partial L(\beta)}{\partial \beta}$$

$$\text{Gradient: } \frac{\partial L(\beta)}{\partial \beta} = \frac{2}{n} X^T (X\beta - Y)$$

FinTantque

c. Implémentation et simulation

Simulation



TP1: Régression linéaire simple

1. Dataset (X,Y)

- variable explicative(feature)
- variable expliquée(target)

2. Modèle

- Régression: Modèle linéaire simple. $Y = \beta X + \varepsilon$

3. Fonction coût

- Erreur quadratique moyenne

$$L(\beta_0, \beta_1) = \frac{1}{n} (X\beta - Y)^T (X\beta - Y)$$

4. Algorithme d'optimisation: Descente de gradient

Tantque ($j < k$) faire

$$\beta = \beta - \alpha \frac{\partial L(\beta)}{\partial \beta} \quad // \text{Gradient: } \frac{\partial L(\beta)}{\partial \beta} = \frac{2}{n} X^T (X\beta - Y)$$

FinTantque

V. explicative

V. expliquée

observations	x	y
	x_1	y_1
	x_2	y_2
	...	...
	x_n	y_n

X=

x_1	1
x_2	1
x_3	1
...	
x_n	1

Y=

y_1
y_2
y_3
...
y_n

β =

β_1
β_0

Création/ lecture d'une BD(X,y)

Splitting de la BD(E. Apprentissage, Ens. Test)

Initialisation des paramètres d'un modèle

Modèle

Fonction coût

Entraînement

Gradients

Mise à jour des paramètres

Test

TP1: Régression linéaire simple


Création/ lecture d'une BD(X,y)



```
import numpy as np
from sklearn.datasets import make_regression
import matplotlib.pyplot as plt
```



```
x,y=make_regression(n_samples=100, n_features=1, noise=10)
y=y.reshape(100,1)
plt.scatter(x,y)
```




TP1: Régression linéaire simple

Splitting de la BD(E. Apprentissage, Ens. Test)



```
from sklearn.model_selection import train_test_split  
  
x_train,x_test,y_train,y_test=train_test_split(x,y,test_size=0.2  
, random_state=42)
```



```
trPlot=plt.scatter(x_train,y_train,c='b')  
tePlot=plt.scatter(x_test,y_test,c='g')  
plt.legend([trPlot,tePlot],["Exemples d'apprentissage","Exemples de test"])  
plt.show()
```

TP1: Régression linéaire simple


Initialisation des paramètres d'un modèle

$$\mathbf{X} = \begin{bmatrix} x_1 & 1 \\ x_2 & 1 \\ x_3 & 1 \\ \dots & \\ x_n & 1 \end{bmatrix} \quad \mathbf{Y} = \begin{bmatrix} y_1 \\ y_2 \\ \dots \\ y_m \end{bmatrix} \quad \boldsymbol{\beta} = \begin{bmatrix} \beta_1 \\ \beta_0 \end{bmatrix}$$

```
▶ X_train=np.hstack((x_train,np.ones((np.shape(x_train)[0],1))))  
X_test=np.hstack((x_test,np.ones((np.shape(x_test)[0],1))))  
  
beta=np.random.randn(2,1)
```

Modèle

```
▶ def model(X,beta):  
    return X.dot(beta)  
  
y_pred_train=model(X_train,beta)  
plt.scatter(x_train,y_train)  
plt.plot(x_train,y_pred_train, c='r')  
plt.show()
```



TP1: Régression linéaire simple

Fonction coût

$X=$

x_1	1
x_2	1
x_3	1
...	
x_n	1

$\beta=$

β_1
β_0

$$L(\beta_0, \beta_1) = \frac{1}{n} \sum_{i=0}^n \varepsilon_i^2 = \frac{1}{n} \sum_{i=1}^n [y_i - (\beta_0 + \beta_1 x_i)]^2 = \frac{1}{n} (X\beta - Y)^T (X\beta - Y)$$



```
def fonction_cout(X,beta,y):  
    n=len(y)  
    term=model(X,beta)-y  
    return (1/n)*term.T.dot(term)[0,0]  
print("mse:", fonction_cout(X_train,y_train,beta))
```

TP1: Régression linéaire simple

Gradient

$$\text{Gradient: } \frac{\partial L(\beta)}{\partial \beta} = \frac{2}{n} X^T (X\beta - Y)$$

```
def grad(X, y, beta):  
    n=len(y)  
    return (2/n)*X.T.dot(model(X,beta)-y)
```


Mise à jour des paramètres

Tantque ($j < k$) faire


$$\beta = \beta - \alpha \frac{\partial L(\beta)}{\partial \beta}$$

FinTantque

```
def gradient_descent(X, y, beta, learning_rate=0.001, n_iteration=1000):  
    for i in range(n_iteration):  
        beta=beta-learning_rate*grad(X, y, beta)  
    return beta
```




$L(\beta_0, \beta_1)$ fonction convexe



$$//\text{Gradient: } \frac{\partial L(\beta)}{\partial \beta} = \frac{2}{n} X^T (X\beta - Y)$$

TP1: Régression linéaire simple

Apprentissage



```
beta_estimer=gradient_descent(X_train,y_train,beta,learning_rate=0.01, n_iteration=2000)
```




```
y_pred_train=model(X_train,beta_estimer)
plt.scatter(x_train,y_train,c='b',label="nuage de points(Apprentissage) ")
plt.plot(x_train,y_pred_train, c='r',label="droite de régression" )
plt.legend()
plt.show()
```

TP1: Régression linéaire simple

Test



```
y_pred_test=model(X_test,beta_estimator)
plt.scatter(x_test,y_test,c='g',label="nuage de points(Test)")
plt.plot(x_test,y_pred_test, c='r',label="droite de régression" )
plt.legend()
plt.show()
```



TP1: Régression linéaire simple


Courbe d'apprentissage



```
def gradient_descent_with_cost_history(X,y,beta,learning_rate=0.001, n_iteration=1000):  
    cost_history=[]  
    for i in range(n_iteration):  
        beta=beta-learning_rate*grad(X,y,beta)  
        cost_history.append(fonction_cout(X,beta,y))  
    return beta, cost_history
```



```
beta_estimator,cost_history=gradient_descent_with_cost_history(X_train,y_train,beta,learning_rate=0.01,  
n_iteration=2000)  
plt.plot(cost_history,c='r')  
plt.xlabel("nb d'itérations")  
plt.ylabel("Erreur")  
plt.show()
```




TP1: Régression linéaire simple

Evaluation du modèle par l'analyse de la variance(Coefficient de détermination)



```
def coef_determination(y, y_pred):  
    u = ((y - y_pred) ** 2).sum()  
    v = ((y - y.mean()) ** 2).sum()  
    return 1 - u/v  
  
print(coef_determination(y_train, y_pred_train))  
print(coef_determination(y_test, y_pred_test))
```



❖ Indicateur de qualité d'ajustement(de régression) :

- Coefficient de détermination R^2

$$R^2 = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{Y})^2}{\sum_{i=1}^n (y_i - \bar{Y})^2} = \frac{SCE}{SCT} = 1 - \frac{SCR}{SCT}$$

- Somme des carrés totale: $SCT = \sum_{i=1}^n (y_i - \bar{Y})^2$
- Somme des carrés expliqués: $SCE = \sum_{i=1}^n (\hat{y}_i - \bar{Y})^2$
- Somme des carrés résiduels: $SCR = \sum_{i=1}^n (\hat{y}_i - y_i)^2$

Commentaire. Le coefficient R^2 donne la proportion de variabilité de y qui est expliquée par le modèle. Plus le R^2 est proche de 1, plus une meilleure adéquation du modèle aux données

Problème d'estimation ponctuelle


❖ Problématique:

Et si on avait plusieurs jeu de données


$$\begin{cases} \widehat{\beta}_0 = -7,8 \\ \widehat{\beta}_1 = 0,52 \end{cases} \quad \begin{cases} \widehat{\beta}_0 = -3,39 \\ \widehat{\beta}_1 = 0,48 \end{cases} \quad \begin{cases} \widehat{\beta}_0 = -1,81 \\ \widehat{\beta}_1 = 0,47 \end{cases}$$

Température (x_i)	Rendement(y_i)
100	45
110	51
120	50
130	61
140	66
150	70
160	72
170	78
180	85
190	85

Rendement d'un champ en fonction de la température



Rendement d'un champ en fonction de la température



d. Estimation des paramètres par intervalle de confiance

Estimation des paramètres par intervalle de confiance

❖ Propriétés statistiques de la droite des moindres carrés:

- (A1) L'erreur ε est une v.a.r non observée avec $\mathbb{E}[\varepsilon] = 0, \mathbb{V}(\varepsilon) = \sigma^2$.
 σ paramètre à estimer en plus de β_0, β_1
- (A2) $\text{Cov}(\varepsilon_i, \varepsilon_j) = 0, \forall i \neq j$
- (A3) $\varepsilon \sim N(0, \sigma^2)$

Commentaires sur l'hypothèse:

- On parle d'hypothèse **d'homoscédasticité A2** (homogénéité des variances).
- Cette variance est supposée **constante et indépendante de x_i** .
- Cette variance σ^2 est un **paramètre du modèle qu'il faudra estimer**.
- **$\text{Cov}(\varepsilon_i, \varepsilon_j) = 0$, les termes d'erreur ε_i sont non corrélés.**

Estimation des paramètres par intervalle de confiance

❖ Propriétés des estimateurs paramètres $\widehat{\beta_0}$ et $\widehat{\beta_1}$:

Théorème:

- $\mathbb{E}[\widehat{\beta_1}] = \beta_1$ et $\mathbb{E}[\widehat{\beta_0}] = \beta_0$ (estimateurs sans biais)
- $S_{\widehat{\beta_0}}^2 = \mathbb{V}[\widehat{\beta_0}] = \sigma^2 \left(\frac{1}{n} + \frac{(\bar{X})^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right) = \sigma^2 \left(\frac{1}{n} + \frac{(\bar{X})^2}{nS_X^2} \right)$
- $S_{\widehat{\beta_1}}^2 = \mathbb{V}[\widehat{\beta_1}] = \left(\frac{\sigma^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right) = \frac{\sigma^2}{nS_X^2}$
- $Cov(\widehat{\beta_0}, \widehat{\beta_1}) = -\frac{n\sigma^2\bar{X}}{S_X^2}$

Commentaires

- Les estimateurs $\widehat{\beta_0}$ et $\widehat{\beta_1}$ sont **sans biais**.
- Ils sont aussi de **variance minimale** parmi tous les estimateurs linéaires.

Estimation des paramètres par intervalle de confiance

❖ Estimation de la variance σ^2 par la variation résiduelle

Le paramètre σ^2 est défini par

$$\sigma^2 = \mathbb{V}(\varepsilon_i) = \mathbb{E}(\varepsilon_i^2)$$

En prenant $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i$ comme estimateur de $\mathbb{E}[y_i]$, il apparaît naturel d'estimer par σ^2

$$S_{\varepsilon}^2 = \hat{\sigma}^2 = \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n - 2} = \frac{\sum_{i=1}^n e_i^2}{n - 2} = \frac{SCR}{n - 2}$$

Commentaires

- $\hat{\sigma}^2$ est un estimateur sans biais de σ^2
- La perte de deux degrés de liberté dans l'expression de S_{ε}^2 est le "coût" de l'estimation de β_0 et de β_1 nécessaire pour obtenir les $\hat{y}_i$.
- **SCR**: Somme des Carrés Résiduelle (Variabilité résiduelle).

Estimation des paramètres par intervalle de confiance

❖ Exemple: calcul des estimateurs des paramètres β_0, β_1

N°obs	x_i	y_i	$\hat{y}_i$	$\varepsilon_i = y_i - \hat{y}_i$	ε_i^2
1	-1	-1	-4/3	1/3	1/9
2	0	-1	-1/3	-2/3	4/9
3	1	1	2/3	1/3	1/9
Moyenne	$\bar{X} = 0$	$\bar{Y} = -1/3$	$\bar{\hat{Y}} = -1/3$	0	2/3
Variance	$S_X^2 = 2/3$	$S_Y^2 = 8/9$	-	-	$\hat{\sigma}^2 = S_\varepsilon^2 = 2/3$

Estimation des paramètres par intervalle de confiance

❖ Lois des estimateurs $\hat{\sigma}^2$, $\hat{\beta}_0$ et $\hat{\beta}_1$

Sous les hypothèses (A1)-(A2), on a :

- Lois de l'estimateur de σ^2

$$\frac{(n-2)\hat{\sigma}^2}{\sigma^2} \sim \chi^2_{n-2}$$

Loi de χ^2 à n-2 degrés de libertés

- Lois des estimateurs $\hat{\beta}_0$ et $\hat{\beta}_1$

$$\hat{\beta}_i \sim \mathcal{N}(\beta_i, \mathbb{V}[\hat{\beta}_i])$$

$$\sigma^2 \rightarrow \hat{\sigma}^2$$

$$\mathbb{V}[\hat{\beta}_i] \rightarrow s^2_{\hat{\beta}_i}$$


Un rappel de probabilité

- Si $U \sim \mathcal{N}(0, 1)$, $V \sim \chi^2(v)$ et U indépendant de V, alors $\frac{U}{\sqrt{\frac{V}{v}}} \sim \mathcal{T}(v)$.

Estimation des paramètres par intervalle de confiance


❖ Estimation des β_i par intervalle de confiance au niveau de confiance $1-\alpha$

$$\mathbb{P}\left(-t_{1-\frac{\alpha}{2};n-2} \leq \frac{\hat{\beta}_i - \beta_i}{S_{\hat{\beta}_i}} \leq t_{1-\frac{\alpha}{2};n-2}\right) = 1-\alpha$$



Avec $t_{1-\frac{\alpha}{2};n-2}$ la valeur telle que $\mathbb{P}(T \leq t_{1-\frac{\alpha}{2};n-2}) = 1-\alpha/2$ et T de la loi de Student $\mathcal{T}(n-2)$

$$\text{IC}(\beta_i) = \left[\hat{\beta}_i \pm t_{1-\frac{\alpha}{2};n-2} S_{\hat{\beta}_i} \right]$$




Estimation des paramètres par intervalle de confiance

❖ Estimation de σ^2 par intervalle de confiance au niveau de confiance $1-\alpha/2$

$$\mathbb{P}\left(\chi^2_{\alpha/2} \leq \frac{(n-2)\hat{\sigma}^{*2}}{\sigma^2} \leq \chi^2_{1-\alpha/2}\right) = 1-\alpha$$

$$\text{IC}(\sigma^2) = \left[\frac{(n-2)\hat{\sigma}^2}{\chi^2_{\alpha/2}}, \frac{(n-2)\hat{\sigma}^2}{\chi^2_{1-\alpha/2}} \right]$$




Estimation des paramètres par intervalle de confiance

❖ Exemple:

$$\begin{aligned}\bar{X} &= 145; \bar{Y} = 66.3; \\ S_X^2 &= 825; S_Y^2 = 186.41; \\ \text{Cov}(X, Y) &= 387.5\end{aligned}$$

$$\begin{cases} \widehat{\beta}_1 = \frac{\text{Cov}(X, Y)}{S_X^2} \approx 0.47, \\ \widehat{\beta}_0 = \bar{Y} - \widehat{\beta}_1 \bar{X} \approx -1.81 \end{cases}$$

Température (x_i)	Rendement(y_i)
100	45
110	51
120	50
130	61
140	66
150	70
160	72
170	78
180	85
190	85



Estimation des paramètres par intervalle de confiance

❖ Exemple:

$$\begin{aligned} \bar{X} &= 145; \bar{Y} = 66.3; \\ S_X^2 &= 825; S_Y^2 = 186.41; \\ \text{Cov}(X, Y) &= 387.5 \end{aligned} \quad \begin{cases} \widehat{\beta}_1 = \frac{\text{Cov}(X, Y)}{S_X^2} \approx 0.47, \\ \widehat{\beta}_0 = \bar{Y} - \widehat{\beta}_1 \bar{X} \approx -1.81 \end{cases}$$

$$\hat{\sigma}^2 = \frac{\sum_{i=1}^n (Y_i - \hat{Y}_i)^2}{n-2} = \frac{1}{n-2} \sum_{i=1}^n (Y_i - \hat{\beta}_0 + \hat{\beta}_1 x_i)^2 \approx 5.5$$

$$S_{\widehat{\beta}_1}^2 = \frac{\hat{\sigma}^2}{n S_X^2} \approx 0.001; \quad S_{\widehat{\beta}_0}^2 = \hat{\sigma}^2 \left(\frac{\sum_{i=1}^n x_i^2}{n \sum_{i=1}^n (x_i - \bar{x})^2} \right) \approx 14.57$$

Estimation des paramètres par intervalle de confiance

❖ Exemple:

Calcul des intervalles de confiance des estimateurs au niveau $1-0.05=0.95$

$$\chi_1^2 = \chi_{0,025;10-2}^2 = 2.18; \chi_2^2 = \chi_{1-0,025;10-2}^2 = 17.13; t_{1-\alpha/2;10-2} = 2.306$$

$$IC(\beta_1) = \left[\widehat{\beta}_1 \pm t_{1-\frac{\alpha}{2};n-2} S_{\widehat{\beta}_1} \right] = [0.47 \pm 2.306 * \sqrt{0.001}] = [0.41, 0.53]$$

$$IC(\beta_0) = \left[\widehat{\beta}_0 \pm t_{1-\frac{\alpha}{2};n-2} S_{\widehat{\beta}_0} \right] = [-1.81 \pm 2.306 * \sqrt{14.57}] = [-10.61, 7.00]$$


$$IC(\sigma^2) = \left[\frac{(n-2)\widehat{\sigma}^2}{\chi_{\alpha/2}^2}, \frac{(n-2)\widehat{\sigma}^2}{\chi_{1-\alpha/2}^2} \right] = [-2.51, 20.2]$$

$$\begin{cases} \widehat{\beta}_1 = \frac{Cov(X,Y)}{S_X^2} \approx 0.47, \\ \widehat{\beta}_0 = \bar{Y} - \widehat{\beta}_1 \bar{X} \approx -1.81 \end{cases}$$

Estimation des paramètres par intervalle de confiance

❖ Exemple:


$$IC(\beta_1) = [0.41, 0.53] \quad IC(\beta_0) = [-10.61, 7.00]$$




Estimation des paramètres par intervalle de confiance

❖ Exemple:

$$IC(\beta_1) = [0.41, 0.53] \quad IC(\beta_0) = [-10.61, 7.00]$$



Estimation des paramètres par intervalle de confiance



$\frac{P}{v}$	0,90	0,80	0,70	0,60	0,50	0,40	0,30	0,20	0,10	0,05	0,02	0,01	0,001
1	0,158	0,325	0,510	0,727	1,000	1,376	1,963	3,078	6,314	12,706	31,821	63,657	636,619
2	0,142	0,289	0,445	0,617	0,816	1,061	1,386	1,886	2,920	4,303	6,965	9,925	31,598
3	0,137	0,277	0,424	0,584	0,765	0,978	1,250	1,638	2,353	3,182	4,541	5,841	12,929
4	0,134	0,271	0,414	0,569	0,741	0,941	1,190	1,533	2,132	2,776	3,747	4,604	8,611
5	0,132	0,267	0,408	0,559	0,727	0,920	1,156	1,476	2,015	2,571	3,365	4,032	6,869
6	0,131	0,265	0,404	0,553	0,718	0,906	1,134	1,440	1,943	2,447	3,143	3,707	5,959
7	0,130	0,263	0,402	0,549	0,711	0,896	1,119	1,415	1,895	2,365	2,998	3,499	5,408
8	0,130	0,262	0,399	0,546	0,706	0,889	1,108	1,397	1,860	2,306	2,896	3,355	5,041
9	0,129	0,261	0,398	0,543	0,703	0,883	1,100	1,383	1,833	2,262	2,821	3,250	4,781
10	0,129	0,260	0,397	0,542	0,700	0,879	1,093	1,372	1,812	2,228	2,764	3,169	4,587
11	0,129	0,260	0,396	0,540	0,697	0,876	1,088	1,363	1,796	2,201	2,718	3,106	4,437
12	0,128	0,259	0,395	0,539	0,695	0,873	1,083	1,356	1,782	2,179	2,681	3,055	4,318
13	0,128	0,259	0,394	0,538	0,694	0,870	1,079	1,350	1,771	2,160	2,650	3,012	4,221
14	0,128	0,258	0,393	0,537	0,692	0,868	1,076	1,345	1,761	2,145	2,624	2,977	4,140
15	0,128	0,258	0,393	0,536	0,691	0,866	1,074	1,341	1,753	2,131	2,602	2,947	4,073
16	0,128	0,258	0,392	0,535	0,690	0,865	1,071	1,337	1,746	2,120	2,583	2,921	4,015
17	0,128	0,257	0,392	0,534	0,689	0,863	1,069	1,333	1,740	2,110	2,567	2,898	3,965
18	0,127	0,257	0,392	0,534	0,688	0,862	1,067	1,330	1,734	2,101	2,552	2,878	3,922
19	0,127	0,257	0,391	0,533	0,688	0,861	1,066	1,328	1,729	2,093	2,539	2,861	3,883
20	0,127	0,257	0,391	0,533	0,687	0,860	1,064	1,325	1,725	2,086	2,528	2,845	3,850
21	0,127	0,257	0,391	0,532	0,686	0,859	1,063	1,323	1,721	2,080	2,518	2,831	3,819
22	0,127	0,256	0,390	0,532	0,686	0,858	1,061	1,321	1,717	2,074	2,508	2,819	3,792
23	0,127	0,256	0,390	0,532	0,685	0,858	1,060	1,319	1,714	2,069	2,500	2,807	3,767
24	0,127	0,256	0,390	0,531	0,685	0,857	1,059	1,318	1,711	2,064	2,492	2,797	3,745
25	0,127	0,256	0,390	0,531	0,684	0,856	1,058	1,316	1,708	2,060	2,485	2,787	3,725
26	0,127	0,256	0,390	0,531	0,684	0,856	1,058	1,315	1,706	2,056	2,479	2,779	3,707
27	0,127	0,256	0,389	0,531	0,684	0,855	1,057	1,314	1,703	2,052	2,473	2,771	3,690
28	0,127	0,256	0,389	0,530	0,683	0,855	1,056	1,313	1,701	2,048	2,467	2,763	3,674
29	0,127	0,256	0,389	0,530	0,683	0,854	1,055	1,311	1,699	2,045	2,462	2,756	3,659
30	0,127	0,256	0,389	0,530	0,683	0,854	1,055	1,310	1,697	2,042	2,457	2,750	3,646
40	0,126	0,255	0,388	0,529	0,681	0,851	1,050	1,303	1,684	2,021	2,423	2,704	3,551
80	0,126	0,254	0,387	0,527	0,679	0,848	1,046	1,296	1,671	2,000	2,390	2,660	3,460
120	0,126	0,254	0,386	0,526	0,677	0,845	1,041	1,289	1,658	1,980	2,358	2,617	3,373
∞	0,126	0,253	0,385	0,524	0,674	0,842	1,036	1,282	1,645	1,960	2,326	2,576	3,291

e. Tests d'hypothèse

Tests d'hypothèses

❖ Test sur β_i (test bilatéral) :

$$\mathcal{H}_0 : " \beta_i = 0 " \quad \text{contre} \quad \mathcal{H}_1 : " \beta_i \neq 0 "$$

Fixer le risque α

Statistique de test : $T_{\hat{\beta}_i} = \frac{\hat{\beta}_i}{s_{\hat{\beta}_i}} \sim \mathcal{T}(n-2)$

Décision: un niveau de test α (usuellement 0,05 ou 0,01), On calcule $T_{\hat{\beta}_i}$

- Si $|T_{\hat{\beta}_i}| > t_{n-2; (1-\alpha)/2}$, alors H_0 est rejetée
- Sinon H_0 est acceptée

où t est la réalisation de T_n et $t_{n-2; (1-\alpha)/2}$ est le fractile d'ordre $1 - \alpha/2$ de la loi $\mathcal{T}(n-2)$.

.

Tests d'hypothèses

❖ Test sur β_i (test unilatéral) :

Exemple de vérifier si β_1 est positive

$$\mathcal{H}_0 : " \beta_1 \geq 0 " \quad \text{contre} \quad \mathcal{H}_1 : " \beta_1 < 0 "$$

Fixer le risque α

Statistique de test : $T_{\hat{\beta}_1} = \frac{\hat{\beta}_1}{s_{\hat{\beta}_i}} \sim \mathcal{T}(n-2)$

Décision: un niveau de test α (usuellement 0,05 ou 0,01), On calcule $T_{\hat{\beta}_i}$

- Si $|T_{\hat{\beta}_1}| \geq t_{n-2;(1-\alpha/2)}$, alors H_0 est acceptée
- Sinon H_0 est rejetée

où t est la réalisation de T_n et $t_{n-2;(1-\alpha)/2}$ est le fractile d'ordre $1 - \alpha/2$ de la loi $\mathcal{T}(n-2)$.

.

Tests d'hypothèses

❖ Test sur β_0 (test de passage par l'origine) :

Exemple de vérifier si β_0 est nul

$$\mathcal{H}_0 : \beta_0 = 0 \text{ contre } \mathcal{H}_1 : \beta_0 \neq 0$$

Fixer le risque α

Statistique de test : $T_{\hat{\beta}_0} = \frac{\hat{\beta}_0}{s_{\hat{\beta}_0}} \sim \mathcal{T}(n-2)$

Décision: un niveau de test α (usuellement 0,05 ou 0,01), On calcule $T_{\hat{\beta}_0}$

- Si $|T_{\hat{\beta}_0}| > t_{n-2; (1-\alpha/2)}$, alors H_0 est rejetée
- Sinon H_0 est acceptée

où t est la réalisation de T_n et $t_{n-2; (1-\alpha/2)}$ est le fractile d'ordre $1 - \alpha/2$ de la loi $\mathcal{T}(n-2)$.

.

Tests d'hypothèses

❖ Test de fisher :

Significativité de la régression en utilisant l'analyse de la variance

$$\mathcal{H}_0 : " \beta_1 = 0 " \quad \text{contre} \quad \mathcal{H}_1 : " \beta_1 \neq 0 "$$

Fixer le risque α

$$\text{Statistique de test : } F = \frac{SCE}{SCR/(n-2)} \sim F_{n-2}^1$$

Décision: rejet ou pas de $\mathcal{H}_0$ si $F > f_{n-2}^2(1 - \alpha)$

Où $f_{n-2}^2(1 - \alpha)$ est le quantile de niveau $(1 - \alpha)$ d'une loi $F_{n-2}^2(1 - \alpha)$

.

f. Pr vision

❖ Prévision d'une valeur ultérieure

On désire prévoir à l'aide du modèle la valeur de la variable y pour une valeur non observé x_{n+1} de x .

D'après le modèle on a $y_{n+1} = \beta_0 + \beta_1 x_{n+1} + \varepsilon_{n+1}$, où y_{n+1} et ε_{n+1} sont des variables aléatoires. La prédiction naturelle est alors :

$$\hat{y}_{n+1} = \hat{\beta}_0 + \hat{\beta}_1 x_{n+1}$$

L'erreur de prédiction est définie par $\hat{y}_{n+1} - y_{n+1}$ et on peut montrer que sous les hypothèses du modèle (incluant l'hypothèse de normalité), on a :

$$\hat{y}_{n+1} - y_{n+1} \sim \mathcal{N}\left(0, \sigma^2 \left(1 + \frac{1}{n} + \frac{(x_{n+1} - \bar{X}_n)^2}{\sum_{i=1}^n (x_i - \bar{X}_n)^2}\right)\right)$$

❖ Prévision d'une valeur ultérieure

Avec les notations et hypothèses précédentes, on obtient:

$$\frac{\hat{y}_{n+1} - y_{n+1}}{\hat{\sigma} \sqrt{1 + \frac{1}{n} + \frac{(x_{n+1} - \bar{X}_n)^2}{\sum_{i=1}^n (x_i - \bar{X}_n)^2}}} \sim \mathcal{T}(n-2)$$

On utilise ce résultat pour construire un intervalle de prédiction pour y_{n+1} , c'est à dire l'intervalle $[A, B]$ tel que

$$\mathbb{P}(A \leq y_{n+1} \leq B) = 1 - \alpha.$$


On en déduit l'intervalle de prédiction pour y_0 au niveau de confiance $1 - \alpha$ suivant :

$$y_{n+1} \in \left[\hat{y}_{n+1} \pm t_{1-\frac{\alpha}{2}, n-2} \hat{\sigma} \sqrt{1 + \frac{1}{n} + \frac{(x_{n+1} - \bar{X}_n)^2}{\sum_{i=1}^n (x_i - \bar{X}_n)^2}} \right]$$

3. Régression polynomiale

Régression polynomiale

❖ Modèle de régression polynomiale



Modèle de régression polynomiale de degré m

$$y = (\beta_1 x + \beta_2 x^2 + \dots + \beta_m x^m + \beta_0 + \varepsilon)$$

$X = (1, x, x^2, \dots, x^m)$, vecteur des entrées + biais

$\beta = (\beta_0, \beta_1, \beta_2, \dots, \beta_m)$, vecteur de poids

Régression polynomiale

❖ Estimation des paramètres $\beta_0, \beta_1, \dots, \beta_m$

1. **Dataset (X,Y)**
 - variable explicative (feature)
 - variable expliquée (target)
2. **Modèle**
 - Régression: Modèle linéaire simple. $Y = \beta X + \varepsilon$

$$(Y \approx \beta X) \text{ où } \mathbf{Y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}, \mathbf{X} = \begin{pmatrix} 1 & x_1 & x_1^2 & \cdots & x_1^m \\ 1 & x_2 & x_2^2 & \vdots & x_2^m \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & x_n & x_n^2 & \cdots & x_n^m \end{pmatrix}, \boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_m \end{pmatrix}, \text{ et } \boldsymbol{\varepsilon} = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{pmatrix}$$



3. Fonction coût

- Erreur quadratique moyenne

$$L(\beta_0, \beta_1, \dots, \beta_m) = \frac{1}{n} (\mathbf{X}\boldsymbol{\beta} - \mathbf{Y})^T (\mathbf{X}\boldsymbol{\beta} - \mathbf{Y})$$

4. Algorithme d'optimisation


- Méthode des moindres carrés
- Descente de gradient



4. Régression multiple

Régression linéaire multiple

❖ Modèle de régression linéaire multiple




	V. explicatives				V. expliquée
	x_1	x_2	...	x_n	y
observations	x_1^1	x_2^1		x_n^1	y_1
	x_1^2	x_2^2		x_n^2	y_2
	...				...
	x_1^m	x_2^m		x_n^m	y_m

Modèle de régression linéaire multiple $y = (\beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n + \beta_0 + \varepsilon)$

$X = (1, x_1, x_2, \dots, x_n)$, vecteur des entrées + biais

$\beta = (\beta_0, \beta_1, \beta_2, \dots, \beta_n)$, vecteur de poids



Régression linéaire multiple

❖ Estimation des paramètres $\beta_0, \beta_1, \dots, \beta_m$

1. Dataset (X,Y)

- variables explicatives (features)
- variable expliquée (target)

2. Modèle

- Régression: Modèle linéaire simple. $Y = \beta X + \varepsilon$

$$(Y \approx \beta X) \text{ où } \mathbf{Y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}, \mathbf{X} = \begin{pmatrix} 1 & x_{1,1} & x_{1,2} & \cdots & x_{1,n} \\ 1 & x_{2,1} & x_{2,2} & \vdots & x_{2,n} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & x_{m,1} & x_{m,2} & \cdots & x_{m,n} \end{pmatrix}, \boldsymbol{\beta} = \begin{pmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_n \end{pmatrix}, \text{ et } \boldsymbol{\varepsilon} = \begin{pmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_m \end{pmatrix}$$

3. Fonction coût

- Erreur quadratique moyenne

$$L(\boldsymbol{\beta}_0, \boldsymbol{\beta}_1) = \frac{1}{n} (\mathbf{X}\boldsymbol{\beta} - \mathbf{Y})^T (\mathbf{X}\boldsymbol{\beta} - \mathbf{Y})$$

4. Algorithme d'optimisation

- Méthode des moindres carrés
- Descente de gradient

V. explicatives				V. expliquée
x_1	x_2	...	x_n	y
$x_{1,1}$	$x_{2,1}$		$x_{n,1}$	y_1
$x_{2,1}$	$x_{2,2}$		$x_{n,2}$	y_2
...				...
$x_{m,1}$	$x_{m,2}$		$x_{m,n}$	y_m

observations

