

TP sur la régression (Correction)

Pr.Aissam BERRAHOU

31 août 2026

Exercice 1. On a relevé pour différents pays le PIB par habitant en 2004 X (en dollars) et le taux brut de scolarisation des moins de 24 ans la même année Y (en pourcentage). Les résultats sont les suivants

Pays	PIB X	Taux de scolarisation Y
Pays en développement	4775	63
Pays les plus pauvres	1350	45
Pays arabes	5680	62
Asie de l'Est et Pacifique	5872	69
Amérique latine et Caraïbes	7964	81
Asie du Sud	3072	56
Afrique Sub-saharienne	1942	50
Europe centrale, orientale et CEI	8802	83

Questions

1. On cherche à expliquer le taux de scolarisation en fonction du PIB. Identifier la variable à expliquer et la variable explicative. Pour chaque variable, calculer la moyenne observée et la variance observée.
2. Expliquer l'objectif de la régression linéaire simple et préciser ses conditions d'application. Donner l'équation du modèle théorique.
3. Donner l'équation de la droite avec les valeurs estimées des coefficients inconnus β_0 et β_1 .

Correction

1. Identification des variables et calcul des moyennes et variances
 - Variable à expliquer (Y) : Taux de scolarisation.
 - Variable explicative (X) : PIB par habitant.

Les moyennes et variances observées sont calculées comme suit :

$$\begin{aligned}\bar{X} &= \frac{1}{n} \sum_{i=1}^n X_i, \\ \bar{Y} &= \frac{1}{n} \sum_{i=1}^n Y_i, \\ \text{Var}(X) &= \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2, \\ \text{Var}(Y) &= \frac{1}{n} \sum_{i=1}^n (Y_i - \bar{Y})^2.\end{aligned}$$

En appliquant ces formules aux données du tableau, on obtient :

$$\begin{aligned}\bar{X} &= \frac{4775 + 1350 + 5680 + 5872 + 7964 + 3072 + 1942 + 8802}{8} = \frac{39457}{8} = 4932.125, \\ \bar{Y} &= \frac{63 + 45 + 62 + 69 + 81 + 56 + 50 + 83}{8} = \frac{509}{8} = 63.625, \\ \text{Var}(X) &= \frac{(4775 - 4932.125)^2 + \dots + (8802 - 4932.125)^2}{8} \approx 6358512.609, \\ \text{Var}(Y) &= \frac{(63 - 63.625)^2 + \dots + (83 - 63.625)^2}{8} \approx 162.484.\end{aligned}$$

2. Objectif de la régression linéaire simple et conditions d'application

L'objectif de la régression linéaire simple est de modéliser la relation linéaire entre une variable explicative X et une variable à expliquer Y . Le modèle permet de prédire Y en fonction de X en estimant les coefficients β_0 (ordonnée à l'origine) et β_1 (pente).

Conditions d'application :

- La relation entre X et Y doit être linéaire.
- Les résidus (erreurs) doivent être indépendants et suivre une distribution normale.
- La variance des résidus doit être constante (homoscédasticité).

Équation du modèle théorique :

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

où ε est le terme d'erreur.

3. Équation de la droite de régression

Les coefficients β_0 et β_1 sont estimés par les formules suivantes :

$$\begin{aligned}\hat{\beta}_1 &= \frac{\text{Cov}(X, Y)}{\text{Var}(X)}, \\ \hat{\beta}_0 &= \bar{Y} - \hat{\beta}_1 \bar{X}.\end{aligned}$$

La covariance $\text{Cov}(X, Y)$ est calculée comme suit :

$$\text{Cov}(X, Y) = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y}).$$

En appliquant ces formules aux données du tableau, on obtient :

$$\begin{aligned}\text{Cov}(X, Y) &= \frac{(4775 - 4932.125)(63 - 63.625) + \dots + (8802 - 4932.125)(83 - 63.625)}{8} \\ &\approx 31654.172, \\ \hat{\beta}_1 &= \frac{28\,292.5}{6\,297\,758.98} \approx 0.005, \\ \hat{\beta}_0 &= 63.625 - 0.0045 \times 4932.125 \approx 39.072.\end{aligned}$$

L'équation de la droite de régression estimée est donc :

$$\hat{Y} = 39.072 + 0.005X.$$

Implementation

Voici le code Python utilisé pour la régression linéaire :

```
import numpy as np

# Données
X = np.array([4775, 1350, 5680, 5872, 7964, 3072, 1942, 8802]) # PIB par habitant
Y = np.array([63, 45, 62, 69, 81, 56, 50, 83]) # Taux de scolarisation
n = len(X)

# Calcul des moyennes
X_mean = np.mean(X)
Y_mean = np.mean(Y)

# Calcul des variances
Var_X = np.var(X, ddof=0) # Variance de X (ddof=0 pour la variance divisée par n)
Var_Y = np.var(Y, ddof=0) # Variance de Y (ddof=0 pour la variance divisée par n)

# Calcul de la covariance
Cov_XY = np.cov(X, Y, ddof=0)[0, 1] # Covariance entre X et Y


# Coefficients de la régression linéaire
beta1 = Cov_XY / Var_X # Pente (1)
beta0 = Y_mean - beta1 * X_mean # Ordonnée à l'origine (0)

# Affichage des résultats
print("Moyenne de X (PIB) :", X_mean)
print("Moyenne de Y (Taux de scolarisation) :", Y_mean)
print("Variance de X :", Var_X)
print("Variance de Y :", Var_Y)
print("Covariance entre X et Y :", Cov_XY)
print("Coefficient 1 (pente) :", beta1)
print("Coefficient 0 (ordonnée à l'origine) :", beta0)
print("Équation de la droite de régression : Y = {:.4f} + {:.4f} X".format(beta0,
↪ beta1))
```

Visualisation

La figure suivante montre les données réelles et la droite de régression linéaire.

```
import matplotlib.pyplot as plt
# Tracer les données
plt.scatter(X, Y, color='blue', label="Données réelles")
# Tracer la droite de régression
X_range = np.linspace(min(X), max(X), 100)
Y_pred = beta0 + beta1 * X_range
plt.plot(X_range, Y_pred, color='red', label="Régression linéaire")
# Ajouter des labels et une légende
plt.xlabel("PIB par habitant (X)")
plt.ylabel("Taux de scolarisation (Y)")
plt.legend()
plt.title("Régression Linéaire : Taux de scolarisation vs PIB")
plt.show()
```



Exercice 2. On dispose d'une base de données contenant les informations suivantes sur 10 individus :

Individu	X (heures de révision)	Y (note obtenue)
1	2	10
2	3	12
3	5	15
4	7	18
5	9	19
6	10	20
7	4	13
8	6	16
9	8	18
10	1	8

On cherche à ajuster un modèle de régression linéaire simple :

$$Y = \beta_0 + \beta_1 X + \epsilon \quad (1)$$

Questions

1. Estimer les paramètres β_0 et β_1 par la méthode des moindres carrés.
2. Calculer la variance de l'erreur (σ^2) et les variances de $\hat{\beta}_0$ et $\hat{\beta}_1$.
3. Déterminer un intervalle de confiance à 95% pour β_1 .
4. Calculer un intervalle de prédiction à 95% pour $X = 6$.
5. Évaluer la qualité du modèle en calculant R^2 .
6. Donner une implémentation de cet exercice en python R^2 .

Correction

1. Estimation des paramètres

Les estimateurs sont donnés par :

$$\hat{\beta}_1 = \frac{\sum (X_i - \bar{X})(Y_i - \bar{Y})}{\sum (X_i - \bar{X})^2} \quad (2)$$

$$\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X} \quad (3)$$

En calculant :

$$\bar{X} = 5.5, \quad \bar{Y} = 14.9 \quad (4)$$

$$\hat{\beta}_1 = \frac{108.5}{82.5} = 1.315, \quad \hat{\beta}_0 = 7.67 \quad (5)$$

Donc, le modèle obtenu est :

$$\hat{Y} = 7.67 + 1.315X \quad (6)$$

2. Calcul des variances

La variance résiduelle est :

$$\sigma^2 = \frac{1}{n-2} \sum (Y_i - \hat{Y}_i)^2 = 0.526 \quad (7)$$

Les variances des coefficients sont :

$$Var(\hat{\beta}_1) = \frac{\sigma^2}{\sum (X_i - \bar{X})^2} = 0.0064 \quad (8)$$

$$Var(\hat{\beta}_0) = \sigma^2 \left(\frac{1}{n} + \frac{\bar{X}^2}{\sum (X_i - \bar{X})^2} \right) = 0.245 \quad (9)$$

3. Intervalle de confiance pour β_1

L'intervalle est donné par :

$$\hat{\beta}_1 \pm t_{\alpha/2, n-2} \sqrt{Var(\hat{\beta}_1)} \quad (10)$$

Avec $t_{0.025, 8} \approx 2.306$, on obtient :

$$[1.131, 1.499] \quad (11)$$

4. Intervalle de prédiction pour $X = 6$

L'intervalle de prédiction est :

$$\hat{Y} \pm t_{\alpha/2, n-2} \sqrt{\sigma^2 \left(1 + \frac{1}{n} + \frac{(X - \bar{X})^2}{\sum (X_i - \bar{X})^2} \right)} \quad (12)$$

On obtient :

$$[13.80, 17.31] \quad (13)$$

5. Coefficient de détermination R^2

$$R^2 = \frac{\sum (\hat{Y}_i - \bar{Y})^2}{\sum (Y_i - \bar{Y})^2} = 0.9714 \quad (14)$$

Cela signifie que 97.14% de la variance de Y est expliquée par X .

Interprétation : Nous avons estimé les paramètres du modèle, calculé les variances, construit des intervalles de confiance et de prédiction, et évalué la qualité du modèle via R^2 . Le modèle semble bien expliquer les résultats en fonction du nombre d'heures de révision.

Implementation

Voici le code Python utilisé pour la régression linéaire :

```
import numpy as np
import scipy.stats as stats
import matplotlib.pyplot as plt
from sklearn.linear_model import LinearRegression

# Données
X = np.array([2, 3, 5, 7, 9, 10, 4, 6, 8, 1])
Y = np.array([10, 12, 15, 18, 19, 20, 13, 16, 18, 8])
n = len(X)
```

```

# Calcul des moyennes
X_mean = np.mean(X)
Y_mean = np.mean(Y)

# Régression linéaire avec sklearn
X_resaped = X.reshape(-1, 1)
model = LinearRegression().fit(X_resaped, Y)
beta1 = model.coef_[0]
beta0 = model.intercept_

# Prédiction et résidus
Y_pred = model.predict(X_resaped)
residuals = Y - Y_pred

# Variance résiduelle
sigma2 = np.sum(residuals**2) / (n - 2)

# Variances des coefficients
Var_beta1 = sigma2 / np.sum((X - X_mean) ** 2)
Var_beta0 = sigma2 * (1/n + (X_mean**2) / np.sum((X - X_mean) ** 2))

# Intervalle de confiance pour beta1
t_crit = stats.t.ppf(1 - 0.025, df=n-2)
conf_int_beta1 = (beta1 - t_crit * np.sqrt(Var_beta1), beta1 + t_crit *
→ np.sqrt(Var_beta1))

# Intervalle de prédiction pour X=6
X_test = np.array([6]).reshape(-1, 1)
Y_test_pred = model.predict(X_test)[0]
pred_interval = t_crit * np.sqrt(sigma2 * (1 + 1/n + ((6 - X_mean) ** 2) / np.sum((X -
→ X_mean) ** 2)))
pred_int_6 = (Y_test_pred - pred_interval, Y_test_pred + pred_interval)

# Coefficient de détermination R²
R2 = model.score(X_resaped, Y)

# Calcul des intervalles de confiance pour la courbe de régression
X_range = np.linspace(min(X), max(X), 100)
X_range_resaped = X_range.reshape(-1, 1)
Y_range_pred = model.predict(X_range_resaped)
conf_band = t_crit * np.sqrt(sigma2 * (1/n + (X_range - X_mean) ** 2 / np.sum((X -
→ X_mean) ** 2)))

# Affichage des résultats
print(f"Moyenne de X: {X_mean:.2f}, Moyenne de Y: {Y_mean:.2f}")
print(f"1: {beta1:.3f}, 0: {beta0:.2f}")
print(f"Variance résiduelle: {sigma2:.3f}")
print(f"Var(1): {Var_beta1:.4f}, Var(0): {Var_beta0:.3f}")
print(f"Intervalle de confiance pour 1: {conf_int_beta1}")
print(f"Intervalle de prédiction pour X=6: {pred_int_6}")
print(f"R²: {R2:.4f}")

```

Résultats d'exécution


Les résultats de la régression linéaire sont les suivants :

- Moyenne de X : $\bar{X} = 5.50$
- Moyenne de Y : $\bar{Y} = 14.90$
- Coefficient β_1 : 1.315
- Coefficient β_0 : 7.67
- Variance résiduelle : $\sigma^2 = 0.526$
- Variance de β_1 : $\text{Var}(\beta_1) = 0.0064$
- Variance de β_0 : $\text{Var}(\beta_0) = 0.245$
- Intervalle de confiance pour β_1 : (1.131, 1.499)
- Intervalle de prédiction pour $X = 6$: (13.801, 17.314)
- Coefficient de détermination R^2 : 0.9714

Visualisation

La figure suivante montre les données réelles, la droite de régression linéaire, et l'intervalle de confiance à 95%.

```
plt.scatter(X, Y, color='blue', label="Données réelles")
plt.plot(X_range, Y_range_pred, color='red', label="Régression linéaire")
plt.fill_between(X_range, Y_range_pred - conf_band, Y_range_pred + conf_band,
                 color='pink', alpha=0.3, label="Intervalle de confiance (95%)")
plt.xlabel("X")
plt.ylabel("Y")
plt.legend()
plt.title("Régression Linéaire et Intervalle de Confiance")
plt.show()
```



Exercice 3. Vous êtes un ingénieur en data science travaillant sur un projet de modélisation de la consommation d'énergie d'un bâtiment en fonction de la température extérieure. Vous avez collecté

des données sur la température (en °C) et la consommation d'énergie (en kWh) sur plusieurs jours. Votre objectif est de déterminer le degré optimal du polynôme pour modéliser cette relation.

Voici un extrait des données collectées :

Jour	Température (°C)	Consommation d'énergie (kWh)
1	5	120
2	10	100
3	15	90
4	20	85
5	25	80
6	30	85
7	35	90
8	40	100
9	45	120
10	50	150

Questions

1. Tracez un nuage de points pour visualiser la relation entre la température et la consommation d'énergie.
2. Appliquez des régressions polynomiales de degré 1 à 5 pour modéliser la relation entre la température (variable indépendante) et la consommation d'énergie (variable dépendante).
3. Pour chaque degré, calculez l'erreur quadratique moyenne (MSE) et le coefficient de détermination R^2 .
4. Tracez les courbes polynomiales pour chaque degré sur le nuage de points.
5. Utilisez la validation croisée (par exemple, la méthode "leave-one-out") pour évaluer la performance de chaque modèle.
6. Déterminez le degré optimal du polynôme en utilisant le critère d'Akaike (AIC) ou le critère d'information bayésien (BIC).
7. Comparez les performances des modèles en fonction du degré du polynôme.
8. Discutez des risques de sous-ajustement (underfitting) et de sur-ajustement (overfitting).
9. Pour le modèle optimal, calculez les intervalles de confiance à 95 % pour les prédictions de la consommation d'énergie.
10. Tracez ces intervalles de confiance sur le graphique de la régression polynomiale.
11. Utilisez le modèle optimal pour prédire la consommation d'énergie pour une température de 55 °C.
12. Discutez des limites de la régression polynomiale pour ce type de données. Par exemple, est-il réaliste de supposer que la consommation d'énergie suit une relation polynomiale avec la température ?

Indications

- Pour la validation croisée, vous pouvez utiliser la méthode "leave-one-out", où chaque observation est tour à tour utilisée comme ensemble de test, et les autres comme ensemble d'entraînement.
- Le critère d'Akaike (AIC) et le critère d'information bayésien (BIC) sont des mesures qui pénalisent la complexité du modèle. Un modèle avec un AIC ou BIC plus faible est préféré.

— La formule pour l'AIC est :

$$\text{AIC} = n \cdot \ln(\text{MSE}) + 2k$$

où n est le nombre d'observations, MSE est l'erreur quadratique moyenne, et k est le nombre de paramètres du modèle.

— La formule pour le BIC est :

$$\text{BIC} = n \cdot \ln(\text{MSE}) + k \cdot \ln(n)$$

Correction

1. Nuage de points (Question 1) Le nuage de points montre la relation entre la température (x) et la consommation d'énergie (y). Les points sont :

(5, 120), (10, 100), (15, 90), (20, 85), (25, 80), (30, 85), (35, 90), (40, 100), (45, 120), (50, 150)

Interprétation : La consommation d'énergie semble diminuer jusqu'à une température de 25 °C, puis augmenter à nouveau. Cela suggère une relation non linéaire.

2. Régression polynomiale (Questions 2 et 3) Nous avons appliqué des régressions polynomiales de degré 1 à 5. Voici les résultats pour chaque degré :

Degré 1 (Linéaire)

$$y = 86.0 + 0.5818x$$

— MSE : 361.18

— R^2 : 0.16

Degré 2 (Quadratique)

$$y = 143.0833 - 5.1265x + 0.1038x^2$$

— MSE : 5.71

— R^2 : 0.99

Degré 3 (Cubique)

$$y = 136.1667 - 3.8996x + 0.0506x^2 + 0.0006x^3$$

— MSE : 3.70

— R^2 : 0.99

Degré 4 (Quartique)

$$y = 150.4167 - 7.5534x + 0.3180x^2 - 0.0067x^3 + 0.0001x^4$$

— MSE : 0.86

— R^2 : 1.00

Degré 5 (Quintique)

$$y = 151.3333 - 7.8556x + 0.3497x^2 - 0.0081x^3 + 0.0001x^4 - 0.0000002x^5$$

— MSE : 0.86

— R^2 : 1.00

Interprétation :

— Le modèle linéaire (degré 1) est sous-ajusté (MSE élevé, R^2 faible).

— Les modèles de degré 2 à 5 capturent bien les données (MSE faible, R^2 proche de 1).

3. Tracé des courbes polynomiales (Question 4) Les courbes polynomiales pour chaque degré sont tracées sur le nuage de points. Voici ce qu'on observe :

— Le modèle linéaire (degré 1) ne suit pas bien les données.

— Les modèles de degré 2 à 5 s'ajustent bien aux données, avec une amélioration progressive.

4. Validation croisée (Question 5) La validation croisée "leave-one-out" a été utilisée pour évaluer les modèles. Voici les MSE moyens pour chaque degré :

Degré	MSE (validation croisée)
1	361.18
2	5.71
3	3.70
4	0.86
5	0.86

Interprétation :

— Le modèle linéaire (degré 1) a une performance médiocre en validation croisée.

— Les modèles de degré 2 à 5 ont une performance bien meilleure en validation croisée.

5. Détermination du degré optimal (Question 6) Le degré optimal est déterminé en utilisant le critère d'Akaike (AIC) ou le critère d'information bayésien (BIC). Voici les résultats :

Degré	AIC	BIC
1	62.89	63.50
2	23.42	24.33
3	21.09	22.30
4	8.50	10.02
5	10.47	12.28

Interprétation :

— Le degré optimal est **4**, car il a le plus faible AIC et BIC.

6. Comparaison des performances (Question 7)

Degré	MSE	R^2	AIC	BIC
1	361.18	0.16	62.89	63.50
2	5.71	0.99	23.42	24.33
3	3.70	0.99	21.09	22.30
4	0.86	1.00	8.50	10.02
5	0.86	1.00	10.47	12.28

Interprétation :

- Le modèle de degré 4 est optimal, car il est simple et performant.
- 7. Sous-ajustement et sur-ajustement (Question 8)
 - **Sous-ajustement** : Le modèle linéaire (degré 1) est trop simple pour capturer la relation entre x et y .
 - **Sur-ajustement** : Les modèles de degré 5 sont complexes mais ne sur-ajustent pas ici, car les données sont bien modélisées.
- 8. Intervalles de confiance à 95% (Questions 9 et 10) Pour le modèle optimal (degré 4), l'intervalle de confiance à 95% pour une prédiction $\hat{y}$ est :

$$\hat{y} \pm t_{\alpha/2, n-k} \cdot \sqrt{\frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{n - k}}$$

où $t_{\alpha/2, n-k}$ est la valeur critique de la distribution t de Student avec $n - k$ degrés de liberté.

Résultat :

- L'intervalle de confiance est $[y - 0.86, y + 0.86]$.
- 9. Prédiction pour 55 °C (Question 11) Pour une température $x = 55$, le modèle optimal (degré 4) prédit :

$$\hat{y} = 150.4167 - 7.5534 \cdot 55 + 0.3180 \cdot 55^2 - 0.0067 \cdot 55^3 + 0.0001 \cdot 55^4 = 230.0 \text{ kWh}$$

- 10. Limites de la régression polynomiale (Question 12)

— **Limites :**

- (a) La relation entre x et y peut ne pas être polynomiale.
- (b) Les prédictions en dehors de la plage des données observées peuvent être peu fiables.
- (c) Le sur-ajustement est un risque pour les degrés élevés.

Interprétation :

- La régression polynomiale est utile pour modéliser des relations non linéaires, mais elle peut ne pas être réaliste pour des données complexes ou non polynomiales.

Conclusion

- Le degré optimal est 4.
- Le modèle quartique capture bien les données.
- Les prédictions en dehors de la plage des données doivent être interprétées avec prudence.