

TP : Régression

(Enoncés)

Pr.Aissam BERRAHOU

31 août 2026

Introduction

Le but de la **régression linéaire simple** est d'expliquer une variable dépendante Y à l'aide d'une seule variable explicative X . Dans le cas de la **régression linéaire multiple**, on utilise plusieurs variables explicatives $X_1, X_2, \dots, X_q$ pour expliquer Y . Enfin, la **régression polynomiale** généralise ces approches en permettant à Y d'être modélisée par une fonction polynomiale des variables explicatives. La variable Y est appelée **variable dépendante** ou **variable à expliquer**, tandis que les variables X_j ($j = 1, \dots, q$) sont appelées **variables indépendantes** ou **variables explicatives**.

Remarque :

- La **régression linéaire simple** suppose une relation linéaire entre Y et X . Si cette hypothèse n'est pas vérifiée, la régression polynomiale peut être utilisée pour capturer des relations non linéaires.
- Dans la **régression multiple**, il est important de vérifier l'absence de multicolinéarité entre les variables explicatives $X_1, X_2, \dots, X_q$. Une forte corrélation entre ces variables peut rendre le modèle instable et difficile à interpréter.
- La **régression polynomiale** introduit des termes non linéaires (comme X^2 , X^3 , etc.) pour modéliser des relations plus complexes. Cependant, il faut éviter le surajustement (*overfitting*) en choisissant un degré polynomial approprié.
- Les modèles de régression, qu'ils soient linéaires, multiples ou polynomiales, reposent sur des hypothèses statistiques (par exemple, normalité des résidus, homoscedasticité). Il est essentiel de vérifier ces hypothèses avant d'interpréter les résultats.
- En pratique, la régression est souvent utilisée pour la prédiction. Cependant, il est important de se rappeler que la prédiction n'implique pas nécessairement une compréhension des mécanismes sous-jacents. Une bonne prédiction ne garantit pas une relation de causalité.
- L'utilisation de techniques de régularisation (comme la régression Ridge ou Lasso) peut

améliorer les performances des modèles de régression, surtout lorsque le nombre de variables explicatives est élevé.

Exercise1

On a relevé pour différents pays le PIB par habitant en 2004 X (en dollars) et le taux brut de scolarisation des moins de 24 ans la même année Y (en pourcentage). Les résultats sont les suivants

Pays	PIB X	Taux de scolarisation Y
Pays en développement	4775	63
Pays les plus pauvres	1350	45
Pays arabes	5680	62
Asie de l'Est et Pacifique	5872	69
Amérique latine et Caraïbes	7964	81
Asie du Sud	3072	56
Afrique Sub-saharienne	1942	50
Europe centrale, orientale et CEI	8802	83

Questions

1. On cherche à expliquer le taux de scolarisation en fonction du PIB. Identifier la variable à expliquer et la variable explicative. Pour chaque variable, calculer la moyenne observée et la variance observée.
2. Expliquer l'objectif de la régression linéaire simple et préciser ses conditions d'application.
3. Donner l'équation du modèle théorique.
4. Donner l'équation de la droite avec les valeurs estimées des coefficients inconnus β_0 et β_1 .

Exercise2

On dispose d'une base de données contenant les informations suivantes sur 10 individus :

Individu	X (heures de révision)	Y (note obtenue)
1	2	10
2	3	12
3	5	15
4	7	18
5	9	19
6	10	20
7	4	13
8	6	16
9	8	18
10	1	8

On cherche à ajuster un modèle de régression linéaire simple :

$$Y = \beta_0 + \beta_1 X + \epsilon \quad (1)$$

Questions

1. Estimer les paramètres β_0 et β_1 par la méthode des moindres carrés.
2. Calculer la variance de l'erreur (σ^2) et les variances de $\hat{\beta}_0$ et $\hat{\beta}_1$.
3. Déterminer un intervalle de confiance à 95% pour β_1 .
4. Calculer un intervalle de prédiction à 95% pour $X = 6$.
5. Évaluer la qualité du modèle en calculant R^2 .
6. Donner une implémentation de cet exercice en python R^2 .

Exercise3

Vous êtes un ingénieur en data science travaillant sur un projet de modélisation de la consommation d'énergie d'un bâtiment en fonction de la température extérieure. Vous avez collecté des données sur la température (en °C) et la consommation d'énergie (en kWh) sur plusieurs jours. Votre objectif est de déterminer le degré optimal du polynôme pour modéliser cette relation.

Voici un extrait des données collectées :

Jour	Température (°C)	Consommation d'énergie (kWh)
1	5	120
2	10	100
3	15	90
4	20	85
5	25	80
6	30	85
7	35	90
8	40	100
9	45	120
10	50	150

Questions

1. Tracez un nuage de points pour visualiser la relation entre la température et la consommation d'énergie.
2. Appliquez des régressions polynomiales de degré 1 à 5 pour modéliser la relation entre la température (variable indépendante) et la consommation d'énergie (variable dépendante).
3. Pour chaque degré, calculez l'erreur quadratique moyenne (MSE) et le coefficient de détermination R^2 .
4. Tracez les courbes polynomiales pour chaque degré sur le nuage de points.
5. Utilisez la validation croisée (par exemple, la méthode "leave-one-out") pour évaluer la performance de chaque modèle.
6. Déterminez le degré optimal du polynôme en utilisant le critère d'Akaike (AIC) ou le critère d'information bayésien (BIC).
7. Comparez les performances des modèles en fonction du degré du polynôme.
8. Discutez des risques de sous-ajustement (underfitting) et de sur-ajustement (overfitting).
9. Pour le modèle optimal, calculez les intervalles de confiance à 95 % pour les prédictions de la consommation d'énergie.

10. Tracez ces intervalles de confiance sur le graphique de la régression polynomiale.
11. Utilisez le modèle optimal pour prédire la consommation d'énergie pour une température de 55 °C.
12. Discutez des limites de la régression polynomiale pour ce type de données. Par exemple, est-il réaliste de supposer que la consommation d'énergie suit une relation polynomiale avec la température ?

Indications

- Pour la validation croisée, vous pouvez utiliser la méthode "leave-one-out", où chaque observation est tour à tour utilisée comme ensemble de test, et les autres comme ensemble d'entraînement.
- Le critère d'Akaike (AIC) et le critère d'information bayésien (BIC) sont des mesures qui pénalisent la complexité du modèle. Un modèle avec un AIC ou BIC plus faible est préféré.
- La formule pour l'AIC est :

$$\text{AIC} = n \cdot \ln(\text{MSE}) + 2k$$

où n est le nombre d'observations, MSE est l'erreur quadratique moyenne, et k est le nombre de paramètres du modèle.

- La formule pour le BIC est :

$$\text{BIC} = n \cdot \ln(\text{MSE}) + k \cdot \ln(n)$$