

TD : Approches et métriques de validation

(Enoncés)

Pr.Aissam BERRAHOU

30 août 2026

Introduction

Les modèles de machine learning sont conçus pour résoudre des problèmes variés, allant de la classification à la régression en passant par des tâches plus spécifiques comme la détection d'anomalies. Pour évaluer la performance de ces modèles, il est essentiel de comprendre et d'utiliser des métriques adaptées au contexte du problème. Les approches de validation, telles que la validation croisée, permettent de s'assurer que les performances mesurées sont robustes et généralisables à de nouvelles données.

Approches de validation

- **Validation simple** : Séparation des données en un ensemble d'entraînement et un ensemble de test.
- **Validation croisée** : Division des données en plusieurs sous-ensembles (folds) pour entraîner et tester le modèle de manière itérative. Les sous-classes incluent :
 - **k-Fold Cross-Validation** : Les données sont divisées en k sous-ensembles de taille égale. Le modèle est entraîné sur $k - 1$ folds et validé sur le fold restant. Ce processus est répété k fois.
 - **Stratified k-Fold Cross-Validation** : Similaire à k-Fold, mais préserve la proportion des classes dans chaque fold, utile pour les problèmes de classification déséquilibrés.
 - **Leave-One-Out Cross-Validation (LOOCV)** : Un cas particulier de k-Fold où $k = n$ (nombre total d'échantillons). Chaque échantillon est utilisé une fois comme ensemble de validation.
- **Validation temporelle** : Utilisée pour les données séquentielles, où les données sont divisées en fonction du temps pour éviter les fuites d'information.

Métriques courantes

- **Classification** :

— **Accuracy :**

$$\text{Accuracy} = \frac{VP + VN}{VP + FP + FN + VN}$$

— **Précision :**

$$\text{Précision} = \frac{VP}{VP + FP}$$

— **Rappel :**

$$\text{Rappel} = \frac{VP}{VP + FN}$$

— **F1-Score :**

$$\text{F1-Score} = 2 \times \frac{\text{Précision} \times \text{Rappel}}{\text{Précision} + \text{Rappel}}$$

— **AUC-ROC :** Aire sous la courbe ROC, qui trace le taux de vrais positifs (TPR) contre le taux de faux positifs (FPR).

- **Régression :**

— **MAE (Mean Absolute Error) :**

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

— **MSE (Mean Squared Error) :**

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

— **RMSE (Root Mean Squared Error) :**

$$\text{RMSE} = \sqrt{\text{MSE}}$$

— **R² (Coefficient of Determination) :**

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

- **Problèmes déséquilibrés :** F1-Score, Courbe Precision-Recall, Métriques pondérées.

Objectif des exercices

Ces exercices visent à renforcer votre compréhension des métriques et techniques d'évaluation en machine learning. Ils couvrent un large éventail de concepts, de la compréhension des métriques de base à la conception de métriques personnalisées pour des scénarios complexes. Les exercices sont conçus pour être résolus sans implémenter de modèles, en se concentrant sur la réflexion et l'application des concepts.

Exercices Simples

Exercice 1 : Calcul de l'accuracy

a) **Problème**

Un modèle de classification binaire a produit les résultats suivants :

- Vrais Positifs (VP) = 50
- Faux Positifs (FP) = 10
- Faux Négatifs (FN) = 20
- Vrais Négatifs (VN) = 120

Calculez l'accuracy du modèle.

b) **Réflexion**

Pourquoi l'accuracy peut-elle être trompeuse dans le cas d'un jeu de données déséquilibré ?

Exercice 2 : Précision et Rappel

a) **Problème**

Un modèle de détection de spam a les résultats suivants :

- VP = 80
- FP = 20
- FN = 30

Calculez :

- La précision (Precision).
- Le rappel (Recall).

b) **Réflexion**

- Dans quel contexte la précision est-elle plus importante que le rappel ?
- Quand devrait-on privilégier le rappel plutôt que la précision ?

Exercice 3 : Courbe ROC et AUC

a) **Problème**

Vous avez les taux de vrais positifs (TPR) et les taux de faux positifs (FPR) suivants pour différents seuils de classification :

- Seuil 1 : TPR = 0.2, FPR = 0.1
- Seuil 2 : TPR = 0.6, FPR = 0.3
- Seuil 3 : TPR = 0.8, FPR = 0.5
- Seuil 4 : TPR = 0.9, FPR = 0.7

Tracez la courbe ROC et estimez l'aire sous la courbe (AUC).

b) **Réflexion**

- Que signifie une AUC de 0.5 ?
- Que signifie une AUC de 1.0 ?

Exercices Intermédiaires

Exercice 4 : F1-Score

a) **Problème**

Un modèle de classification a les résultats suivants :

- $VP = 60$
- $FP = 15$
- $FN = 25$

Calculez le F1-Score.

b) **Réflexion**

- Pourquoi le F1-Score est-il utile dans le cas de jeux de données déséquilibrés ?
- Quelle est la différence entre le F1-Score et la moyenne harmonique ?

Exercice 5 : Matrice de confusion multiclasse

a) **Problème**

Voici une matrice de confusion pour un modèle de classification à 3 classes :

	Prédit A	Prédit B	Prédit C
Classe A	50	10	5
Classe B	8	60	12
Classe C	3	15	70

Calculez :

- La précision pour chaque classe.
- Le rappel pour chaque classe.
- La précision globale (accuracy).

b) **Réflexion**

- Quelle classe est la mieux prédite par le modèle ?
- Quelle classe est la plus difficile à prédire ?

Exercice 6 : Métriques de régression

a) **Problème**

Vous avez les valeurs réelles et prédites suivantes pour un problème de régression :

Valeur Réelle	Valeur Prédite
10	12
15	14
20	18
25	27
30	29

Calculez :

- L'erreur absolue moyenne (MAE).

- L'erreur quadratique moyenne (MSE).
- La racine de l'erreur quadratique moyenne (RMSE).

b) **Réflexion**

- Quelle est la différence entre MAE et RMSE ?
- Pourquoi RMSE est-elle plus sensible aux grandes erreurs que MAE ?

Exercices Avancés

Exercice 7 : Conception d'une métrique personnalisée

a) **Problème**

Vous travaillez sur un problème de prédiction de fraude bancaire. Les faux positifs (FP) coûtent à l'entreprise 10 € par cas, tandis que les faux négatifs (FN) coûtent 500 € par cas. Les vrais positifs (VP) rapportent 100 € (en évitant des pertes), et les vrais négatifs (VN) n'ont aucun coût ni gain.

- Concevez une métrique personnalisée qui prend en compte ces coûts et gains.
- Expliquez comment vous pourriez optimiser un modèle pour maximiser cette métrique.

b) **Réflexion**

- Pourquoi les métriques traditionnelles comme l'accuracy ou le F1-Score ne sont-elles pas adaptées à ce problème ?
- Comment pourriez-vous valider que votre métrique personnalisée est robuste et alignée avec les objectifs métier ?

Exercice 8 : Analyse des limites de l'AUC-ROC

a) **Problème**

Supposons que vous avez deux modèles de classification binaire avec les courbes ROC suivantes :

- Modèle A : $AUC = 0.85$
- Modèle B : $AUC = 0.80$

Cependant, dans un contexte métier spécifique, le coût d'un faux positif est 10 fois plus élevé que celui d'un faux négatif.

- Expliquez pourquoi l'AUC-ROC pourrait ne pas être suffisante pour choisir entre ces deux modèles.
- Proposez une alternative pour comparer les modèles dans ce contexte.

b) **Réflexion**

- Comment pourriez-vous adapter la courbe ROC pour tenir compte des coûts asymétriques ?
- Quelle autre visualisation ou métrique pourriez-vous utiliser pour prendre une décision éclairée ?

Exercice 9 : Analyse de la robustesse des métriques

a) Problème

Vous avez un modèle de régression qui prédit des valeurs continues. Vous remarquez que les erreurs de prédiction sont fortement corrélées avec la magnitude des valeurs réelles (par exemple, le modèle fait de plus grosses erreurs pour les grandes valeurs).

- Proposez une métrique qui prend en compte cette hétéroscédasticité (variabilité non constante des erreurs).
- Comment pourriez-vous ajuster le modèle pour minimiser cette métrique ?

b) Réflexion

- Pourquoi les métriques traditionnelles comme le RMSE ou le MAE pourraient-elles être trompeuses dans ce contexte ?
- Quels sont les risques de ne pas tenir compte de l'hétéroscédasticité dans l'évaluation d'un modèle ?

Exercice 10 : Évaluation d'un modèle en présence de données manquantes

a) Problème

Vous avez un jeu de données avec des valeurs manquantes. Vous avez appliqué plusieurs techniques d'imputation (remplacement des valeurs manquantes) et entraîné un modèle sur chaque jeu de données imputé.

- Proposez une méthode pour évaluer la performance du modèle tout en tenant compte de l'incertitude liée à l'imputation.
- Comment pourriez-vous comparer les performances des modèles entraînés sur des jeux de données imputés différemment ?

b) Réflexion

- Quels sont les risques d'ignorer l'incertitude liée à l'imputation dans l'évaluation d'un modèle ?
- Comment pourriez-vous intégrer cette incertitude dans la prise de décision métier ?