

TD : Approches et métriques de validation

(Correction)

Pr.Aissam BERRAHOU

10 avril 2025

Introduction

Les modèles de machine learning sont conçus pour résoudre des problèmes variés, allant de la classification à la régression en passant par des tâches plus spécifiques comme la détection d'anomalies. Pour évaluer la performance de ces modèles, il est essentiel de comprendre et d'utiliser des métriques adaptées au contexte du problème. Les approches de validation, telles que la validation croisée, permettent de s'assurer que les performances mesurées sont robustes et généralisables à de nouvelles données.

Approches de validation

- **Validation simple** : Séparation des données en un ensemble d'entraînement et un ensemble de test.
- **Validation croisée** : Division des données en plusieurs sous-ensembles (folds) pour entraîner et tester le modèle de manière itérative. Les sous-classes incluent :
 - **k-Fold Cross-Validation** : Les données sont divisées en k sous-ensembles de taille égale. Le modèle est entraîné sur $k - 1$ folds et validé sur le fold restant. Ce processus est répété k fois.
 - **Stratified k-Fold Cross-Validation** : Similaire à k-Fold, mais préserve la proportion des classes dans chaque fold, utile pour les problèmes de classification déséquilibrés.
 - **Leave-One-Out Cross-Validation (LOOCV)** : Un cas particulier de k-Fold où $k = n$ (nombre total d'échantillons). Chaque échantillon est utilisé une fois comme ensemble de validation.
- **Validation temporelle** : Utilisée pour les données séquentielles, où les données sont divisées en fonction du temps pour éviter les fuites d'information.

Métriques courantes

- **Classification** :

— **Accuracy** :

$$\text{Accuracy} = \frac{VP + VN}{VP + FP + FN + VN}$$

— **Précision** :

$$\text{Précision} = \frac{VP}{VP + FP}$$

— **Rappel** :

$$\text{Rappel} = \frac{VP}{VP + FN}$$

— **F1-Score** :

$$\text{F1-Score} = 2 \times \frac{\text{Précision} \times \text{Rappel}}{\text{Précision} + \text{Rappel}}$$

— **AUC-ROC** : Aire sous la courbe ROC, qui trace le taux de vrais positifs (TPR) contre le taux de faux positifs (FPR).

- **Régression** :

— **MAE (Mean Absolute Error)** :

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

— **MSE (Mean Squared Error)** :

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

— **RMSE (Root Mean Squared Error)** :

$$\text{RMSE} = \sqrt{\text{MSE}}$$

— **R² (Coefficient of Determination)** :

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

- **Problèmes déséquilibrés** : F1-Score, Courbe Precision-Recall, Métriques pondérées.

Objectif des exercices

Ces exercices visent à renforcer votre compréhension des métriques et techniques d'évaluation en machine learning. Ils couvrent un large éventail de concepts, de la compréhension des métriques de base à la conception de métriques personnalisées pour des scénarios complexes. Les exercices sont conçus pour être résolus sans implémenter de modèles, en se concentrant sur la réflexion et l'application des concepts.

Exercice 1 : Calcul de l'accuracy

Solution :

a) **Calcul de l'accuracy**

L'accuracy est donnée par la formule :

$$\text{Accuracy} = \frac{VP + VN}{VP + FP + FN + VN}$$

Avec les valeurs fournies :

$$\text{Accuracy} = \frac{50 + 120}{50 + 10 + 20 + 120} = \frac{170}{200} = 0.85 \quad (85\%)$$

b) **Réflexion**

L'accuracy peut être trompeuse dans le cas d'un jeu de données déséquilibré, car elle ne tient pas compte de la distribution des classes. Par exemple, si 95% des données appartiennent à une classe, un modèle qui prédit toujours cette classe aura une accuracy de 95%, mais sera inutile pour détecter l'autre classe.

Exercice 2 : Précision et Rappel

Solution :

a) **Calcul de la précision et du rappel**

- **Précision :**

$$\text{Précision} = \frac{VP}{VP + FP} = \frac{80}{80 + 20} = \frac{80}{100} = 0.8 \quad (80\%)$$

- **Rappel :**

$$\text{Rappel} = \frac{VP}{VP + FN} = \frac{80}{80 + 30} = \frac{80}{110} \approx 0.727 \quad (72.7\%)$$

b) **Réflexion**

- La précision est plus importante dans les contextes où les faux positifs sont coûteux (par exemple, un test médical faux positif peut causer du stress inutile).
- Le rappel est plus important dans les contextes où les faux négatifs sont dangereux (par exemple, ne pas détecter une maladie grave).

Exercice 3 : Courbe ROC et AUC

Solution :

a) **Tracé de la courbe ROC**

Les points de la courbe ROC sont : - (FPR = 0.1, TPR = 0.2) - (FPR = 0.3, TPR = 0.6) - (FPR = 0.5, TPR = 0.8) - (FPR = 0.7, TPR = 0.9)

La courbe ROC est tracée en reliant ces points. L'AUC peut être estimée en calculant l'aire sous cette courbe.

b) **Réflexion**

- Une AUC de 0.5 indique que le modèle ne fait pas mieux qu'une prédiction aléatoire.
- Une AUC de 1.0 indique un modèle parfait qui sépare parfaitement les classes.

Exercice 4 : F1-Score

Solution :

a) **Calcul du F1-Score**

Le F1-Score est donné par :

$$\text{F1-Score} = 2 \times \frac{\text{Précision} \times \text{Rappel}}{\text{Précision} + \text{Rappel}}$$

Avec les valeurs fournies :

$$\text{Précision} = \frac{60}{60 + 15} = \frac{60}{75} = 0.8 \quad (80\%)$$

$$\text{Rappel} = \frac{60}{60 + 25} = \frac{60}{85} \approx 0.706 \quad (70.6\%)$$

$$\text{F1-Score} = 2 \times \frac{0.8 \times 0.706}{0.8 + 0.706} \approx 2 \times \frac{0.565}{1.506} \approx 0.75 \quad (75\%)$$

b) **Réflexion**

- Le F1-Score est utile pour les jeux de données déséquilibrés, car il combine la précision et le rappel en une seule métrique.
- Il s'agit de la moyenne harmonique de la précision et du rappel, ce qui pénalise les déséquilibres entre ces deux métriques.

Exercice 5 : Matrice de confusion multiclasse

Solution :

a) **Calcul des métriques**

- **Précision par classe** : - Classe A : $\frac{50}{50+10+5} = \frac{50}{65} \approx 0.769$ - Classe B : $\frac{60}{8+60+12} = \frac{60}{80} = 0.75$
- Classe C : $\frac{70}{3+15+70} = \frac{70}{88} \approx 0.795$ - **Rappel par classe** : - Classe A : $\frac{50}{50+8+3} = \frac{50}{61} \approx 0.820$
- Classe B : $\frac{60}{10+60+15} = \frac{60}{85} \approx 0.706$ - Classe C : $\frac{70}{5+12+70} = \frac{70}{87} \approx 0.805$ - **Précision globale (accuracy)** :

$$\text{Accuracy} = \frac{50 + 60 + 70}{50 + 10 + 5 + 8 + 60 + 12 + 3 + 15 + 70} = \frac{180}{233} \approx 0.773 \quad (77.3\%)$$

b) **Réflexion**

- La classe C est la mieux prédite (précision et rappel les plus élevés).
- La classe B est la plus difficile à prédire (rappel le plus faible).

Exercice 6 : Métriques de régression

Solution :

a) **Calcul des métriques**

- **MAE** :

$$\text{MAE} = \frac{|12 - 10| + |14 - 15| + |18 - 20| + |27 - 25| + |29 - 30|}{5} = \frac{2 + 1 + 2 + 2 + 1}{5} = \frac{8}{5} = 1.6$$

- **MSE** :

$$\text{MSE} = \frac{(12 - 10)^2 + (14 - 15)^2 + (18 - 20)^2 + (27 - 25)^2 + (29 - 30)^2}{5} = \frac{4 + 1 + 4 + 4 + 1}{5} = \frac{14}{5} = 2.8$$

- **RMSE** :

$$\text{RMSE} = \sqrt{2.8} \approx 1.673$$

b) **Réflexion**

- Le MAE est moins sensible aux grandes erreurs que le RMSE.
- Le RMSE pénalise davantage les grandes erreurs, ce qui peut être utile si ces erreurs sont critiques.

Exercice 7 : Conception d'une métrique personnalisée

Solution :

a) **Métrique personnalisée**

Une métrique possible est :

$$\text{Métrique} = (100 \times VP) - (10 \times FP) - (500 \times FN)$$

Cette métrique prend en compte les coûts et gains associés à chaque cas.

b) **Optimisation du modèle**

Pour maximiser cette métrique, on peut ajuster le seuil de classification pour minimiser les FN, car ils ont un coût élevé.

c) **Réflexion**

- Les métriques traditionnelles ne tiennent pas compte des coûts asymétriques.
- Pour valider la robustesse, on peut utiliser une validation croisée en calculant la métrique sur chaque fold.

Exercice 8 : Analyse des limites de l'AUC-ROC

Solution :

a) **Limites de l'AUC-ROC**

L'AUC-ROC ne tient pas compte des coûts asymétriques. Dans ce cas, le modèle A (AUC = 0.85) pourrait avoir un taux de FP trop élevé, ce qui serait coûteux pour l'entreprise.

b) **Alternative**

On peut utiliser une **courbe de coût-décision** ou une **courbe de profit** pour visualiser le compromis entre les coûts et les bénéfices.

c) **Réflexion**

- La courbe ROC peut être adaptée en pondérant les FP et FN en fonction de leurs coûts.
- Une alternative est d'utiliser une métrique personnalisée comme dans l'Exercice 7.

Exercice 9 : Analyse de la robustesse des métriques

Solution :

a) **Métrique adaptée à l'hétéroscédasticité**

Une métrique possible est :

$$\text{Métrique} = \frac{1}{n} \sum_{i=1}^n \frac{|y_i - \hat{y}_i|}{y_i}$$

Cette métrique donne plus de poids aux erreurs sur les petites valeurs.

b) **Ajustement du modèle**

On peut utiliser une régression pondérée ou transformer la variable cible (par exemple, en utilisant un logarithme).

c) **Réflexion**

- Le RMSE et le MAE sont sensibles aux grandes erreurs, ce qui peut être trompeur en présence d'hétéroscédasticité.
- Ignorer l'hétéroscédasticité peut entraîner des prédictions inexactes pour certaines plages de valeurs.

Exercice 10 : Évaluation d'un modèle en présence de données manquantes

Solution :

a) **Méthode d'évaluation**

Utilisez une **validation croisée multiple** : - Imputez les données manquantes plusieurs fois avec différentes méthodes.

- Entraînez et évaluez le modèle sur chaque jeu de données imputé.
- Calculez la performance moyenne et l'écart-type pour tenir compte de l'incertitude.

b) **Comparaison des modèles**

Comparez les performances moyennes et les intervalles de confiance pour chaque méthode d'imputation.

c) **Réflexion**

- Ignorer l'incertitude liée à l'imputation peut conduire à une estimation trop optimiste de la performance.
- Intégrer cette incertitude permet de prendre des décisions plus robustes.